

Hardware, Electromagnetic and Localization Security

Pierciro Caliandro

25 maggio 2022

Capitolo 1

Introduzione

1.1 Introduzione

Attacco fisico invece di informatico, viene applicato un attacco di tipo EM: si mandano segnali fisici su un apparato per indurre malfunzionamento o rubare dati.

Si arriva all'impatto sull'elettronica, si cerca quindi di ottenere dei rudimenti di sicurezza fisica: 3 aspetti di livello diverso, dal sistema, alla parte di comunicazione alla parte elettronica.

Aspetti fondamentali:

- short range vulnerabilities: dispositivi medici avranno tutte funzionalità wireless: pacemakers va configurato, quindi in base alla risposta configura il dispositivo con un accoppiamento di tipo NFC, in futuro anche le protesi più "sciocche" come una placca per le ossa saranno wireless, sarà funzionalizzato con diversi sensori per verificare infezioni etc... ed essere letto da fuori.

Qualunque oggetto impiantato sarà funzionalizzato, a seguito di interventi di qualunque tipo (punti di sutura etc...) che sarà provvisto di sensori.

È tutto vittima di attacco informatico, per rubare dati in maniera non intenzionale.

Il corpo diventa quindi un nodo di Internet, si parla di **Internet of the bodies**, ci possono essere diversi tipi di sensori che interagiscono. C'è una lista svariata di oggetti di medica che controllano le attività fisiche.

L'accesso non intenzionale al dispositivo ha un impatto potenzialmente dirompente, lo scenario va a parare in una medicina guidata dai dati dove si mischiano diverse discipline, è il concetto di **medicina di precisione**: parte dalle terapie oncologiche, in ingegneria è la capacità della medicina di apprendere. Se la terapia oggi va bene, il corpo umano cambia e quindi tale terapia può necessitare di essere aggiornata.

Il punto critico è che per rendere questa visione operabile, occorre avere sistemi pervasivi + AI per poter poi tirare fuori una cura.

È una medicina assistiva che può essere integrata con sensori nella casa che controllano l'utente paziente, si parla di 3 tipi di dispositivi, ci interessa capire come questi comunicano e non il loro funzionamento:

- wearable
- epidermici
- implantable

che devono avere la safety by design, quindi non devono fare male quando indossati, la security by design e quindi essere sicuri da progettazione e poi la privacy by design, quindi capire come è possibile che i dati vengano usati impropriamente.

Abbiamo ad esempio strumenti epidermici che rilascia cortisolo quando ad esempio viene misurato

da un sensore che scende sotto soglia una certa misura.

Ci sono quindi 3 tipi di links:

- on-body link
- through-the-body
- off-the-body

Analizzeremo tutto a livello di modello fisico-matematico.

Ci sono poi problemi per quanto riguarda la lettura dei dati, qui c'è la corrispondenza fisica di come si leggono tali dati, ma c'è anche il come si fa per accedere al dispositivo, ad esempio ci sono delle micro-antenne non volute.

1.1.1 Introduzione generale sulla cybersecurity

Si completa il concetto di cybersecurity con gli aspetti fisici e di comunicazione, vi sono delle criticità nelle comunicazioni sulla rete. Ce ne sono però alcune che non vengono prese in considerazione spesso, che è opportuno non tralasciare come appunto la comunicazione a corto raggio: si viaggia in ambienti affollati per rubare dati da cellulari ad esempio se è abilitato il sistema NFC. Normalmente la distanza è dell'ordine del metro, ma su un posto affollato è fattibile, il lettore viene posto vicino al cellulare e ruba dati.

Per le reti ad ampio raggio, ci sarà la sicurezza delle reti da cui però rimangono fuori tutta una serie di apparati che sono ad esempio i sistemi di localizzazione. Ormai quasi tutte le applicazioni usano la posizione per fare delle operazioni, usano EMF per portare dati e sono attaccabili: è "facile" far credere ad un device di trovarsi in un luogo anzi che in un altro.

È stato dimostrato che era possibile controllare uno yacht di lusso semplicemente ingannando il sistema di navigazione, ad esempio. È ancora più semplice inibire i servizi, quindi fare in modo che il servizio non funzioni e basta, un'altra applicazione è quella di sfruttare le EMF usate nei radar per capire dove si trova qualche oggetto, quindi disturbare un radar vuol dire interrompere il funzionamento di un sistema target a bassi rischi.

Cerchiamo quindi di capire come disturbare o difendere un sistema di navigazione o un radar, per cercare di capire come proteggerli nel mondo reale.

Entreremo poi nell'hardware, vedendo vari metodi su come attaccare l'hardware stesso: anche qui, si da per acquisito che il chip sia sicuro in quanto non si può aprire ed occorre per forza passare per il software, ma in realtà negli anni vi sono stati una serie di side channel, come ad esempio isolare termicamente un device.

Ma se si può monitorare la temperatura del device, è possibile capire che elaborazioni sta facendo e quindi capire le attività dell'utente, questo vale anche per le RAM etc... ad esempio vedere quanto sono frequenti le rotture delle singole celle della RAM etc...

1.1.2 Sicurezza informatica e cybersecurity

È un concetto molto ampio, spesso confuso con la cybersecurity, ma la prima vuol dire mantenere in sicurezza l'informazione anche se non è digitale. Non basta quindi proteggersi da attacchi via rete, il concetto è molto più ampio della cybersecurity. Ci sono tantissime definizioni standard per cybersecurity, ma è meglio partire da un approccio che vede il sistema moderno come formato da tante entità, che possiamo dividere in 3 parti:

- hardware, che non è per forza l'hardware del calcolatore, anche un banale pezzo di carta con su scritta una password.

- software, l'hardware visto da un punto di vista informatico è correlato con programmi applicativi che possono avere delle debolezze, occorre quindi anche proteggere l'interno della macchina
- parte di comunicazione, in quanto il mondo moderno di IoT o cloud prevede che l'informazione viaggi fra utente e server o fra vari utenti

La maggior parte delle informazioni continuano a mandare informazioni a qualche server chissà dove (magari in CINA **cit**), in questo modo ci sono diverse facilitazioni.

Questo vuol dire aver venduto parte della privacy a qualcuno o comunque delegato, che non è detto che sia malvagio ma c'è una comunicazione che avviene continuamente e quindi potrebbe interessare a qualcun altro per intervenire sul canale di comunicazione ed entrare in casa.

Questo rimanendo ancora nell'accezione più classica della comunicazione, ma abbiamo anche comunicazione a livello di corto raggio, quindi per gestire queste 3 componenti principali occorre mettere in atto tutta una serie di contromisure che non sono solo quelle che vederemo ma sono molto più ampie:

- procedure di autenticazione, come il controllo di accessi in un edificio, ci possono essere informazioni che vengono classificate come sensibili ed a cui non si può accedere (es. badge per accedere a determinati uffici). Già questo aspetto se ben fatto sarebbe una grossa protezione, soprattutto per software ed hardware security in quanto vorrebbe dire avere degli alti livelli di sicurezza - sicurezza a livelli più bassi, CIA: Confidentiality, Availability and Integrity. Devono valere questi 3 principi nell'information security: - C è un concetto diverso dalla privacy, sta proprio nel non rivelare l'informazione che non dovrebbe essere nota. - I, ovvero la capacità del sistema di non perdere le informazioni che può essere accidentale o anche dovuta ad attacchi, esempi come i ransomware possono portare ad avere dei costi. Ci sono anche altre tipi di compromissione di integrità, che riguardano ad esempio il disturbo di un segnale riguardo la posizione - A, il fatto che l'informazione sia integra non vuol dire che possa essere utilizzata. Ad esempio se si perde la password per accedere a determinati dati, mantenerle ha un suo costo

Vedremo come declinare queste 3 caratteristiche nei casi di studio del corso.

Ci sono delle definizioni da dare:

- vulnerabilità: sfruttate dall'attaccante, qualsiasi sistema ha una debolezza da qualche parte nella sua progettazione. Se può essere sfruttata per ridurre una delle 3 cose, possiamo chiamare tale debolezza una vulnerabilità
- un cyber attacco sfrutta la vulnerabilità per ridurre la sicurezza.

Più comuni tecniche di attacco:

- backdoor: vie lasciate aperte dagli sviluppatori, come porte aperte etc...
- DoS: negazione del servizio, si fa in modo che per qualche motivo il servizio sotto attacco divenga indisponibile, come ad esempio richieste di accesso ad un server molteplici volte. Nella parte wireless è molto usato, mediante il **jammer**: è un sistema che trasmette con la massima potenza possibile sul canale usato dal sistema per comunicare, che disturba la comunicazione fino a negare il canale per comunicare. È una tecnologia banale per effettuare DoS
- attacchi ad accesso diretto non autorizzato.

- eavesdropping, dove si ascolta e se ci sono delle informazioni riservate si possono captare.
Esempio: canale della DSB, ogni aereo mette la posizione, è un canale in chiaro e quindi ascoltare ed usare quei dati in modo malevolo può creare problemi.
- phishing
- privilege escalation
- social engineering
- reverse engineering
- side channel attack: verificare dei canali correlate con l'informazione da difendere o attaccare, per capire cosa sta succedendo.
- spoofing: attacco che tende a confondere la persona o entità sotto attacco mediante l'invio di falsi dati. Si presta bene alla comunicazione wireless, molto usato nei sistemi di localizzazione tipo GPS perché è noto a tutti come è standardizzato il segnale che arriva al satellite e quindi si può ricostruire e trasmettere. Ma quando lo si ricostruisce si inseriscono delle false informazioni, per far ad esempio cambiare posizione al GPS.
- tampering: alterazione fisica del dispositivo
- malware

È importante inoltre ribadire la differenza fra sicurezza intesa come - safety: concetto che esprime la capacità di mettersi al riparo da accadimenti dannosi per l'uomo e per la vita umana. Ad esempio la precipitazione dell'aereo, mantenere tale proprietà occorre salvaguardarsi da qualsiasi cosa può accadere. Ad esempio, un aereo può precipitare perché il sistema di comunicazione si danneggia o interferisce con un altro - security: la security è correlata, ma non è sovrapposta bensì è come "un ombrello" che permette di mantenere la safety.

Se installiamo un sistema di sicurezza in casa, veniamo protetti da chi vuole entrare, ma non dal fatto di poter cadere e battere la testa scivolando nella vasca (**super cit.**

Ci occuperemo della security, ma molte delle cose che vederemo possono o non possono essere usate anche per garantire la safety.

È inoltre importante tenere a mente che ormai l'ambiente è pieno di EMF, quindi lo spettro EM è molto pieno e quindi aggiungere qualche altra fonte diventa semplice, quindi vedremo questa cosa.

Parte I

Parte Electromagnetic

Capitolo 2

Lezione 2

2.1 Interazione elettromagnetica col corpo umano

Cosa accade quando una onda EM interagisce col corpo umano: occorre sapere cosa succede perché quando un dispositivo deve essere immesso nel mercato deve garantire la safety: vincolo sulla potenza che rilascia nel corpo umano. È un vincolo di progetto, occorre capire cosa si intende per potenza che entra nel corpo umano, occorre anche sapere che succede quando un dispositivo riceve un'onda EM per non far funzionare il dispositivo.

Quando un onda investe il corpo umano, abbiamo un'onda elettrica ed una magnetica che investono il corpo umano e quindi 3 fenomeni:

- propagazione
- riscaldamento, dovuto all'assorbimento di potenza
- effetti chimico-fisici

Ci interessa come punto fondamentale la propagazione, il riscaldamento è un effetto. In altri contesti, l'obiettivo è scaldare il corpo (come nella fisioterapia), ma comunque occorre capire anche cosa accade perché l'assorbimento di potenza produce dei vincoli che occorre tenere conto.

Questi fenomeni sono legati a:

- materiale
- frequenza: cambierà in base a che tipo di oggetto sta irradiando, come sono fatti i tessuti etc...

Tipicamente, l'esposizione del campo sul corpo produce delle correnti, quando consideriamo l'interazione col corpo umano abbiamo 4 tipi di correnti:

- correnti di conduzione: sono legate alla presenza di elettroni liberi, ad esempio se ci sono dei fluidi.

Gli elettroni, quando si applica un campo E , tenderanno a muoversi in una determinata direzione secondo la **legge di Ohm**:

$$\underline{J} = \sigma \cdot \underline{E} \quad (2.1)$$

- correnti di convezione: dovuti alla deriva di ioni. Gli ioni in alcuni casi possono essere discolti in fluidi corporei (sangue etc...) quindi anche in questo caso s'è c'è un campo le particelle possono spostarsi
- corrente di polarizzazione: la più dominante, legata alla presenza di composti polari, come l'acqua. Tali composti possono oscillare rispetto a posizioni di equilibrio, quindi subiscono una sollecitazione dovuta ad un campo incidente.

- corrente di spostamento:

$$\underline{J}_s = \frac{d\underline{D}}{dt} \Leftrightarrow j\omega\underline{D} = j\omega\epsilon\underline{E} \quad (2.2)$$

è quella che ci piace per comunicare con il corpo umano, le altre sono non volute. Teniamo conto dei fenomeni introducendo una costante dielettrica complessa, è:

$$\dot{\epsilon} = \epsilon' - j\epsilon'' - j\frac{\sigma}{\omega} \quad (2.3)$$

, che deriva dalla

$$\Delta x \underline{H} = j\omega \dot{\epsilon} \underline{E} + \underline{J}_0 \quad (2.4)$$

dove \underline{J}_0 è la sorgente (appunti):

- i termini in j rappresentano la dissipazione
- i termini reali rappresentano sia accumulo che propagazione di energia.

Abbiamo che

$$\epsilon' = \epsilon_0 \epsilon_r \quad (2.5)$$

dove ϵ_0 ed ϵ_r sono relativamente costante dielettrica nel vuoto e costante dielettrica relativa, mentre ϵ'' è legata alla dissipazione dei materiali non per la legge di Ohm.

Invece σ ($[\frac{S}{m}]$) è legata legge di Ohm. Nei dielettrici, la dissipazione per effetto Joule non è quella dominante, abbiamo che $\epsilon'' > \frac{\sigma}{\omega}$ (nel corpo umano), quindi possiamo trascurare il termine.

Introduciamo quindi una conducibilità elettrica equivalente

$$\sigma = \epsilon'' \cdot \omega \quad (2.6)$$

$\sigma = \epsilon'' \cdot \omega$, così che ω sia l'inverso ed

$$\dot{\epsilon} = \epsilon' - j\frac{\sigma}{\omega} \quad (2.7)$$

quindi avremo, quando lavoriamo con i tessuti una

$$\bar{\epsilon} = \epsilon_0 \epsilon_r - j\frac{\sigma}{\omega} \quad (2.8)$$

Un altro termine importante è la tangente di delta:

$$\tan\delta = \frac{\epsilon''}{\epsilon'} = \frac{\sigma}{\omega\epsilon''} = \frac{\sigma}{\omega\epsilon_0\epsilon_r} \quad (2.9)$$

dove, l'ordine di grandezza del $\tan\delta$ è:

- nel caso di buoni materiali, per fare ad esempio un antenna che irradia bene e scaldi poco, il $\tan\delta$ deve essere dell'ordine di 10^{-3}
- nel corpo umano abbiamo un ordine di 10^{-1} , quindi non è buono per stabilire una comunicazione.

La complicazione è che il corpo umano non è omogeneo, quindi le costanti cambiano in quanto dipendono dal punto, poi c'è anche la dipendenza dalla frequenza che fa sì che l'andamento possa essere molto dipendente dalla frequenza.

2.1.1 Corrente di polarizzazione

È quella dominante, il materiale umano è vincolato, quindi per gli elettroni non c'è movimento libero ma saranno comunque distorti dal campo.

Abbiamo 3 tipologie:

- polarizzazione dipolare
- polarizzazione molecolare-ionica
- polarizzazione elettronica

Polarizzazione dipolare Ci sono alcuni materiali, come l'acqua, che pur essendo elettricamente neutri, hanno una zona positiva ed una negativa. Possiamo immaginare di avere un'addensamento di cariche positive da una parte e di cariche negative da un'altra, quindi avremo due cariche Q e $-Q$ a distanza l , quindi abbiamo un dipolo fisico-chimico con associato un momento di dipolo

$$dp = lQ \quad (2.10)$$

È quindi una piccola antennina sensibile ai campi che vi si applicano. Tali molecole sono, per quanto neutre, orientate a caso ma se si applica un campo elettrico E questo tenderà ad allineare tutte queste molecole, in direzione del campo stesso, come mostrato in figura

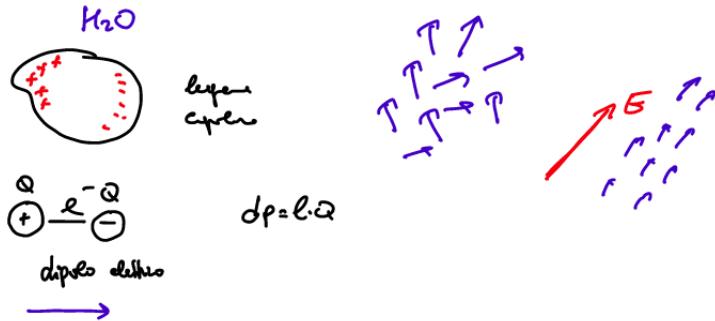


Figura 2.1: Polarizzazione delle molecole a seguito dell'applicazione di un campo elettrico

Il mezzo viene quindi polarizzato per effetto del campo esterno.

Polarizzazione Ionica Nel corpo umano c'è tanta acqua, quindi è molto importante. Ci sono nel corpo altri materiali solidi, in cui è più difficile riconoscere la molecola in quanto sono organizzati sotto forma di reticolo, dove ogni nodo ha una composizione ionica e quindi una parte positiva ed una negativa ad esempio NaCl: l'Na si va ad "appiccicare" al Cl negativo.

Nella singola cella, un pezzo è negativo ed uno è positivo, quando si applica un campo E , l'oggetto non può muoversi poiché vincolato, ma può essere deformato, quindi la polarizzazione ha effetto sulla modifica del reticolo, come riassunto nella figura sottostante

Polarizzazione elettronica Questa agisce direttamente sull'atomo, dove abbiamo il kernel positivo e la nube di elettroni. Anche in questo caso, in presenza di un campo E esterno la nube elettronica si può distribuire, su una forma magari più schiacciata, quindi abbiamo ancora un effetto dovuto allo stimolo esterno

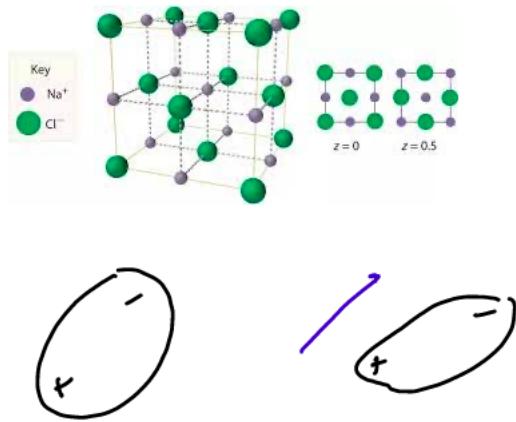


Figura 2.2: Effetti della polarizzazione ionica



Figura 2.3: Effetti della polarizzazione elettronica

La dissipazione risulta nel momento in cui è necessario trasferire informazione, in quanto occorrono dei segnali sinusoidali, avremo che il campo esterno ha la seguente forma

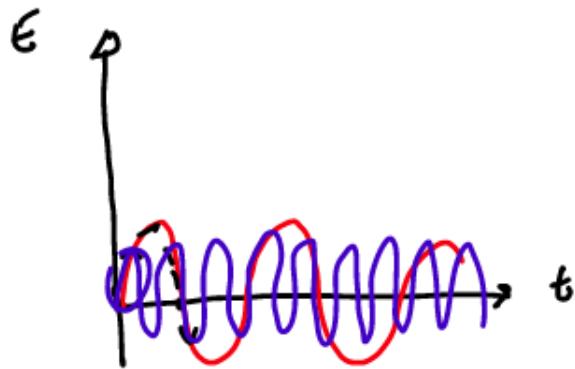


Figura 2.4: Andamento nel tempo del campo elettrico generato da un segnale sinusoidale

questa applicazione di una forza elettrica alla struttura produce lavoro, siccome la materia vuole stare in un certo modo, la struttura tenderà ad opporsi allo stimolo e quindi ci sarà inerzia che produce attrito e che quindi conseguentemente verrà prodotto un riscaldamento.

La dissipazione è quindi dovuta alla coesione complessiva dell'organismo che tende a non far muovere le molecole come vogliono.

È simile a cosa accade con un forno a microonde: se metto del grasso non si cuoce bene, se lo metto in acqua questa cede il calore e lo fa riscaldare più velocemente.

Se ci fosse una frequenza maggiore, ci sarebbe un ritardo in quanto il corpo umano ha del ritardo per capire che sta succedendo qualcosa e quindi le molecole sono sollecitate contro una forza, ci sarà

quindi prima un po' di inerzia per cui ci vuole del tempo prima che la struttura si accorga che sta arrivando un fonte d'onda, ma finché se ne accorge arriva già il fronte negativo e quindi quello che avviene è che l'interazione con la materia è ridotta e concentrata sulla parte esterna.

Occorre ora capire come rappresentare il corpo umano: si usa il modello di Debye, per cui abbiamo

$$\epsilon = \epsilon_\infty + \frac{\epsilon_s - \epsilon_\infty}{1 + j\omega\tau} \quad (2.11)$$

dove

- ϵ_s è la costante statica (??)
- ϵ_∞ è la costante ottima
- τ è il tempo di rilassamento, legato al tempo che serve alla molecola per sentire lo stimolo e tornare alla condizione iniziale dopo che lo stimolo è finito. È quindi il ritardo con cui viene seguito lo stimolo

Se rappresentiamo consideriamo una rappresentazione grafica:

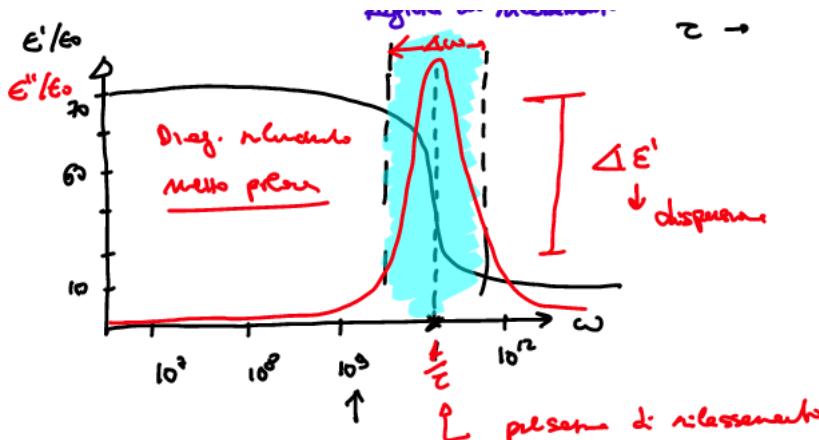


Figura 2.5: Andamento del rapporto $\frac{\epsilon'}{\epsilon_0}$ ed $\frac{\epsilon''}{\epsilon_0}$

teniamo conto che i GHz sono nell'ordine 10^9 , mettiamo ad $\frac{1}{\tau}$ la pulsazione di rilassamento. Avviene che la parte reale, quindi la capacità di immagazzinare energia e trasmetterla, in prossimità della frequenza in rosso ha un passaggio brusco, in un range di frequenza abbastanza stretto, la regione celeste che è la regione di rilassamento. La parte immaginaria ha un andamento totalmente opposto, in quella finestra c'è un assorbimento importante, le perdite sono elevate e quindi la potenza ceduta viene dissipata dal corpo. Questo è il diagramma di rilassamento in un mezzo polare, le conseguenze da un punto di vista di comunicazione è nel che lavorare nella finestra celeste ci sono due fenomeni negativi:

- molte perdite, se mando 1W di potenza buona parte del segnale è propagato;
- guardando alla permittività, mandando un segnale con una banda importante avrà ogni componente spettrale con una diversa velocità di propagazione e quindi avremo informazione dispersa

Quindi tutti i mezzi biologici sono dispersivi, quindi occorre lavorare distanti dalla zona di rilassamento perché il segnale ha effetti dispersivi e distorcenti.

Visto invece dal punto di vista della fisioterapia, conviene lavorare in quella fascia perché c'è dissipazione e quindi riscaldamento.

L'acqua ha una pulsazione di rilassamento dell'ordine di 20GHz, quindi il forno a microonde che funziona a 2450 MHz non è molto lontano.

Questo avverrebbe se ci fossero solo composti polari come l'acqua, ma l'espressione quando consideriamo un corpo umano va adeguata a composti come proteine etc... ottenendo

$$\dot{\epsilon} = \epsilon' - j \frac{\sigma}{\omega \epsilon_0} = \epsilon_\infty + \frac{\epsilon_s - \epsilon_\infty}{1 + (j\omega\tau)^{1-\alpha}} \quad (2.12)$$

(dove $0 < \alpha < 1$), ottenendo l'espressione di Cole-Cole.

Mettendo tutto insieme, si è visto che tutto il corpo umano si può rappresentare con 4 di queste espressioni

$$\dot{\epsilon} = \sum_{i=1}^4 \frac{\epsilon_{si} - \epsilon_\infty}{1 + (j\omega\tau_i)^{1-\alpha_i}} + \epsilon_\infty - j \frac{\sigma_0}{\omega} \quad (2.13)$$

dove tutti i parametri con la i e σ sono dipendenti dai tessuti del corpo considerato.

Rappresentando la finestra di dispersione, abbiamo 3 finestre per i vari parametri:

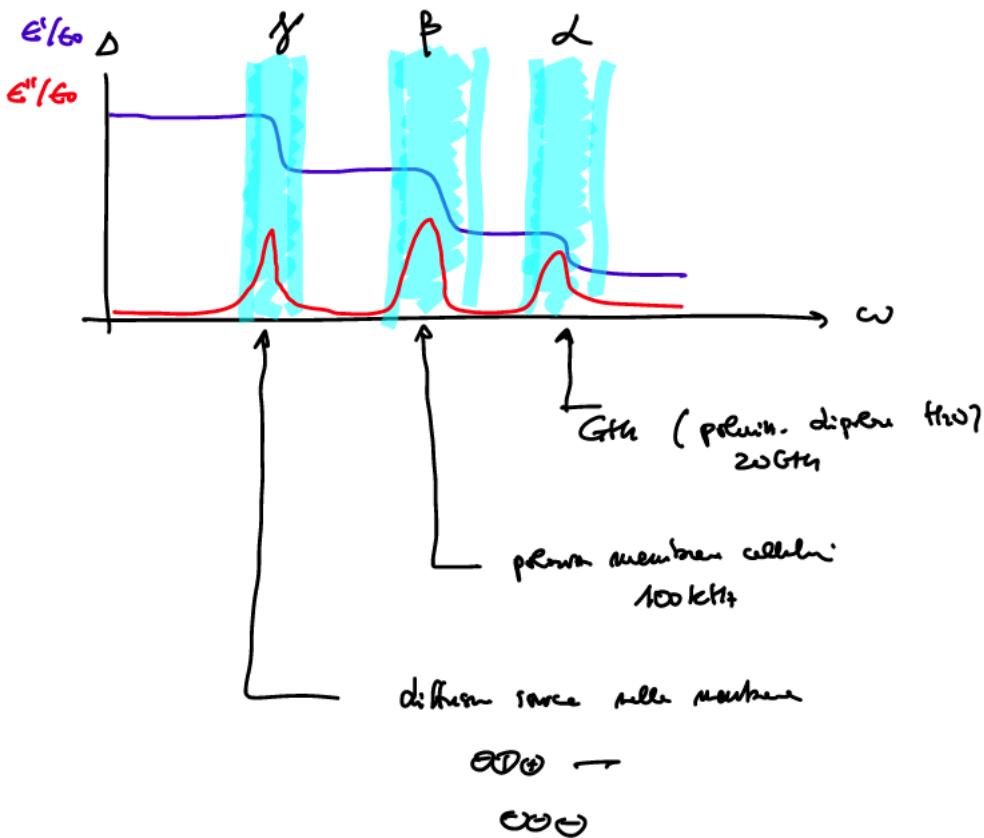


Figura 2.6: Finestre di dispersione

nelle varie finestre ci sarà un incremento di perdite locale, questa è la risposta del corpo umano tessuto per tessuto (grasso, pelle, ...) in termini di riscaldamento, ed hanno nomi γ , β α , dove comandano diversi effetti

γ comanda la polarizzazione dipolare dell'acqua

β comanda la polarizzazione delle membrane cellulari

Tessuto	10 Mhz ($\frac{\epsilon_r}{\sigma}$)	434 Mhz	915 Mhz	2450 Mhz
Grasso	54 205	15 60	5 820	12 341
Muscolo	283 715	57 1120	55 1450	50 2272

α diffusione ionica nelle membrane

Immaginando di avere delle cariche libere: applicando il campo questi ioni entrano, poi applicandone un altro escono e quindi c'è assorbimento che produce delle perdite.

2.1.2 Come caratterizzare i materiali

Negli anni 90, sulla spinta dell'evoluzione della telefonia mobile, si è studiato l'impatto del telefono sulla testa e molti gruppi hanno studiato come caratterizzare i tessuti (sugli animali), usando l'espressione come interpolatore ed hanno estratto i parametri che sono di interpolazione. Ci sono dei DB dove in base alla frequenza ed al materiale c'è la lista dei parametri e quindi introducendola nella Cole-Cole generalizzata si ottiene la ϵ .

Uno dei DB è Italiano, del CNR: niremf.ifac.cnr.it/emfref o [/tissprop](http://tissprop): si possono scaricare direttamente i parametri oppure avere i valori di permettività e conducibilità: otteniamo diversi valori tra cui la lunghezza d'onda ($\lambda = \frac{\lambda_0}{\sqrt[2]{\epsilon_r}}$). Prendendo ad esempio il muscolo, all'aumentare della frequenza, la conducibilità aumenta, la permettività diminuisce. Più c'è presenza di acqua, più permettività e conducibilità sono elevate. Ne riportiamo alcuni: la differenza di conducibilità è importante, quindi il muscolo dissiperà sicuramente più potenza del grasso. Cerchiamo ora di caratterizzare tutto da un punto di vista ingegneristico

Assorbimento

Un'onda arriva su un materiale: una grandezza importante è la densità di potenza dissipata nel corpo

$$p_j = \frac{1}{2}\sigma|E|^2 \quad (2.14)$$

e si misura in $\frac{W}{m^3}$.

Per le norme di emissione si considera la SAR (Specific Absorption Rate), data da:

$$SAR = \frac{p_j}{p} \quad (2.15)$$

misurato in $\frac{W}{kg}$ e che indica quanta potenza viene assorbita per unità di massa del dispositivo, ed è quindi data da

$$\frac{\partial P}{\partial m} = \frac{1}{2\rho}\sigma|E|^2 \quad (2.16)$$

e si usa in quanto è più facile da misurare.

Se abbiamo un organo e vogliamo calcolare la potenza avremo quindi:

$$P(\Omega_m) = \int_{\Omega_m} P(r')SAR(r)dr' \quad (2.17)$$

dove

$$SAR(r) = \frac{1}{2\rho(r)}\sigma(r)|E(r)|^2 \quad (2.18)$$

Le misure vengono fatte su dei "fantocci" che simulano le caratteristiche EM del corpo, il modo più semplice è usare acqua zucchero e sale:

- l'acqua ha una permittività intorno a 70 Ghz
- il sale abbassa la ϵ_r
- lo zucchero aumenta la σ

Ci sono delle ricette per ricostruire ogni organo e poter quindi misurare il SAR, altrimenti si usano fantocci da "macellaio", pezzi di carne etc...

Propagazione nei tessuti biologici

Consideriamo il caso più semplice possibile, dove il corpo umano è un mezzo omogeneo, avrà quindi una permittività $\epsilon' - j\frac{\sigma}{\omega}$.

Immaginiamo di avere i due mezzi, (1) e (2) e che arrivi un campo elettrico che sia un'onda piana, si propaghi in direzione z, come mostrato in seguito:

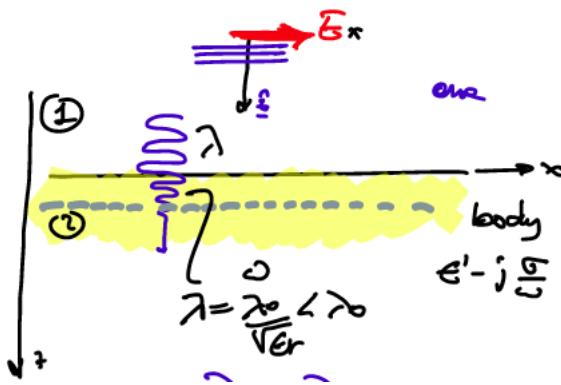


Figura 2.7: Esempio di propagazione di un'onda EM che attraversa due mezzi

Cosa accade al corpo: abbiamo, per un'onda piana

$$E_x(z) = E_0 e^{-jkz} \quad (2.19)$$

dove k è la costante complessa di propagazione

$$k = \beta - j\alpha \quad (2.20)$$

ed α e β sono rispettivamente il fattore di propagazione ed il fattore di attenuazione:

$$\alpha = \omega \sqrt{\mu \epsilon'} \left\{ \frac{1}{2} \left[\sqrt[2]{1 + \left(\frac{\epsilon'}{\epsilon} \right)} - 1 \right] \right\}^{\frac{1}{k}} \quad (2.21)$$

(esponente della quadra forse sbagliata).

Sia α che β dipendono dalla propagazione e dal mezzo.

L'onda entra nel mezzo e man mano tenderà ad attenuarsi per via delle perdite, è importante capire da che punto in poi possiamo dire che l'onda si sia attenuata: definiamo $\delta_s = \frac{1}{\alpha}$ ed è tale per cui z(profondità) = δ_s :

$$\left| \frac{E_x(\delta)}{E_y(\delta)} \right| = \frac{1}{e} \quad (2.22)$$

che è circa del 37%, quindi comunicare sotto questa soglia diventa molto complicato, la densità di potenza proporzionale al modulo di E si è ridotta invece del 13%. Abbiamo un grafico come quello in 2.8:




Figura 2.8: Attenuazione del SAR

supponiamo di fissare un valore di riferimento del SAR: questo sarà ottenuto nel mezzo, al variare della frequenza, ad una profondità via via crescente: se la profondità diminuisce lo spessore aumenta, quindi aumentando la frequenza otterremmo una profondità di penetrazione molto sottile. Fissando la profondità, all'aumentare della frequenza, il SAR tende ad abbassarsi quindi le conseguenze sono che volendo arrivare i profondità per comunicare con un dispositivo in profondità occorre usare frequenze basse, per cui il δ_s è basso, aumentando la frequenza l'interazione è sempre più in superficie (**ricorda di smentire i coglioni che dicono che il 5G fa male perché entra nel corpo. COJONI, leggete le frequenze usate COJONI**).

Capitolo 3

Lezione 3

3.1 Discontinuità fra due mezzi

Cosa accade quando c'è una discontinuità: il corpo umano può essere rappresentato in modo semplice come un mezzo non omogeneo, e quando l'onda incide il corpo umano sperimenterà una serie di effetti. Cosa accade quindi quando l'onda attraversa una superficie: consideriamo una superficie che separa due materiali differenti, materiale 1 e 2 ovvero grasso e muscolo: immaginiamo di avere determinati campi elettrici \underline{E} e di induzione \underline{D} e vediamo cosa succede alla potenza rilasciata sul corpo: la distribuzione della potenza dipende dall'incidenza dell'onda, possiamo avere campo elettrico paralleli o normale e dipendentemente dal fatto che il campo arrivi normale o parallelo avremo il **teorema di continuità dei campi**: a ridosso della discontinuità la componente tangente dei campi si conserva, quindi il campo parallelo sulla discontinuità π si conserva senza avere salti, mentre la E_{\perp} non si conserva, c'è un salto ma sappiamo che si conserva la componente D_{\perp} .
Da queste considerazioni, cerchiamo di capire le conseguenze sulla distribuzione di potenza a ridosso delle superfici:

1. Polarizzazione tangente:

$$\underline{E} = \underline{E}_{\parallel} \quad (3.1)$$

avremo che

$$P = \frac{1}{2} \sigma |E|^2 \quad (3.2)$$

e quindi le due P , una prima della superficie di separazione ed una dopo saranno

$$p_1 = \frac{1}{2} \sigma_1 |E_1|^2 \quad p_2 = \frac{1}{2} \sigma_2 |E_2|^2 \quad (3.3)$$

ne consideriamo il rapporto che sarà dato da

$$\frac{p_1}{p_2} = \frac{\sigma_1}{\sigma_2} \quad (3.4)$$

2. Polarizzazione normale: ripartiamo da

$$\frac{p_1}{p_2} = \frac{\frac{1}{2} \sigma_1 |E_1|^2}{\frac{1}{2} \sigma_1 |E_2|^2} \quad (3.5)$$

dove le componenti ortogonali NON sono più uguali come prima, quindi esprimiamo uno in funzione dell'altro:

$$\epsilon_1 E_{\perp 1} = \epsilon_2 E_{\perp 2} \quad (3.6)$$

ricaviamo $E_{\perp 1}$ che messo nel rapporto fa sì che questo dipenda anche dalla permittività:

$$\frac{p_1}{p_2} = \frac{\sigma_1}{\sigma_2} \left| \frac{\epsilon_2}{\epsilon_1} \right|^2 \quad (3.7)$$

	ϵ_r	σ
muscolo	60	1
grasso	15	0,1

Con degli esempi, CAPIAMO:

il mezzo 1 è grasso, mentre mezzo 2 è il muscolo. Fissiamo una frequenza fra quelle libere, $f = 434$ MHz e abbiamo ϵ_r e σ : nella polarizzazione tangente, avremo che

$$p_f = \frac{1}{10} p_m \quad (3.8)$$

(dove f ed m sono fat e muscle), mentre nella polarizzazione ortogonale avremo

$$p_f = \frac{16}{10} p_m \quad (3.9)$$

quindi si inverte: in un caso la potenza è maggiore nel muscolo, nell'altro caso nel grasso. Come sono gli andamenti:

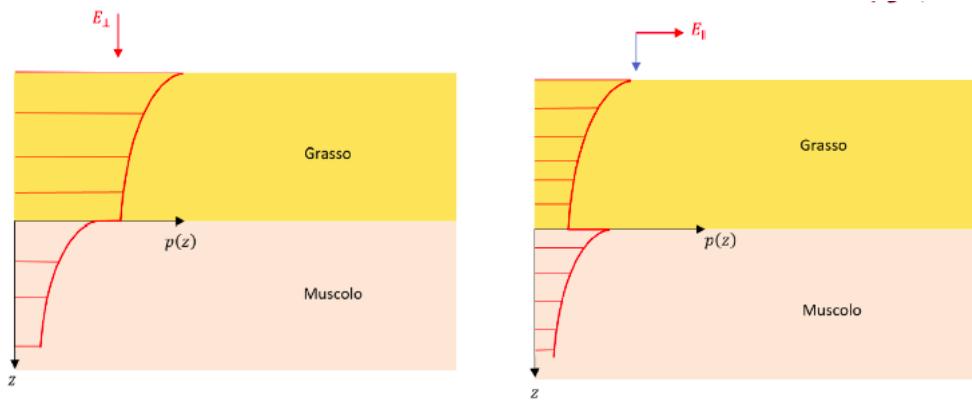


Figura 3.1: Variazione di densità di potenza in base all'incidenza del campo E

la potenza man mano che si scende in profondità si attenua con legge esponenziale. Nel caso tangente, nella discontinuità, la potenza nel grasso è $\frac{1}{10}$ di quella nel muscolo, c'è un salto netto e poi continua a calare per via dell'attenuazione.

Nel caso parallelo, c'è un salto ma in direzione opposta, perché in questo caso la potenza è maggiore nel grasso.

L'effetto di assorbimento dei tessuti dipende quindi da come è fatto il dispositivo che genera il campo, in base a come lo genera: se normale, il valore nel muscolo è basso, mentre se parallelo è maggiore e quindi anche l'effetto di esposizione del corpo sarà differente.

Vediamo ora l'effetto di questa potenza assorbita

3.2 Effetti dell'assorbimento di potenza

L'effetto principale è il riscaldamento ("effetto microonde"), quindi l'esposizione EM ha come effetto principale questo riscaldamento, che in alcuni casi come i sistemi terapeutici è voluto (sempre es. fisioterapia), in molti casi sono effetti collaterali, non voluti quindi si cerca di ridurli. Cerchiamo di capire il legame fra il SAR e la variazione di temperatura nel corpo: c'è l'equazione di Fourier che spiega come evolve un processo termico, che nel caso di una sorgente EM ha un pezzo in più

$$\rho C \frac{\partial T(t)}{\partial t} = \Delta(K \Delta T) + p \quad (3.10)$$

dove

- la temperatura T dipende da tempo e posizione ($T(t, \underline{r})$);
- ρ è la densità (?)
- C è il calore specifico ovvero la quantità di calore assorbita da 1g di sostanza durante la variazione di temperatura di 1° ($\frac{J}{kgC}$)
- K è il coefficiente di conducibilità termica

$$\frac{\Phi Q}{\Delta T} \left(\frac{W}{mC} \right) \quad (3.11)$$

più k è elevato più il mezzo tende ad essere isolante. Infine p è la densità di potenza assorbita ($\frac{W}{m^3}$).

Ora, è molto più agevole considerare la stessa equazione quando dividiamo ambo i membri per ρ , in quanto

$$\frac{P}{\rho} = SAR \quad (3.12)$$

questo è il termine "forzante", questa diventa la sorgente del termine noto e quindi rilascia calore e tale potenza è una sorgente che si chiama **endogena**, in quanto è fornita all'interno del materiale mediante onda EM: se poggiamo un pezzo di metallo caldo su un oggetto, questa è una sorgente esogena, mentre questa si origina dall'interno.

Nel corpo umano ci sono un paio di peculiarità:

- è vivo, quindi si oppone a degli stress esterni, in questo caso il riscaldamento dell'onda EM col sangue che è un sistema di raffreddamento: il vaso si dilata ed il passaggio di sangue toglie calore. C'è un termine che si oppone al riscaldamento
- c'è poi un termine dovuto alla combustione chimica del cibo, che genera energia e si oppone

Otteniamo quindi la nuova equazione, Bioheat equation (Pennes 1948)

$$\rho C \frac{dT(t)}{dt} = \Delta(k\Delta T) + p + M - B \quad (3.13)$$

dove:

- M è il metabolismo ($\frac{W}{m^3}$), calore metabolico,
- B è la perfusione sanguigna, che ha segno meno perché tende ad opporsi per l'incremento dovuto agli altri termini.

Abbiamo che

$$B = W \cdot c_b(T - T_{arteria}) \quad (3.14)$$

dove T arteria se stiamo bene è di 37° , se questa diminuisce è il sangue che tende a scaldare, altrimenti raffredda. Ma dopo un po' c'è shock termico e quindi il tessuto comincia a bruciare: se ne vediamo l'andamento

c'è un punto in cui va giù, ovvero quando la temperatura supera il 44° la perfusione sanguigna non ce la fa più perché il vaso non si può più estendere ed i tessuti necrotizzano (nel punto cerchiato si verifica l'ipertermia).

Occorre quindi evitare che la temperatura inserita nel corpo dal dispositivo sia vicina ai 43° - 44° ,

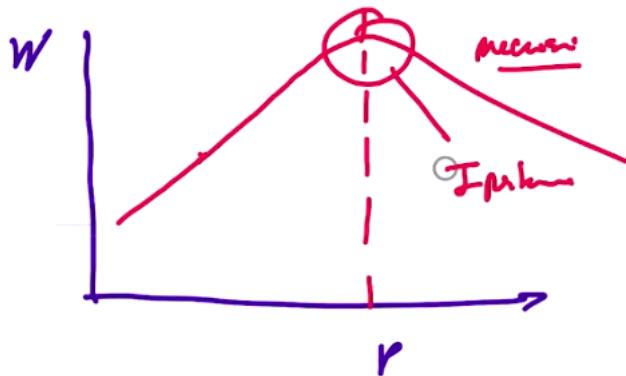


Figura 3.2: Andamento della perfusione sanguigna, in funzione della densità di potenza

altrimenti si arriva a bruciare.

Ci interessa l'equazione perché c'è un modo semplice per misurare il SAR: il cellulare rilascia un certo SAR nella testa, si parte dall'equazione di Pennes: il primo termine è istantaneo, poi c'è il termine di conduzione, la M quando c'è una sorgente esterna è piccolo rispetto al calore esterno ed anche la B è un fenomeno lento: il τ del fenomeno EM è veloce (ordine dei ns), se tocchiamo qualcosa di caldo non è istantaneo capire che si passa ad una temperatura fredda (ordine s), quindi applicando un fenomeno EM in un Δt minore di un minuto nell'equazione rimane solo che

$$\rho C \frac{\partial T}{\partial t} \simeq p \quad (3.15)$$

quindi dividiamo per ρ ed otteniamo il SAR, che è proporzionale alla variazione di temperatura in un tempo abbastanza breve, quindi la posso approssimare come

$$C \frac{\Delta T}{\Delta t} \leq 1m \quad (3.16)$$

Se mettiamo in una bacinella un liquido body-like (acqua zucchero sale) ed introduciamo un telefono cellulare, se facciamo una "foto" all'esterno (con termocamera o sondine), la zona sarà calda verso l'esterno e man mano sempre più fredda, così si può misurare il SAR prodotto dai dispositivi radianti.

3.3 Normative EM

Il progetto del dispositivo deve essere safety by design, quindi devo progettare prima il dispositivo che abbia fra i requisti una certa intensità di campo EM.

Le attività del capire le soglie di esposizione nascono negli anni 80-90, l'impulso è stato dato dall'esplosione dei telefoni cellulari, c'è stato uno sforzo grande nel 97'-98' per capire quali parametri considerare e come caratterizzarli.

Prima sono stati fatti degli studi con animali e tessuti espiantati e poi fatta una grossa analisi della letteratura scientifica. Sono stati poi fatti degli studi per cercare di correlare con le malattie (come tumori etc...), si è poi cercato di ridurre gli effetti accertati a breve termine, infine noti gli effetti gli studi si sono spostati sull'individuare le dosi soglia per evitare tali effetti.

Ci sono due classi di effetti dell'esposizione ai campi EM:

1. effetti diretti:

- accoppiamento con campi E a bassa frequenza
- accoppiamento con campi B a bassa frequenza

- assorbimento di energia EM.

Queste 3 tipologie di fenomeno producono due effetti percepibili:

- riscaldamento di organi e tessuti, ed è quella più facilmente quantificabile perché produce calore
- stimolazione di nervi e muscoli: c'è un disturbo dovuto al segnale, è possibile che il muscolo si contragga o che vengano stimolati degli effetti chimici e sono difficili da caratterizzare perché sono a lungo termine e sono più difficili da mettere in evidenza.

2. effetti indiretti, legati principalmente a

- alle correnti di contatto
- accoppiamento del campo EM con dispositivi impiantati, interazione con un dispositivo impiantato nel corpo. I primi pacemaker erano sensibili al telefono cellulare, sono stati poi protetti con dei filtri

Sull'analisi e la ricondizione degli effetti sono stati individuati dei limiti: inizialmente sono stati individuati i limiti di base, ovvero quelli legati alle grandezze EM che producono direttamente l'effetto, ovvero campo E nel corpo, al SAR ed in alcuni casi alla densità di potenza ovvero a grandezze direttamente generate nel corpo e che sono direttamente correlabili agli effetti diretti.

Chiaramente cambiano in base alla frequenza, aumentandola, diminuisce la permittività sulla pelle. Misurarle è difficile, quindi sono stati introdotti degli **insiemi di livelli di riferimento o derivati**: sono delle grandezze che si possono valutare in assenza del corpo umano: se abbiamo un cellulare a contatto con la testa, leviamo la testa e calcoliamo le grandezze in un volume che sarebbe stato occupato dalla testa.

Se scelti bene, rispettando i livelli di riferimento allora questi implicheranno che tali valori verranno rispettati anche quando sarà presente il corpo umano, MA NON vale il viceversa: se vengono rispettati i requisiti di base, non è detto che vengano rispettati quelli di riferimento.

Le restrizioni di base sono quindi legate alla misurazione "in situ", mentre invece le restrizioni derivate sono misurate in assenza del corpo umano e quindi il loro rispetto implica i primi.

Abbiamo ad esempio quelli per l'ELF fra 1-100 KHz

1-10 mA/m ²	Effetti biologici minori (1 mA/m ² è relativo alle attività elettrofisiologiche del cuore e del sistema nervoso)
10-100 mA/m ²	Effetti visivi e sul sistema nervoso
100-1000 mA/m ²	Possibili rischi per la salute (contrazione muscolare, livello di eccitazione dell'extrasistole ventricolare)
> 1000 mA/m ²	Rischi acuti (2 mA/m ² livello per l'attivazione della fibrillazione ventricolare)

Figura 3.3: Effetti sul corpo umano in corrispondenza di Extremely Low Frequency

poi la microonde (100 Mhz in su), la sperimentazione animale indica come soglia di danno alla salute un incremento della temperatura di 1°C, per legarlo alla grandezza EM si è visto dalle misure che applicando un SAR per 6 min di 4 W/kg si innalza la temperatura di 1°C.

I limiti di base del SAR sono diversi fra operatori e popolazione: un operatore può essere più esposto in quanto può prendere le dovute precauzioni, difatti per i lavoratori mediati su 6 min i valori sono circa 5 volte tanto, inoltre la media va fatta sui 10g: se ad un certo punto c'è un hotspot, possibile

SAR	Lavoratori	Corpo intero	0.4 W/kg	}	Media su 6 minuti
		Testa e tronco	10 W/kg		
		Arti	20 W/kg		
	Popolazione	Corpo intero	0.08 W/kg		Valori mediati su 10 g di tessuto omogeneo
		Testa e tronco	2 W/kg		
		Arti	4 W/kg		

Figura 3.4: Limiti del SAR mediato su 6 minuti

superare il limite ma per un punto non posso buttare il dispositivo e quindi si fa una media su 10 g di materiale: si misurano i valori di SAR sui 10g e si fa questa media mobile così da buttare gli outliers

Nel caso di dispositivi wearable, i limiti dei lavoratori sono coincidenti con quelli della popolazione. Vi è poi un altro aspetto: le analisi vengono spesso fatte nel caso peggiore, ovvero quando viene trasmessa una sinusoide, quindi un segnale continuo.

Nella realtà ogni dispositivo di telemetria ha un **duty cycle**: ci sono parti alte e poi periodi di nulla, come mostrato in figura:

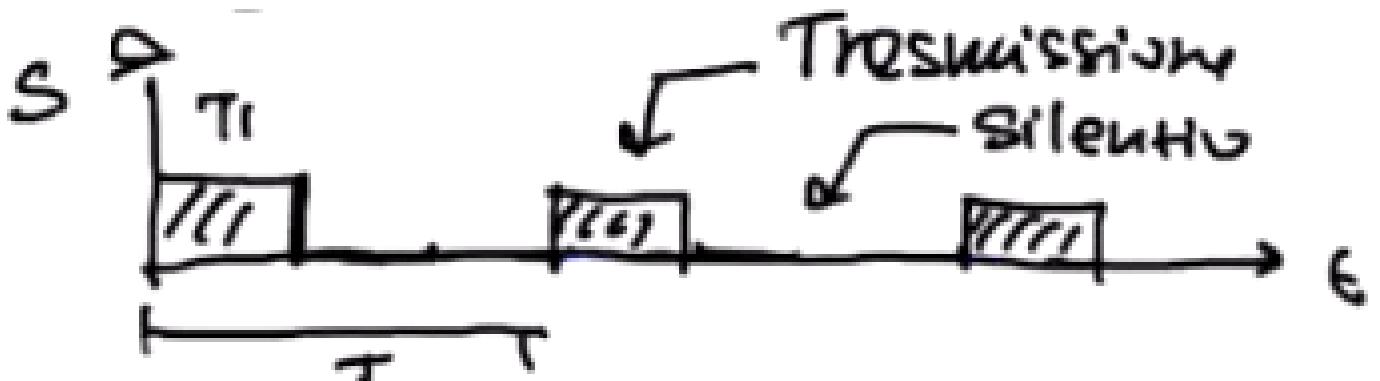


Figura 3.5: Trasmissione classica di un dispositivo di telemetria

Immaginiamo di avere un esempio in cui un dispositivo trasmette una volta il giorno lo stato di salute di una protesi impiantata, dove:

- la trasmissione dura $T = 1\text{min}$;
- il SAR di picco è pari a $10 \frac{W}{kg}$, quindi sopra soglia

averemo un minuto al giorno in cui il SAR è sopra soglia, ma facendo la media otteniamo

$$\langle SAR \rangle_{6\text{min}} = \frac{1}{6} \cdot 10 = 1,67 \frac{W}{kg} \quad (3.17)$$

e quindi sotto la soglia di omologazione, avremo quindi un valore che è $d \cdot SAR$.

Se però un soggetto è portatore di oggetti come pacemaker i limiti vanno impostati per ogni istante di tempo: se viene messo in atto un attacco isico e si produce una potenza molto elevata, questo viene messo fuori uso.

In Italia ed in Europa: il quadro italiano si pone in maniera molto restrittiva rispetto a quelle europee, dove in Europa sono indicati 40 V/m, in Italia ce ne sono 6. Inoltre, ovunque vanno rispettati certi valori, in siti come scuole etc.. ci devono essere valori ancora più bassi, inoltre a regime vanno rispettati dei valori ancora più bassi. La legislazione italiana fissa 3 livelli:

- limite di esposizione: 20 V/m, non devono poter essere misurati in zone che non sono ad esempio dei tralicci recintati
- valore di attenzione: in alcuni ambienti dove ci si viva per un tempo maggiore di 4h consecutive non ci devono essere più di 6 V/m
- obiettivi di qualità: fare in modo che progressivamente in qualunque punto si vada verso i 6 V/m.

3.3.1 Come fare una valutazione

Ci si muove su tre livelli a complessità crescente:

1. Misura del campo EM in assenza del corpo umano, andando a misurare i livelli di campo nel volume occupabile dall'uomo, si media per 6 min e si confrontano con i livelli derivati. Se rientrano nella normativa, possiamo omologare il dispositivo

2. Se da valori più elevati, occorre salire di complessità. Qui va fatta una simulazione EM, in cui si introduce il corpo umano, ma può andare bene un fantoccio di forme standard (cubi, cilindri), spesso di materiale omogeneo.

Con un simulatore si simula il dispositivo e si calcolano campi e SAR nel fantoccio

3. Se ancora i valori sono elevati, si fa una nuova simulazione con un modello antropomorfo, ovvero con tutti i tessuti del corpo umano con la sua permittività e conducibilità e si valuta il SAR iterando ciascun componente del corpo umano.

Se non si è conformi, tocca tornare alla progettazione.

Esistono dei fantocci, il più famoso è visible human (progetto HUGO), un ergastolano che venne messo sotto gelatina, ghiacciato e fatto a fette e dopo la sedia elettrica venne "fotografato". È un fantoccio dove ci sono tutti i tessuti.

Capitolo 4

Lezione 4

4.1 Link bodycentrici - generalità

Si fa riferimento a quei collegamenti nei quali in qualche modo compare il corpo umano, qui non solo c'è una sorgente che irradia, ma c'è un oggetto che si pone nel mezzo ed è molto complesso (corpo umano).

Possiamo caratterizzare questi sistemi in base a

A) orientamento della radiazione: immaginiamo di avere un corpo, possiamo avere un'antenna fuori che sta irradiando nel corpo oppure un'irradiazione che dal corpo irradia verso l'esterno. Possiamo quindi avere link:

- into the body, dove abbiamo ad esempio:
 - * sensori
 - * harvester: raccolgono l'energia esterna e la forniscono all'elettronica
 - * sistemi di telemedicina: possiamo avere un dispositivo che cerca di interrogare dei sensori che sono all'interno del corpo
 - * terapia fisica, ovvero l'irraggiamento del corpo umano ai fini della terapia
- out of the body (esterno), dove l'irradiazione dal corpo va verso l'esterno. Abbiamo:
 - * telemedicina, il sensore trasmette il dato verso l'esterno
 - * sensori
 - * trackers o beacon: dispositivi che servono per identificare la persona. Il dispositivo trasmette informazioni ad esempio sulla posizione

B) tipologia di interazione

- quasi statica, i campi E e B sono poco variabili nel tempo:
 - * induttivo, si lavora principalmente col campo B
 - * di tipo capacitivo, in cui si lavora col campo E
- zona di midfield, è una zona intermedia che domina molte delle applicazioni body centriche, non siamo più nel campo lontano ma non possiamo più separare campo elettrico e magnetico
- radiativa, abbiamo che i campi non sono più così separabili

Immaginiamo di avere un elemento radiante, ed una corrente (antenna di cellulare, smartwatch etc...) ed avere r che è la distanza dominante: abbiamo 3 regioni

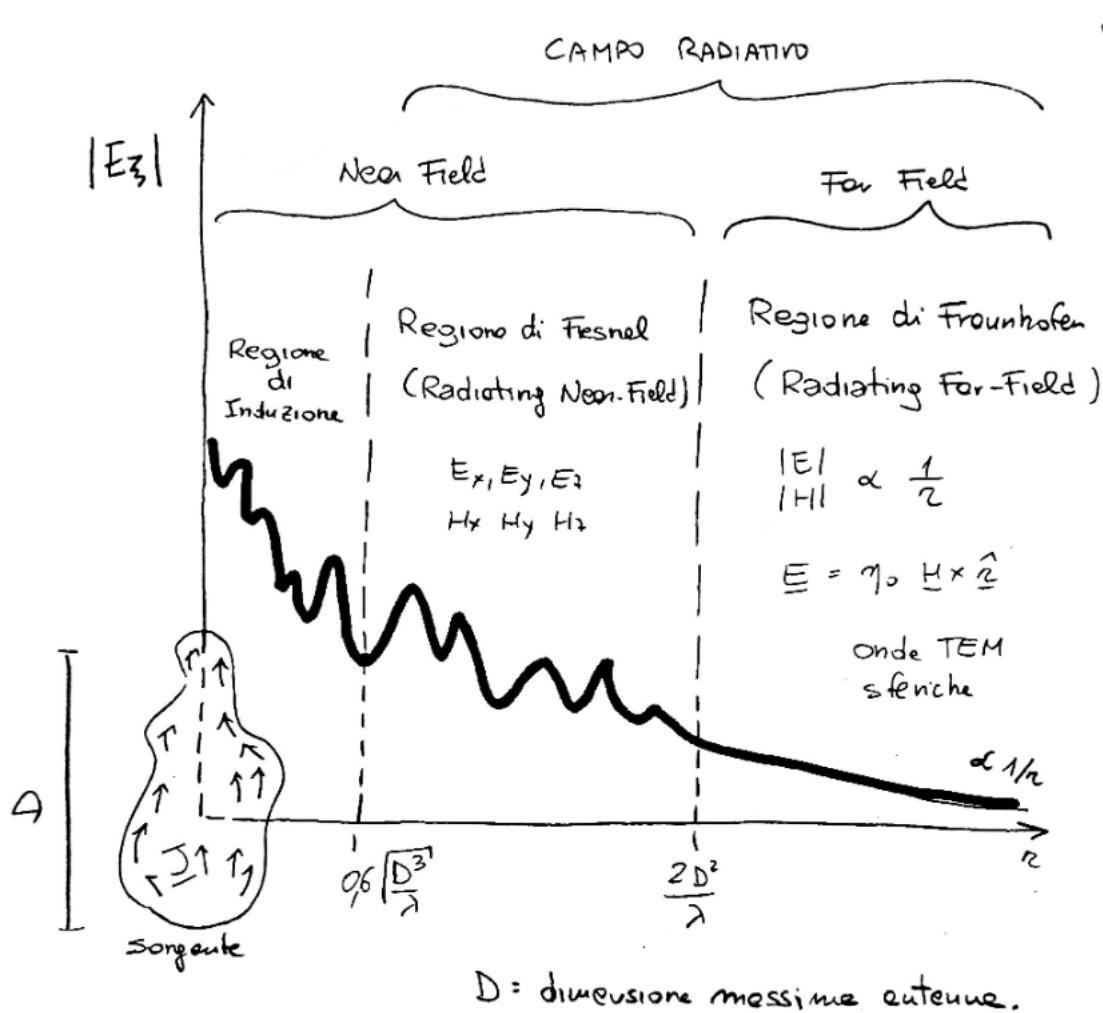


Figura 4.1: Regioni del campo radiativo

Nella zona di far field il campo elettrico e magnetico sono fra loro ortogonali, (anche a k che è la direzione di propagazione) e la densità di potenza è reale ed è proporzionale al campo elettrico, (copia tutte le formule)

Nella zona induttiva, che è il near field, il campo varia molto lentamente e l'energia è induttiva(??) ma possiamo usarla per far colloquiare due dispositivi, ci sono tutte le componenti e sono mischiate e non si possono separare. Poi c'è la zona di mezzo dove comunque non si segue $\frac{1}{r}$.

Va tenuto chiaro che: nelle zone vicine, quando abbiamo a che fare col corpo umano, c'è energia reattiva che magnetostatica o elettrostatica che NON si propaga ma si può "raccogliere" ed accoppiare e quindi usare per le applicazioni.

Un altro aspetto importante sono le frequenze di lavoro:

- basse, Low Frequency ed High Frequency (kHz - MHz), le LF vanno 30-300 kHz, mentre HF 2-30 MHz. Sono tipiche dei sistemi quasi statici, quando lavoriamo con queste stabiliamo un regime quasi statico e quindi tutto interviene in campo quasi statico. Qui il campo si attenua di meno quando interagisce col corpo, lo spessore pelle è maggiore ma sono coinvolti dei dispositivi più grandi. Se volessi con una sola antenna trasmittente leggere tante antenne del corpo umano dovrei usare queste frequenze
- elevate, UHF e microwave. Le UHF sono 300 MHz - 3 GHz, mentre le microwave sono da 1 - 3 GHz. Sono tipiche dei sistemi radiativi. Penetrano meno, circa 4 cm nel corpo e quindi

possono interagire con la pelle meglio (penetrano meno) ma hanno come vantaggio di permettere l'utilizzo di antenne più basse.

•

L'antenna è un oggetto poco miniaturizzabile, quindi in molti dispositivi l'ingombro è dovuto alla presenza di antenne (similmente a quanto accade per la batteria) soprattutto se l'antenna deve essere piccola.

Altro aspetto importante sono le geometrie, i layout

- in dispositivi quasi statici, abbiamo
 - coil, avvolgimenti nei sistemi magneto-statici
 - piastre, che svolgono la funzione di condensatore
- in sistemi radiativi abbiamo
 - dipoli
 - loop
 - slot
 - patch

Seguono poi le tipologie di servizio, ovvero perché usiamo il sistema bodycentrico:

- comunicazione: uno degli scopi principe.
Sistemi wearable, con cui è possibile fare delle body area network. Ad esempio, in ambito militare, quando vanno in missione c'è una rete mesh fra i vari soldati: ognuno ha una radio che permette di stabilire una comunicazione con gli altri fino ad arrivare al capo
- telemetrica e comando: abbiamo un dispositivo sul corpo o al suo interno, che deve mandare un messaggio all'esterno (telemetria). Il comando invece serve principalmente a configurare dei dispositivi impiantati: le pompe ad infusione, dispositivi che rilasciano farmaco, neuro-stimolatori periodicamente vanno controllate dagli esperti del settore (**NON NOI**).
- Wireless Power Transfer: trasferimento di energia per alimentare un dispositivo che non ha batteria o per evitare che la batteria di un dispositivo venga consumata per comunicare.
Anche se un dispositivo medico non ha la batteria si cerca di non usarla i più possibile, quindi l'energia che serve per comunicare viene fornita dall'esterno.
L'esempio classico è la ricarica del cellulare o dello spazzolino elettrico
- Marker / Labeling: alcuni dispositivi medici possono essere dei **marcatori**. I marker non trasmettono informazione, ma servono ad esempio per centrare il corpo umano rispetto a qualche altra sorgente.
Il labeling è l'associazione al dispositivo medico un codice, simile al codice a barre, fatto a radiofrequenza da sistemi RFID quindi si può assegnare un identificativo ad un oggetto per leggere e scrivere dentro. Si fa quindi identificazione e tracking, ma anche localizzazione.



Figura 4.2: Schema di comunicazione half duplex

4.1.1 Architetture di comunicazione

Abbiamo due modalità per stabilire un link:

- link simmetrici
- link asimmetrici

differiscono sostanzialmente nella gerarchia con cui uno trasmette ed uno riceve, c' è differenza nei protocolli usati, nella progettazione hardware etc...

Link simmetrici

In un link in generale abbiamo due oggetti, A e B che devono scambiarsi delle informazioni.

In un link simmetrico, possiamo definire trasmettitore TX e ricevitore RX: TX manda il segnale ed RX deposita tale segnale su un carico.

È possibile anche che si scambino i ruoli fra i due ad un certo punto, quindi non parlano mai contemporaneamente (half duplex).

L'esempio classico sono il cellulare che parla con stazione RB e poi altro cellulare, o anche i walkie talkie.

Ambe due i dispositivi hanno la stessa elettronica e serve una fonte locale di alimentazione, quindi o una alimentazione ad un cavo fisico oppure una batteria.

Esempi: bluetooth BT, che funziona a 2450 MHz, bluetooth BLE (low energy) che permette di avere una durata della batteria più lunga: la prima cosa da fare è il pairing fra i dispositivi.

LTE (ex 4G), che è Long Term Evolution, 850-900 - 2100 MHz, ci sono i sistemi UMTS, CDMA, SCDMA

Wi Fi, le cui frequenze sono 2450 - 5800

5G, che ha diverse frequenze, 700 MHz, LTE, 3600Mhz, 26GHz fino a 60 GHz.

Sistemi IoT: LoRa (Long Range) e SIGFOX: sono sistemi di Wireless Lan, sistemi con cui interconnettere oggetti e quindi molto usati in sistemi di IoT, possono collegarsi ad un hotspot tipo WiFi ma con range molto più alto e con batterie che durano molto tempo (ordine anni). Le frequenze sono più basse, 433 Mhz e 868 Mhz.

Link asimmetrici

Altra filosofia, che è molto gerarchizzata: tipicamente c'è un oggetto che si chiama lettore (Reader) che va ad interrogare un altro oggetto "stupido" da un punto di vista dell'elettronica e risponde per riflessione, quindi non ha sensori ma in qualche modo riflette il segnale modulandolo in modo da poter codificare i valori 0 ed 1. Per farlo, c'è un interruttore del D che permette di modulare ma è molto semplice e non richiede batteria o elettronica complessa, tutta l'energia che serve per attivare l'interruttore arriva dal trasmettitore, a differenza invece del Reader.

Ci sarà un link diretto dal lettore al trasmettitore e poi un link inverso che va dal dispositivo al reader.

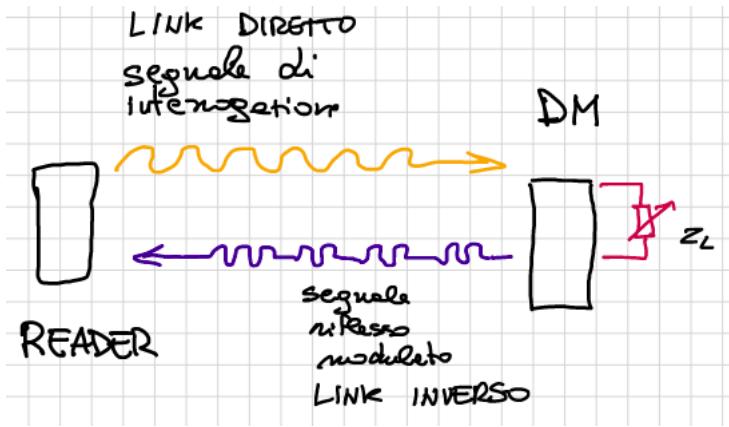


Figura 4.3: Schema di comunicazione full duplex

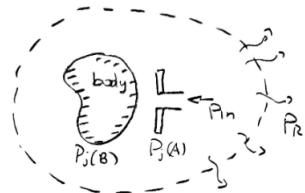


Figura 4.4: Schema di trasmissione

In questo caso i due dispositivi possono mandare segnali contemporaneamente, quindi con comunicazione full duplex. Abbiamo dispositivi monouso, come cerotti che evitano l'uso di batterie e costano meno.

4.1.2 Efficienza dei collegamenti

Quando si fa un collegamento, una delle cose più preziose è l'energia, in quanto sistemi wearable non possono essere collegati alla corrente e quindi tutta l'energia è data dalla batteria che non ha durata lunga, inoltre nel corpo umano si perde tanta energia per via delle perdite.

Introduciamo in due step:

1 solo antenna che trasmette in prossimità del corpo umano, ad esempio l'orologio che prova a collegarsi al wifi: abbiamo il corpo, un dispositivo che sta irradiando e che produce una radiazione che poi entra magari nel corpo.

Consideriamo poi una superficie che racchiude tutto:

potremmo applicare il thm di Pointing, abbiamo della potenza irradiata, della potenza dissipata nel corpo (P_j), quindi la potenza totale che fornisce è

$$P_{in} = P_r + P_j(k) + P_j(B) + P_j(A) \quad (4.1)$$

se abbiamo un sistema di comunicazione deve prevalere la potenza irradiata, mentre invece per sistemi che fanno terapia deve prevalere quella dissipata.

Possiamo caratterizzare la bontà del trasmettitore in base alla efficienza

$$\vartheta_R = \frac{P_R}{P_{in}} = \frac{P_r}{P_j(A) + P_j(B)} \equiv \frac{R_R}{R_R + R_j} \quad (4.2)$$

abbiamo in più il termine (verde) che è proprio specifico della presenza del corpo. Si possono anche associare le resistenze delle antenne.

Quando non c'è il corpo umano, la R_R tende ad andare proporzionalmente come il raggio dell'antenna, l'andamento è simile a questo (metti immagine), le prestazioni migliorano ingrandendo l'antenna in modo da avere una resistenza di radiazione migliore ed enfatizzare quindi la parte radiata.

Se abbiamo anche il corpo, aumentando le dimensioni dell'antenna irradia meglio ma manda più potenza nel corpo e ci sarà maggiore dissipazione. Se $\frac{R}{\lambda}$ aumenta abbiamo due effetti opposti:

- da una parte aumenta la resistenza di radiazione
- ma da una parte aumenta anche la resistenza di perdita

(copia ASSOLUTAMENTE L'IMMAGINE DEL DONDOLO)-

Nei sistemi radianti, non comanda la lunghezza in se, ma la lunghezza RISPETTO alla lunghezza d'onda. Abbiamo il seguente andamento:

ad un certo punto, superato questo, il dispositivo irradierebbe come uno piccolo e quindi sarebbe poco efficiente.

È un tradeoff e vale ogni volta che abbiamo un mezzo con perdite (pelle, pneumatico, etc...) l'effetto di portare un dispositivo in prossimità di un mezzo avrà un valore ottimale e tale valore ottimale dipende poco dalla forma dell'antenna (dipolo, loop, slot) ma tanto dalla forma: gli oggetti fatti a loop hanno una l_{max} ottimale in termini di ingombro.

2 Consideriamo ora anche il link in presenza del corpo umano.

Possiamo avere la seguente immagine:

un'antenna che irradia, chiamiamo P_L la potenza che verrà raccolta per far funzionare il dispositivo. Il parametro che descrive quanto p efficiente questo trasferimento di potenza dal tx all'oggetto è il PTE: $\frac{P_L}{P_{in}}$ e va massimizzato per avere un link efficiente.

Dipenderà anche in questo caso dai tessuti, dalla posizione rispetto al corpo (più in profondità, maggiore l'attenuazione), dipende anche dalla forma delle antenne coinvolte ed ovviamente dalla frequenza (PTE tende a diminuire quando la frequenza aumenta perché l'attenuazione del corpo aumenta ed è quindi più difficile eseguire il comportamento).

Possiamo scrivere $P_L = P_{in} \cdot PTE$, fissando la PTE, per aumentare la P_L va aumentata la P_{in} , ma nel corpo aumenta anche il SAR ovvero la potenza rilasciata: qui il problema è che per aumentare la P_L potremmo aumentare la potenza in ingresso ma se aumenta troppo il SAR sfiora i limiti di legge e qui si capisce bene cosa vuol dire safety by design.

Il primo anello della catena di progettazione deve:

- SAR < SAR_{max}
- P_{in} ≤ P max

viene quindi fuori un vincolo per la PTE, imposto dal SAR: questo ci dice quindi quanto deve essere fatto bene il collegamento in modo da poter minimizzare la potenza necessaria.

4.2 Link in near field

Negli anni di fine 800 (1831) vengono fatti i primi studi da Faraday sulla induzione EM: gli studi avevano a che fare con due coil, in modo che questi potessero trasferirsi energia senza che questi si toccassero. L'accoppiamento veniva fatto mediante l'uso di materiale ferromagnetico, per molti anni venne usato ad esempio nei trasformatori ma non per la comunicazione.

Agli inizi del 1900 ci sono gli esperimenti di Hertz e di Tesla, dove si parla proprio di trasmissione di informazione a distanza, Telsa introdusse anche i concetti di risonanza in quanto la sua ambizione era rifornire l'energia nelle città tramite una torre che mandava energia sulle case della città.

Sono applicate nelle comunicazioni a bassa frequenza e piccola distanza, in ambito medico abbiamo

dispositivi IMD (Implanted Medical Device) che possono essere pacemaker, defibrillatori, neurostimolatori etc... la comunicazione viene stabilita con un altro coil messo sulla superficie del body stabilendo un link a bassa frequenza. Sono link di tipo quasi statico, basati o su accoppiamento induttivo, o su accoppiamento induttivo risonante o accoppiamento capacitivo. Le frequenze di lavoro sono le HF ed LF, anche attorno ai KHz: in queste condizioni la capacità di conduzione del corpo è bassa, quindi basse perdite che permettono di avere PTE elevata, inoltre la permittività è elevata. I dispositivi non sono vere e proprie antenne, sono una specie di elettrodi in quanto lavorano in campo vicino.

Capitolo 5

Lezione 5

5.1 Inductive (Magnetic) coupling

Nell'accoppiamento siamo nel regime delle LF (125 KHz) e delle HF(13-56 MHz) e possiamo usarlo per dispositivi medici impianti ma anche per la ricarica wireless.

Tipicamente vengono usati due coil, di cui uno fa da trasmettitore ed uno raccoglie il campo vicino, siamo in campo vicino e non si può parlare di antenne:



Figura 5.1: Coil usati per l'accoppiamento magnetico

abbiamo due spire ai capi della seconda spira vogliamo raccogliere la tensione. Parliamo di link induttivo perché avviene per induzione di Farady o magnetico perché avviene per il passaggio del campo da un coil all'altro, a noi interessa anche come sistema di comunicazione: questo sistema funzionerà come un trasformatore

(M è il coefficiente di mutuo accoppiamento) ed abbiamo

$$\frac{V_1}{V_2} = \frac{N_1}{N_2} \quad (5.1)$$

$$\frac{I_1}{I_2} = \frac{N_2}{N_1} \quad (5.2)$$

ed inoltre

$$V_2 = -M \frac{dI_1}{dt} \quad (5.3)$$

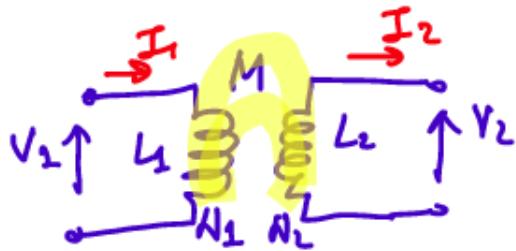


Figura 5.2: Sistema di comunicazione

nel caso ideale abbiamo che tutto il flusso del primario è raccolto dal secondario e quindi vale:

$$M = \sqrt{L_1 \cdot L_2} \quad (5.4)$$

nel caso reale invece abbiamo:

$$M = k \sqrt{L_1 \cdot L_2} \quad (5.5)$$

dove k è il **coefficiente di accoppiamento**, e vale $k \in [0, 1]$.

Vogliamo vedere come esprimere M per il sistema di due coil che sarà poi quello che legherà la tensione nel device rispetto alla tensione accesa nel primario:

se c'è un filo lineare percorso da una corrente I

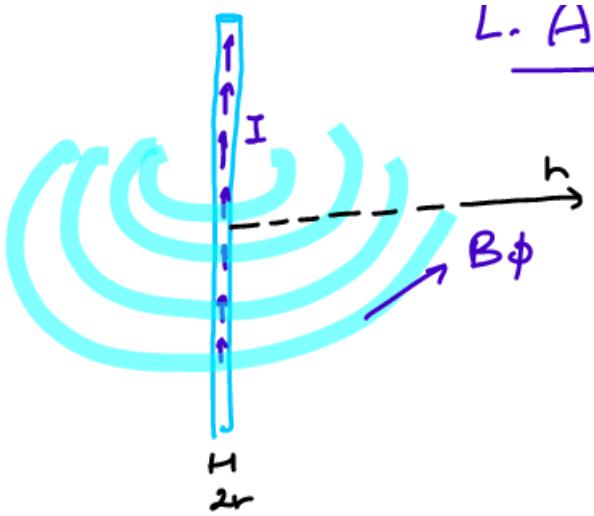


Figura 5.3: Campo magnetico generato da un filo lineare

viene generato un campo magnetico e dalla **legge di induzione di Ampere** abbiamo

$$\underline{B} = \frac{\mu_0 I}{2\pi r} \underline{\Phi} \quad (5.6)$$

se "curviamo" questo filo otteniamo questa configurazione mettiamo un generatore in modo che scorra una corrente nel verso mostrato, allora verrà generato un campo magnetico le cui linee di forza sono come mostrate, considerando la B_z che sarà

$$B_z = \frac{\mu_0 I a^2}{2(a^2 + r^2)^{\frac{3}{2}}} \quad (5.7)$$

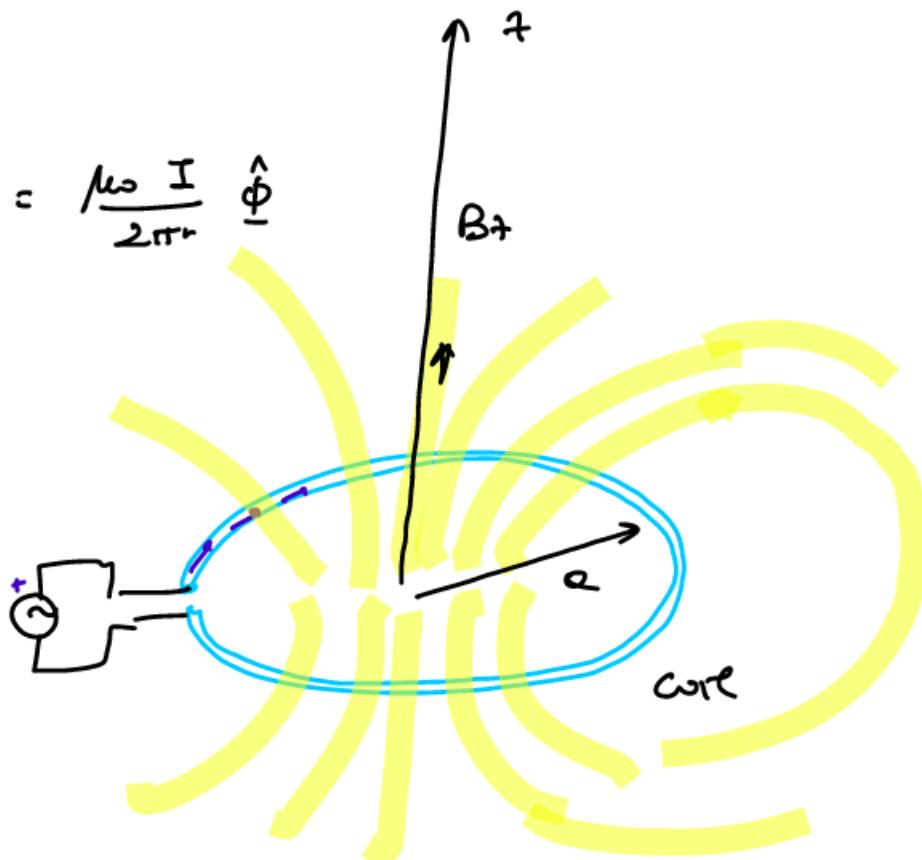


Figura 5.4: Campo magnetico generato da un filo lineare curvato

se supponiamo di avere N spire, l'espressione precedente viene moltiplicata per N .

Si vede intanto che se la distanza è $r \gg a$, allora $(a^2 + r^2) \approx r^2$, quindi avremo un andamento come $\frac{1}{r^3}$ e quindi il campo più forte si avrà nelle vicinanze ed avremo che B_z si può approssimare con

$$B_z = \frac{\mu_0 N I a^2}{2} \frac{1}{r^3} \quad (5.8)$$

Consideriamo ora due coil, uno che trasmette ed uno che riceve

avremo che RX concatenerà alcune delle linee del campo magnetico e quindi vale la **legge di Faraday**, che dice che un campo magnetico B variabile nel tempo che concatena una spira chiusa andrà ad indurre una ELF (Forza Elettromotrice Indotta) (vedi bene).

Se consideriamo il flusso ϕ del campo magnetico:

$$\phi(t) = \iint \underline{B}(t) \cdot d\underline{s} \quad (5.9)$$

allora la EMF sarà

$$V_2 = -N \frac{d\phi}{dt} \quad (5.10)$$

c'è un meno perché la tensione che viene indotta ai capi nel secondario a sua volta tende a muovere degli elettroni che genera un campo magnetico che si oppone al primo (altrimenti si violerebbe il




Figura 5.5: Sistema di due coil (tx ed rx)

principio di conservazione).

La applichiamo al nostro caso:

$$V_2 = -N_2 \frac{d}{dt} \psi_{2,1} = -N_2 \frac{d}{dt} \iint_{S_2} \underline{B}_1 da \quad (5.11)$$

dove il pedice a destra è la causa, quello a sinistra è l'effetto (coil 2, coil 1), sostituiamo poi l'espressione per \underline{B} (supponendo che i due coil siano colinerari, quindi allineati rispetto a z) ottenendo:

$$V_2 = -N_2 \frac{d}{dt} \iint_{S_2} \frac{\mu_0 I_1 a^2 N_1}{2(a^2 + r^2)^{\frac{3}{2}}} da \quad (5.12)$$

supponendo che i coil siano piccoli, possiamo considerare che il campo sia costante sul coil, possiamo integrare e moltiplicare per l'area:

$$V_2 = - \iint \frac{dI}{dt} \quad (5.13)$$

e la confrontiamo con la V_2 ottenuta dalla precedente, quindi M è $f(N_1 \cdot N_2, b^2, \frac{1}{r^3})$.

Cosa succede invece se il TX e l'RX non sono allineati: supponiamo di avere un angolo α fra i due assi, il secondario raccoglierà meno flusso e quindi possiamo tenere conto della mutua rotazione con un $\cos(\alpha)$, ottenendo un'espressione più completa di M aggiungendo il $\cos(\alpha)$

$$M = \frac{\mu_0 I a^2 N_1}{2(a^2 + r^2)^{\frac{3}{2}}} \pi b^2 \cos \alpha \quad (5.14)$$

Per incrementare il trasferimento di potenza fra un coil e l'altro possiamo:

1. aumentare l'intensità del campo \underline{B} , ma viene limitato dai limiti del campo a basse frequenze
2. possiamo diminuire la distanza fra tx ed rx, ma non è una cosa che si può fare sempre, ad esempio per un dispositivo medico impiantato

3. aumentare la frequenza del campo B, in modo che l'attenuazione sia meno evidente. La derivata nel dominio armonico è un $-j\omega$ ma l'aumento della corrente ha delle contro-indicazioni. Abbiamo $\frac{dI}{dt} \rightarrow -j\omega I$ (quindi V_2 aumenta) ma questo fa sì che ci siano più perdite e si dissipino di più (più potenza)
4. aumentare il flusso concatenato, ovvero fare in modo che il secondario raccolga più possibile del primario che tipicamente si ottiene facendo in modo che il primario ed il secondario abbiano le stesse dimensioni oppure facendoli lavorare per **risonanza**.
Anche qui occorre fare i conti con le normative di esposizione

5.1.1 Accoppiamento induttivo risonante

Uno dei modi è quindi fare un'accoppiamento induttivo risonante: si deve a Telsa, alla risonanza si ha tipicamente un massimo trasferimento di potenza (o quanto meno di stimolo).

Per far risonare i due sistemi occorre, innanzitutto fare in modo che il tx sia risonante: occorre agire sulle dimensioni in modo che la parte immaginaria x sia pari a 0.

Sull'RX c'è poco margine, se abbiamo un loop piccolo e ne vediamo la reattanza in ingresso X_{in} se $2\pi B \parallel x$ allora la reattanza sarà induttiva, ovvero > 0 e si comporterà come un circuito.

Ci sarà poi il carico del dispositivo, ovvero qualcosa che gli permetta di utilizzare l'energia, occorre aggiungere un condensatore che può essere messo sia in serie che in parallelo.

Avremo quindi il coil trasmittente e possiamo mettere in risonanza sia tramite un condensatore in serie oppure con un condensatore in parallelo entrambe danno la stessa potenza sul carico ma

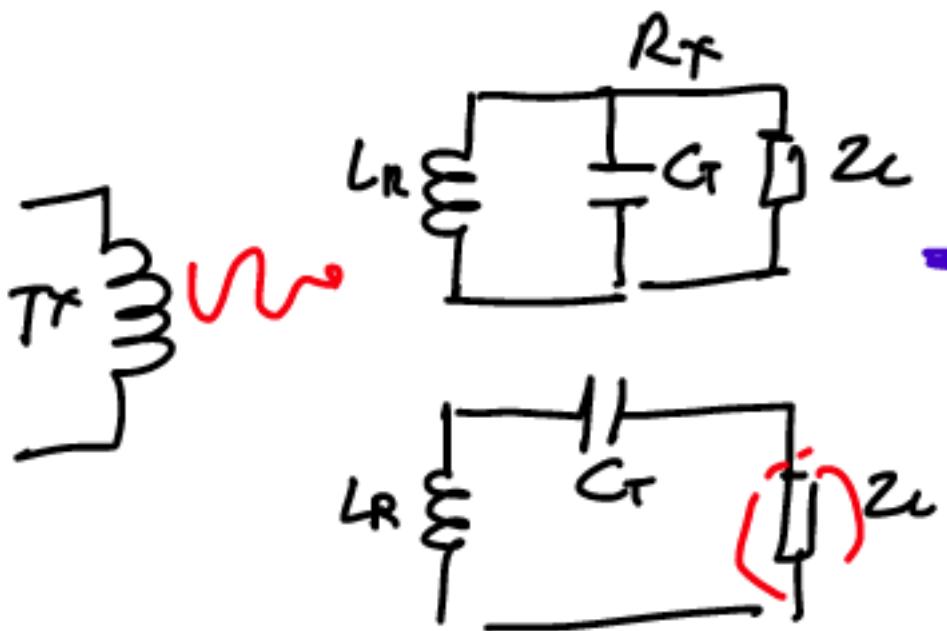


Figura 5.6: Condensatore in parallelo o in serie per il ricevente

cambiano i valori mutui di corrente e di tensione:

- lo schema in parallelo darà corrente bassa e tensione elevata
- lo schema in serie il contrario tipicamente si sceglie il parallelo: dopo il carico, c'è tipicamente un rettificatore AC→DC e poi deve esserci un convertitore da corrente alternata a corrente continua per alimentare la circuiteria digitale (l'elettronica).

Questo tipo di dispositivo lavora meglio con alte tensioni, quindi si preferisce usare uno schema parallelo.

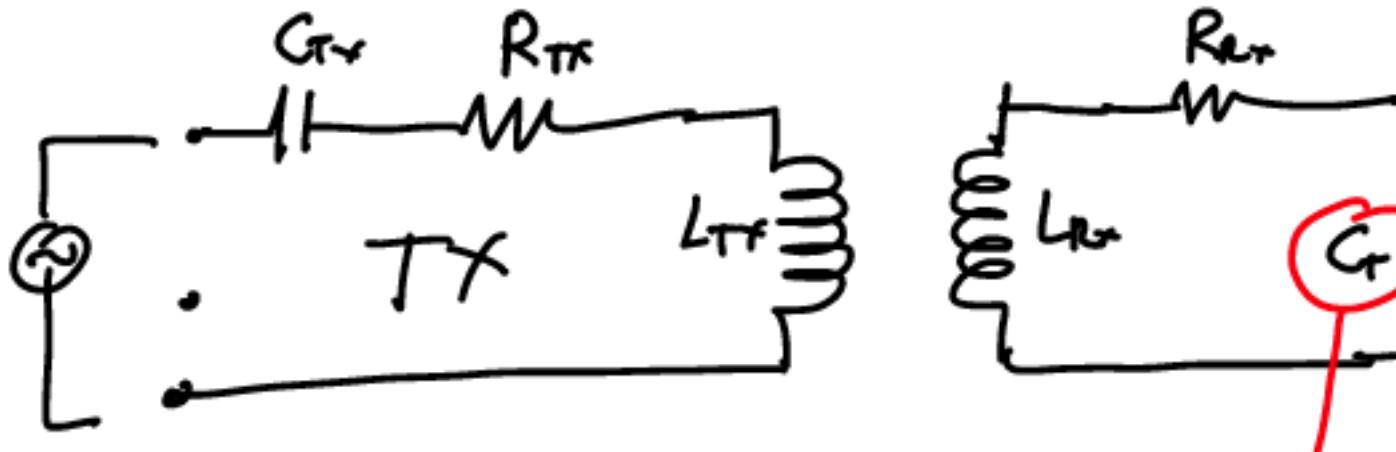


Figura 5.7: Schema circuitale di TX ed RX

Abbiamo quindi il nostro modello circuitale TX ed RX: dove nel ricevitore C_T è il condensatore di tuning. La C_T va scelta in modo tale che

$$f_0 = \frac{1}{2\pi\sqrt{L_{R_x} \cdot C_T}} \quad (5.15)$$

Abbiamo trovato che

$$V_2 = -N_2 \frac{d}{dt} \iint_R \underline{B} ds \quad (5.16)$$

passando al dominio dei fasori, sappiamo che $\frac{d}{dt} = j\omega$ ed abbiamo quindi

$$V_2 = -N_2 j\omega B_0 S_{RX} \cos \alpha Q_{RX} \quad (5.17)$$

in più compare il fattore di qualità Q del ricevitore, dove è definito come

$$Q_{RX} = \omega \frac{\Xi_{RX}}{P_{j,RX}} \quad (5.18)$$

Più Q è elevato e meno potenza dissipata ci sarà e quindi più quella che viene immagazzinata. Per fare quindi in modo che aumenti V_2 occorre avere un fattore di qualità elevato che si ha quando il sistema è risonante, ancora di più se in parallelo.

Avere un Q elevato comporta una criticità operativa, ovvero la banda è stretta in quanto la larghezza di banda è

$$B \propto \frac{1}{Q} \quad (5.19)$$

(quanto più è alto il fattore di qualità tanto più c'è sensibilità a spostamenti dalla frequenza di lavoro).

Con la V_2 , quando questa è maggiore di una tensione di threshold che è connesso al coil primario, il secondario si accende e comincia a funzionare, quindi V_2 deve essere $> V_{th}$ e fissata la distanza sappiamo quali sono il fattore di qualità da avere etc... che sono valori minimi.

Un parametro di performance che ci interessa è la **PTE (Power Transfer Efficiency)**, definita come

$$PTE = \frac{P_L}{P_{in}} \quad (5.20)$$

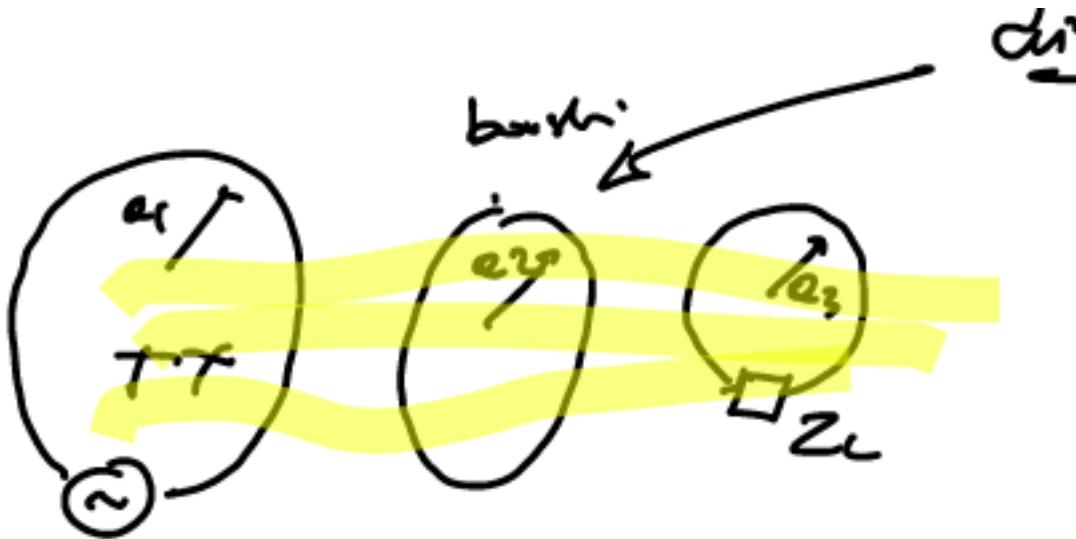


Figura 5.8: Sistema con coil booster

quindi la

$$(1 - PTE)P_{in} \quad (5.21)$$

è quella persa.

È stato trovato che la PTE è data da:

$$PTE = \left[1 + \frac{1}{q} + \frac{1}{M^2 Q_{TX} + Q_{RX}} \left(2 + q + \frac{1}{q} \right) \right]^{-1} \quad (5.22)$$

IMPORTANTE: QUESTO GROSSO GOAT DI MARROCCO TI FA PORTARE IL FORMULARIO (KING)), dove q è dato da:

$$q = \sqrt{\frac{1 + M^2 \cdot Q_{TX} \cdot Q_{RX}}{1 + M^2 \cdot Q_{TX} Q_{RX}^{-1}}} \quad (5.23)$$

e vale per un circuito risonante parallelo.

Nota importante: a frequenza basse (dove siamo) le perdite dei tessuti sono basse, cioè la condutività σ (legata alle perdite) è piccola. Siamo nell'ordine dei 100KHz e contano quasi più le perdite sui conduttori che sul tessuto.

Tipicamente quindi i due coil conviene farli di dimensioni simili in modo che buona parte del campo B prodotto dal primario viene raccolto dal secondario, in alcuni casi però non è possibile farli simili perché magari un coil ricevente deve poter raccogliere più coil tx, quindi è possibile usare un coil booster:

il booster ha dimensioni intermedie fra i due, è a corto circuito ed ha l'effetto di ridirezionare il flusso verso coil più piccoli.

Funziona come un **direttore di antenna**, in modo che se il coil è piccolo ed in un posto difficilmente raggiungibile possiamo usare un coil intermedio in modo che venga ridirezionato il flusso fino a dove serve.

5.1.2 Criticità

Principalmente legata la disallineamento: immaginiamo di avere la classica stratificazione, col dispositivo IMD (copia disegno)

l'ideale sarebbe avere il coil che trasmette in un certo punto, ma una volta impiantato non posso più vederlo, per cui se abbiamo un disallineamento non concateno più il massimo del campo e quindi avremo un notevole decadimento delle prestazioni.

Una soluzione è porre dei magneti con opportune polarità in modo che il campo prodotto di polarizzazione fra i due magneti vada a far allineare i coil, quindi si possono impiantare dei micromagneti sotto pelle sia sul tx che sull'rx

Altra criticità è la flessibilità: in molte applicazioni, soprattutto quando il dispositivo deve aderire a delle protesi o a degli organi, viene realizzato con un'elettronica flessibile, si può realizzare su delle membrane.

Immaginiamo di avere il coil "spalmato" su qualcosa che può flettersi, ma questo provoca un cambiante nella forma che provoca un detuning: cambia il fattore di qualità e si abbassa la tensione raccolta.

L'oggetto va quindi progettato a priori per quelle condizioni.

Ultimo punto, riguarda i materiali. Essendo a frequenze basse, le perdite sui conduttori pesano e quindi servono conduttori con perdite basse come il rame, che però non è biocompatibile. Oggetti biocompatibili sono il titanio, che non è però un buon conduttore (1.5 ordini in meno del rame) e quindi tende ad avere perdite maggiori.

Si può usare il rame andando a fare un coating, ovvero un rivestimento del conduttore di rame con materiale biocompatibile, come ad esempio

- silicone
- materiali ceramici, che vanno bene per dispositivi solidi
- poliammide (PEEK il più usato, polimero semi cristallino), sono polimeri ovvero materiali fatti da tanti monomi agglomerati che formano una matrice molto solida
- zirconia

5.1.3 Comunicazione del ricevitore col trasmettitore (modulazione capacitiva)

Per la comunicazione inversa si può usare un link simmetrico, quindi si invertono le parti oppure si usa un link asimmetrico (come si tende a fare sempre di più) cioè il ricevitore va a modificare l'accoppiamento col trasmettitore ovvero fa quella che si chiama una **modulazione capacitiva**: si fa in modo che il sensore vada con una logica binaria a modificare l'accoppiamento col primario così che questo si renda conto che qualcosa sta irradiando dall'altro lato.

Consideriamo il circuito di prima:

abbiamo poi un altro pezzo, una scatola dove troviamo un altro condensatore che si può connettere / sconnettere con interruttore (sarà il condensatore di modulazione) e quindi sarà il blocco che esegue tale modulazione, sarà un circuito integrato.

Lo switch ha due stati, 0 o 1 (chiuso aperto) ed in base a questo il V_1 vedrà una cosa o un'altra:

- switch open: bit '0', V_1 sarà dato (risolvendo il circuito) nel dominio dei fasori

$$V_1 = \frac{1}{j\omega G_X} I_1 + j\omega L_{TX} I_1 + R_{TX} I_1 - j\omega M I_2^{(0)} \quad (5.24)$$

e dove la frequenza è pari alla frequenza di risonanza

$$f_0 = \frac{1}{2\pi\sqrt{L_{RX} \cdot C_T}} \quad (5.25)$$

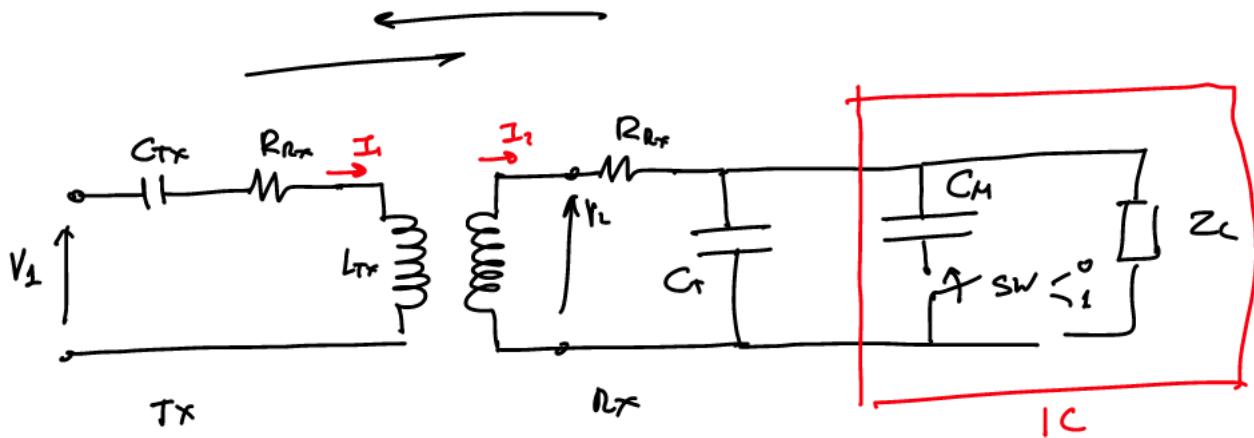


Figura 5.9: Schema per la modulazione capacitiva

abbiamo poi che il circuito è risonante e quindi il valore visto è alto, perché l'accoppiamento è forte.

Ripuliamo quindi i termini reattivi in quanto siamo in risonanza ottenendo

$$V_1^{(0)} = R_{TX}I_1 - j\omega M I_2^{(0)} \quad (5.26)$$

- switch close: bit '1', abbiamo la somma dei due condensatori, di tuning e di modulazione e quindi avremo una f_1 diverso dalla frequenza di risonanza:

$$f_1 = \frac{1}{2\pi\sqrt{L_{RX}(C_T + C_M)}} \neq f_0 \quad (5.27)$$

I due coil quindi non si parlano bene perché non sono in risonanza e quindi la V_1 vista dal primario sarà bassa

$$V_1^{(1)} = R_{TX}I_1 - j\omega M I_2^{(1)} \quad (5.28)$$

governando lo switch secondo elettronica digitale (apri/chiudi) facciamo in modo che V_1 sia modulato in ampiezza in quindi ottenere una situazione di questo tipo: vogliamo mandare questa stringa, sul writer si vedrà un qualcosa del genere:

dove abbiamo il segnale modulato in ampiezza.

Questo è il sistema con cui funzionano i sistemi NFC.

È il primo collegamento in campo vicino visto, usato sia in ambito medico che anche in campo logistico, basato su coil:

- patenti
- codice fiscale

tutto funziona esattamente così.




Figura 5.10: Segnale di risposta del ricevente

Capitolo 6

Lezione 6

6.1 Near-field: link capacitivi

Sono dei link meno usati degli altri ma hanno dei risvolti interessanti. Lavorano a frequenze un po' più alte, sui pochi MHz, ma se le dimensioni sono piccole si può anche arrivare al GHz. Immaginiamo un condensatore a facce piane e parallele, immaginiamo che sia alimentato da un generatore

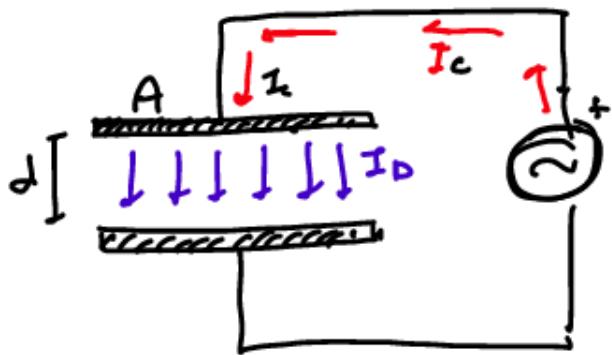


Figura 6.1: Esempio di circuito

la corrente gira sul filo, il circuito ha un interruzione ma la corrente circola poiché viene generata una corrente di spostamento fra le facce del condensatore (legata al campo che si propaga e che carica il condensatore).

La I_d sarà

$$\epsilon_0 \epsilon_r A \frac{\partial E}{\partial t} \quad (6.1)$$

oppure nel dominio dei fasori

$$j\omega \epsilon_0 \epsilon_r A \underline{E} \quad (6.2)$$

Possiamo immaginare di avere il condensatore a cavallo del corpo umano, così, da poter mandare un'informazione alla piastra dentro.

Si divide il condensatore a metà, su ogni faccia di esso, collegandola come segue le correnti faranno lo stesso giro di prima, abbiamo quindi due oggetti separati:

- il primo è fatto con le due metà della prima faccia, sarà il tx
- il secondo è fatto dalle due metà dell'altra, sarà per noi il rx

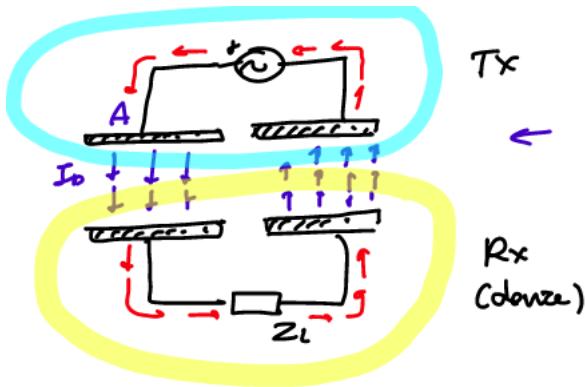


Figura 6.2: Divisione del circuito

il dispositivo deve quindi avere due elettrodi belli larghi che userà per accoppiarsi elettrostaticamente con i due elettrodi del ricevente.

L'accoppiamento come detto è principalmente elettrostatico, quindi domina il campo E .

Occorre però fare attenzione: fra le due coppie di armature non abbiamo solo la corrente di spo-

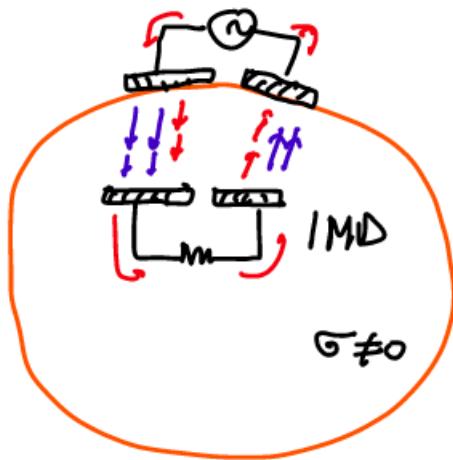


Figura 6.3:

stamento, il mezzo corporeo ha una conducibilità $\neq 0$, quindi ci saranno anche delle correnti di conduzione che sono legate al fatto che il materiale permette di spostare anche elettroni.

Nuovamente ci sono due fenomeni contrastanti:

- propagazione, legato alle correnti di spostamento;
- dissipazione, legato alle correnti di conduzione.

Cerchiamo di caratterizzare le due entità:

- $I_d = \epsilon_0 \epsilon_r A \frac{\partial E}{\partial t}$
- la corrente di conduzione è data dalla legge di Ohm: abbiamo il body

la resistenza del blocchetto è $R = \frac{1}{\sigma} \frac{d}{A}$, quindi $I_c = \frac{V \sigma(\omega) A}{d}$

come facciamo ad enfatizzare la corrente di spostamento:

- se aumentiamo il campo E :

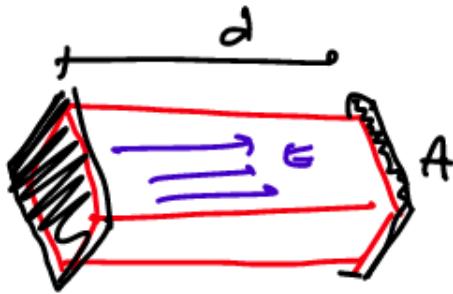


Figura 6.4: Rappresentazione di un blocchetto di corpo

- possiamo aumentare la V_0 del generatore, ma se il campo aumenta dobbiamo fare attenzione ai limiti di esposizione
- ridurre d , ovvero la distanza fra le due armature così che il campo sia più intenso. Ma ci sono delle limitazioni legate all'installazione
- aumentare l'area A delle placche (degli elettrodi), anche qui un punto di attenzione è l'ingombro per dispositivi impiantati
- incrementare la frequenza, poiché la I_d pro a $j\omega$ (che è la derivata rispetto al tempo nel campo dei fasori), ma l'aspetto critico sono le perdite nei tessuti

Per ridurre la I_c occorre fare l'opposto di quello che si faceva prima:

- ridurre l'area A , ma si riduce anche la I_d
- ridurre la tensione di eccitazione del condensatore ma di nuovo si riduce anche l'altra

come sempre va trovato il compromesso in base all'applicazione, occorre effettuare una trade off analysis delle cose.

6.1.1 PTE (Power Transfer Efficiency) e SAR

Per analizzare la PTE si fa un circuito equivalente tenendo conto che ora le perdite nei tessuti non sono così trascurabili (verso i MHz le perdite sui tessuti sono più importanti di quelle sui conduttori). Facciamo quindi questo circuitino equivalente

(ogni resistenza fa riferimento alle perdite!!): il filo è approssimabile bene con l'induttanza in genere, possiamo assumere che le $R_C \ll R_T$. C'è una formula che dice che la PTE (rapporto fra la potenza rilasciata sul carico e la potenza in ingresso) è

$$PTE = \frac{R_L}{R_L + R_T} (1 - |\gamma|^2) \quad (6.3)$$

e stesso vale per

$$R_T = R_L \left[\frac{d}{A \epsilon_0 \epsilon_r} \right] \quad (6.4)$$

Quindi la PTE complessivamente aumenta se:

- aumenta la A
- diminuisce la d

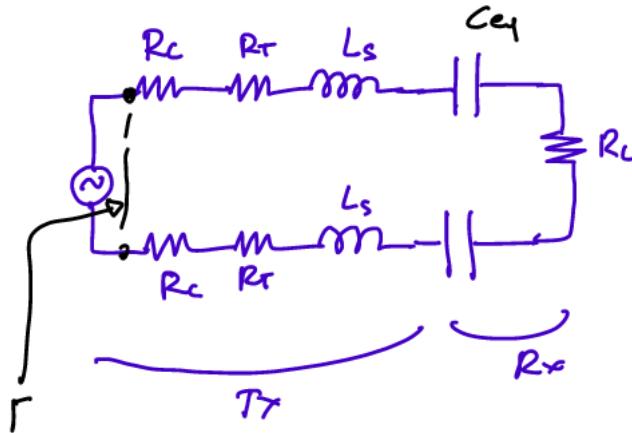


Figura 6.5: Circuito equivalente

quindi elettrodi larghi e dispositivi molto vicini.

Vediamo come è correlata la massima potenza di tx immissibile nel dispositivo rispetto al SAR:

sappiamo che il SAR è limitato: $SAR_{max} = \begin{cases} 2 \frac{W}{kg} & \text{per testa e addome} \\ 4 \frac{W}{kg} & \text{per testa e addome} \end{cases}$ negli arti

alla potenza massima:

$$PTE = \frac{P_L}{P_{TX}} \quad (6.5)$$

considerando

$$P_{TX}(1 - PTE) \quad (6.6)$$

questa è la potenza che viene dissipata nel corpo, ovvero la P_j , quindi $PTE * P_{TX}$ è proprio la potenza ceduta al corpo mentre quella dissipata è l'altra.

Consideriamo 10g di tessuto:

$P_j(10g) = \int \int_{10gr} SAR dm$, ammettendo il SAR costante perché il volume è piccolo, possiamo ottenere $SAR * 10^{-2} \text{ W}$, quindi $P_j max(10gr) = SAR_{max} 10^{-2} \text{ W}$ che è la massima potenza che si può rilasciare in una massa di 10g.

Facciamo un'ipotesi brutale: immaginiamo che tutta la potenza venga rilasciata in un paio di cubetti di 10gr, quindi la max potenza rilasciabile in 20g è: $2 * 10^{-2} SAR_{max}$ che è molto conservativa come ipotesi perché la potenza viene distribuita su un volume maggiore.

Allora la $P_j max(20g) = P_{TX}(1 - PTE)$ da cui la $P_{TX max} = 2 * 10^{-2} SAR_{max} / (1 - PTE)$, quindi se il SAR è $2 \frac{W}{kg}$ otteniamo un $P_{j max} = \frac{0.04}{1 - PTE} W$, nella testa ed addome, mentre negli altri avremmo $\frac{0.08}{1 - PTE} W$.

Quindi se la PTE fosse il 50%, ma in realtà tipicamente è molto più bassa, avremmo circa 0.1W di P_{TX} che può suonare bene (da quindi un'ordine di grandezza di riferimento).

6.1.2 Criticità

La criticità è simile a quella dell'accoppiamento induttivo ovvero i disaccoppiamenti, i due condensatori tendono a chiudere meno bene le correnti è c'è una perdita di efficienza di trasferimento.

Il campo lavora su delle discontinuità, quindi nel grasso come ricordiamo (è poco vascolarizzato) c'è maggiore (vedi sopra).

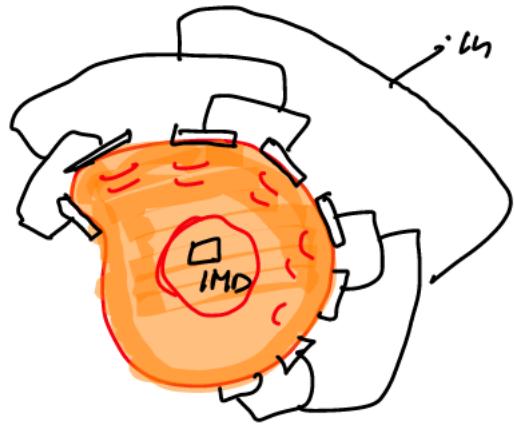


Figura 6.6: Disposizione di vari dispositivi impiantati sul corpo

6.2 Link nel mid-field

Fin ora abbiamo visto link a frequenze molto basse, aumentandola i dispositivi sono più lontani e non si può più approssimare ad elettrostatico o magnetostatico, siamo quindi nel midfield (regione di Fresnell, non siamo così lontani).

Quando siamo a frequenze maggiori del GHz, e tipicamente più piccole dei 3GHz le perdite del corpo sono più alte, quindi σ_{body} è più alta ma ci spostiamo qui perché se la frequenza è più elevata:

- c'è un vantaggio nel bitrate, posso trasmettere informazioni più velocemente
- gli oggetti possono diventare elettricamente più grandi e quindi possiamo usare anche più oggetti contemporaneamente e quindi usare degli array di trasmettitori nel corpo

RICHIAMO: ciò che comanda nel mondo delle antenne non è la lunghezza l del dispositivo ma la sua dimensione elettrica che è $\frac{l}{\lambda}$ e la lunghezza d'onda nel vuoto è λ_0 ma in un mezzo con perdite è $\lambda_0/\sqrt{\epsilon_r}$ e quindi se abbiamo aria e sotto un mezzo biologico, se arriva un'onda con una certa λ_0 , quando entra nel mezzo la lunghezza d'onda diminuisce perché viene divisa per il valore di permittività del mezzo.

Quindi all'aumentare della frequenza, siccome $\lambda_0 = \frac{c}{f}$ la lunghezza fisica del dispositivo è

$$L_e = \frac{L}{C} f \sqrt{\epsilon_r} \quad (6.7)$$

quindi abbiamo un dispositivo elettricamente più grande pur rimanendo piccolo, quindi abbiamo un maggiore controllo sul campo EM irradiato.

La lunghezza EM è

$$L_e \propto f \sqrt{\epsilon_r} \quad (6.8)$$

e la frequenza migliore si ha per 1GHz, ovvero l'efficienza di un'antennina impiantata anche tenendo conto delle perdite è quella ottimale e vale nell'ipotesi in cui $D_{IMD} > 1\text{cm}$ e si ottiene la frequenza alla quale l'oggetto impiantato risulta efficiente come antenna.

Abbiamo come altro vantaggio di poter usare più di un dispositivo:

possiamo usare vari tipi di trasmettitori all'esterno che, siccome la frequenza è elevata, sono geometricamente piccoli ma elettricamente più grandi.

Possiamo quindi collegarli con una rete di fascio, mandano un segnale in ingresso posso far sì che

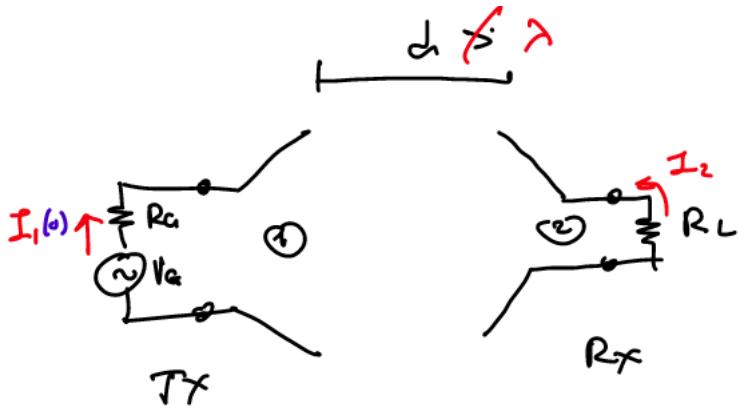


Figura 6.7: Rappresentazione di un'antenna come rete a due porte

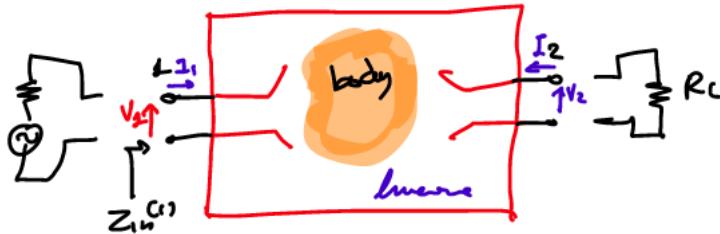


Figura 6.8: Rappresentazione dell'antenna come una "scatola chiusa"

ciascuno irradia un campo solo nel punto dove serve, quindi per focalizzare l'interrogazione in una piccola regione e si può fare perché gli oggetti sono piccoli geometricamente ma grandi (e quindi posso farli risonanti) elettricamente.

Il vantaggio è che ognuno produrrà un SAR più basso, riuscendo quindi a rimanere entro i limiti delle normative.

I conti sono complicati, non possiamo usare i concetti di guadagno delle antenne etc... quindi si introduce un modo di lavorare che non necessita approssimazione ma si rinuncia al rappresentare tutti i fenomeni: introduciamo il **guadagno di trasduzione**

6.2.1 Guadagno di trasduzione (Transducer Power Gain)

Il guadagno di trasduzione tiene conto di vari fatti ed è specifico per una configurazione particolare. Per ottenerlo, dobbiamo rappresentare l'antenna come una rete a due porte: immaginiamo di avere due antenne una che tx ed una che rx

le antenne sono vicine, la distanza d non è più grande di λ e quindi c'è disturbo.

Occorrerebbe fare un calcolo del campo e della tensione raccolta, ma ci interessa analizzare il link di comunicazione, quindi che succede sul carico del ricevitore quando alimentiamo il trasmettitore: immaginiamo di rappresentare tutto come una scatola che verrà analizzata solo ai morsetti

guardando quindi tensione V_1 e corrente, che consideriamo entrante nella rete I_1 e le V_2 ed I_2 . Non perdiamo nulla perché dipendono dalle interazioni EM che stanno "dentro la scatola", che sono le osservabili.

Consideriamo che il sistema sia lineare, possiamo immaginare che la tensione che vediamo ad una



Figura 6.9: Ricevente chiuso in corto circuito

porta sia $V_1 = I_1$, guarderemo il seguente sistema: $\begin{cases} V_1 = I_1(0)Z_{11} + Z_{12}I_2 \\ V_2 = I_1(0)Z_{21} + Z_{22}I_2 \end{cases}$ la corrente viene considerata sul punto di alimentazione, da cui la valutazione in 0 (ma la corrente tipicamente scorre ovunque).

I coefficienti Z sono la **matrice di impedenza**

$$\begin{bmatrix} Z_{11} & Z_{12} \\ Z_{21} & Z_{22} \end{bmatrix} = [Z]$$

dove i coefficienti sulla diagonale corrispondono al caso in cui si misura la corrente sulla porta 1 quando la porta 2 è in circuito aperto e viceversa, ovvero:

$$Z_{ii} = \left. \frac{V_i}{I_i} \right|_{I_j=0} \quad (6.9)$$

Gli altri due coefficienti sono uguali se la rete è **reciproca**:

$$Z_{ij} = Z_{ji} = \left. \frac{V_i}{I_j} \right|_{I_i=0} \quad (6.10)$$

ed sono l'**impedenza mutua** ed è il termine che da l'accoppiamento fra le due porte. L'impedenza in ingresso alla porta 1 si esprime come

$$Z_{in}^{(1)} = \frac{V_1}{I_1} = Z_{11} + Z_{12} \frac{I_2}{I_1} \quad (6.11)$$

quindi la dipendenza è mediante il termine di impedenza mutua che da l'accoppiamento, e vale anche il viceversa

$$Z_{in}^{(2)} = \frac{V_2}{I_2} = Z_{22} + Z_{21} \frac{I_1}{I_2} \quad (6.12)$$

Immaginiamo alcuni casi

1) L'antenna rx è chiusa in corto circuito

L'impedenza che vedo è $Z_{in}^{(1)}$, se $V_2 = 0$ possiamo calcolare

$$\frac{I_2}{I_1} = -\frac{Z_{21}}{Z_{22}} \quad (6.13)$$

e quindi avere

$$Z_{in}^{(1)} = Z_{11} - \frac{Z_{12} \cdot Z_{21}}{Z_{22}} = Z_{11} - \frac{Z_{12}^2}{Z_{22}} \quad (6.14)$$

Quando questo avviene l'oggetto alimentato è fortemente infastidito dalla presenza dell'oggetto non alimentato



Figura 6.10: Antenna ricevente in circuito aperto

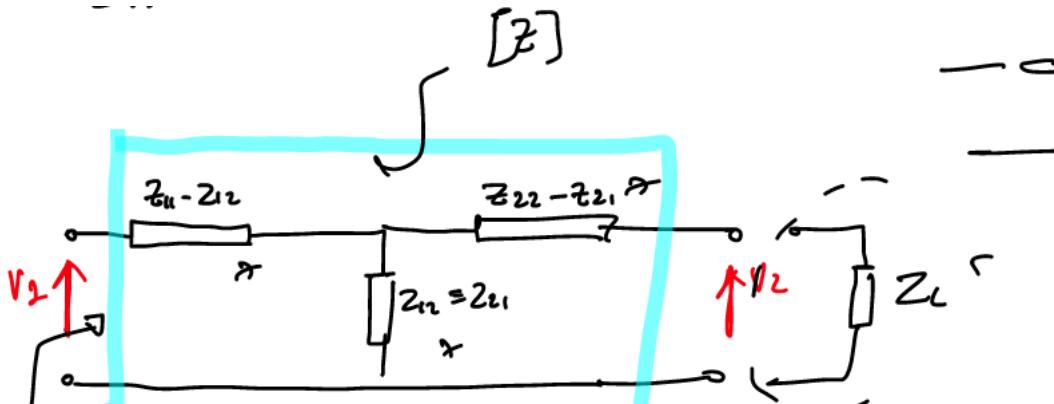


Figura 6.11: Rete "a T" equivalente alla rete a due porte

2) L'antenna rx è in circuito aperto: la configurazione è la seguente

avremo $I_2 = 0$ e vediamo la $Z_{in}^{(1)}$, dall'espressione di prima viene cancellato un termine e quindi

$$Z_{in}^{(1)} = Z_{11} \quad (6.15)$$

e possiamo dire che l'impedenza in ingresso sia simile a quella dell'antenna se fosse isolata. Normalmente in queste condizioni l'antenna tx risente poco della rx (a meno che questa non sia molto grande). **IMPORTANTE: la Z_{11} NON rappresenta l'impedenza dell'antenna isolata, ma è molto simile soprattutto se l'antenna ricevente è piccola.**

3) Il caso più generale è quando RX è collegato ad un carico Z_L , $Z_{in}^{(1)}$ si ricava in quanto esistono diverse rappresentazioni circuitali:

- a π ;
- a T

che hanno le stesse relazioni di grandezze in uscita di una rete a due porte, è dimostrabile (**ma io credo al prof sulla parola**).

La rete più semplice è quella a T, una rete a T che ha la stessa matrice di impedenza di una rete a due porte ha questi valori:

calcolando l'impedenza in ingresso $Z_{in}^{(1)}$ corrisponde a quella di una rete a due porte. Si può fare risolvendo il circuito (che viene lasciato per esercizio?) ottenendo

$$Z_{in}^{(1)} = Z_{11} - \frac{Z_{12}^2}{Z_{22} - Z_L} \quad (6.16)$$

Se nell'antenna da sola bastava la Z in ingresso qui serve la matrice Z, e questo si chiama

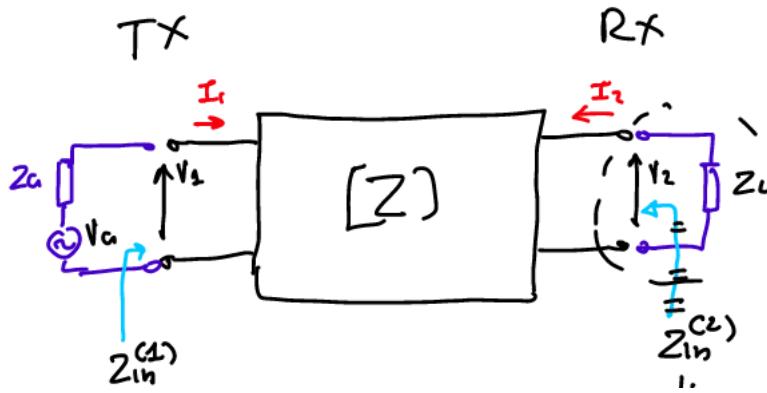


Figura 6.12: Rete a due porte con matrice d'impedenza

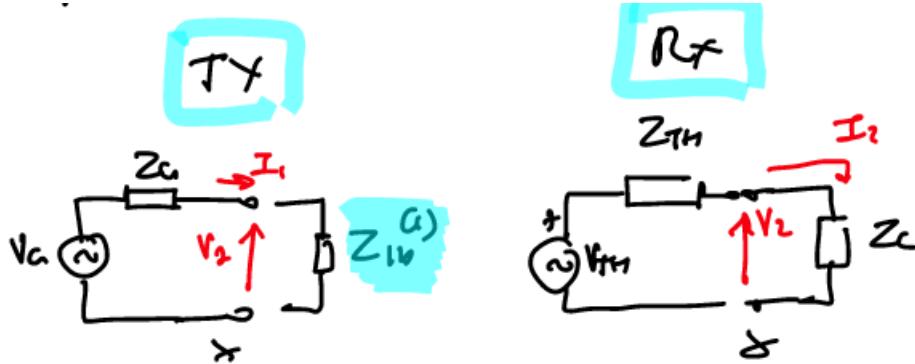


Figura 6.13: Equivalenza di Thevenin per rx e tx

impedenza passiva, tiene conto dell'altro oggetto ma non alimentato (se fosse alimentato ci vorrebbe l'impedenza attiva e sarebbe più complesso).

Vogliamo esprimere la potenza che viene raccolta dal carico del rx rispetto a quella che viene mandata in ingresso ed (altro) ed introduciamo il guadagno di trasduzione.

Ripartiamo dalla rete a due porte, che rappresentiamo con la matrice di impedenza

possiamo quindi vedere le impedenze in ingresso alle diverse porte del tx e dell'rx, sappiamo che sono date da:

$$Z_{11}^{(1)} = Z_{11} - \frac{Z_{12}^2}{Z_{22} + Z_L} \quad (6.17)$$

e

$$Z_{22}^{(2)} = Z_{11} - \frac{Z_{12}^2}{Z_{11} + Z_G} \quad (6.18)$$

Vediamo l'equivalenza di Thevenin:

guardando da sinistra, un'osservatore vedrà tutto quello che accade dentro dal valore di $Z_{11}^{(1)}$ e questo è per il tx, mentre per l'rx: ci saranno impedenza di Thevenin e generatore di Thevenin che vanno calcolate.

Possiamo quindi studiarli separatamente, nel secondo valuteremo la potenza che verrà distribuita sul carico.

Partiamo dalla Z_{th} che è l'impedenza passiva che vediamo verso l'interno avendo staccato il genera-

tore, quindi è uguale all'impedenza di ingresso che avremmo calcolato con il circuito attivo

$$Z_{Th} = Z_{in}^{(2)} \quad (6.19)$$

La tensione del generatore è data dal fatto che il circuito è aperto, riprendiamo l'espressione di V_2 circuitale

$$V_2 = Z_{21}I_1 \quad (6.20)$$

in quanto il termine con I_2 è 0 perché i circuiti sono staccati.

Esplicitiamo

$$V_1 = V_{C1} - Z_G I_1 \equiv Z_{11} I_1 + Z_{12} I_2 \Big|_{I_2=0} \quad (6.21)$$

sapendo che $I_2 = 0$ avremo

$$I_1 = \frac{Z_G}{Z_{11} + Z_G} \quad (6.22)$$

Inseriamo l'espressione trovata per trovare la

$$V_{Th} = V_2 = \frac{Z_{21}}{Z_{11} + Z_G} V_G \quad (6.23)$$

Ora possiamo usare i due circuiti per fare delle considerazioni di potenza: consideriamo 2 potenze

- P_L , che il trasmettitore rilascia al carico del ricevitore.

È data da

$$P_L = \frac{1}{2} R_L |I_2|^2 \quad (6.24)$$

è quella che serve al dispositivo impiantato per farlo funzionare. La I_2 si ricava da

$$I_2 = \frac{V_{Th}}{Z_{in} + Z_L} \quad (6.25)$$

quindi

$$P_L = \frac{1}{2} \frac{|Z_{21}|^2 |V_G|^2 R_L}{|Z_{11} + Z_G|^2} \frac{1}{|Z_{22} - \frac{(Z_{21}^2)}{Z_{11} + Z_G} + Z_L|^2} = \frac{1}{2} \frac{|Z_{12}|^2 |V_G|^2 R_L}{|(Z_{11} + Z_G)(Z_{22} + Z_L) - Z_{12}^2|^2} \quad (6.26)$$

- $P_{in}^{(1)}$ che è quella che entra nell'antenna trasmittente data da

$$P_{in}^{(1)} = \frac{1}{2} R_{in}^{(1)} |I_1|^2 \quad (6.27)$$

In particolare

$$P_{in}^{(1)} = \frac{1}{2} R_{in}^{(1)} \frac{|V_G|^2}{|Z_{11} + Z_G|^2} \quad (6.28)$$

Definiamo ora la **potenza disponibile** in ingresso (available power) che è la $P_{AV,G}$ che è la massima potenza che il generatore può erogare verso la rete e che viene erogata nelle condizioni in cui l'impedenza delle rete è il complesso coniugato dell'impedenza del condensatore

$$Z_{in}^{(G)} = Z_G^* \quad (6.29)$$

(adattamento coniugato, $R_{in}^{(1)} = R_G$ e $X_{in}^{(1)} = -X_G$) quindi

$$P_{AV,G} = \frac{|V_G|^2}{8R_G} \quad (6.30)$$

Qualcosa del genere si fa in uscita ed è la **network available power**, che è la massima potenza che la rete è in grado di rilasciare al carico e si ha la massima quando l'impedenza in ingresso in 2 è uguale al complesso coniugato della Z_L .

Vale

$$P_{AV,N} = \max PL = \frac{|V_{Th}^{hev}|^2}{8R_{Th}} \quad (6.31)$$

Definiamo finalmente il G_T (transducer power gain) uguale per definizione a

$$G_T \triangleq \frac{P_L}{P_{AV,G}} \quad (6.32)$$

ed è importantissima perché dipende dal fatto che rx non è adattato al carico, che c'è un mezzo con perdita etc... e la dobbiamo ottimizzare perché sappiamo che

$$P_L = P_{AV,G}G_T \quad (6.33)$$

sostituendo nella precedente viene fuori la relazione

$$G_T = \frac{4R_G R_L |Z_{12}|}{|(Z_{11} + Z_G)(Z_{22} + Z_L) - Z_{12}^2|^2} \quad (6.34)$$

(che è adimensionale essendo un guadagno). (N.B: la X è la reattanza). È la grandezza da tenere in conto quando si progetta il sistema.

Capitolo 7

Lezione 7

7.1 Ancora sul guadagno di trasduzione

Possiamo scrivere la potenza che finisce sul carico P_L , che è quella che serve al dispositivo se non ha una batteria per accendersi come

$$P_L \equiv P_{R \rightarrow T} P_{AV,G} G_T \quad (7.1)$$

(il pedice T indica il transponder) dove G_T è specifica della configurazione, quindi se ad esempio ruoto un dispositivo rispetto all'altro devo ricalcolare il guadagno di trasduzione.

In ingegneria è solito calcolare il margine, che è **ciò che permette di dormire la notte**, ovvero avere della capacità in più per le evenienze: p_0 è la minima potenza da rilasciare sul carico tale per cui il ricevitore funziona, ovvero la $\min\{P_L\}$, il margine in scala lineare è

$$M = \frac{P_L}{p_0} \quad (7.2)$$

dove p_0 è la power sensitivity.

Se la quantità è < 1 stiamo rilasciando una potenza più piccola di quella che serve al dispositivo per funzionare, quindi non avremo il link, mentre più è maggiore di 1 e più il link è robusto.

Normalmente si rappresenta in DB:

$$M_{db} = P_{AV,G} + G_T - p_0 - M_0 \quad (7.3)$$

dove M_0 è un margine aggiuntivo che cerca di tenere conto di eventuali difetti fisici dell'oggetto per cui conta che viene mantenuta della potenza in più.

Il radio collegamento si stabilisce quando $M_{db} > 0$, quindi più è grande più si compensano fenomeni di cui non si era tenuto conto durante il progetto.

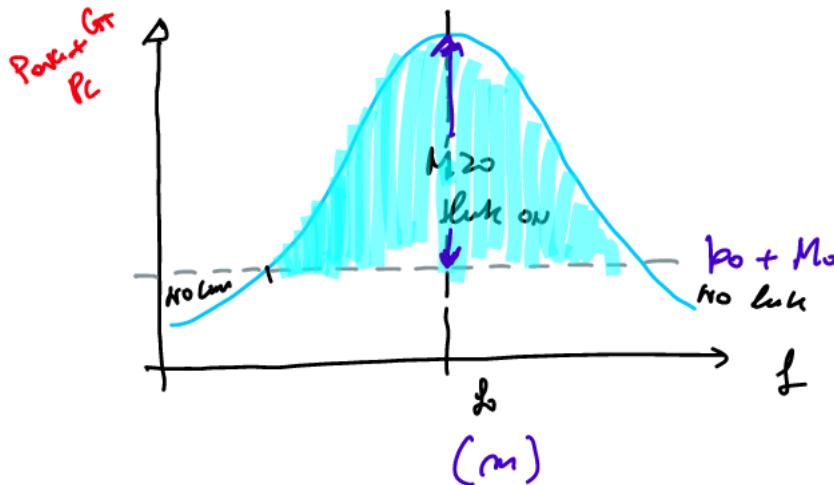
Con margine pari a 0 ce dice bene se funziona na volta sola a culo, mentre invece con della potenza di riserva c'è una sicurezza maggiore.

esempio:

la linea rappresenta la sensitivity + margine aggiuntivo, quindi dire che $M_{db} > 0$ vuol dire che $P_{AV,G} + G_T > p_0 + M_0$. Se abbiamo progettato bene il dispositivo il picco sarà sulla frequenza di lavoro f_0 , avremo quindi una regione dove c'è il collegamento ed una dove non c'è.

Il grafico si fa spesso rispetto anche ad un parametro di progetto, come ad esempio la dimensione, la freccia viola indica quanto si è sicuri che il dispositivo sia robusto rispetto a delle cose che non si è riusciti a prevedere.

Fissata la potenza in ingresso (che è strettamente finita) occorre progettare i dispositivi al meglio possibile in modo che G_T sia elevato.



7.1.1 Guadagno di sistema

(Orfanidis, pdf free: libro di EM dove nel cp 5 c'è questa parte).

Il guadagno di sistema è definito come:

$$g = \frac{\max\{P_L\}}{\text{Potenza entrante nella rete}(P_{in})} = \frac{P_{av,in}}{P_{in}} \quad (7.4)$$

dove la massima P_L è quella che abbiamo chiamato la $P_{av,in}$.

Questa espressione differisce da quella di prima in quanto presuppone l'adattamento coniugato in ingresso ed in uscita, quindi è il caso migliore: se il transponder venisse progettato perfettamente adattato rispetto a ciò che vede in ingresso e l'interrogatore perfetto rispetto a ciò che arriva dall'esterno avrei questo massimo: per l'adattamento coniugato deve valere:

- $Z_{in}^{(1)} = Z_G^*$
- $Z_{in}^{(2)} = Z_L^*$

moltiplicando:

$$g \cdot P_{in} = P_{L,max} \quad (7.5)$$

otteniamo l'upper bound per il link.

Perché è importante: quando si fa un progetto, non si "spacca subito il capello" se magari ci sono molti parametri, quindi se il link va progettato secondo certe condizioni ci si chiede se occorre progettare l'antenna proprio così.

Posso assicurare che le due antenne riescano a comunicare? Quello che si fa è fare un design di massima senza preoccuparsi di adattare subito le antenne, ma messe in un certo modo nel caso migliore si riesce a tx una potenza sufficiente da poter fare accendere l'antenna rx? Allora controllo il guadagno di sistema, se mi ci trovo e quindi il margine è sufficiente per lavorare, allora penso a poter ottimizzare le antenne per poter lavorare.

Il calcolo si ottiene mettendo le espressione trovate prima:

$$g = \frac{\frac{1}{8} \frac{|V_{Th}|^2}{R_{Th}}}{\frac{1}{2} \frac{|Z_{12}|^2 R_L |V_G|^2}{|(Z_{11} + Z_G)(Z_{22} + Z_L) - Z_{12}^2|^2}} \quad (7.6)$$

Esiste poi un'espressione molto pulita se si fa riferimento alla **matrice di scattering**, "cugina" della matrice di impedenza, ovvero è una rappresentazione con un'onda di tensione che entra che è a_1 ed

	G[DB]
A	-15
B	-25

un'onda di tensione che torna indietro (l'onda riflessa dall'interfaccia) b_1 ed anche le a_2, a_2 dove V_1 e V_2 in funzione di A:

$$V_1 = \sqrt{Z_0}(a_1 + b_1) \quad (7.7)$$

$$V_2 = \sqrt{Z_0}(a_2 + b_2) \quad (7.8)$$

si può anche trovare una relazione matriciale, (Z_0 è l'impedenza di riferimento della linea. Tipicamente, se il carico non è complesso, sono 50Ω) e la matrice di scattering è tale per cui:

$$\begin{bmatrix} b_1 \\ b_2 \end{bmatrix} = \begin{bmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{bmatrix} \cdot \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} \quad (7.9)$$

per capirci l' S_{11} corrisponde al coefficiente di riflessione della porta 1 isolata dalla 2.

Otteniamo quindi un'espressione del guadagno di sistema:

$$g = \frac{|S_{21}|^2}{(1 - |S_{11}|^2)(1 - |S_{22}|^2)} \quad (7.10)$$

Esempio:

immaginiamo di avere un moncherino di un braccio, nel quale siano stati impiantati dei sensori miografici che raccolgono gli impulsi della mano che si apre/chiude (**perché il muscolo lo ricorda :O**). Immaginiamo di mettere due sensori A e B e sopra l'antenna TX

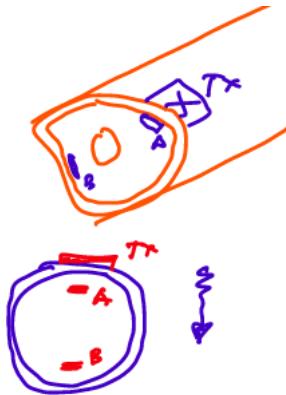


Figura 7.1: Sensori su moncherino (la seconda immagine è la vista in sezione)

si usano due sensori perché si acquisisce il segnale del muscolo agonista ed antagonista. I due dispositivi sono a differenti profondità rispetto al TX e quindi daranno guadagni di trasduzione diversi. Immaginiamo di aver calcolato i guadagni di trasduzione, troviamo questa situazione: $p_0 = -15dBm$, dove $x dBm = xdB - 30$, quindi se $1W = 0dB \rightarrow 1W = 30dBm$ ($1W = 1000\text{ mW}$) $M_0 = 3dB$, cerchiamo la $P_{av,G}$ per attivare il link fra i due dispositivi.

Abbiamo visto che $P_{av,G} + G_T > p_0 + M_0$, $P_{av,G} > -G_T + p_0 + M_0$. Riconduciamo alla stessa unità di misura poi:

A $P_{av,G} = -15dBm + 3dB + 15dB$. Portiamo tutto in dBm, riscriviamo $P_{av,G} = M_0 \frac{p_0}{G_T}$, vanno espressi p_0 e G_T o in W o in mW. Quindi, in dB: $-45dB + 3dB + 15dB = -27dB$, che sono $3dBm$ ovvero $2mW$.

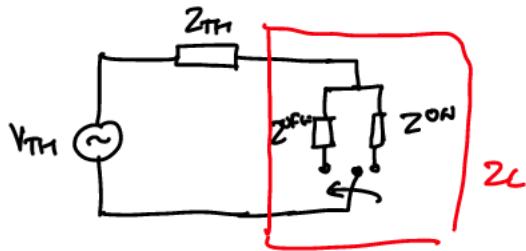


Figura 7.2: Circuito di Thevenin del ricevitore senza sorgente

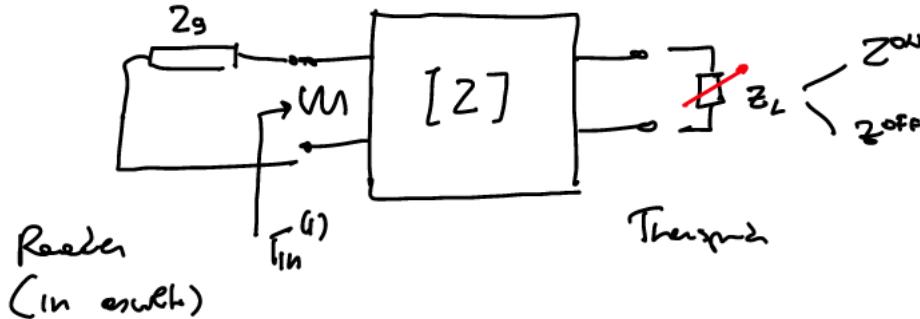


Figura 7.3: Schema della rete a due porte

B +25dB -15 dBm +3dB.

Riportiamo tutto in dB, +25dB (-15-30)dB + 3dB = -17 dB. Conviene riportare tutto in dB visto che il margine aggiuntivo è espresso in dB.

tenere presente che:

- 3dB \approx 2W e quindi per i dBm si ragiona in mW.

7.1.2 Link asimmetrico - guadagno di Round-Trip

Consideriamo di avere un ricevitore RX che sia privo di sorgente e per comunicare con il trasmettitore deve usare la modulazione del segnale di interrogazione (simile a ciò che avviene nei link induttivi). Prendiamo il circuito di Thevenin del RX:

immaginiamo che nella modalità in cui $TX \rightarrow RX$ il carico venga collegato ad uno switch che in base ad una logica binaria, se si vuole trasmettere 1 o 0, commuta su uno dei due carichi.

I due carichi sono molto diversi, quindi normalmente $Z_{OFF} \gg Z_{ON}$.

I due dispositivi sono accoppiati, quindi il trasmettitore si accorgerà che dall'altra parte sta cambiando qualcosa:

Il coefficiente di riflessione che il reader vede è dato da

$$\Gamma^{(1)} = \frac{Z_{in}^{(1)} - Z_g}{Z_{in}^{(1)} + Z_g} \quad (7.11)$$

l'impedenza tramite $Z_{in}^{(1)}$ è funzione del particolare stato di commutazione del carico.

Si può far vedere che ci sono segnali sinusoidali che vengono trasmessi, rimuovendo la portante si

vede che la potenza che il transponder manda indietro al reader si scrive come

$$P_{R \leftarrow T} = \frac{1}{4} |\Gamma_{in}^{(1)}(Z^{ON}) - \Gamma_{in}^{(1)}(Z^{OFF})|^2 \cdot P_{av,G} \quad (7.12)$$

quindi dipende dalla potenza massima iniettata nella porta moltiplicata per una grandezza che dipende dai valori di impedenza.

Valori tipici: $Z^{OFF} \rightarrow \infty$ $Z^{ON} \rightarrow Z_L$.

Quindi come caratterizziamo il link andata e ritorno: introduciamo il guadagno di Round-Trip definito come:

$$G_{RT} = \frac{P_R \leftarrow T}{P_{av,G}} = \frac{1}{4} [\Gamma_{in}^{(1)}(Z^{ON}) - \Gamma_{in}^{(1)}(Z^{OFF})]^2 \quad (7.13)$$

che è data da

$$\left| \frac{Z_G \cdot Z_{12}^2}{Z_{11} + Z_G} \right|^2 \cdot \frac{1}{|(Z_{11} + Z_G)(Z_{22} + Z_L) - Z_{12}^2|^2} \quad (7.14)$$

dove deve valere la condizione:

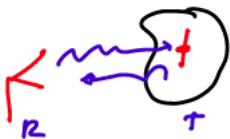
$$P_{R \leftarrow T} = P_{av,G} G_{RT} > p_R \quad (7.15)$$

per stabilire il link totale inverso.

Possiamo anche qui definire un margine di Round-Trip (in dB siamo in scala $10 \log_{10}$):

$$M_{RT} \left| dB = P_{av,G} + G_{RT} - p_R - M_0 \quad (7.16) \right.$$

quando la quantità è ≥ 10 abbiamo che il link inverso è attivato.



c'è il segnale che va dal reader al transponder e poi dal transponder torna indietro e viene raccolto dal reader. Abbiamo quindi due margini:

- per il link diretto:

$$M_D = P_{av,G} + G_T - p_T - M_0 \quad (7.17)$$

- per il link di Round-Trip:

$$M_{RT} = P_{av,G} + G_T - p_T - M_0 \quad (7.18)$$

quindi il link è stabilito quando ambe due le grandezze sono maggiori di 0, altrimenti può accadere che accendo il transponder ma questo risponde "debolmente" o viceversa.

Tipicamente qui il bottleneck è l' M_D perché tipicamente la sensitivity del transponder è molto più "scarsa", specialmente se questo è senza batteria.

Se il link diretto è verificato ho quindi buone possibilità che lo sia anche quello inverso (ma non è sempre così).

In generale, $G_{RT} \ll G_T$ perché nel primo caso c'è un'attenuazione dovuta al fatto che entra e poi torna indietro quindi se il mezzo è con perdite subisce due forti attuazioni invece di una sola.

La maggior parte di questi link funziona posizionando il lettore sul corpo e leggendo dal dispositivo impiantato. Ci sono dei casi in cui c'è vantaggio a leggere il dato da fuori, ad esempio protesi che monitorano le infezioni in modo che ad esempio un lettore che è in bagno legga il dato per individuare i precursori dell'infezione.

Ovviamente si è esposti ad attacchi malevoli.

7.2 Link in campo lontano

Qui valgono tutte le grandezze inserite studiando le antenne classiche. Questo tipo di link si ha tipicamente quando abbiamo dispositivi wearable che comunicano con l'esterno:

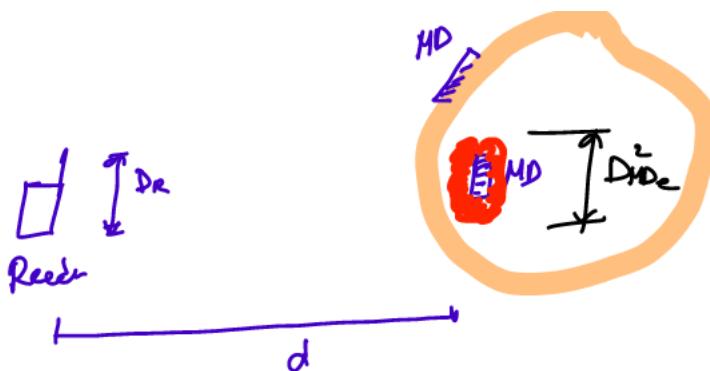


Figura 7.4: Esempio di link di comunicazione in far field

abbiamo il corpo ed immaginiamo che il dispositivo sia o all'esterno o anche all'interno ma venga interrogato a distanza.

Abbiamo il reader (interrogatore) e la distanza d è tale per cui ogni oggetto è nel campo lontano dell'altro, da cui la **distanza di Fraunhofer**:

$$r_F \geq \frac{2D^2}{\lambda} \quad (7.19)$$

Per il reader, abbiamo

$$d > \frac{D_r^2}{\lambda} \quad (7.20)$$

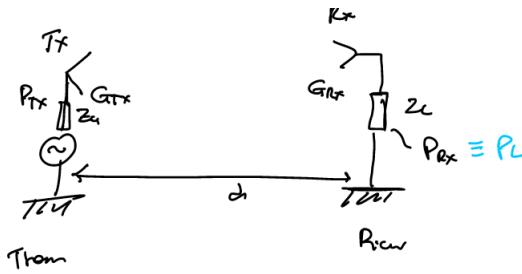
dove λ_0 è sempre quello nel vuoto.

Per il dispositivo sul corpo, la dimensione che conta è quella dove c'è della distribuzione di corrente ovvero dove il corpo diventa un pezzo dell'antenna e quindi

$$d > \frac{D_{MD}^2}{\lambda_0} \quad (7.21)$$

dove immaginiamo una zona dove ci sono delle correnti di conduzione che possono a loro volta produrre delle radiazioni.

In queste condizioni, possiamo studiare i due oggetti separatamente per poi metterli assieme con le regole di campo lontano:



il trasmettitore sarà caratterizzato da guadagno e potenza entrante mentre il ricevitore dal guadagno e dalla potenza rilasciata sul carico, allora (Friis)

$$P_{RX} = P_{TX} G_{TX} G_{RX} \tau_{TX} \tau_{RX} \left(\frac{\lambda^2}{4\pi d^2} \right) \eta_p \quad (7.22)$$

dove abbiamo:

- τ_{TX} vale

$$\tau_{TX} = 4\pi \frac{R_{TX} R_G}{|Z_{TX} + Z_G|^2} \quad (7.23)$$

mentre τ_{RX}

$$\tau_{RX} = 4\pi \frac{R_{RX} R_L}{|Z_{RX} + Z_L|^2} \quad (7.24)$$

e valgono 1 quando c'è adattamento coniugato:

$$\begin{cases} \tau_{TX} = 1 & \text{se } Z_{TX} = Z_G^* \\ \tau_{RX} = 1 & \text{se } Z_{RX} = Z_L^* \end{cases}$$

- I prodotti sono il guadagno realizzato di TX ed RX

$$G_{TX} \cdot \tau_{TX} = \tilde{G}_{TX} \quad (7.25)$$

$$G_{RX} \cdot \tau_{RX} = \tilde{G}_{RX} \quad (7.26)$$

(rx tiene conto del fatto che non tutta la potenza raccolta può essere trasferita al carico perché può esserci del disallineamento).

- La η_P tiene conto di come sono allineate le polarizzazioni fra le due antenne (efficienza di polarizzazione), matematicamente:

$$\eta_P = |\hat{h}_{RX} \cdot \hat{h}_{TX}|^2 \quad (7.27)$$

- Il termine $(\frac{\lambda_0}{4\pi d})^2$ è l'attenuazione di spazio libero, quindi la densità di potenza si attenua per volumi più grandi in quanto si distribuisce man mano che ci allontaniamo su sfere più grandi. Il 2 vale solo per lo spazio libero, altrimenti ci sarà un valore più altro se ci sono riflessioni da terreno pareti etc...

Capitolo 8

Lezione 8

8.1 Far field - link simmetrici

Abbiamo considerato il link diretto, dove abbiamo che i due dispositivi sono posti a distanza grande rispetto alla distanza di Fraunhofer.

Continuiamo con link diretti, ricaviamo dalla formula di Friis la distanza massima del collegamento: introduciamo una p del ricevitore che è la power sensitivity del ricevitore: se $P_{rx} \geq p_{rx}$ allora il link sarà attivo altrimenti non si stabilisce.

Considerando l'uguaglianza, $P_{rx} = p_{rx}$, possiamo trovare la distanza massima per cui tale collegamento si stabilisce: facciamo Friis⁻¹ e troviamo che

$$d_{max} = \frac{\lambda}{4\pi} \sqrt{\frac{G_{TX} P_{TX} G_{RX} \tau_{TX} \tau_{RX}}{p_{rx}}} \eta_P \quad (8.1)$$

dove:

- se il tx è adattato, abbiamo una proporzionalità $\propto \sqrt{\frac{G_{RX}}{p_{RX}}}$
- se invece c'è adattamento anche con il ricevitore c'è proporzionalità con $\propto \sqrt{G_{RX}}$

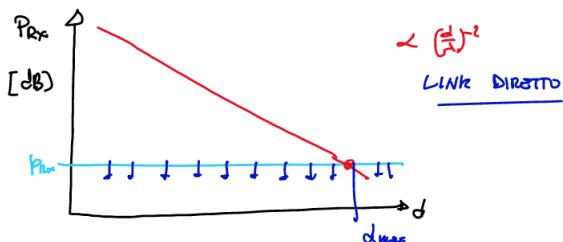
In dB, avremo che

$$d_{max} \Big|_{dB} \propto \frac{1}{2} G_{RX} \Big|_{dB} \quad (8.2)$$

sappiamo che 3dB è circa un 2x di guadagno, ogni 6dB (4 volte di guadagno) si ha un raddoppio della distanza del link (la radice la porta a 2).

Invece, un aumento di guadagno di 3dB dice che la distanza di lettura aumenta di un fattore $\sqrt{2}$ (circa 1 volta e mezza) (IMPORTANTE).

Facciamo un grafico per questo concetto:



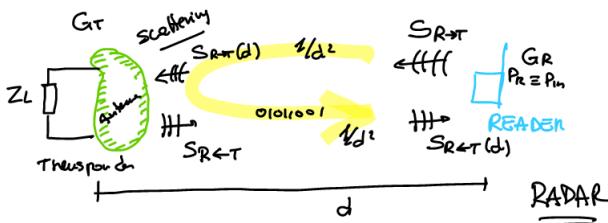
c'è un'attenuazione che andrebbe come $(\frac{d}{\lambda})^{-2}$. Avendo quindi fissato il sistema di lettura, un modo per aumentare la distanza è cercare di abbassare la sensitivity (ma ci sono i limiti fisici ad un certo punto).

Per link simmetrici vale la stessa cosa, basta invertire rx con tx, in questo caso il trasponder è dotato di una sorgente locale di alimentazione.

8.2 Far field - link asimmetrici

Qui i ruoli fra trasponder ed interrogatore non si scambiano mai, applicheremo quindi nuovamente un protocollo di modulazione dell'impedenza, ma non nell'accoppiamento bensì nel back scattering (riflessione).

Immaginiamo la seguente situazione:



la distanza d è di campo lontano, il reader avrà un suo guadagno G_R ed anche il transponder G_T .

Il reader manderà un segnale ed il transponder lo andrà a riflettere modulandolo: avremo un vettore di Pointing dal transponder verso il reader e poi ci sarà un giro di round trip indietro, abbiamo un fenomeno di **scattering**, che verrà pilotata dal carico.

Questo è il classico modello radar, dove c'è un'antenna che manda impulsi verso un aereo ma qui la differenza è che il segnale che torna indietro deve portare informazione ovvero una sequenza binaria. Scriviamo la densità di potenza

$$S_{R\rightarrow T}(d) = \frac{1}{2Z_0} |E_{R\rightarrow T}(d)|^2 \quad (8.3)$$

che si può anche scrivere come

$$S_{R\rightarrow T}(d) = I_{R\rightarrow T} \cdot \frac{1}{d^2} \quad (8.4)$$

dove la I è l'intensità di radiazione che è densità di potenza per unità di angolo solido ($\frac{W}{sr}$).

Entra in gioco nel guadagno dell'antenna trasmittente

$$G_R = \frac{I_R 4\pi}{P_R} \quad (8.5)$$

da cui possiamo ricavare

$$P_R = \frac{P_{in} G_R}{4\pi} \quad (8.6)$$

la inseriamo nell'espressione della densità di potenza ottenendo

$$S_{R\rightarrow T}(d) = \frac{P_{in} G_R}{4\pi d^2} \quad (8.7)$$

che ci dice come si attenua la potenza man mano che ci si allontana da una sfera di raggio d .

Introduciamo ora il concetto di **radar cross-section**: è l'area di uno scatteratore isotropico (riflette

allo stesso modo in tutte le direzioni), quindi una sferetta metallica, che una volta investita dal campo retro-diffonde nella direzione dove c'è il mio oggetto la stessa quantità di potenza.

È la σ , che va valutata in campo lontano ($d \rightarrow \infty$):

$$\sigma = \lim_{r \rightarrow \infty} 4\pi r^2 \frac{S^{scatt}}{S^{in}} = \lim_{r \rightarrow \infty} 4\pi r^2 \frac{|E^{scatt}|^2}{|E^{in}|^2} \quad (8.8)$$

Come si utilizza: conosciamo il campo incidente, possiamo quindi calcolare il campo che emerge dal transponder e torna indietro dal ricevitore:

$$S_{R \leftarrow T}(d) = \sigma \frac{S_{R \rightarrow T}(d)}{4\pi d^2} \quad (8.9)$$

è la potenza $S_{R \leftarrow T}(d)$ e che quindi porterà il segnale che torna indietro.

La potenza rilasciata sul carico del ricevitore sarà uguale a:

$$P_{R \leftarrow T} S_{R \leftarrow T}(d) \cdot A_{C,R} \quad (8.10)$$

dove A_C è l'area efficace del reader, ovvero una superficie equivalente che se investita da un'onda raccoglie una quantità di potenza uguale da quella che avrebbe raccolto l'antenna (ed è più piccola dell'area geometrica):

$$A_e = \lambda^2 \frac{G}{4\pi} \quad (8.11)$$

Mettendo quindi tutto dentro:

$$P_{R \leftarrow T} = \frac{P_{in} G_R A_{e,R}}{(4\pi d^2)^2} \eta_P \sigma_T \quad (8.12)$$

ci aggiungiamo η_P , che è il **polarization loss factor**, perché se abbiamo un oggetto di una certa forma ed irradiamo con un campo, per effetto della forma probabilmente il campo scatterato avrà una forma differente, quindi quando incide sull'antenna può non avere la stessa polarizzazione di quando è partito e quindi si tiene in conto con questo fattore.

Questa è l'equazione del radar, dipende anche dalla capacità di scatterare del transponder in una direzione rispetto che in un'altra.

Abbiamo anche che σ può essere considerata in due casi:

- monostatica: il segnale è raccolto dalla stessa antenna che interroga
- bistatico: abbiamo due antenne, una illumina il bersaglio ed un'altra prende il segnale retro-diffuso (tipicamente c'è un vantaggio per quanto riguarda la qualità del segnale)

ragioniamo con situazione monostatica:

la potenza che torna indietro è $\propto \frac{1}{d^4}$ perché deve fare un round trip quindi abbiamo due attenuazioni da $\frac{1}{d^2}$ quindi il segnale retrodiffuso è molto flebile rispetto ad un oggetto che sta trasmettendo di suo. Dobbiamo ora fare in modo che arrivi dell'informazione: occorre intanto isolare il dispositivo da tutto il riflesso dell'ambiente. Questo si ottiene con la modulazione, in modo che il segnale che si sovrappone al disturbo oscilli.

Passiamo ad un'antenna che abbia un'impedenza d'ingresso Z_a ed un carico Z_L con un generatore equivalente che tiene conto del campo che arriva, possiamo esprimere σ come

$$\sigma = \frac{\lambda^2}{4\pi} G |A - \Gamma^*|^2 \quad (8.13)$$

quindi è lo scattering di un dispositivo caricato.

Γ^* è un coefficiente di riflessione generalizzato, dato dal coefficiente che vedo fra l'antenna ricevente ed il suo carico. Ha come differenza rispetto al classico che c'è un complesso coniugato, perché c'è

qualcosa che deve immagazzinare energia.

A è un complesso che dipende da forma e soprattutto dimensione dell'antenna scatterante: se la dimensione di tale antenna è $L \ll \lambda$ allora $A \simeq 1$. In queste condizioni la σ del transponder sarà data da:

$$\sigma_T = \frac{\lambda^2}{4\pi} G_T^2 \left| 1 - \frac{Z_L - Z_{in,T}^*}{Z_L + Z_{in,T}} \right|^2 \quad (8.14)$$

da cui, avendo $Z_{in,T} = Z_A$ e sviluppando il comun denominatore:

$$\left| \frac{Z_L + Z_{in,T} - Z_L + Z_{in,L}^*}{Z_L + Z_{in,T}} \right|^2 = \frac{4R_{in,T}^2}{|Z_L + Z_{in,T}|^2} \quad (8.15)$$

ottenendo infine

$$\sigma_T = \frac{\lambda^2}{4\pi} G_T^2 \frac{4R_{in,T}^2}{|Z_L + Z_{in,T}|^2} \eta_P \quad (8.16)$$

aggiungiamo di nuovo l'efficienza di polarizzazione perché l'oggetto può cambiare la polarizzazione. Questa è quindi l'area di scattering equivalente con un guadagno G_T ed una certa impedenza del carico (Z_L), che quella che possiamo variare per far variare l'RCS: possiamo quindi controllare quanto questo oggetto rifletta, se lo facciamo on due stati cambia l'informazione che torna indietro e quindi possiamo mandare informazione.

Abbiamo che

$$P_{R \leftarrow T} = \left(\frac{\lambda}{4\pi d} \right)^4 P_{in} G_R^2 G_T^2 \frac{4R_{in,T}^2}{|Z_L + Z_{in,T}|^2} \eta_P^2 \quad (8.17)$$

ci interessa che l'equazione sia dominabile andando ad agire sull'impedenza del carico.

Modulazione di impedenza

Immaginiamo di avere due stati:

- 0, associato ad un'impedenza di carico che sia virtualmente un circuito aperto $Z_L \rightarrow \infty$, e quindi $P_{R \rightarrow T} = 0$
- per lo stato 1 si può scegliere: $Z_L = 0$ (corto circuito) che ci da una potenza

$$P_{R \leftarrow T} = \left(\frac{\lambda}{4\pi d} \right)^4 P_{in} G_R^2 G_T^2 \cdot \frac{4R_{in,T}^2}{|Z_{in,T}|^2} \eta_P^2 \neq 0 \quad (8.18)$$

così possiamo cambiare a piacimento la potenza retro diffusa.

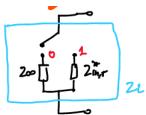
Una scelta di questi due livelli ha un grosso limite: l'oggetto comincia a riflettere ciò che arriva, ma se il RX switcha fra ∞ e 0, l'aspetto critico è che, funzionando solo con l'energia che arriva da lontano, non raccolgo quindi potenza: non c'è un carico collegato, quindi la corrente raccolta non può essere immagazzinata.

Conviene quindi che uno dei due stati sia compresa fra 0 ed ∞ , quindi prendiamo $Z_L = Z_{in,T}^*$ dove quindi in questo stato assorbe e immagazzina energia, mentre nell'altro caso no:

$$P_{R \leftarrow T} = \left(\frac{\lambda}{4\pi d} \right)^4 P_{in} G_R^2 G_T^2 \eta_P^2 \quad (8.19)$$

non c'è più dipendenza fra le impedenze. Quindi, nel caso 1 non abbiamo carica remota per il dispositivo, perché non è in grado di raccoglierla.

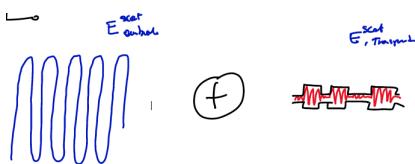
Vediamo ora come avviene effettivamente la comunicazione: nello spazio possiamo avere persone, altri oggetti che saranno di dimensioni sicuramente più grandi di quelle di tx ed rx. Quando tx produce il suo campo, immaginiamo un'onda continua che si distribuisce in varie direzioni avremo



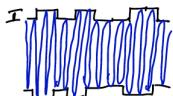
una riflessione non modulata, quindi la stessa sinusoide con la stessa frequenza (attenuata) che finirà sull'rx e poi l'effetto prodotto dalla modulazione di impedenza:

abbiamo quindi nel carico del transponder nuovamente uno switch che connette due stati. Avremo quindi l'inviluppo con dentro l'onda che viene riflessa: ha la stessa frequenza del reader ma è modulata in ampiezza.

Sul reader ci sarà la somma delle onde blu e rosse, l'ambiente grande rifletterà molto di più dell'oggetto che trasmette:



ai capi del transponder vedremo quindi un qualcosa del genere:



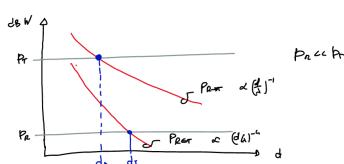
avremo quindi il segnale totale al reader, tolta la sinusoide rimane l'inviluppo e possiamo estrarre il valore inviato.

Si chiama **modulazione di back scattering**, che è la tecnologia con cui funzionano tutti i sistemi di identificazione in radiofrequenza.

Per la distanza massima del collegamento, dobbiamo tenere conto che

- il link diretto ($R \rightarrow T$), governato dalla formula di Friis serve ad accendere ed alimentare il transponder. Questo va come $(\frac{d}{\lambda})^2$ e si attiva quando $P_{R \rightarrow T} \geq P_T$
- il link inverso ($R \leftarrow T$), che va da transponder a reader e serve a modulare il backscattering. Va come $(\frac{d}{\lambda})^4$ Si attiva quando $P_{R \leftarrow T} \geq P_R$

il link si stabilisce quindi quando sono verificate ambe due le condizioni. Anche qui facciamo un grafico per capire la distanza massima del collegamento:



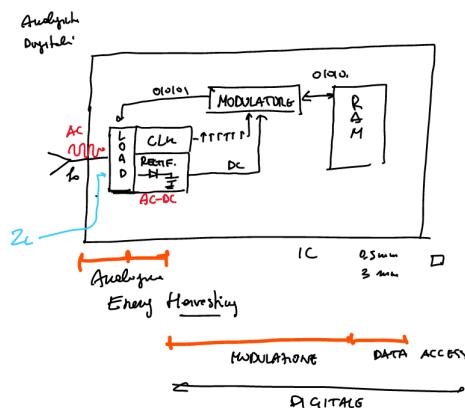
dove $p_R \ll p_T$ in quanto $p_R : -100dBm\% - 70dBm$ mentre $p_T : -20dBm\% - 5dBm$,

avremo quindi che $d_{max} = \min\{d_D, d_I\}$ tipicamente il bottleneck è il link al quale compete la lunghezza più breve che è quasi sempre il link diretto.

8.2.1 Logica di modulazione

Cosa c'è nel transponder per acquisire energia e pilotare il transponder alto/basso: c'è una logica di modulazione che ha delle parti analogiche e delle parti digitali.

Lo schema è il seguente:



la prima cosa che avviene è un passaggio da analogico a digitale, c'è un rettificatore (immaginiamo un diodo collegato ad un condensatore, come se fosse la batteria virtuale del dispositivo) si passa quindi da AC a DC, la corrente alimenterà i componenti, primo fra cui il modulatore.

Il modulatore comanda il carico e lo fa aprire o chiudere fra due valori, la frequenza a cui vengono fatte queste operazioni è tipicamente più bassa della f_0 di interrogazione: c'è un clock che scandisce tale frequenza, quindi anche il segnale di clock serve per gestire il modulatore. Abbiamo poi la RAM che mantiene l'informazione, da cui si legge e su cui si scrive.

Tutta l'attività è svolta da un circuito integrato che è molto piccolo (chip da 0.5mm - 3mm)

La prima parte è analogica dove avviene l'energy harvesting, ovvero il raccogliere l'energia, poi c'è il blocco di data modulation ed infine il data access che sono parti digitali.

Il blocco analogico mette in contatto col mondo esterno, quello digitale serve per fare le operazioni. Da un punto di vista a radio frequenza, ci interessa la Z_L per fare i calcoli di adattamento: vedremo l'impedenza del primo blocco analogico: avremo una parte reale dovuta alle perdite e poi un condensatore che serve ad immagazzinare l'energia che arriva da fuori, che può essere serie o parallelo



avremo che $Z_C = R_{LC} - \frac{1}{j\omega C_{LC}}$ dove la parte R_{LC} è tra $1\Omega - 20\Omega$, mentre il denominatore sta fra $100 - 200\Omega$, è quindi questo il circuito a cui l'antenna di deve adattare per avere un $\tau_T = 1$, deve avvenire che

$$\begin{cases} R_{in,T} = R_{ic} \\ X_{in,T} = -X_{in,C} \end{cases}$$

quindi l'antenna deve essere progettata per lavorare non in risonanza (induttanza ?), sarà l'insieme ad essere risonante.

Capitolo 9

Lezione 9

9.1 Lezioncina di storia

Abbiamo visto vari meccanismi di comunicazione sul corpo umano, sia a bassissima distanza con oggetti nel corpo, sia con oggetti sul corpo ed anche come possa avvenire la trasmissione di informazione senza usare batteria.

Vediamo un implementazione di queste tecnologie di comunicazione basate su modulazione, introduciamo l'identificazione a radio frequenza: nata come evoluzione del codice a barre ed evoluta nelle applicazioni sensoristiche.

Leon Theremin: inventore Russo dell'800, noto per il **theremin**: strumento musica suonato con le mani, sfrutta l'EM per suonare (ha un dipolo ed un loop), quindi muovendo le mani si può cambiare timbro ed altezza del suono.

Guerra fredda: America e Russia non si vogliono bene (:'(), donarono all'ambasciatore Russo (?) un'antenna nascosta senza batterie, così che gli Americani avevano ascoltato le comunicazioni. Primo oggetto spia della storia inventato da Theremin, **the great seal bug**, la cosa interessante è che non aveva fonte di alimentazione: monopolo, che termina in una membrana sottile che è quindi una cavità risonante (un microfono a condensatore), le onde sonore mettevano in risonanza l'oggetto ma così non viene trasmesso nulla. Al di fuori, la spia inviava una portante a 300MHz, che viene raccolta dal monopolo. Questo vede una capacità variabile e gli cambia la frequenza di risonanza effettuando una modulazione in ampiezza (back scattering, 80 anni fa :O).

È il primo esempio di dispositivo di spionaggio.

Passati gli anni, venne ripreso per applicazioni civili

9.2 IoT - introduzione

La tecnologia dell'RFID si innesta nel contesto di come sta cambiando l'Internet adesso: l'Internet di ieri è una comunicazione host-to-host passando per la rete, oggi internet si sta "spalmando" nel mondo, quindi si mescola al tessuto quotidiano diventandone parte integrante.

Già 30 anni fa si ipotizzava che il PC sarebbe stato spezzato e distribuito in casa su diversi schermi, senza più doversi sedere davanti al PC fisso.

Quasi tutti gli oggetti oggi hanno delle espansioni digitali (es libri, QR code etc...), SPIME: (SPace + tIME), nell'internet di domani avremo un sistema nervoso che ingloba sia linee che trasmettono dati che nodi che includono sensori ed hanno capacità di captare cosa accade intorno.

Tutti i sensori di mare, terra etc... servono per avere una comprensione maggiore per poter poi prendere delle decisioni in maniera più consapevole, il tutto è sia in macro-scala che micro-scala, ad esempio oggetti che possono essere impiantati nel corpo umano per capire meglio come questo funziona.

Arriviamo all'IoT, il presente: sensori apposti su qualunque tipo di oggetto nella manifattura dei dispositivi e comunicano con il nucleo di Internet mediante la comunicazione wireless.

Ha molte declinazioni, fra cui "Industria 4.0", in cui non c'è solo il controllo automatico, la robotica ma anche l'interconnessione fra gli oggetti.

Per avere IoT serve:

- capacità di etichettare gli oggetti
- capacità di misurare una grandezza fisica
- la capacità di essere localizzato

es: il cellulare fa IoT, in quanto fra i compiti che svolge geolocalizza (AAAA GOOGLE SA DOVE SONO AIUTO), tracciando la posizione nel tempo: è possibile creare un "digital twin" del mondo reale, nel quale riusciamo a ricostruire anche le interazioni logiche e fisiche.

Applicazioni dell'IoT: siamo ancora agli albori, si può immaginare di usare i dati in combinazione con AI per l'agricoltura di precisione (riducendo i pesticidi), smart cities, medicina smart etc... da qui viene estratta una "saggezza" ovvero la capacità di prendere decisioni.

Il grosso degli oggetti interconnessi sono

- automobili
- webcams
- ...

Noi (loro) siamo (sono) interessati in Internet of Helthcare Things: sono oggetti che possono essere identificati univocamente, connessi ad internet e capaci di comunicare l'un l'altro ed usati in ambiente medico. Cosa si può fare:

- localizzare gli asset: in un ospedale ci sono molti oggetti, che si perdono. A livello minimo se ne fa il tracking
- gestione automatica delle risorse, dove in senso lato è anche capire lo stato di salute del paziente

Vantaggi:

1. punto di vista del paziente: può essere monitorato in continuo da remoto, quindi poter avere la possibilità di avere warning nel caso in cui qualche parametro vitale stia andando fuori controllo (anche ad es. se si cade).

C'è anche possibilità di avere assistenza da remoto in caso di eventi come cadute e non ultimo la possibilità di trasferire dati ad una centrale di controllo remota.

Infine, consulti medici da remoto ed automatic reminder, ovvero la possibilità che la rete ricordi che devo fare delle cose come prendere delle medicine

2. staff medico: un po' il duale, ovvero la possibilità di avere un accesso remoto allo storico del paziente.

Poter usare algoritmi (AI) per individuare nei dati dei pattern anomali (pattern recognition?). Accesso alla cartella clinica del paziente con un web browser.

3. manager: può meglio controllare il fatto che alcuni dispositivi vengano rubati, ma può anche avere una notifica quando questi escono da una certa area.

Può fare analisi statistiche sul consumo di apparecchiature, ottimizzare il personale in una sala operatoria, capire come si muove il personale durante un intervento.

Non ultimo, pianificare la manutenzione preventiva.

Un oggetto è detto interconnesso quando ha una o più di queste caratteristiche:

- identificazione
- localizzazione
- auto-diagnosi
- sensing
- attuazione (anche da remoto)
- local computing (edge computing: es, estrarre delle feature e mandare solo quelle nel cloud e non tutti i dati pesanti)

per interconnettere l'oggetto, si usa elettronica microscopica: oggetti piccoli quanto granelli di sabbia, che si collegano ad antenne di forma variabile in base alla frequenza, ottenendo una catena per cui c'è:

- sensore, spesso senza batteria che contiene un ID e lo stato fisico di ciò che misura
- acceso da remoto con la tecnica di modulazione in back-scattering
- l'oggetto intermedio acquisisce l'informazione e lo manda nel cloud

È, a livello minimo, il **primo metro dell'IoT**, da cui si possono implementare tutti i servizi aggiuntivi.

9.3 RFID

In un sistema di identificazione ci sono:

- identificatore che tx ed rx, dove ci sono aspetti di antenne, propagazione ed eventualmente sensistica
- transponder, spesso chiamato tag in quanto è nato come evoluzione del codice a barre. Riceve un comando, si attiva e rimanda un dato

ragioniamo su dispositivi di etichettatura EM:

- in principio ci sono state le etichette stampate, dove c'è tutto ciò che serve sapere e si legge
- codice a barre, salto concettuale enorme. È una rappresentazione visiva di un "numero" (**NUMERELLO SOTTO**). Rispetto al precedente, l'informazione non è scritta nel codice a barre, che appunto contiene solo un codice ed è quindi un puntatore ad un file dove c'è effettivamente l'informazione.
Quindi si entra da tutt'altra parte dove poi si legge il dato: viene letto in maniera ottica, la distanza è di pochi cm (ma scadit ha fottuto questa distanza).
- carte magnetiche o smart card: funziona concettualmente come il codice a barre, ma mentre quest'ultimo è leggibile, qui è nascosto in un chip o codificato nella striscia magnetica quindi per leggerlo occorre dare energia dall'esterno. Possiamo quindi immagazzinare più dati, in alcuni casi riscriverli, ma senza adeguato lettore o software io, **UOMO DELLA STRADA** non posso leggere il dato

- RFID, dove il comportamento è lo stesso della smart card ma la lettura avviene in modalità wireless, quindi senza contatto galvanico.
Anche qui c'è un puntatore e quindi il dato può essere cambiato senza cambiare il codice.

Differenza fra barcode ed RFID:

- quantità di dati: in RFID c'è un microchip che può contenere fino a Kb di dati, barcode poche centinaia di bit
- RFID è difficile da leggere "in strada", barcode si
- se il barcode si riga o si incrosta non si legge, RFID è più tollerante
- se barcode è coperto manca di leggibilità ottica, RFID è meno sensibile
- copia o modifica non autorizzata: codice a barre si può copiare, RFID è difficile
- barcode si leggono uno alla volta, RFID si possono leggere "apparentemente" in più alla volta
- maggiore distanza di lettura di RFID (2m), cambia proprio la finalità del sistema

l'idea del transponder, prima di Theremin è nata durante la II WW, poi Theremin e nel 48' è uscito il primo articolo che descrive un sistema RFID completo.

Già una decina di anni dopo ci sono anti-taccheggio (sistemi ad 1 bit senza elettronica).

Avanzo dell'elettronica, per monitorare gli animali, anni 90' sistema molto noto è il Toll system (telepass) o l'immobilizer dell'automobile (es auto che non hanno chiavi).

Nuovo secolo: inchiostri conduttrivi, oggetti di tutti i tipi e chi più ne ha più ne metta.

Funzionamento: un oggetto che include un microchip ed un antenna e poi c'è un lettore: il lettore manda energia o comandi, il transponder raccoglie l'onda e rimanda un'informazione modulandola. Quando il tag passa sotto al lettore si stabilisce la comunicazione, non è necessaria la visibilità ottica fra reader e tag ed inoltre si possono leggere più tag alla volta.

9.3.1 Classificazione

Abbiamo 3 tipologie di tag e transponder:

- attivi: hanno una fonte di alimentazione, tipicamente una batteria. Hanno a che fare tipicamente con i link simmetrici, possono trasmettere anche senza back scattering, hanno costi elevati ed autonomia scarsa, un esempio sono i tile (tracker BL) possono essere letti fino a 100aia di metri
- semi-passivi: tag a batteria ma non la usano per trasmettere ma solo per attività di bordo ovvero l'acquisizione del dato sensoristico che richiede poca energia mentre la comunicazione continua ad avvenire per riflessione. Serve anche per amplificare la capacità del chip, così che questo possa accendersi anche se la distanza è molta. Capacità elevata (ordine di anni, es il telepass: la batteria dura 4-5 anni), sono anche detti BAP (Battery Assisted Passive)
- passivi: il grosso che si trova, alimentati da remoto e funzionano solo con backscattering modulation. Costi anche più bassi di 5cent, distanze coperte minore di 20m.

Hanno campi di applicazione differenti: su una maglietta di Decathlon si mette un passivo, in un contenitore di vaccini di cui si vuole monitorare la temperatura si mette attivo o semi-passivo.

Si può anche classificare in base alla memoria:

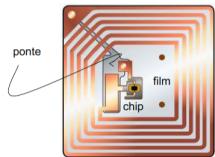
- tag a bit unico: trasmettono un'informazione binaria (ON/OFF) e sono usati come sistemi anti-taccheggio: c'è un "varco" formato da coil ed abbiamo il tag, funziona in due modalità:
 1. sistema acusto-magnetico: ci sono due strisce di metallo vicine. La prima striscia è fatta di materiale ferro magnetico amorfico che quando eccitato da un campo magnetico ad opportuna frequenza oscilla (come una corda). Tipicamente riceve toni a 58KHz, quindi oscillando va a modulare il campo EM. Il coil dell'anti-taccheggio si accorgerà quindi che c'è qualcosa. Di fianco c'è il secondo, che invece è un magnete, più rigido del primo, che tende ad amplificare il campo magnetico prodotto dall'interrogatore. Ha un effetto di enfasi sulla risonanza della prima striscia, non è in contatto con la prima.
La prima striscia serve a comunicare che c'è al varco, la seconda striscia fa sì che, se deattivata, il disturbo osservato dal varco è più flebile (per de-attivarlo viene mandato un campo EM che lo rovina, viene de-magnetizzata la seconda strip). Altrimenti, il segnale sarà forte ed il varco suonerà.
 2. codice a barre + adesivo dove dentro c'è un coil (spesso sta nei libri). Il coil si richiude su due piazzole, una di fronte all'altra, quindi su un condensatore che porta in risonanza il circuito, è come avere un piccolo circuito (RLC), il dispositivo quindi concatena un po' di campo EM prodotto dal varco e quindi questo si rende conto che c'è l'oggetto (sono risonanti). Per portarlo fuori dalla risonanza, occorre rovinare il coil, ad esempio bucandolo, ma nei negozi si mette in un cestino dove c'è un coil più grosso che genera un campo elevato che produce quindi una ddp molto intensa ai capi del materiale e quindi il materiale che sta nel mezzo (che può essere plastica etc...) riceve un cambiamento in permittività

- tag con memoria, che sono read /write

Le frequenze sono state standardizzate sia a livello regionale che mondiale:
(copia dalle slides le due immagini)

9.3.2 Tag ed accoppiamento magnetico

Sistema più complesso:



abbiamo ancora il coil e per chiudere il circuito occorre realizzare un pezzo di conduttore dalla parte opposta e si chiude con il condensatore di tuning, infine abbiamo il microchip che produce la modulazione capacitiva.

Il coil ha più spire perché $B \propto N \cdot I$, questa è una versione in cui il filo che produce il coil è avvolto in un cilindretto di ferrite, che ha una permeabilità relativa, è un dispositivo impiantabile (dangerous things vende sta roba, nome molto confortante). (funzionamento, vedi sopra), all'interno del microchip abbiamo i pad, il rettificatore all'interno che permette il passaggio AC-DC quindi parte analogica + parte digitale (come lo schema di sopra).

9.3.3 NFC

È un sistema HF, basato su accoppiamento induttivo e modulazione capacitiva, (gli oggetti sono coil) la differenza è nello standard di comunicazione nato per mettere in piedi una comunicazione bidirezionale quando due oggetti NFC vengono accostati a pochi mm o cm.

Si stabilisce una rete p2p e si scambiano i dati, la frequenza è quella di 15-56 MHz ed ormai lo hanno quasi tutti i cellulari (usato per lo più per i pagamenti).

Un sistema di questo tipo ha varie declinazioni di utilizzo:

- leggere un tag NFC
- usato come TAG, ovvero altri oggetti lo leggono

il dispositivo può essere quindi sia iniziatore che transponder, la comunicazione è sempre passiva (mediante modulazione), ormai (bho nme ricordo che dovevo scrivere), inoltre la comunicazione è cifrata. Il protocollo di sicurezza più usato per l'NCF è MIFAR.

Capitolo 10

Lezione 10

10.1 Tag ad accompiamento EM

Sono nella banda 860 MHz- 960 MHz, sono antenne vere e proprie (principalmente dipoli) con forme molto differenti: ricorre spesso la configurazione a "meandro" perché permette di ottimizzare le dimensioni ed il t-match (generalizzazione del dipolo ripiegato) che serve per adattare l'impedenza. Ci sono poi dipoli spessi, il fatto che siano larghi serve ad ottenere una banda più larga: non serve perché la comunicazione è a banda larga, ma serve per compensare il fatto che poggiando l'antenna su diversi materiali questa tende a desintonizzarsi: compensa la variazione di prestazione dovuta al fatto non si sa a priori dove su che i dispositivi verranno posti i dipoli; ma fare dipoli spessi a priori ha impatto sul costo.

Abbiamo visto diverse misure (vedi capitoli prima):

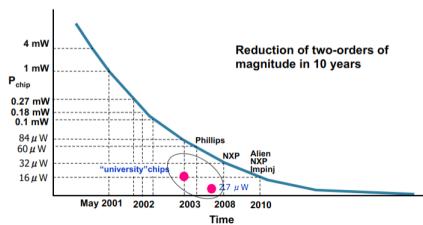
- max distanza di lettura
- da un punto di vista elettrico, possiamo considerare un microchip come circuito RC, dove la capacità tiene conto della quantità di energia immagazzinata e la resistenza tiene conto di eventuali perdite. Si cerca quindi di ottenere adattamento coniugato, così che l'insieme antenna + microchip sia un circuito risonante.
L'antenna di per se è induttiva, mettendole insieme occorre che il dispositivo risoni alla frequenza di lavoro.
- τ è coefficiente di tx in potenza, deve essere vicino ad 1 ed il massimo si ha in adattamento coniugato

Il τ è proprio il coefficiente più importante quando si progetta il tag (oltre al guadagno), questo entrava nella formula di Friis, quindi la massima distanza è $\propto \sqrt{G_T \tau}$, vediamo quindi come cambia la distanza di lettura: (immagine) per un τ circa 0.6 la distanza di lettura è scesa del 20%, quindi per un $\tau \geq 0.7$ abbiamo un adattamento discreto. Qui non conta tanto se usiamo tutta la potenza bensì a che distanza riusciamo a leggere, 0.7 è un valore da tenere sotto controllo.

Notiamo inoltre che la r_{max} è $\propto \sqrt{G_T \tau}$, quindi ogni volta che (ragionando in dB) aumentiamo di 6dB abbiamo un raddoppio della distanza e può fare molto la differenza.

10.1.1 Sensibilità del chip

Si parte dalla legge di Moore, dove si è passati da chip con molti transistor a multicore (per via dei limiti fisici). Qualcosa è accaduto anche qui, in termini della potenza necessaria per aggiungere un microchip:



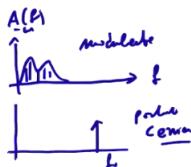
siamo passati da 1mW di 20 anni fa a 0.1mW, passando da una distanza di 20m a quella di 2m di 20 anni fa.

10.1.2 Modulazione

Abbiamo visto che quando il tag deve mandare indietro informazione cambierà l'ampiezza del segnale riflesso mediante modulazione in ampiezza, c'è una logica interna che commuta fra i due stati (immagine).

La modulazione serve a fare in modo che il segnale da trasmettere venga "incasellata" in un certo canale di frequenza: se abbiamo un segnale in banda base, ma il segnale che voglio trasmettere non può usare la banda attuale, occorre spostarsi avanti in frequenza individuando una "finestra" e occorre fare in modo che si sposti il segnale.

Si moltiplica quindi per una sinusoide, che è una delta di Dirac, avremo lo stesso segnale valutato nel punto $\omega - \omega_0$



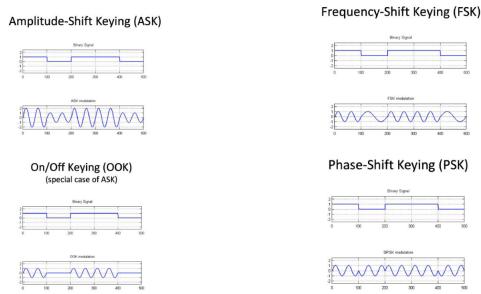
Possiamo quindi moltiplicare tanti segnali in tanti canali differenti:

- $S(\omega)$ è il segnale che porta l'informazione (modulante)
- c'è la portante, segnale monocromatico ($\delta(\omega - \omega_0)$)

(immagine) immaginiamo che questo sia il segnale da trasmettere $m(t)$ e sia M il picco del segnale. Questa è la modulante, poi abbiamo la sinusoide che ha come picco A , la $a(t)$. Quando ne facciamo il prodotto, otteniamo un segnale che sarà fatto così: (immagine) il segnale rosso è l'inviluppo, la portante oscillatorà all'interno dell'inviluppo. Questo ci permette di inviare informazione sul canale che ci serve. In ricezione si fa una demodulazione e si recupera il segnale in banda base (la prima). Si definisce quindi l'indice di modulazione M che è il valore massimo della modulante diviso il picco della portante: $m = \frac{M}{A}$ in %, ad esempio $m = 0.5$ vuol dire che: se la modulante è una ancora sinusoide, il segnale portato oscillatorà fra: $A \pm mA$, quindi se vale il 50%, il max andrà fra 0.5 ed 1.5 se ammettiamo che la portante abbia ampiezza unitaria.

Quanto più vicino ad 1 (l'indice di modulazione), più semplice sarà decodificare e recuperare il segnale in banda base quando si fa la demodulazione.

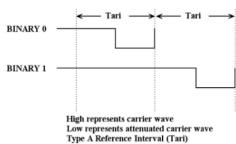
Abbiamo a che fare con una modulazione in cui $m(t)$ è un segnale digitale: dobbiamo trasmettere bit da reader a tag e viceversa, quindi la modulante sarà un segnale che ha un livello alto ed uno basso, possiamo quindi avere:



- una modulazione in ampiezza dove al livello basso corrisponde uno 0 (OOK, ASK);
- una modulazione in frequenza a livello 1 abbiamo una sinusoide con periodo più breve e a livello 0 una sinusoide con passo più alto, vantaggio è che trasmetto sempre energia ma con frequenze differenti (FSK);
- un altro caso è la PSK: quando passo da 0 ad 1 moltiplico per -1, anche qui usiamo una sola frequenza ma inverti la fase.

Su queste modulazioni di base sono costruite quelle che si trovano nell'RFID, in particolare prima di trasmettere il dato viene fatto un **encoding**: lo 0 e l'1 vengono codificati come combinazioni di livelli alti e bassi, serve anche per gestire in maniera efficiente la potenza a disposizione.

Abbiamo ad esempio la PIE:



dove

- 0 è rappresentato da livello alto e poi una transizione
- 1 è rappresentato da livello alto per più tempo e poi una transizione

questo permette di avere una maggiore immunità al rumore, tra l'altro il reader che usa questa modulazione trasmette sempre energia, così che il chip potrà sempre accendersi.

Nel reader, si può controllare il tempo tari, agendo su di esso si può ottimizzare la perdita di informazione e la velocità di interrogazione: maggiore tar i, più lenta è l'interrogazione ma più robusto rispetto ad agenti esterni.

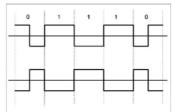
Vediamo quindi lo schema di reader/tag:

- reader fa il coding
- c'è poi modulazione in ampiezza con un certo indice di modulazione (ordine del 90%, piuttosto profondo) ed abbiamo il segnale modulato. Ingrandendolo, vediamo delle oscillazioni
- il segnale entra nel chip, c'è il blocco che produce il segnale in continua per alimentare l'elettronica, la parte in radio frequenza viene demodulata per decodificare la stessa stringa binaria (al di là delle possibili perdite)

Lato chip, questo usa una specie di modulazione in frequenza, per applicarla serve ogni volta che si passa dal valore alto al basso si usano due sinusoidi di frequenza diverse ma chi le da al tag, non ha elettronica per generarle.

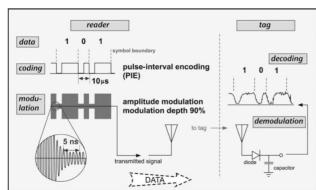
È stata inventata una modulazione tale per cui:

- la portante rimane la stessa
- c'è encoding sui bit che deve trasmettere il chip che producono una sotto-frequenza:



lo 0 e l'1 sono dati da due segnali diversi, quando c'è uno 0 c'è un inversione. È come se lo zero fosse associato ad un'onda quadra di frequenza doppia. La frequenza è la stessa, ma a valle dell'encoding ho introdotto una diversa frequenza, ogni volta che si passa da un bit all'altro (anche da 1 ad 1) si moltiplica per -1 (c'è anche un po' di modulazione in fase).

La catena è quindi questa:



l'antenna raccoglie il segnale dal reader, avviene il coding: modulazione in ampiezza, si va poi ad aprire e chiudere il circuito in modo che il segnale sarà alto o basso in base a come si apre/chiude e sulla cresta della sinusoida c'è una piccola variazione che è la sinusoida modulata in ampiezza che si sovrappone al rumore ambientale.

Una volta rimosso il rumore (che è costante), si ottiene una sinusoida sporca ma che si può riconoscere.

Man mano che ci si allontana in reader avrà difficoltà a riconoscere la sinusoida e questo dipende dalla sensitivity del reader ed anche dal coefficiente di modulazione del tag, quindi il collo di bottiglia è il link inverso dal tag al reader.

Potenze

La quantità di potenza trasmissibile in RFID non è per nulla banale: abbiamo visto che è legata alla distanza di lettura.

Si usano frequenze libere, quindi c'è un limite di emissione: quello europeo è riassunto in seguito

Frequency Band	Power	Duty cycle	Channel spacing	EIRP (ECC Decisions)	Notes
# 2440 - 2514 MHz	500 mW c.i.r. 1 W e.i.r.f.	up to 100%	> 15 %		Power levels above 500 mW are restricted to one radio frequency channel and the boundaries of a tracking and tracing system. The boundaries of a tracking and tracing system are defined by the boundaries of the tracking and tracing system.
#d 865 - 868 MHz	6.16 W ERP	1.0%	200 kHz		1.0% below (1.1%) shall be used, preferable way.
#d 865.6 - 867.6 MHz	3.2 W ERP	1.0%	200 kHz		1.0% below (1.1%) shall be used, preferable way.
#d 867.6 - 868 MHz	0.8 W ERP	1.0%	200 kHz		1.0% below (1.1%) shall be used, preferable way. In option of frequency agility.

EIRP indica l'intensità di campo che sto generando, che è il prodotto

$$EIRP = ERP \cdot 1.6 \quad (10.1)$$

negli USA è 4W perché siamo a frequenze maggiori, quindi attenuazione maggiore che è compensata con un po' di aumento di potenza.

È fondamentale quando si fa il budget.

10.2 Memorizzazione - UHF Gen 2 tag

I microchip hanno una memoria, divisa in banchi ed in più importanti sono due:

- EPC, dove ci si scrive il codice del prodotto sul quale viene apposto il tag (es il NUMERELLO del codice a barre). È memoria scrivibile
- tid memory: è il seriale del microchip, stringa non scrivibile. È posta nel produttore, ogni chip ha un codice diverso e permette la distinzione. C'è un problema di bit (ricorda ipv4)
- user memory: si può usare per scrivere dati utente, normalmente si possono scrivere poche parole
- zona protetta dove è possibile scrivere una password: tipico comando è il kill che serve a danneggiare permanentemente il microchip (es dopo un acquisto), il comando richiede la password
- CRC-16 che serve per integrità

(copia immagine va, NO).

EPC ha avuto debutto 20 anni fa, ad opera di Wal*Mart che ha imposto l'uso di tag RFID, poi è arrivato il Department of Defense, ora in Italia la polizia di stato.

10.3 Sicurezza di dispositivi medicali

Abbiamo visto molti scenari di comunicazione che hanno a che fare con il corpo umano, ora dobbiamo tenere conto che gli oggetti sono soggetti a vulnerabilità (**c'è tanta gente cattiva :()**).

Immaginiamo di avere diversi dispositivi nel corpo, che possono essere connessi con altri dispositivi per formare una **body area network**, sia per applicazioni biomedicali che sportive. Possiamo avere dispositivi impiantati che svolgono delle azioni salva vita, come elettro-stimolatori, pacemaker etc... che devono svolgere un processo con una certa cadenza di azioni ed acquisiscono molte informazioni sulla nostra salute. Avendo impiantato un dispositivo abbiamo "aperto" una canale wireless che è fondamentale per due aspetti:

- molti dei dispositivi nel tempo vengono configurati. Es: pacemaker viene periodicamente rivalutati in termini della configurazione. Il pacemaker ha un coil, viene poggiato un altro coil e riprogrammato. Lo può fare anche un mal intenzionato
- soprattutto i dispositivi wearable devono trasmettere dati fuori, anche elettro o cardiotimolatori mandano dati. Abbiamo un canale in ingresso ed in uscita

i dispositivi sono vulnerabili ad attacchi di tipo fisico ed informatico.

I dispositivi fisici che vanno sul corpo necessitano di poter avere:

- identificazione, ad esempio se facciamo un intervento occorre sapere che ci sono degli eventuali dispositivi impiantati, ad esempio la (americana) ha pensato di inserire degli RFID nei dispositivi impiantati

- configurabilità ed aggiornamento: si può fare aggiornamento del software anche di dispositivi impiantati
- auditable: se il dispositivo fallisce, occorre avere dei file di log per capire cosa va male. Serve sia per progettare meglio il dispositivo che per l'agenzia delle assicurazioni

il punto critico con i dispositivi medici è che questi gestiscono **dati personali**: questa è la parola chiave che ha che fare con la certificazione dei dispositivi medici.

Abbiamo le seguenti definizioni:

- un dato personale è un'associazione di un'ID personale ed un record di attività (es: nome con il numero di passi al giorno)
- una record di attività associa uno pseudonimo ad un dato relativamente ad attività, transazioni, locazioni, o altre persone
- uno pseudonimo può essere nome e cognome ma anche un codice, che di per sé non dice nulla ma da qualche parte in un DB si arriva al nome e cognome. Deve essere univoco e rappresentabile con un set univoco di valori.

Abbiamo quindi dati personali e pseudonimi.

La gestione dei dati personali apre due grossi capitoli:

- security: impostare dei confini contro utenti non autorizzati, quindi proteggere i dati da accessi non autorizzati. Il problema qui è fare in modo che i dati non siano acceduti a dati a cui non può (anche in chiaro). Qui occorre proteggersi da accessi non autorizzati, es: i dispositivi medici devono essere protetti dalle modifiche ai dati. Va risolto a livello fisico;
- privacy: l'utente deve avere consapevolezza di chi sta utilizzando e chi userà i dati, quindi anche eventualmente che possano essere vendute. La privacy è quindi definire un limite alle politiche relativamente all'uso del dato, quindi dare all'utente il controllo dell'informazione su chi manipola i dati e chi li usa, qui può esserci breccia sulla confidenzialità. Si firma un contratto.

hanno un peso molto maggiore quando si ha a che fare con dispositivi medici, perché i dati sono dati sanitari. Tutto ciò che ha a che fare con i dati sensibili deve essere legato a security e privacy, quindi si sta passando alla parte di security and privacy by design.

I due aspetti si combinano:

	Personal Data	Non-Personal Data
Unauthorized User (mechanism)	Security and Privacy	Security
Authorized User and Use (policy)	Privacy	/

es: nel caso 3, possiamo accedere ai dati ma magari non possiamo usarli come vogliamo.

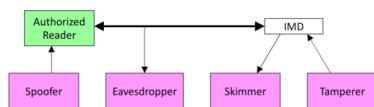
10.3.1 Fondamenti di sicurezza

Abbiamo diverse proprietà:

- autenticazione: poter dimostrare che un'entità può accedere ai dati (es con password). Lato malevolo, c'è lo spoofing, quindi impersonare un'entità che è qualificata per accedere a dei dati.

- confidenzialità: si scambiano informazioni su un canale, ci può essere lato malevolo eavesdropping, quindi intercettazione di dati. Molto più semplice se il canale è di tipo wireless
- integrità: devo garantire lato servizio che l'informazione che memorizzo e quella che trasmetto non siano state in alcun modo modificate. Lato malevolo può esserci interesse a modificare il dato acquisito dal sensore
- disponibilità, ovvero garantire che le risorse del sistema siano istantanee e continue in qualunque momento, non possiamo ammettere disservizi. Può esserci un tentativo di DoS lato attaccante, ad esempio mandando una serie di informazioni inutili che rende la comunicazione col dispositivo inutilizzabili.

Abbiamo quindi il seguente schema:



Lo skimmer è un dispositivo che legge i dati del dispositivo medico cercando di rubarli. C'è poi il tamperer (effrattore) che cerca di provocare un malfunzionamento nel dispositivo.

La privacy ha diversi obiettivi:

1. il fatto di avere un dispositivo impiantato non può essere noto;
2. device-type privacy: se il dispositivo è visibile, non può essere noto il modello
3. specific device id: non si può sapere il codice del dispositivo
4. measurement and log privacy: entità non autorizzate non possono avere accesso ai dati di telemetria
5. non deve essere possibile identificare un paziente da un dispositivo
6. tracciamento, le entità non autorizzate non possono usare i dati del dispositivo medico non solo per identificare ma per tracciare

la fase di design del sistema deve anche includere una fase di privacy assessment, quindi prima di mettere in vendita il dispositivo occorre verificare che vi siano procedure che garantiscono gli obiettivi.

10.3.2 Tipi di attacco

Abbiamo due tipi di attacco:

- passivo: l'avversario si limita ad ascoltare
- attivo, l'avversario può iniettare informazioni

può essere:

- interno: l'avversario può essere qualcuno che può essere autorizzato
- esterno
- singolo

- associazione criminale

non esiste la sicurezza al 100%, si può solo aumentare la sicurezza e più si aumenta la sicurezza può il "malintenzionato" deve avere un livello di conoscenza maggiore.

Il target dell'attacco può essere

- paziente, acquisire informazioni come dove si trova, la malattia (diagnosi) e creargli un fastidio psico fisico
- dispositivo o produttore, può acquisire l'informazione per spionaggio industriale
- sistema che gestisce le risorse, può voler usare il dispositivo in maniera non autorizzata o compromettere la rete

Le minacce possono quindi avvenire:

- al sistema di telemetria, magari posso far sì che il dato non sia più accurato
- al software: coordina sia il sensore che il sistema di telemetrica
- all'hardware o interfaccia di sensore

abbiamo quindi le due grandi classi di sicurezza informatica:

- cybersecurity: proteggere da un attacco dispositivi che includono procedure o programmi informatici. Si attacca un sistema informatico, tipicamente con un malware.
- physical security: protezione da azioni fisiche ed eventi che possono causare perdita di dati o funzionalità. Significa anche protezione rispetto ad incendi, atti di vandalismo etc... qui c'è un attacco di tipo EM. Attacchi fatti a dispositivo fatti da componenti hardware

sono completamente differenti ma che hanno diverse tecnologie di mitigazione: il primo è il grosso del problema, il secondo è più subdolo perché non si sa dove sta.

L'utente che ha oggetti wearable deve stare attento a diverse cose, ora è cruciale sia per un fattore di pre-design che di post design.

Capitolo 11

Lezione 11

11.1 Security and privacy threats

Attacco passivo: fa eavesdropping su dati privati, quindi anche un dispositivo impiantato potrebbe avere dati come diagnosi o ECG, l'effetto di captazione non mette a repentaglio il funzionamento del dispositivo, ma è una violazione della privacy.

Gli attacchi sono stati dimostrati su dispositivi off-the-shelf (comuni, non sofisticati).


Gli attacchi attivi invece consistono nell'inviare un comando non autorizzato al dispositivo, di tipo fisico e che può mettere in difficoltà il dispositivo

- spegnere un pacemaker da fuori;
- defibrillatore aggressivo, che rilascia uno shock al cuore;

esempio realmente accaduto: sistema che rilascia insulina in modalità controllata, misura il livello di glucosio e deve rilasciare l'insulina. Sul dispositivo hanno individuato problemi di privacy security: potevano essere artefatte delle letture di livelli di insulina ed usare la valvola in maniera impropria, somministrando dosi basse o elevate.

Cosa si può fare: la via maestra è quella dell'encryption, così che anche se le informazioni vengono rilevate non si può fare nulla oppure fare in modo che il device rilasci informazione solo su autorizzazione:

si usa RSA, il dispositivo medico e l'interrogatore hanno le due chiavi e nota una chiave è difficilissi-



simo recuperare l'altra. È richiesta un'attività di calcolo importante, quindi vuol dire un incremento di energia e di risorse. La chiave è contenuta nel dispositivo ed è protetta dall'accesso esterno.

Ma così come ci si ingegna a cercare tecniche crittografiche sofisticate, dall'altro c'è la crittoanalisi: cercare di capire come funziona il cifrario. Si da per scontato che l'attaccante conosca come è fatto il cifratore, l'unica cosa che deve fare è individuare la chiave segreta. Chi progetta i dispositivi deve fare del proprio meglio per rendere il recupero della sk il più arduo possibile ammettendo che sia noto il protocollo, l'hardware etc...

Per rubare la chiave, da un punto di visto fisico, si può applicare un side channel attack: un side channel non proviene tanto dall'algoritmo ma dall'implementazione fisica (nei circuiti e componenti), così da permettere che vengano estratti numeri e cercare di capire come l'effetto fisico, elettronico

meccanico possa.

È difficile fare penetration test perché l'informazione recuperata può essere elettrica, termica, acustica etc...

Basandosi su analisi temporale: serve avere conoscenza tecnica. Es: il segnale seguente è un tentativo di scoprire la chiave segreta del cifrario RSA, usando un'analisi in potenza. Il picco dell'algoritmo dice che si stanno facendo delle azioni senza moltiplicazioni, mentre quella di destra include le moltiplicazioni. Quindi, con un approccio statistico si può capire come vengono codificati 0 ed 1.

4 tipi di side channel:

- Timining: basato sulla misura di quanto tempo viene occupato da alcuni task computazionali, quanto ci mette il dispositivo a comparare una password fornita dall'attaccante con quella incognita della vittima. Si osservano le variazioni sul tempo che viene usato per fare delle operazioni crittografiche si può trovare la chiave, avendo molti trial a disposizione;
- Power-monitoring attack: fa uso dell'informazione sulla variazione di potenza consumata dall'hardware durante il calcolo. Osservando la CPU, abbiamo molte informazioni su quanta potenza sta consumando durante le operazioni. Occorre avere accesso nel dispositivo
- acoustic crypto analysis: in alcuni casi, mentre il sistema lavora le parti meccaniche possono produrre dei suoni associate alle operazioni di crittografia
- attacchi EM: grossa branca, non necessitano contatto fisico col dispositivo. Tutti gli elementi elettronici emettono onde EM, a frequenze preferenziali, nel dispositivo sono delle micro-antenne che producono campi che non volontariamente rivelano informazioni a patto che non siano ben progettati.

Negli attacchi EM si cerca di misurare la sk misurando la variazione EM emessa dal dispositivo ed applicando signal processing in maniera massiva. Nota la sk possiamo entrare in maniera libera al dispositivo, questi attacchi sono tipicamente passivi, ma in alcuni casi possono essere attacchi dove si manda un segnale che rovina il dispositivo. Se si ha la possibilità si possono fare delle analisi più accurate andando a spacchettare il dispositivo, togliendo l'involucro etc... per avvicinarsi di più alla sorgente emittente.

Le emissioni avvengono perché i dispositivi hanno due front-ends:

- analogico, per acquisizione dati dei sensori, per fare harvesting di energia, per comunicare il dato...
- digitale, è fatta di transistor che computano fra due livelli alto/basso per processare informazioni binarie. La corrente scorre e vengono prodotte delle onde quadre in banda base e quindi questa transizione basso/alto è molto netta, quindi la trasformata di Fourier darà un segnale con lo spettro molto elevato: la corrente continua non irradia, man mano che la frequenza comincia a salire il movimento degli elettroni produce un'irradiazione che contiene informazioni di cosa sta accadendo all'interno.

Per prendere le informazioni, il modo più facile è usare un coil ad induzione: (immagine) si avvicina al dispositivo emittente, l'informazione va ad un digital converter che recupera la forma d'onda

Tipicamente abbiamo la noise, l'informazione è sui picchi che ci dicono che ci sono delle transizioni importanti.

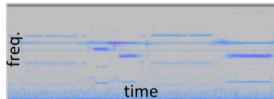


Figura 11.1: x tempi ed y frequenze

11.1.1 Emissione

L'emissione può essere diretta ed in generale non intenzionale. L'emissione diretta è legata alle correnti che portano il segnale da un circuito all'altro, man mano che passano come effetto collaterale irridiano su una banda piuttosto larga, le componenti a frequenze più elevate sono le più appetibili per l'attaccante perché sono lontane dal rumore. Occorre avvicinarsi al dispositivo con i coil di lettura, in alcuni casi per ottenere buoni risultati occorre fare unpacking del dispositivo. Le correnti sono quindi intenzionali e producono delle emissioni intenzionali, va contrastato il fenomeno in progettazione.

Ci sono poi le emissioni non intenzionali: quando la corrente si propaga, interagendo con altri dispositivi, fanno sì che venga indotto una emanazione di nuove componenti spettrali, rivelando delle informazioni anche di questo ulteriore dispositivo, quindi indirettamente possiamo sapere cose su un dispositivo che magari sta facendo elaborazione.

Piccole osservazioni, che spesso sono ignorate dal progettista, è estremamente delicato. Vi sarà un segnale digitale, che può portare a produrre un segnale che è modulato in ampiezza e facendoli interagire troveremo che la sinusoide viene parzialmente modulata, quindi il disturbo sinusoidale del dispositivo 1 + il segnale del dispositivo 2 fanno sì che si abbia una modulazione in ampiezza non intenzionale su cosa sta facendo il dispositivo 2: (immagine).

Per catturare le emissioni:

- accesso al dispositivo
- potersi avvicinare per captare
- catturare i dati in campo lontano, usando delle antenne direttive: persona con il medical device, l'attaccante deve dotarsi di antenna direttiva e può pensare di catturare i dati a distanza in modo che non sia visto. Per dispositivi passivi è molto improbabile, mentre per bluetooth è fattibile.

11.1.2 Esempio: attacco Mifare

Mifare è un protocollo di sicurezza proprietario della società NxP che produce dispositivi RFID, NFC... spinoff della Philips e sono fra i maggiori produttori di chip.

Le due chiavi sono una dentro alla serratura ed una della carta:

- primo step è autenticazione, se viene stabilito che le chiavi siano accoppiate si va avanti altrimenti nulla
- attacco: l'attaccante arriva con un dispositivo che finge di essere una carta, poi comincia a captare cosa il reader risponde
- scarica il dato dalla carta impostare e recupera la chiave crittografica
- attacco: si passa col coil vicino alla carta utente carpendone i dati. Il dispositivo aveva impersonificato il lettore fisso.

quindi la lettura può essere effettuata in maniera fisica, quanto più il sistema è semplice maggiore è la probabilità che siano poco sicuri. L'aumento di sicurezza è sempre relativa ad un aumento di consumo di potenza e quindi di una minore autonomia.

È un attacco passivo, che legge senza dare fastidio al dispositivo

11.1.3 Fault-induction attack

Si mette il dispositivo in condizioni di lavorare male, così che mi manderà informazioni più ricche di quelle in condizioni ideali, così da avere più dati su cui applicare la cryptoanalysis. Facendo funzionare un dispositivo in maniera errata può mostrare comportamenti non protetti in fase di progettazione, si fanno lavorare fuori specifica per ottenere più informazioni.

I danni possono essere permanenti, arrivando a danneggiare il dispositivo crittografico, producendo:

- reset memoria
- piccoli tagli al bus dati

oppure produrre un malfunzionamento transitorio, facendo ad esempio in modo di mandare un segnale a frequenze maggiori, aumentando la temperatura di funzionamento, rivelando codici a cui altrimenti non avrei avuto accesso.

Si può poi anche mandare radiazione focalizzata che possa mettere in difficoltà il dispositivo.

Progettando un dispositivo occorre quindi fare in modo che l'attaccante:

- non consumi la batteria
- non abbia overflow dei dati
- non ci sia jam della comunicazione

La suscettibilità dice quanto un dispositivo è incline a raccogliere dei disturbi che produce verso l'esterno.

Nel caso passivo domina l'emissione, anche essa quantificabile, qui dipende dalla suscettibilità.

sindrome della Havana: non molti anni fa, sono stati riportati dei sintomi biofisici da alcuni ambasciatori Americani: la vittima sentiva una specie di suono fastidioso, che veniva percepito da un posto specifico ma dove poi non c'era nulla, altri sentivano una specie di vibrazione come una risonanza meccanica.

L'effetto è stato documentato in articolo del 2018: la congettura è che i diplomatici fossero stati attaccati da un'antenna a microonde che mandava una onda dalla forma di una specie di "palla", in modo che se ci fosse un dispositivo impiantato il danno fosse stato importate. Quindi prima di andare sul posto, se fa la bonifica EM così da stare più sicuri.

11.2 Privacy

La capacità di poter controllare come vengono utilizzate le informazioni personali, non molto tempo fa (2004) la FDA (equivalente del CE) ha approvato l'utilizzo di dispositivi RFID impiantati così da poter accedere ai dati medici anche quando l'utente non è in grado di cooperare.

L'attaccante non deve essere in grado di tracciare il dispositivo medico, dobbiamo avere il controllo della nostra posizione, di quale dato viene utilizzato e dell'uso che se ne fa. Dati privati:

- nome
- storia medica
- tracking, ovvero evoluzione nel tempo delle informazioni

11.2.1 Violazione della privacy

Viene costruita una storia dell'utente senza che esso ne sia a conoscenza, quindi c'è privacy breach in quanto viene mostrato l'ID personale ad una parte non autorizzata + tracking che rileva la registrazione di un fenomeno. Siamo in un centro commerciale: Helen si compra un cappello, tutti gli oggetti hanno un etichetta EM, dove c'è un puntatore col quale il negozio può risalire alle informazioni. Il cappello è quindi ora un oggetto digitale, in quanto l'etichetta ha un identificativo univoco in grado di fornire dati.

Helen ha il cappello, lo compra e può pagarlo con la carta di credito. Il negozio sa che Helen ha acquistato il cappello #1, supponiamo che l'informazione resti privata.

Helen esce con sto cappello difettato e decide di non togliere l'etichetta perché c'ha un armadio digitale e se diverte a cataloga cappelli e scarpe (tacci tua Helen).

Continua a passeggiare per negozi e quando entra nel negozio, siccome ci sono sicuramente dei varchi, attraversandolo questo si rende conto che sta passando un tag RFID rivela il codice del cappello. Dallo store B passa a C, D ed E e se c'è un sistema di controllo degli accessi centralizzato, si riesce a ricostruire il cappello #1 e quindi tracciato la persona.

A na certa, Helen incontra un'amica Suzie che ha acquistato un maglione, pure lei co sta mania de tene le etichette (so matte). Quindi abbiamo due entità di cui sappiamo quali traiettorie hanno percorso: sebbene non sia stato commesso nessun illecito, viene prodotta molta informazione da un'etichetta con RFID, le informazioni possono essere rivendute in quanto i negozi possono avere la facoltà di rivenderle ad aziende terzi.

Si può fare la profilazione del gusto, inoltre le informazioni specifiche della persona non appaiono in nessun dato pubblico ma basta recuperare l'associazione cappello - Helen per ricondurre tutto a lei.

Ci si muove in una zona "grigia" per quanto riguarda la legalità, ci sono ancora dei punti dove l'informazione viene acquisita in maniera non nota.

11.3 Security and privacy by design

Il ruolo dell'ingegnere in questi casi è di prevenire delle "sbavature" di questo tipo e quindi di applicare delle misure di security and privacy by design, che accompagnino il dispositivo durante tutto il suo ciclo di vita: sia quando viene impiantato che aggiornato etc...

Sta avvenendo una trasformazione delle regole per l'immissione nel mercato dei dispositivi medici:

- aspetti di biocompatibilità
- requisiti sulla compatibilità elettromagnetica
- anche il software va descritto (vedi SERT)
- necessità di assicurare che siano stati considerati anche aspetti di sicurezza e privacy

l'FDA considera le linee guida come motivo per rigettare la domanda di immissione.

C'è un aspetto collaterale: rendere i dispositivi più sicuri prevede di complicare il dispositivo.

Usando sistemi crittografici viene ridotta la possibilità di accedere al dispositivo in maniera libera: se un paziente sta in India (**cit***) occorre fare in modo che i dati siano leggibili, ma se non ci sono i sistemi adeguati. Occorre bilanciare l'usabilità con la sicurezza.

11.3.1 Mitigazione degli attacchi

Si sta andando verso la creazione di chiavi che abbiano una genesi di tipo biometrico: costruisco una chiave misurando un fenomeno fisico come l'ECG, in quanto è noto che i segnali generati sono diversi

da individuo ad individuo, anche la variabilità fra i battiti cardiaci.

Il dispositivo medico ed il lettore non si scambiano una chiave fissa, bensì viene volta per volta costruita misurando un fenomeno fisico che cambia volta per volta: il cerotto o l'aggeggio smart fa delle misurazioni che producono due chiavi identiche se misurano ad esempio il battito cardiaco, sappiamo che la misurazione sta avvenendo sul corpo.

Altra possibilità è fare in modo che la lettura possa avvenire solo a piccole distanze: il dispositivo che legge deve sapere quanto ci mette a leggere il dato così da sapere quanto è distante.

In ultimo, si usa un 3° dispositivo, il watch dog elettronico, che si frappone fra il MD ed il lettore:

- il lettore non si autentica col dispositivo medico ma lo fa con lo shield
- il MD può avere una elettronica semplice, la potenza crittografica sta nel watch dog.
- il lettore si fa prima riconoscere dallo shield, che interroga il dispositivo medico e restituisce la risposta

Variazione sul tema: lo shield produce un jamming sul dispositivo medico così che il lettore non possa interagirvi, una volta che il lettore si è autenticato con lo shield quest'ultimo tira giù la barriera e può avvenire la comunicazione.

Ultimo, usare un canale diverso da quello della comunicazione per l'autenticazione (es 500 KHz) oppure usare un'autenticazione di tipo diverso:

- ottico
- tattile: per leggere il dato, avviciniamo il dito per far sì che la frequenza si adatti e si trasmetta il dato

11.3.2 Contromisure

Si lega alla branca dell'EMC (EM Compatibility), molto di quel know si trasmette in sicurezza:

- schermare il dispositivo per ridurre la potenza del segnale, quando si può fare, così da non permettere la lettura esterna
- randomizzare il segnale trasmesso, si mischia il segnale fittizio

Capitolo 12

Lezione 12

12.1 Compatibilità EM

Le problematiche che ci possono essere sono riconducibili a


- emissione
- suscettibilità

entriamo ora nel dominio della compatibilità EM, vedremo in particolare

- emissione radiata: ha a che fare con la capacità di rivelare segreti, ma anche produrre interferenze verso altri dispositivi vicini
- suscettibilità radiata: è una proprietà o un effetto legato alla ricezione di disturbi che siano non intenzionali o di tipo malevolo.

è una branca dell'ingegneria molto sviluppata negli anni.

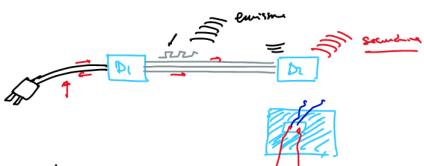
Introduciamo il concetto di **disturbo**, tipicamente si fa riferimento a questo schema qui:



il secondo blocco può essere sia la vittima che anche l'effratore, quindi il malevolo.

Affinché i due interagiscano fra di loro è necessario che vi sia un canale, quindi un percorso di accoppiamento in modo che il campo prodotto dall'emettitore raggiunga la vittima e viceversa.

Per avere l'interazione devono esserci tutti e 3 i pezzi, è il classico schema dell'interferenza EM (EMI). Come avviene l'emissione di un segnale: per effetto di correnti, quindi immaginiamo il seguente schema:



abbiamo dei dispositivi legati fra di loro da bus dati, ovvero che devono trasportare segnali.

Può poi capitare che il dispositivo sia collegato alla presa di rete, le correnti che scorrono devono farlo per necessità, se il loro contenuto spettarle è elevato viene prodotta un'emissione, che può produrne un'altra nel dispositivo D_L che può fornire informazioni in maniera involontaria.

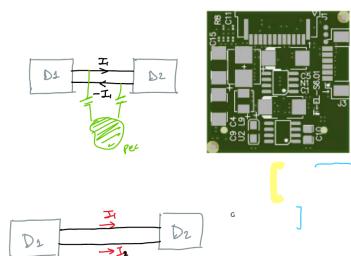
La suscettibilità è il caso duale: lo schema è lo stesso, tutti i percorsi dai quali i produce energia possono raccoglierla, quindi i fili possono divenire antenne: se ci sono delle aperture, il campo può uscire ma anche entrare dall'esterno.

In entrambe i casi, il disturbo viene emesso/raccolto per radiazione, esistono anche di tipo condotto dove il canale sono dei fili che raccolgono il segnale e lo trasmettono da altre parti, chiaramente in questo caso il canale è più efficiente dell'etero in quanto c'è meno attenuazione.

Vediamo due modelli per capire come funzioniamo i fenomeni e da quali parametri sono determinati

12.1.1 Modelli di emissione

Consideriamo nuovamente una coppia di dispositivi, che possono anche essere due circuiti integrati in un PCB:



i dispositivi sono interconnessi, sui fili passeranno delle correnti che dovrebbero essere di conduzione. L'effetto radiativo dovrebbe tendere a bilanciarsi, ma la situazione non è così pulita: un circuito pcb è fatto da linee che non sono del tutto isolate, quindi se immaginiamo di porre un oggetto metallico vicino, si satbiliranno delle interazioni con i fili (che possiamo schematizzare come dei condensatori) che faranno sì che le correnti non siano più bilanciate. Chiamiamo nel nuovo modello le correnti I_1 ed I_2 generiche e non meglio specificate. Quando abbiamo due correnti diverse, si possono sempre scomporre in due set di correnti: possiamo introdurre delle **correnti di modo comune**, che chiameremo I_C e delle **correnti di modo differenziale** I_D , possiamo scrivere come sovrapposizione degli effetti:

- $I_1 = I_C + I_D$
- $I_2 = I_C - I_D$


e ricavare le due:

- $I_C = \frac{I_1 + I_2}{2}$
- $I_D = \frac{I_1 - I_2}{2}$

possiamo quindi rifare il disegno:

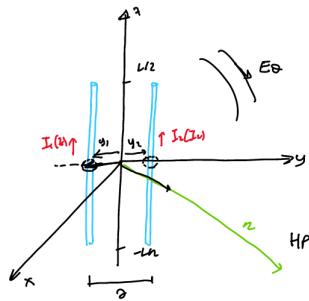
vanno in qualche modo sovrapposte, applicando la sovrapposizione degli effetti.

Le correnti di modo differenziale sono quelle che dobbiamo avere nel dispositivo, con cui trasferiamo potenza e dati. Le correnti di modo comune sono degli effetti collaterali, legate all'interazione con



oggetti vicini, possiamo immaginarle come "antenne nascoste" e sono un problema da un punto di vista del funzionamento perché produrranno irradiazione, ma da un punto di vista della sicurezza sono una vulnerabilità perché tx al di fuori della basette delle informazioni.

Per fare delle analisi quantitative, immaginiamo che i fili siano paralleli ed approssimabili a dei dipoli:



ammettiamo che i fili siano lunghi l e la spaziatura sia s , avremo poi le due correnti.

L'oggetto viene considerato con il **metodo degli Array**: questo è un array di due fili, possiamo inserire le posizioni

- $y_1 = -\frac{s}{2}$;
- $y_2 = \frac{s}{2}$

e valutiamo l'irradiazione dei fili come se fossero un array.

Facciamo delle ipotesi:

- campo lontano
- trascuriamo gli effetti di oggetti vicini

se abbiamo fili rettilinei disposti in questo modo, il campo elettrico avrà una componente E_θ che sarà:

$$E_\theta = MI(0) \frac{e^{-jk_0 r}}{r} f(\theta) \quad (12.1)$$

è la corrente in $z = 0$, $f(\theta)$ trattandosi di un dipolo non dipende da ϕ .

Se $L \ll \lambda$ perché stiamo parlando di linee di conduzione quindi sono tratti piccoli possiamo immaginare che i fili siano dei dipoli elementari, quindi la funzione di radiazione è

$$f(\theta) = \sin\theta \quad (12.2)$$

$$M = \frac{j\eta_0 k_0}{4\pi} L = j \frac{120\pi 2\pi}{c 4\pi} f L = j \frac{60\pi}{c} f \cdot L \quad (12.3)$$

C'è l'effetto che l'intensità del campo aumenta anche con la frequenza, è il campo del singolo filo, consideriamo quello dei due fili e ne facciamo la somma con la **teoria degli array**:

$$E_\theta^A = E_\theta^1 + E_\theta^2 = M \frac{e^{-jk_0 r}}{r} F(\theta, \phi) \sin\theta \quad (12.4)$$

dove

$$F(\theta, \phi) = \sum_{n=1}^2 I_n e^{j k_0 \underline{\rho}_n \cdot \hat{r}} \quad (12.5)$$

è il **fattore di array** ed abbiamo:

- $\underline{\rho}_n = y_n \hat{y}$;
- \hat{r} , versore di osservazione

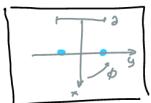
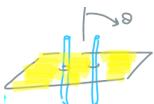
Abbiamo quindi

$$\underline{\rho}_n \cdot \hat{r} = y_n \sin \theta \sin \phi \quad (12.6)$$

c'è dentro $\hat{r} \cdot \hat{y}$ e quindi otteniamo

$$E_\theta^A = M \frac{e^{-j k_0 r}}{r} [I_1 e^{-j k_0 \frac{s}{2} \sin \theta \sin \phi} + I_2 e^{+j k_0 \frac{s}{2} \sin \theta \sin \phi}] \sin \theta \quad (12.7)$$

Per ripulire l'espressione, andiamo ad osservare cosa succede su un piano che attraversa i due fili, semplifichiamo per $\theta = \frac{\pi}{2}$:



quindi ci mettiamo sul piano giallo.

L'espressione che otteniamo è

$$E_\theta^A = M \frac{e^{-j k_0 r}}{r} [I_1 e^{-j k_0 \frac{s}{2} \sin \phi} + I_2 e^{+j k_0 \frac{s}{2} \sin \phi}] \quad (12.8)$$

guardiamo il dispositivo in sezione e vediamo cosa succede fra i due elementi.

Possiamo particolareggiare l'espressione dei due casi dei due modi.

Modo differenziale

La condizione è che $I_1 = I_D$ ed $I_2 = -I_D$ e quindi la E_θ^A sarà dato da

$$E_\theta^A = -j f \cdot L \frac{e^{-j k_0 r}}{r} 2 j \sin(k_0 \frac{s}{2} \sin \phi) \cdot I_D = \frac{120\pi}{c} f \cdot L \frac{e^{-j k_0 r}}{r} \sin(k_0 \frac{s}{2} \sin \phi) \cdot I_D \quad (12.9)$$

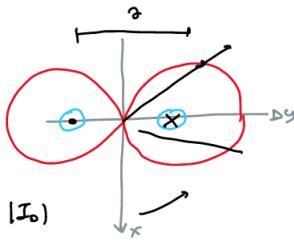
(NB: esponenziale è il termine di onda sferica!) il $k_0 \dots$ viene dalla formula di Eulero.

Come è fatto l'andamento in coordinate polari:

considerando $\phi = 0$, il sin fa 0 e quindi il campo è 0, il campo prodotto è fatto nel seguente modo:

L'irradiazione massima si ha per $\phi = \pm 90^\circ$, dove abbiamo

$$|E_{\theta, \max}^D(\phi = 90^\circ)| = \frac{120\pi}{c} \frac{f \cdot L}{r} \sin(k_0 \frac{s}{2}) |I_D| \quad (12.10)$$



se ammettiamo che la spaziatura $s \ll \lambda$ (ed è lecito), allora abbiamo $\sin k_0 \frac{s}{2} \approx k_0 \frac{s}{2}$ ma abbiamo anche

$$\sin k_0 \frac{s}{2} \approx k_0 \frac{s}{2} \quad (12.11)$$

e

$$\frac{2\pi s}{\lambda} \frac{1}{2} = \frac{2\pi s \cdot f}{c} \frac{1}{2} = \frac{\pi f \cdot s}{c} \quad (12.12)$$

e quindi infine

$$|E_\theta^D|_{max} = \frac{120\pi}{c} \frac{f \cdot L}{r} \pi \frac{f \cdot s}{c} \quad (12.13)$$

(nb: c è la velocità della luce!!), che numericamente è $1,31 \cdot 10^{-14} \frac{f^2 L s}{r} |I_D|$.

Analizzando, vediamo che dipende dalla corrente di modo differenziale, quindi normalizziamo per la corrente di conduzione ed otteniamo

$$\frac{|E_\theta^D|_{max}}{|I_D|} = 1,31 \cdot 10^{-14} \frac{f^2 L s}{r} \quad (12.14)$$

che ha unità di misura $\frac{V}{m} [A^{-1}] = \frac{\Omega}{m}$ e quindi è la **Funzione di Leakage**, quindi non è affatto vero che una linea di trasmissione non irradia, tale irradiazione dipende dal quadrato della frequenza e questa è la ragione per cui le linee di trasmissione non si usano mai a frequenza elevata.

C'è poi la dipendenza dal prodotto $(L \cdot s)$, dove se i fili sono lunghi L e la distanza è s questa rappresenta l'area fra i due fili, quindi un modo per ridurre l'irradiazione è

- non avere delle tracce lunghe, ridurre la lunghezza dei fili
- avere delle tracce molto vicine, diminuire s

Questi sono gli aspetti che devono essere tenuti conto nella security by design

modo comune

Qui abbiamo $I_1 = I_2 = I_C$ e questo nasce dallo sbilanciamento delle linee di conduzione per effetto dell'accoppiamento con degli oggetti vicini.

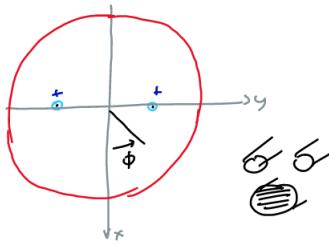
Otteniamo un'espressione simile dove però avremo dei coseni al posto dei seni

$$E_\theta^C = M \frac{e^{-jk_0 r}}{r} I_C 2 \cos(k_0 \frac{s}{2} \sin \phi) \sin \theta \quad (12.15)$$

Ci mettiamo anche qui nella condizione sul piano $(\theta = \frac{\pi}{2})$ e possiamo disegnare il diagramma di irradiazione:

è un diagramma abbastanza omni-direzionale, quindi non c'è nessuna direzione verso cui riusciamo a proteggere l'informazione. Sempre considerando $k_0 s \ll 1$ possiamo approssimare il cos ad 1. Qui, per $\phi = 0$ abbiamo la massima radiazione ed otteniamo un campo massimo

$$E_{\theta, max}^C \approx 2M \frac{e^{-jk_0 r}}{n} I_C = 2j \frac{60\pi}{c} f \cdot L \frac{e^{-jk_0 r}}{r} I_C \quad (12.16)$$



Anche ora possiamo calcolare una funzione di trasferimento che prescinde dal valore della corrente di modo comune ottenendo

$$\frac{|E_{\theta, \text{max}}^C|}{|I_C|} = \frac{120\pi}{c} \frac{f \cdot L}{r} = 1.26 \cdot 10^{-6} f \cdot \frac{L}{r} \quad (12.17)$$

Qui vediamo che dipende solo con la prima potenza dalla frequenza, quindi la crescita è meno spedita del caso precedente. Dipende poi dalla lunghezza dei fili, non dipende più dalla distanza perché è come avere un unico dipolo un po' più grande sulla quale scorre una corrente che è la somma delle due, è poi inversamente proporzionale alla distanza.

Il coefficiente è molto più alto dell'altro $10^{-6} \gg 10^{-14}$ quindi l'effetto è molto più aggressivo: piccole correnti di modo comune possono produrre elevati livelli di campo irradiato, comunicando all'esterno delle informazioni su cosa sta avvenendo all'interno.

esempio:

immaginiamo di stare ad una frequenza di $100MHz$, che può essere la frequenza di clock di un dispositivo biomedicale. Immaginiamo che

- i fili abbiamo la lunghezza $L = 1\text{cm}$;
- $s = 1\text{mm}$;
- osserviamo il fenomeno ad $r = 1\text{m}$ di distanza;

Calcoliamo:

- la funzione di trasferimento del modo differenziale: $1.31 \cdot 10^{-14} \cdot 10^{16} \cdot 10^{-2} \cdot 10^{-3} = 1.31 \cdot 10^{-3} \frac{\Omega}{m}$. Quindi $1mA$ produrrà $1.3 \cdot 10^{-6} V/m$ di emissione, che è basso ma è un valore più alto di quello che il telefono riesce a percepire e quindi identificabile e misurabile
- modo comune: $1.26 \cdot 10^{-6} \cdot 10^8 \cdot 10^{-2} = 1.26 \frac{\Omega}{m}$, quindi confrontato con quello di sopra abbiamo effettivamente che $1mA \rightarrow 1.26 \frac{mV}{m}$ che è un livello di campo facilmente individuabile

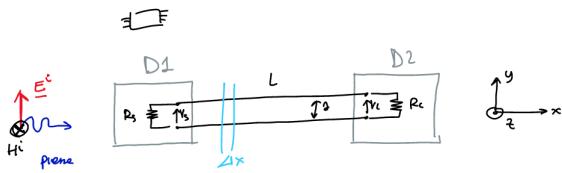
se non si possono fare collegamenti corti e vicini, l'unica cosa che si può fare è richiudere il circuito in una scatola PEC, che è un oggetto metallico che blocca l'irradiazione spuria, ma non si può fare sempre (ad esempio in molti dispositivi medici impiantati o da "spalmare" sul corpo umano)

12.1.2 Suscettibilità

È legata all'inclinazione di un dispositivo elettronico di raccogliere disturbi provenienti dall'esterno. Facciamo sempre un modello:

due dispositivi collegati da un bus, possiamo modellare i dispositivi con due carichi reali R_L ed R_S , con le tensioni V_S e V_L , L è la lunghezza ed s la spaziatura.

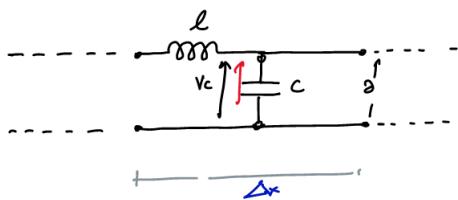
Immaginiamo che da fuori arrivi un campo EM, dove il campo elettrico si propaga nella direzione indicata, polarizzato verticalmente (E), mentre il campo magnetico entrante nel foglio (H). Il campo investe il dispositivo radente, abbiamo:



•

- $\underline{E}^i = \underline{E}_y^i \cdot \hat{y}$
- $\underline{H}^i = -\underline{H}_z^i \cdot \hat{z}$

vogliamo esprimere le due tensioni sia rispetto alla geometria che rispetto al campo incidente. Consideriamo una "fettina" di lunghezza $H(??) \cdot x$, che modelliamo come un'induttanza ed una capacità (tutte per unità di lunghezza):



Abbiamo un spessore lungo Δx e vale:

$$c = \pi \epsilon_0 \epsilon_r \frac{1}{\ln \frac{s}{r\omega}} \left[\frac{F}{m} \right] \quad (12.18)$$

e poi abbiamo

$$l = \frac{\mu_0}{\pi} \ln \frac{s}{r\omega} \left[\frac{H}{m} \right] \quad (12.19)$$

possiamo tenere conto di

1. un generatore di corrente equivalente: si ottiene calcolando la tensione indotta V_C dal campo elettrico incidente, che è data dalla circuitazione del campo E :

$$V_C = - \int_0^s \underline{E}^i \cdot \underline{dy} = - \int_0^s E_y^i dy \quad (12.20)$$

e poi abbiamo la corrente I^i che viene iniettata per effetto del campo incidente

$$I^i = \frac{V_C}{X_C} = -j\omega c \int_0^s E_y^i dy \quad (12.21)$$

2. un generatore di tensione, può essere in serie o in parallelo: consideriamo nuovamente il pezzo di filo di prima, immaginando che faccia parte di una spira chiusa dove una parte è un condensatore ed il resto una curva matematica.

Verrà generata una forza elettromotrice indotta (sempre la circuitazione)

$$emf = \oint_{\mathcal{C}} \underline{E}^i \cdot \underline{dl} \quad (12.22)$$

È una forza potenziale che vale qualunque sia il percorso chiuso, possiamo esprimere in funzione di H , mediante il **teorema di Stokes** che dice che

$$emf = \oint_{\mathcal{C}} \underline{E}^i \cdot d\underline{l} = \iint_{S(\mathcal{C})} \nabla \times \underline{E} \cdot \hat{u} d\sigma \quad (12.23)$$

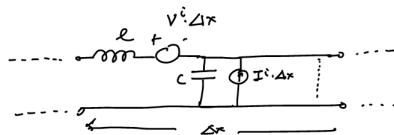
(\mathcal{C} è il contorno chiuso).

Otteniamo quindi una emf in funzione del campo magnetico

$$emf = V^i = j\omega\mu_0 \int_0^s H_z dy \quad (12.24)$$

È una tensione per unità di lunghezza

Consideriamo quindi il circuitino di prima



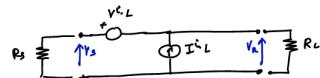
Se ammettiamo che i fili siano molto vicini rispetto alla lunghezza d'onda $s \ll \lambda$ possiamo assumere che il campo elettrico incidente sia costante per $0 < y < s$, possiamo quindi calcolare gli integrali moltiplicando semplicemente per s , ottenendo

$$V^i = j\omega\mu_0 H_z^i \cdot s \quad (12.25)$$

e

$$I^i = -j\omega c E_y^i \cdot s \quad (12.26)$$

se poi immaginiamo che $L \ll \lambda$, abbiamo che tutta la linea è assimilabile ad quanto segue:



vediamo due casi:

- V^i ON e I^i OFF (togliamo il generatore):

$$V_S = \frac{R_S}{R_S R_L} V^i L \quad (12.27)$$

e

$$V_L = -\frac{R_S}{R_S R_L} V^i L \quad (12.28)$$

- V^i OFF e I^i ON

$$V_S = \frac{R_S R_L}{R_S R_L} I^i L \quad (12.29)$$

e V_L sarà uguale

possiamo quindi scrivere la tensione totale

$$V_L = -\frac{R_L}{R_S + R_L} + j\omega\mu_0 H_z^i (s \cdot L) - j\omega c E_y^i (s \cdot L) \frac{R_S R_L}{R_S R_L} \quad (12.30)$$

Questa tensione può creare problemi di funzionamento al dispositivo 2, dipende nuovamente dall'area sottesa ai fili, quindi nuovamente i fili devono essere corti e vicini.

Considerazioni

P_L che è la potenza raccolta sul carico L, che è data da

$$P_L = \frac{1}{2} \frac{|V_L|^2}{R_C} \quad (12.31)$$

Per fare in modo che la potenza raccolta dal dispositivo sia piccola, è necessario che R_L sia molto elevato, al limite per ∞ il dispositivo sarebbe immune, ma l'impedenza di terminazione dipende dalle operazioni che deve fare il dispositivo.

Possiamo aggiungere un componente di **choke**, che serva a tagliare l'effetto del disturbo in maniera selettiva:

immaginiamo di avere un microchip RFID, che abbia dei piedini ai quali collegiamo un antenna che farà energy harvesting o trasmetterà informazione.

Il chip ha anche un'altra coppia di piedini che servono per pilotare un sensore che funziona in corrente DC, non ha quindi meccanismi di protezione. Se arriva un'onda che investe il dispositivo, entreranno delle correnti di radiofrequenza nel dispositivo che produrranno un malfunzionamento, che falserà di molto la lettura di un dato. Si inseriscono due dispositivi di choke che devono generare un'impedenza elevata per evitare che entrino correnti a radiofrequenza, generando però impedenza elevata a frequenze elevate.

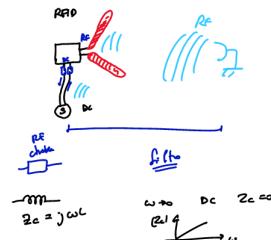
Come deve essere fatto per far passare la continua ma attenuare le frequenze elevate: un induttore, ha un'impedenza

$$Z_C = j\omega L \quad (12.32)$$

quindi quando $\omega \rightarrow 0$ e siamo in continua.

$Z_C = 0$ e quindi il segnale entra e viene processato, ma all'aumentare della frequenza aumenta l'impedenza e quindi taglia la radiofrequenza mentre attenua la continua.

Lo schema usato tipicamente è il seguente:



così che anche se viene raccolta la radio-frequenza il chip è immune perché questa non passa. Questo è quello che tipicamente si fa, distribuire dei choke fatti con induttori o bid di ferrite.

Parte II

Parte Hardware

Capitolo 13

Blocco 1 - Introduzione e nozioni di background

13.1 Panoramica dei contenuti

Vediamo gli attacchi sull'hardware vero e proprio. Vedremo:

- sicurezza;
- design di componenti hardware;

hardware security inquadrata in due tematiche:

- trust, sulla catena produttiva che ci ha portato ad avere quel dispositivo. Posso fidarmi di chi ha fatto il dispositivo?
- vulnerabilità: il dispositivo non è maliziosamente modificato, ma è suscettibile ad attacchi, tipicamente side channel attack su vari livelli.

Vedremo poi le contromisure per gli aspetti di attacchi trust e di tipo vulnerabilità: è come sempre una gara continua tra due fazioni (Cesati cit*), vediamo anche delle primitive per rendere sicuro l'hardware:

- TRNG
- Physically Unclonable Functions

Sarà un approccio molto nozionistico, per avere tutte le chiavi di interpretazione dell'hardware security

13.2 Nozioni di background

L'aspetto di hardware security si inquadra tipicamente nel più ampio campo della **dependability**: capacità del sistema di operare come ci aspettavamo, che comprende 3 aspetti, siamo in un concetto più ampio. I sistemi dependable si comportano secondo le specifiche di progettazione, 3 aspetti:

- qualità, come essere sicuri che il dispositivo non è affetto da guasti di produzione. La produzione delle VLSI è sempre affetta da difetti ed è invalutabile che i difetti creino dei guasti. 10% dell'area del chip è usata solo per il "design for test", che sia assicura che il dispositivo non sia guasto.

- affidabilità: livello di fiducia che abbiamo che il dispositivo opererà bene nel corso del tempo, contro degli eventi random. I livelli di affidabilità sono tipicamente elevati per permettere che il dispositivo sia affidabile
- sicurezza: livello di certezza che il dispositivo funzioni bene sia in fase di produzione che durante la vita utile del dispositivo. I nemici non sono eventi casuali ma eventi maliziosi.

Nell'ottica dei sistemi dependable la security è una declinazione di questo aspetto, infatti tecniche applicate per garantire l'affidabilità e la reliability sono anche usate per la sicurezza.

Un sistema è sicuro se l'hardware è intoccabile: questo dicono gli esperti di cybersec, il dispositivo è fuori dalla portata dell'attaccante se ci sono dei ciphertext, ma non è più il caso. Ormai il dispositivo stesso è un oggetto di attacco, non più solo il canale. Dividiamo in

- hardware trust:
 - siamo sicuri che l'hardware sia fatto da sorgenti di cui ci fidiamo?
 - ci sono modifiche maliziose, ad esempio con trojan?
 - quali sono gli effetti del trojan?
- hardware security
 - alla fase di progettazione, c'erano cose che non abbiamo tenuto in considerazione sfruttabili da un attaccante?
 - Possibili vulnerabilità di side channel
 - transient execution attacks (come Spectre e Meltdown)

Cos'è l'hardware: è ciò che consideriamo il proof of trust nella crittografica, ma questo concetto è molto poco evidente siccome i dispositivi ormai sono tanti.

Già dai tempi della guerra fredda c'erano nozioni di hardware attacks (es. fotocopiatrice hackerata russa), anche ultimamente ci sono stati casi di attacchi basati su trojan volontari: 'kill switch' nelle difese siriane.

Successo anche con virus del 91' che creò dei problemi nell'amministrazione Iraquena.

Ci sono delle evidenze che possono dare indizio: Huawei, provider network non più fidati, legittimi sospetti che l'hardware sia potenzialmente affetto da problemi, hardware trojan è un pò una "prova di fede", ma non si può pensare che non ci sia a priori soprattutto in dispositivi dove la sicurezza è importante.

Anche casi di router CISCO e dispositivi wearable, che devono avere degli aspetti di security perché l'attacco non è necessariamente qualcosa che ruba informazione ma anche DoS, oppure battery drain (sempre trojan) che può causare un DoS.

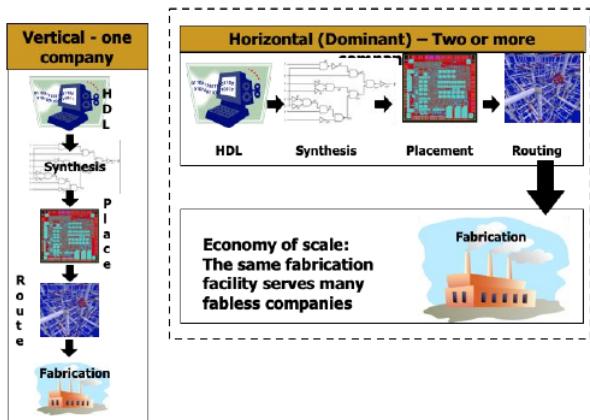
Gli attacchi sono tanti, vedremo anche aspetti di dispositivi contraffatti: esiste un modo dove vendono il dispositivo per ciò che non è a scopi di lucro.

Si vendono dispositivi senza test, contraffatti e che potrebbe causare problemi, altro aspetto di problematiche di trust.

C'è poi tutta la questione di attacchi di tipo side channel, che ad esempio mettono delle probe direttamente sul chip.

13.3 VLSI industry

Una volta la supply chain era verticale, ma ormai una compagnia che fa tutto da sola è raro



Andare "foundless" permette di non legarsi a dei volumi limitati della produzione: producendo solo i propri semiconduttori non si riesce a rientrare nei costi, quindi si sfrutta l'economia di scala sfruttando delle found esterne che fanno grossi volumi, ad esempio a Taiwan: faccio il progetto e loro lo realizzano (azienda).

È stata la fortuna anche di ARM, disaccoppiamento di IT e di silicio, è buono da un punto di vista economico (modello orizzontale) ma introduce una problematica: si creano vari player:


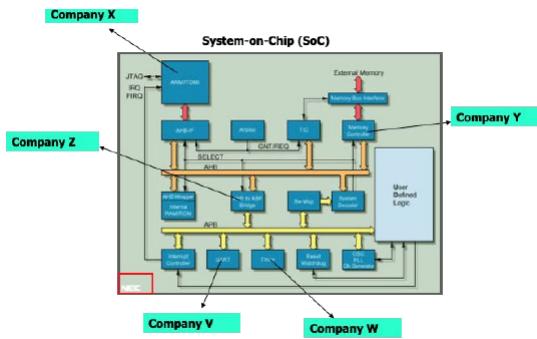


Figura 13.1:

ma chiunque dei player può essere non trusted:

- può esserci un problema di IP vendor: c'è un esplosione interna di hardware scritti in software: linguaggi che descrivono un hardware da un punto di vista software. Quando si descrive un chip è usare gli Hardware Description Language (HDL, forse Cesati con sys embedded?). Può aver messo delle modifiche nel codice che attivi qualcosa di non voluto. La verifica è difficile come in software, si può fare coverage etc... ma un attore sa come farsi non scoprire
- system integrator: può esserci sia un problema che chi ha messo insieme le varie IP: un chip composto da core, memorie etc... viene assemblato da un produttore che è un system integrator. Può aggiungere delle modifiche che causino backdoor, leakage informazioni etc... che può causare un attacco
- manufacturer: nella parte di produzione, possono essere modificate le performance dei transistor per far fallire il dispositivo

quindi i tanti attori potrebbero avere interesse a causare problemi, questo è il System on Chip:




il microprocessore del cellulare non ha solo CPU, ma memoria, cache, interfaccia di I/O etc..., tipicamente come nel caso di ARM, il piccolo pezzetto del processore è messo con le memorie etc... e nel SOC ogni pezzo può venire da una 3° parte non fidata. Facendo tutto in casa sei sicuro, prendendo pezzi da varie parti si rischia di inserire nel dispositivo cose che causano grossi problemi.

All'interno della attuale supply chain, abbiamo che normalmente il codice HDL è fatta mediamente negli USA, mentre chi fa verifica e produzione sta in China, quindi ci sono tante entità in gioco. C'è poi il discorso del counterfeiting: usare alcune parti del flusso di produzione per fare prodotti

- over-produzione, produce più chip e vende il surplus che non ho richiesto in mercato secondario
- alcuni chip vengono buttati perché ci sono dei guasti, qualcuno può tenerseli e venderli sotto banco

Esistono poi casi in cui ci sono i recycled IC: soprattutto nel 3° mondo, tanta gente stacca i componenti da dispositivi vecchi, li ripulisce e li rivende come nuovi. Il costo della manodopera è zero e vengono rimessi come nuovi, è un altro problema perché limita la vita utile dei dispositivi elettronici.

In generale, nella supply chain ci sono tantissime problematiche



13.3.1 Definizioni di base

Soprattutto quando si parla di intellectual property, ci sono 4 forme legalmente definite:

- patents, quando si registra una invenzione con un governo, si ottengono i diritti legali di escludere qualunque altro dalla manifattura o dalla vendita;
- trademarks, ovvero un nome, frase o suono o simbolo associato ad un servizio o prodotto;
- copyrights, leggi che proteggono espressioni scritte o artistiche
- trade secrets, ovvero una formula, pattern o compilazione di dati che permette all'utente un vantaggio sui competitor

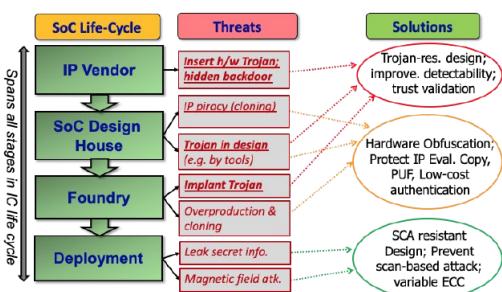
nel nostro caso come è stato scritto il dispositivo per fare delle cose.

Spesso quando si fa un dispositivo elettronico si comprano delle IP come memoria etc... non si sa cosa c'è dentro ed è critico per la sicurezza.

Vediamo delle definizioni per la sicurezza, in termini di informazione:

- C: rendo noti dati che dovrebbero essere segreti
- I: modifco dati che non dovrebbero essere modificati
- A: rendere un dispositivo non più accessibile

può essere più oscuro cosa è l'hardware security: ci sono le IP, non sappiamo come è stato prodotto l'hardware e quali possono essere le vulnerabilità. Parlando di rischi hardware: aspetti relativi all'IP, fino al deployment:



possiamo avere aggiunto delle backdoor nell'IP, oppure modificare il dispositivo per renderlo attaccabile.

Le soluzioni sono varie, ad esempio per i trojan occorre migliorare la loro detection, mitigare i side channel.

Parlando di vulnerabilità hardware, intendendo superfici di attacco:

- hardware trojan;
- attacchi fisici;
- IP piracy;
- IC piracy & counterfeiting;
- tampering;
- reverse engineering
-

per ogni tipo di problematica ci sono diversi tipi di nemici, fra cui anche enti governativi di 3° parti.

13.4 Design dell'hardware per sistemi sicuri

Intanto si implementa l'encryption, ma occorre anche essere in grado di evitare gli accessi sui dispositivi.

Ci sono dei vincoli in più per dispositivi IoT o embedded: devono lavorare a bassa potenza e con rapporto di power /performance che è elevata, in quanto c'è la batteria e quindi non si può usare

tutta la potenza di calcolo e quindi ci non vincoli aggiuntivi in progettazione.

La superficie di attacco è ovunque, quindi i parametri di progettazione devono essere non pesanti e compatibili con l'IoT.

Vogliamo che il sistema IoT offra:

- funzioni di sicurezza di base;
- resistenza alla manomissione;
- content security;
- identificazione utente;
- accesso sicuro alla rete;
- disponibilità
- sicurezza dello storage;

abbiamo però diversi problemi e sfide che possono essere interessanti per domande di ricerca

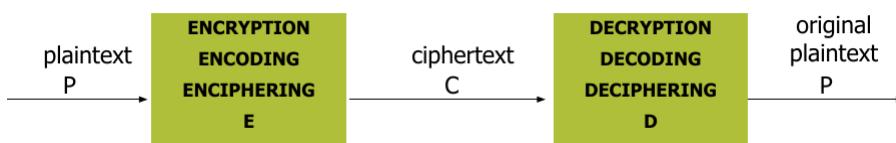
- fare qualcosa a bassa potenza ma non attaccabile
- chip che lavora a bassa potenza ma è scevro da side channel attacks
- ...

parlando in generale del canale si parla di crittografia: partendo dal sub cipher di Giulio Cesare, fino ad Enigma della II guerra mondiale, ma c' un aspetto interessante sulla crittografia: questa non è migliore se il chip che lo implementa, ricorda la security by obscurity. Nella crittografia moderna il processo è noto e pubblicizzato perché si cerca di trovare un feedback per rilevare delle vulnerabilità. È tutto basato sul fatto che senza la chiave in bruteforcing non si fa nulla, è computazionalmente complesso.

I problemi sul canale sono:

- intercettazioni della conversazione
- creazione dal nulla
- blocco

se riusciamo a superare le vulnerabilità sul canale, riusciamo a fermare questi attacchi. Si parla di cryptology: gara fra chi crea il nuovo cifrario e chi lo rompe "in tempi umani". Partendo da un PT, si ottiene un CT:



Nel caso della crittologia classica, l'ambiente ostile è solo sul canale, quindi dobbiamo far si che chi cerca di fare dei danni non ci riesca: dobbiamo accorgercene oppure impedirgli di decodificare, si usano quindi una coppia di chiavi, una di encryption ed una di decryption.

Abbiamo che tipicamente:

- crittografia simmetrica (AES), più veloci
- crittografia asimmetrica (RSA), basati su chiave pubblica, privata e spesso sono usate per fare lo scambio delle chiavi.

L'obiettivo della crittoanalisi è rompere il cifrario:

- cercare la frequenza delle lettere se si conosce la lingua
- etc...

sempre tutti basati sulla conoscenza del cfrato e quindi senza conoscere l'hardware che implementa il cifrario.

Teoricamente è possibile ipotizzare un sistema crittografico che sia rotto, ma praticamente i sistemi crittografici sono sempre attaccabili ma in termini di tempo.

Ci sono diversi tipi di chipers:

- substitution ciphers: le lettere del plaintext vengono sostituite da altre mediante E;
- transposition ciphers: l'ordine delle lettere di P viene ri-arrangiato da E;
- product cipher, dove $E = E_1 \circ E_2 \circ \dots \circ E_n$;

AES tipicamente combina le cose.

Possono esserci poi degli approcci di attacco:

- ricerca esaustiva, se lo spazio delle chiavi è abbastanza piccolo, si tentano tutte le possibili
- statistical analysis: è comparabile al modello "unigram" dell'inglese.
L'1-gram mostra la frequenza dei singoli caratteri della lingua, più è lungo C e più l'analisi avrà effetto

Un buon cipher:

- combina substitution e transposition, quindi ci sono permutazione, scramble etc... che sono parametri che rendono difficili inferire il plaintext dal ciphertext
- DES ed AES sono due implementazioni

Abbiamo poi la differenza fra

- stream cipher: si codifica ogni bit del plaintext, si sostituisce di volta in volta una lettera con un'altra;
- block cipher: si usa un blocco di caratteri che vengono cifrati per intero

abbiamo poi la problematica della Public key encryption: stream e block cipher sono basati sull'uso di una chiave segreto condivisa, ma se ho tanti party devo avere qualcosa che va come $O(n^2)$ nel numero di chiavi che limitano molto la crittografia simmetrica, da cui nasce la Pub key encryption:

- Diffie Hellman: si usa la chiave pubblica per cifrare e solo la privata per decifrare, si scala ad $O(n)$
- il problema è che deve essere facile decifrare il messaggio conoscendo le chiavi ma non deve essere facile ricavare una chiave dell'altra o da un plaintext attack

La pub key encryption è circa 10000 volte più lenta della symmetric encryption, quindi tipicamente è usata per iniziare la comunicazione fra due parti e poi passare a chiave simmetrica.

13.4.1 Crittoanalisi

Cerca su canale di trovare il modo di capire se ci sono informazioni che possono essere dedotte o partendo dalla parola crittografata, o dalle parole del plaintext o disponendo della chiave di enc/dec. Esistono diversi approcci per poter dedurre il messaggio o la chiave

- ciphertext-only attack
- known plaintext attack, dove l'analista deve avere sia C che P e cerca di dedurre E tale che

$$C = E(P) \quad (13.1)$$


- probable plaintext attack, dove una decifratura parziale fornisce un match parziale con C, quindi da degli indizi
- chosen plaintext attack
- chosen ciphertext attack
- **side channel attack**

i primi sono tutti basati sulla conoscenza parziale del plaintext / ciphertext ma non usano il dispositivo.

Nel caso del side channel attack non ci limitiamo a cercare approcci matematici per dedurre la parola dal plaintext, ma cerchiamo di aggiungere informazioni dal dispositivo stesso, quindi per rompere il codice. Riduco i tempi che ci metterei per decifrare / rompere il cifrario.

13.5 VLSI design e dependability

La progettazione di un sistema elettronico parte dalle specifiche, si fa la traduzione:

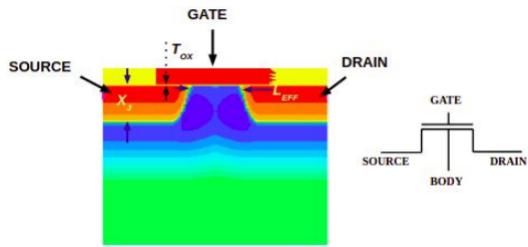


si ottengono i wafer, che sono delle "foto" dei chip e che vengono affettate per inserirle nel chip. Il burn in è il test esaustivo del dispositivo per vedere se ci sono delle problematiche, poi viene testato in produzione e mandato al cliente.

La progettazione del sistema può essere diviso in vari aspetti, a seconda dei livelli di astrazione.

Nel caso di transistor:

funzionalmente è come un interruttore controllato da un gate che crea connessione fra un drain



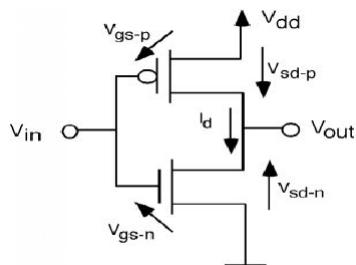
ed un source. (???)

Sempre per la solita legge di Moore, c'è una crescita esponenziale della densità che si possono mettere nello spazio del silicio: Moore notò che la densità dei transistor raddoppiava di anno in anno ma ormai la cosa è morta perché la legge esponenziale (varia nel campo logaritmico) è limitata (siamo a dimensioni di pochi nanometri).

Si ha avuto quindi un technology scale che ha portato ad ottenere miglioramenti delle performance. Per noi il transistor è un interruttore che si apre/chiude in base al valore alto basso di tensione (0/1 valore logico) ed in base ai transistor abbiamo acceso /spento:

- il transistor nMOS è tale per cui se il gate è alto, lo switch è ON, altrimenti è OFF
- il pMOS è il contrario

Il vero successo è stato il cMOS, ovvero combinare i due MOS ed il vantaggio è che non c'è connessione diretta fra ground e V_{in} :



Il passaggio fra una porta logica ed un'altra causa ritardo, le porte logiche permettono di realizzare qualunque funzione booleana, si possono realizzare le diverse porte anche più complesse.

In generale nella cMOS, per implementare la funzione logica:

- accendendo quello sotto, l'uscita è 0 e viceversa

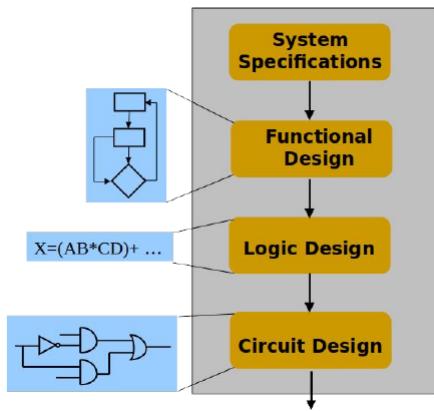
Tradurre la logica in design (VLSI design) è stato il grande progresso degli ultimi anni, dai tempi del primo computer: si parte dalle specifiche e si crea un chip. Non si scrivono più a mano le equazioni booleane che vogliamo sui chip, in quanto abbiamo miliardi di transistor. Il ciclo quindi prevede:

scendendo poi più in basso, l'insieme delle porte logiche è trasformato in un insieme di porte in silicio e poi c'è la fabbricazione.

Il processo di produzione dei semiconduttori è fatto mediante foto-litografia, con una frequenza alta (UV per avere una λ piccola), è un percorso iterativo.

I wafer sono circolari perché vengono persi dai lingotti, creati da un crogolio di silicio fuso, c'è un seme da cui viene fuori un mono-cristallino enorme.

Si affettano in wafer circolari, perché la crescita è concentrica, vengono poi fatte delle metalizzazioni



per connettere i transistor.

Uno dei primi microprocessori fu l'intel 4004, passando da 2300 transistor ai 4.95 miliardi del ryzen 5.

Ci sono diversi requirement di progettazione:

- si parte dall'input/output, quindi ad esempio un full adder che prenda come input X, Y, C_{in} e restituisca in output S, C_{out}
- per la descrizione si usano gli HDL, non si fanno più i transistor bensì si specifica cosa si vuole come in un classico linguaggio di programmazione.
I due più famosi sono VHDL e Verilog
- vi è poi il design logico, con le tabelle di verità del componente
- successivamente, c'è la schematizzazione del transistor
- i transistor infine si trasformano nel layout, ovvero come apparirebbe il vero e proprio chip se si potesse aprire

Il processo è quindi iterativo:

- fpga, programmabile
- asic, dispositivo non modificabile dalla fabbrica

e questo riassume gli standard di progettazione attuale.

Avendo dei bug hardware nel silicio è un problema (it's not a bug, it's a feature!), mentre nelle FPGA c'è programmabilità ma non sono ottimizzate e non sono ad alte prestazioni quindi si va comunque sugli ASIC che hanno bassi costi.

13.5.1 VLSI chip yield

Parliamo di ASIC: può succedere di tutto, l'aria è filtrata per evitare delle impurità perché quando si produce un semi-conduttore può creare dei difetti e dei guasti nel silicio.

C'è quindi un grosso lavoro per aumentare la resa di produzione: un processo produttivo maturo avrà una resa elevata, ma altrimenti sicuramente ci saranno dei chi guasti. Quindi occorre testare tutti i chip che produco, perché la cosa peggiore è avere dei chip guasti che arrivano al cliente rispetto ad avere un chip da buttare.

Questo avviene mediante test: si applicano dei vettori al dispositivo e si verificano le uscite attese, è fatto su tutti i chip e per accelerare la velocità del test si modificano i dispositivi elettronici anche per aumentare la copertura del test.

Si ha anche un 10% di perdita di resa del chip, nell'area del test, che è dovuta all'uso per i test. Vogliamo quindi scoprire che è meglio avere una perdita di resa, quindi 20 / 100 chip si buttano piuttosto che avere meno dispositivi fallati in vendita.

Il defect level deve tendere allo 0, ovvero avere dei dispositivi in vendita sicuramente funzionanti, la parte di qualità della dependability è tale per cui i chip hanno defect level bassissimo.

Esiste la regola del "10", o anche "20", ovvero che costa sempre 10 volte di più trovare un guasto su un chip incapsulato in un sistema sempre più grande.

Il test cerca il numero di chip guasti sul totale, c'è il concetto di clustering che ci aiuta (forse Pellegrini), si usano dei flip-flop scan che permettono di creare una grande catena di scan per avere più osservabilità sui chip e trovare i guasti.

Si usano queste scan chain, che vengono usate solo in produzione, ma la controllabilità dei flip flop nel chip possono essere usati per fare anche debugging del microprocessore.

Il test è quindi applicare i vettori a tutto il circuito ed anche alla scan chain per verificare che non ci siano errori, si fa perché "what you see is not what you get": nel manufacturing non si riesce ad essere deterministici in ciò che si è creato.

C'è un'implicazione di sicurezza, il fatto che varia il processo produttivo rende in qualche modo il dispositivo "unico": un PUF sfrutta il fatto che ogni chip è diverso dall'altro e quindi di avere una specie di impronta digitale.

Parlando di qualità ed affidabilità i due aspetti sono fra loro allacciati: (ricopia)

- la qualità ed il test fanno in modo di trovare tutti i guasti a tempo 0
- l'affidabilità fa in modo di trovare tutti i guasti che si manifesteranno dopo nel tempo

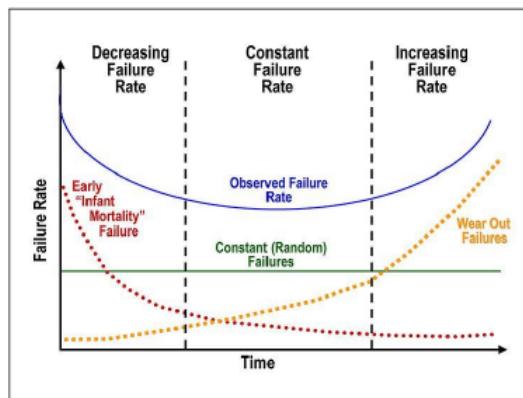
13.6 Fault tolerant design

Le tecniche tornano tutte utili per la security.

Per ottenere massima affidabilità si deve aumentare l'hardware usato: in un sistema elettronico, inizialmente, ha un failure rate più elevato per poi calare perché i guasti che stavano per avvenire in produzione scompaiono.

Ad un certo tempo, sperabilmente, i dispositivi si guastano costantemente nel tempo per motivi random, per poi crescere verso la fine della vita.

Abbiamo questo grafico



ci aspettiamo di avere un dispositivo che permette di lavorare nella parte centrale.

Vediamo la differenza fra

- guasto: questione tipicamente fisica, c'è un problema sul componente

- fault, errore: conseguenza, esempio il processore deve sommare due addendi. Uno dei due ha un bit flipato e la somma fallisce. Ma può anche accadere che il guasto sia mascherato, ad esempio se riflippo quel bit nel registro, non ho il fault.
- failure: se 1 bitflip avviene su un'immagine, vederemo un pixel di colore diverso. Se invece questo avviene ad esempio sul PC o sull'IP il danno può essere ben più grave.

in un sistema complesso il failure rate si misura con la λ_{sys} che se non ci sono guasti è la somma: se un ho automobile che funziona su 4 gomme, basta che se ne rompa 1 per avere un sistema che non funziona più

$$\lambda_{sys} = \sum_{i=1}^k \lambda_{c,i} \quad (13.2)$$

se invece abbiamo un camion, c'è della **ridondanza** che aumenta quindi l'affidabilità.

Abbiamo poi:

- la legge del fallimento esponenziale:


$$R(t) = e^{-\lambda t} \quad (13.3)$$

- Mean Time To Failure:

$$MTTF = \int_0^{\infty} R(t)dt \quad (13.4)$$

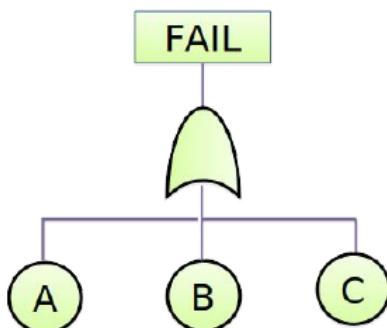
Per misurare l'affidabilità di un sistema, abbiamo i **reliability block diagram**.

Il primo caso è quello del diagramma in serie:



dove se si rompe un blocco è finita, si blocca il flusso.

Abbiamo poi la fault tree analysis:



Si possono anche applicare la Markov chain per calcolare l'affidabilità del sistema.

Ci sono poi delle tecniche di ridondanza per migliorare l'affidabilità del sistema: un modo è aumentare le cose che si usano per fare la stessa cosa

- Hardware redundancy

- Time redundancy
- Information redundancy

per far sì che il sistema viva più a lungo, non viene gratis: devo aumentare la ridondanza, ad esempio passare da x risorse ad $x + \text{"qualcosa"}$.

Le tecniche si possono anche usare per problemi di sicurezza.

Si possono:

- usare 3 blocchi che fanno la stessa cosa e che vanno nel voter, che da il risultato finale come la maggioranza degli ingressi (TMR). Maschera i guasti, costano in hardware ma hanno questo grosso vantaggio e quindi abbiamo availability del 100%. Semplice dal punto di vista progettuale
- time redundancy: ripetere l'operazione più volte, ad esempio il caso in cui si usano 2 thread per fare la stessa cosa.
Non usiamo più risorse hardware, ma ci si mette più tempo per fare la stessa cosa (ad esempio flip flop a basso livello). Anche questa è semplice
- information redundancy è aggiungere più risorse per fare la stessa cosa: è complessa, si mettono le mani sui dati, ad esempio con i bit in più per la parità per la rivelazione/correzione di errori (L'anima di Giacconi aleggia su di me).

Capitolo 14

Blocco 2 - Trust Issues

14.1 Hardware trojan

Hardware security, nelle problematiche di trust: tutto ciò che fa in modo che noi sospettiamo che qualche attore malizioso sia inserito, iniziamo da cosa è un hw trojan: è un sistema che aggiunto al componente elettronico che usiamo crea un malfunzionamento.

Possiamo fare tassonomia degli hw trojan, è abbastanza ampia ma che ci mostra che il trojan può mostrarsi in diversi livelli della produzione di hardware.

Siamo nel caso dell'hw trust: siamo sicuri che un sistema sia fatto da sorgenti fidate? Ci sono modifiche nel dispositivo?

Un hw trojan è un'aggiunta malevola od una modifica ad un elemento del hardware. Queste modifiche, a differenza di una modifica sw sono permanenti al sistema elettronico e come esso si comporta nella sua missione.

Il concetto del trojan viene dal cavallo di Troia etc... bisogna fidarsi ma anche controllare: è una questione di fiducia nel processo che ha portato ad avere il dispositivo.

Dobbiamo tenere in considerazione la possibilità che tale modifica possa essere stata introdotta, anche se non ne abbiamo una prova empirica.

Siamo familiari a software trojan, come ransomware, etc... Nel caso hardware, c'è un po' un atto di fede: sono presenti nell'hw e occorre fare in modo di scovarli.

È analogo a trovare la presenza di un guasto nel dispositivo nella sua produzione, quindi le tecniche di rilevazione dei guasti in produzione è simile alla rilevazione degli hw trojan:

- un guasto di produzione è random
- hw trojan crea un malfunzionamento dell'hw, ma può essere identificato con tecniche di testing che devono essere più accurate. Sono difficili da trovare

Il problema è che non ci fidiamo di chi ha fatto il circuito integrato o l'IP:

- possiamo avere problemi a livello di IP, ad esempio inserito nel codice dell'HDL
- nella foundry, qualcuno aggiunge modifiche al layout

Possiamo fidarci dell'hardware sono se gestito in casa, ma ormai non è più così. Possiamo avere:

- IP trust issue: un sistema composto da diversi componenti che sono IP, (vedi immagine sopra) e quindi vendono da 3° parti che potrebbero avere all'interno degli attori malevoli
- system integrator
- produzione

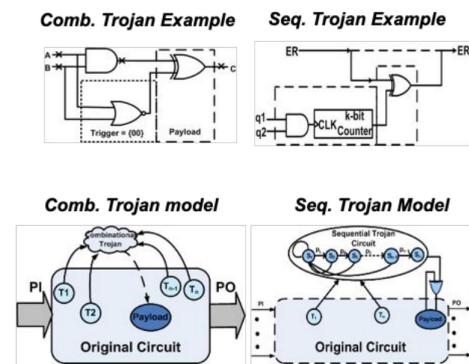
Nel modello attuale orizzontale di produzione, possiamo avere questo: (immagine) c'è una parte trusted, ma poi mandando in fabbrica possiamo avere problemi di trust, quindi qualcosa nelle interfacce, la fabbricazione, il test dei dispositivi potrebbe non essere fidato. Se degli attori non fidati sono nel mezzo, abbiamo qualcosa non fidato. Ma possiamo anche avere che delle IP o delle std sec hanno delle modifiche, quindi diversi attori possono causare problematiche.

14.1.1 Esempi di hw trojan

Si identificano tipicamente due parti:

- trigger: basandosi sulla combinazione di segnali interni al sistema fa partire l'effetto del trojan
- payload: effetto del trojan

esempi:



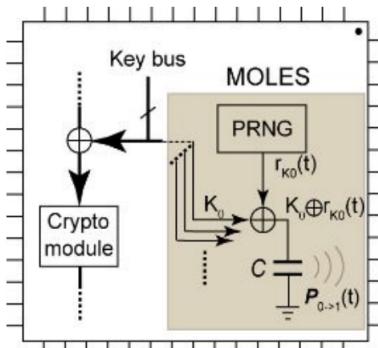
nell'esempio combinatorio, se A e B sono 0, il valore di C viene invertito per l'effetto del trojan, si attiva ogni volta che c'è combinazione di ingressi.

Qualcosa di più elaborato è un trojan sequenziale: l'attivazione non è sempre basata sulla combinazione degli ingressi, ma anche dal tempo.

Quando q1 e q2 sono pari ad 1, il clock passa da 0 ad 1, dopo alcuni cicli di clock il contatore arriva ad avere il bit più significativo ad 1, che diventa l'effetto payload in modo che il valore di ER cambi. C'è quindi ad esempio una macchina a stati che crea la condizione per far partire il payload.

Il trojan può anche non necessariamente modificare la funzione interna del dispositivo:

MOLES*: Info Leakage Trojan



qui il trojan crea una emissione EM da parte del chip, che viene catturata a valle da qualcuno che fa side channel observation. In questo caso, abbiamo un crypto module (AES) con la chiave di k bit, che vengono anche captati da un trojan che mischiando con un PRNG carica un condensatorino nel dispositivo.

Caricando /scaricando il condensatore, per via del movimento di cariche, ci sono delle emissioni EM, che possono essere captate per vedere il contenuto della chiave.

Il trojan è chiamato MOLE (spia), la parte colorata serve per far trapelare la chiave, ma invece di fare carica /scarica del condensatore che sarebbe troppo ovvio si aggiunge un PRNG che almeno apparentemente disaccoppia le emissioni EM dal contenuto della chiave.

14.1.2 Trovare i trojan

La verifica fatta nel flusso di progettazione del VLSI, si fanno verifiche sull'hardware, sul fatto che porte logiche abbiano gli output attesi etc...

Per test e verifica cerchiamo cose non intenzionali, quindi è più facile, mentre nel caso di trojan è più complesso perché sono messi a posta per essere difficilmente trovabili.

Le funzionalità trovate potrebbero anche essere non documentate.

Un altro tipico caso di problematiche dei trojan è una silicon backdoor: metto un antenna in un dispositivo per ricevere / emettere informazioni da un attore malizioso.

Può causare malfunzionamenti, è complesso trovare la problematica se non è documentata, perché se l'antenna non è attiva in lettura /scrittura non ce ne accorgiamo, si trovano con tecniche che vedono emissioni EM, densità di potenza etc...

Altre tecniche possono essere anche silicon time bomb, che può causare grossi problemi affidabilitistici:

- può capitare dopo molto tempo
- è fatto con molti pattern, magari combinazioni molto rare di segnali interni che causano il malfunzionamento

può essere triggerato da:

- counter
- chiavi interne

può anche essere fatto a diversi livelli, anche non attivarlo "manualmente" ma far sì che l'effetto si attivi su combinazione di segnali interni o su guasti.

Le applicazioni dove possono verificarsi i pericoli sono molteplici, i trojan possono interessare ogni tipo di applicazione, possiamo vedere un'idea dei possibili modelli di attacco nella filiera produttiva:

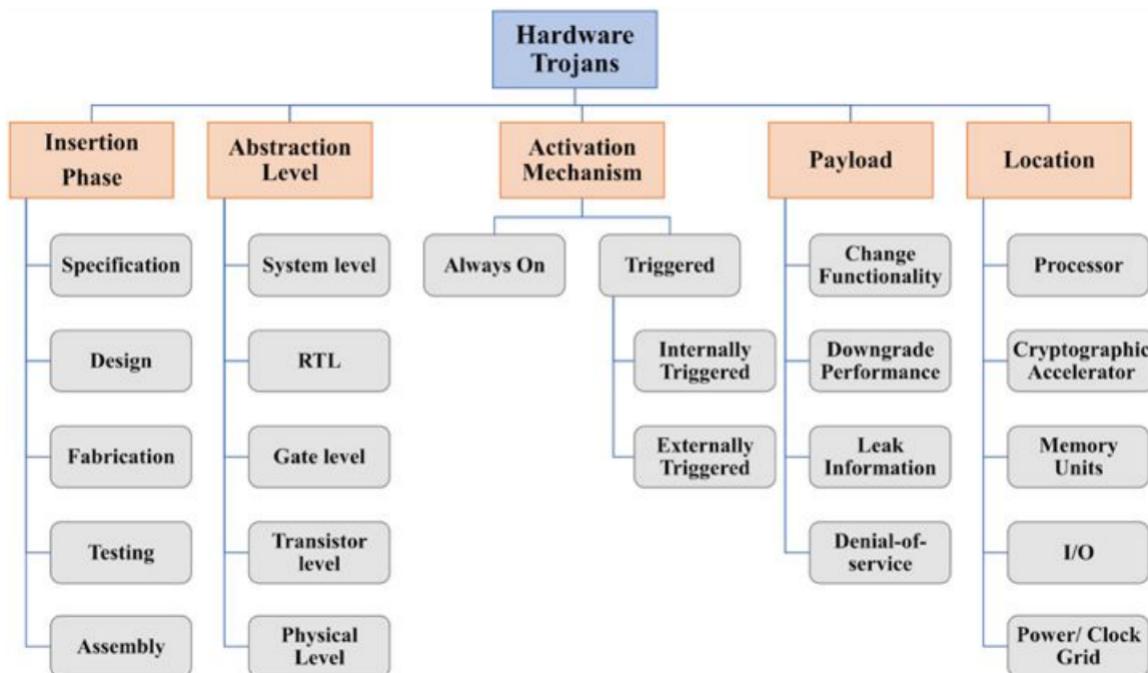
Model	Description	3PIP Vendor	SoC Developer	Foundry
A	Untrusted 3PIP vendor	Untrusted	Trusted	Trusted
B	Untrusted foundry	Trusted	Trusted	Untrusted
C	Untrusted EDA tool or rogue	Trusted	Untrusted	Trusted
D	Commercial-off-the-shelf component	Untrusted	Untrusted	Untrusted
E	Untrusted design house	Untrusted	Untrusted	Trusted
F	Fabless SoC design house	Untrusted	Trusted	Untrusted
G	Untrusted SoC developer with trusted IPs	Trusted	Untrusted	Untrusted

nei dispositivi off-the-shelf possiamo avere addirittura che non sia trusted nulla, il trust ha un costo relativo alla verifica di tutti gli attori che realizzano il componente.

Per verificare ad esempio un 3PIP, ad esempio un processore, potremmo verificare che faccia tutto ciò che deve ma vuol dire ho la versione "golden" dell'IP core ma non è sempre vero che ce lo abbia, quindi quando compriamo a "scatola chiusa" è complesso trovare cose non documentate.

14.2 Tassonomia dei trojan

Possiamo separarli per diversi aspetti:



uno stesso trojan ha delle caratteristiche in ciascuno dei punti: diciamo che se li contiamo tutti, abbiamo la combinazione dei diversi aspetti.

In ciascuno ci sono dei livelli che vanno dal basso verso l'alto, inoltre ad esempio un cambiamento delle funzionalità può essere rilevato con un test, ma un leak di informazioni è più complesso da rilevare etc... In base al livello o al tipo di attributo, può essere più o meno facile la rilevazione mediante test (il livello rtl è quello del HDL).

Possiamo quindi fare una distinzione per:

1. Fase di inserzione:

- fase delle specifiche: in questa fase possono essere alterate le specifiche sulle funzionalità o altri requisiti di design
- fase di design: qui lo sviluppatore può usare blocchi di 3PIP e celle standard, il trojan può essere posto ad esempio in una libreria delle celle standard
- fase di fabbricazione: i developers creano un mask set ed usano i wafer per produrre i dies. Un esempio di trojan è un cambiamento leggero alla mask
- fase di testing: si possono inserire trojan per fare leakage di informazioni

- fase di assemblaggio: qui i developers assemblano il chip testato ed altri componenti hardware su un circuito PCB stampato.
Può essere fatto un assemblaggio malevolo che introduca trojan

2. Livello di astrazione:

- livello di sistema: qui ci sono i diversi moduli hardware, interconnessioni e protocolli di comunicazione. I trojan possono essere attivati dai moduli stessi
- register-transfer level: livello RTL, i design del chip descrivono ogni modulo funzionalmente in termini dei registri, segnali e funzioni booleane.
Un trojan può essere facilmente progettato ed inserito in fase di RTL perché l'attaccante ha pieno controllo sulle funzionalità di design
- livello di gate: la SoC è rappresentata come un insieme di gate logici interconnessi.
Un attaccante può controllare con attenzione tutti gli aspetti del trojan inserito
- livello dei transistor: a questo livello chi scrive il trojan ha controllo sulle caratteristiche del circuito, come la potenza ed il tempo.
- livello fisico: il trojan può essere inserito andando a modificare le dimensioni dei cavi e le distanze fra gli elementi del circuito

3. Meccanismo di attivazione:

- sempre ON: i trojan sono sempre attivi e non necessitano un trigger
- trigger interno: i trojan sono attivati all'interno del device target
- trigger esterni: i trojan sono attivati da un input inviato sul modulo target

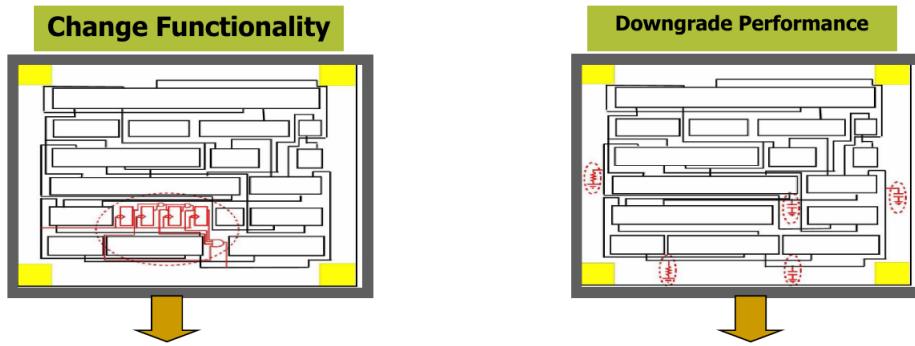
4. Payload:

- Leak information: un trojan che vuole esfiltrare delle informazioni, come dati sensibili
- Denial-of-Service: l'obiettivo è un DoS, quindi ad esempio l'esaurimento delle risorse

5. Locazione:

- logica random: un trojan può essere inserito nella porzione della random logic di un SoC
- processing unit: embeddato nelle unità logiche che sono parte del processore
- Cryptographic accelerator: i cryptomoduli sono spesso target dei trojan in quanto lavorano con degli assests, come chiavi private e plaintext sensibili
- unità di memoria: i trojan sono nei blocchi di memoria
- porte di I/O: il trojan può risiedere sopra o dentro il PCB
- Power supply: i SoC moderni includono un grande numero di regolatori distribuiti etc... dove possono essere messi dei trojan
- clock grid: i trojan possono cambiare la frequenza del clock

Vediamo alcuni esempi, anche per capire come lo stesso trojan abbia diverse caratteristiche



14.2.1 Esempi di trojan

Un trojan di questo tipo ha qualcosa che ad un certo punto cambia il valore di qualcosa, si rileva se si riesce a vedere il cambiamento durante il test.

Il downgrade performance va ad aumentare le capacità sulle piste di collegamento, aumentando i carichi capacitivi o resistivi, quindi aumento le τ (costante dei condensatori) ovvero peggiorano i tempi di ritardo da una porta logica ad un'altra.

Il sistema può quindi non riuscire a rispettare il clock per cui è stato progettato. Il tempo di propagazione attraverso una porta logica si basa sui tempi di carica e scarica dei condensatori che sono ad ingressi ed uscite della porta logica stessa.

Il clock del sistema è limitato da quanto velocemente si caricano / scaricano i condensatori, quindi nel progetto cerchiamo di ridurre i τ , per creare danno quindi aumento questi apposta in modo da causare ritardi che creerebbero dei problemi nella rete combinatoria, quindi il sistema non funziona più.

Gli stessi trojan hanno diverse manifestazioni in base al livello di astrazione su cui si trova: il primo è ad un gate level, nel secondo caso siamo a physical level, connessioni fra transistor.

Anche i trigger cambiano: caso 1 abbiamo un contatore che attiva il trojan, caso due viene aggiunto un condensatore in più (porte logiche sono implementate con transistor), quindi le performance peggiorano perché c'è un condensatore in più da caricare.

Esistono molti benchmark di trojan, esiste un repository (trust-hub.org) che riporta i trojan con la stessa tassonomia. È utile per evitare di trovare trojan in hardware.

14.3 FPGA

Sono possibili target di trojan. Sono composte da:

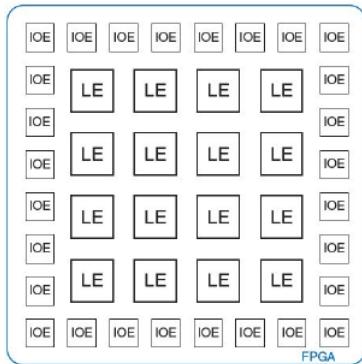
- elementi logici
- interfaccia di I/O
- interconnessioni programmabili

è hardware riprogrammabile quante volte voglio.

In generale, le FPGA sono array di risorse logiche interconnesse:

possiamo programmare la funzione logica di ciasun LE ma anche le interconnessioni fra i LE.
Nel LE ho:

- lookup table




- flip flop
- multiplexer

La lookup table è una tabella di verità programmabile, abbiamo una memoria dove a locazione (0,1) mettiamo un bit e così via...


Se siamo in grado di programmare il contenuto di 4 entry, possiamo programmare 16 diverse tabelle

- $X = A'B'C + ABC'$
- $Y = AB'$

(A)	(B)	(C)		(X)
data 1	data 2	data 3	data 4	LUT output
0	0	0	X	0
0	0	1	X	1
0	1	0	X	0
0	1	1	X	0
1	0	0	X	0
1	0	1	X	0
1	1	0	X	1
1	1	1	X	0



(A)	(B)	(C)		(Y)
data 1	data 2	data 3	data 4	LUT output
0	0	X	X	0
0	1	X	X	0
1	0	X	X	1
1	1	X	X	0



I due grandi vendor di FPGA erano Altera (ora acquisita da Intel) e Xilings (acquisito da AMD) e questo ci dice tanto su quanto importanti stanno diventando le FPGA.

Usiamo dei CAD tool che permettono di sintetizzare qualunque progetto in HDL in dei bitstream che si sintetizza in una FPGA, questo rende l'hardware softwarizzato.

14.3.1 Hardware trojan in FPGA

Possono interessare diversi livelli:

- IP block, ovvero quello che è il bitstream che programma le FPGA. Non è facile trovarli perché gli stream sono cifrati e non possiamo fare reversing del bitstream e quindi metterci un torjan lo rende difficile da trovare;
- Abbiamo poi la FPGA fabric. possiamo avere connessioni non volute, porte logiche in più etc...

In entrambe i casi, possono essere dipendenti dall'IP o indipendenti:

- trojan dipendenti dagli IP, quindi dove una foundry malevola o un vendor di FPGA può implementare un trojan hardware che monitora i valori logici di diverse tabelle di lookup nella fabric

- non dipendenti dall'IP, quindi una foundry o vendor malevoli possono implementare il trojan nel chip della FPGA in modo completamente indipendente dall'IP che viene caricata in essi. Il trojan occupa una piccola parte delle risorse della FPGA

C'è anche la differenza in base al payload:

- malfunzionamento: trojan hardware nelle FPGA che causano dei malfunzionamenti corrompendo le LUT oppure i valori nelle SRAM
- leakage dell'IP: oggi le FPGA, come detto, hanno la possibilità di cifrare il bitsream per poter proteggere l'IP che è caricato nel dispositivo stesso. Comunque, l'encryption protegge solo da un attacco diretto, quindi mediante un trojan hardware è possibile aggirare tale protezione

Capitolo 15

Blocco 3 - Problemi di vulnerabilità

15.1 Recap

Per le problematiche i trust, si parla in primo luogo di hw trojan. Quando noi parliamo di hw security c'è un opponent che vuole causare delle problematiche: possiamo avere modifiche del hw causate da agenti malintenzionati.

Inquadriamo questo come problematica di hw trust, la problematica è dove i trojan compaiono e questo può avvenire in tutta la catena produttiva: IP, integrazione, produzione, etc... ci sono diversi livelli di inserimento.

Questo ritorna nella tassonomia, un trojan avrà una sua proiezione su ciascuna delle qualità dell'immagine, questo è in generale il modo in cui si definiscono i trojan.

Abbiamo sempre payload + trigger: ad esempio il trigger può essere l'aggiunta nel circuito di una NOR (??) (rivedi l'immagine).

Trojan sequenziali hanno un'attivazione più complessa, perché serve la combinazione di stati, posiamo poi avere dei trojan che abbiano come effetto un DoS, ad esempio cambiare un bit del PC facendo hijacking di ciò che stava facendo il processore: a decode stage c'è un'eccezione, si va quindi in trap e quindi DoS.

Spesso i trojan sono cose che vengono realizzate e risolte.

Esempio del leak di una chiave (es di AES): MOLE, capta i valori della chiave e carica / scarica dei condensatori che generano dei campi EM in modo che le emissioni siano monitorate, sfruttando il side channel. Combinazione di:

- modifica hardware
- sfruttare un side channel

non si può trovare il trojan, almeno funzionalmente, perché le operazioni vengono fatte dal processore. Quindi per verificarlo, possiamo vedere l'assorbimento di potenza medio del circuito, oppure vedere le costanti RC (tipiche dei circuiti elettronici) così che se abbiamo dei fan out aggiunti in più avremo dei ritardi maggiori ma è comunque difficile.

È complesso trovarli perché mentre si fanno i test sappiamo quali possono essere i difetti, li possiamo prevedere, mentre qui:

- non sappiamo come sono fatti i trojan;
- non sappiamo come è fatto il circuito (IP), potrebbe essere stato modificato;

Si possono anche avere dei trojan che si inseriscono a livello di testing, mediante tecniche di scan si può boicottare il comportamento del dispositivo.

Ci sono anche casi di attivazione esterna, ad esempio combinazioni di input esterne o anche delle

antenne che si accoppiano con un attaccante esterno per causare malfunzionamenti.

Il payload può poi essere un DoS, un attacco alle performance, un leak delle informazioni o anche un aumento delle τ per abbassare le frequenze di lavoro (??).

Gli stessi trojan possono avere due descrizioni diverse in base alla tassonomia: un **change functionality**, che magari aggiunge delle porte logiche come una porta OR o XOR, può fare diverse cose. Il payload può essere introdotto a livello di porte logiche, o magari ho mandato in foundary tutta la descrizione del chip e quando viene fatta la metalizzazione del chip qualcuno peggiora le performance elettriche aumentando ad esempio i carichi capacitivi o resistivi così da avere delle performance peggiori.

Abbiamo quindi modifiche o a livello logico oppure a livello fisico.

FPGA: software hardware codesing, molto interessanti, poco costose e permettono di scrivere hardware che giri sulle FPGA.

Hanno grosso potenziale ed anche su sbocchi lavorativi, molto a confine fra software ed hardware.

Le soluzioni qui si possono creare mettendo le mani proprio sull'architettura.

Da un punto di vista di sicurezza ci sono due punti di attacco:

- l'hardware di cui sono fatte, in quanto sono fatte di blocchi che poi vengono collegati mediante software, quindi possiamo modificare il blocco (foundary)
- trojan che sono nella parte di programmazione, nell'IP block: il bitstream non è in chiaro, fare reverse engineering non è facile:
 - i vendor non lo documentano molto
 - spesso sono cifrati, vengono vendute delle IP. Si lavora quindi su una black box

Qui i trojan sono anche più plausibili, è come se fosse software

15.2 Vulnerabilità hardware

L'altro lato della medaglia, focalizzeremo la vulnerabilità sul side channel: nel mondo ideale è isolato da chi vuole attaccare.

La vulnerabilità è basata sul fatto che questa cosa non è più vera, si basa sul concetto del **side channel attack**: ci sono attacchi che funzionano anche sul test, se le strutture di test che vengono messe lì e non usate dopo le uso per trovare i segreti, la root of trust non vale più (isolamento totale).

La crittografia è basata sull'astrazione matematica: basandosi solo sulle informazioni che ho sul canale, servirebbe tempo molto lungo per fare bruteforcing e trovare la parola in chiaro.

Qui abbiamo più informazioni che ci permettono di diminuire il tempo necessario al ricavare l'informazione in chiaro.

Parliamo quindi di side channel attacks fisici, che permettono di ottenere ulteriori informazioni per poter rompere la crittografia.

Nel caso reale, gli attacchi possono avvenire su tutto il canale e non solo sugli end points.

I side channel che si possono usare sono tanti:

- uso di potenza, assorbimento di corrente
- emissioni EM
- emissioni ottiche delle giunzioni, più invasivo
- timing e ritardi generali nei processori
- acustici

vederemo i primi due per lo più.

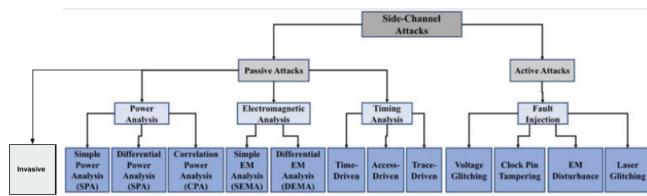
Il tipico setup è dato da:

- dispositivo sotto attacco
- input ed output passati al dispositivo

vediamo tutte le informazioni che il dispositivo può tirare fuori, misurandole con oscilloscopi, probes etc...

Esistono anche setup economici che permettono mediante probes appositi di rompere la crittografia sul dispositivo target.

Abbiamo anche qui una tassonomia:



possiamo già classificare due branche:

- attacchi passivi: non si fa nulla sul dispositivo. Non aggiungo ingressi che permettono di cambiare lo stato del dispositivo per aumentare cosa io posso osservare. Faccio solo osservabilità, "origlio" ulteriori dati, senza modificare nulla
 - attacchi invasivi, metto dei probe sul chip
 - analisi della potenza: cerchiamo di correlare il segreto alla potenza osservata
 - analisi elettromagnetica: correliamo il segreto alle emissioni EM
 - timing: come sopra ma correlo al tempo
- attacchi di tipo attivo: metto le mani nell'hardware, aggiungiamo dei nostri input per aumentare lo spazio delle cose che possiamo osservare. Possono essere
 - glitching, introduco degli errori;
 - modifco il clock;
 - disturbo EM;
 - glitching con il laser, l'equivalente delle particelle ionizzanti

possiamo anche avere degli approcci invasivi: se vogliamo vedere delle informazioni, ad esempio attività in memoria, lo vediamo come emissioni di fotoni ma occorre aprire il dispositivo ed osservare, quindi il side channel è invasivo e costoso.

Probing: mettere dei mini-sensori per vedere i valori di tensione, per cui serve:

- avere una visione completa del target
- è facile poter creare dei danni nel dispositivo

Potremmo poi bloccare il RNG, così che la chiave creata sia nota, possiamo poi ricostruire dei fusibili che sono stati distrutti, che magari sono state rotte in seguito al test, in modo da riutilizzarle; è un attività di micro-probing accurata.

Ci sono poi le attività di fault injection per introdurre degli errori, ad esempio nei vari round dell'AES, che poi possiamo correlare con le versioni non corrette in modo da capire in base all'errore, delle informazioni in più.

15.3 Attacco

Quando si attacca, si cerca di scoprire la chiave, vale l'assunzione di Kerckhoff per cui la segretezza deve essere solo nella chiave, il resto è noto, non vogliamo security by obscurity.

Gli attacchi side channel hanno una fase in cui si interagisce con l'hardware per ottenere delle caratteristiche fisiche (emissione EM, potenza) e presi i dati ottenuti li correlo con un'analisi a posteriori per capire cosa sta avvenendo nel dispositivo.

Possiamo cercare di correlare almeno una parte della chiave, così che dopo sia più semplice la ricerca esauriva sulla parte mancante (vengono esponenzialmente dimezzate le ricerche da fare).

15.3.1 Classificazione degli attacchi

Vediamo due categorie:

- semplici: cercano di mappare il risultato di un numero limitato di tracce con delle attività del dispositivo. Cerchiamo di capire algoritmamente cosa sta facendo il dispositivo
- differenziale: cerchiamo molte tracce per correlarle con la parola segreta che viene trattata. Cerchiamo di derivare la chiave, abbiamo un modello che correliamo a cosa osserviamo.

Per fare il side channel attack, misuriamo la potenza assorbita: non ci interessano né la media né il picco perché non si possono correlare col segreto, voglio fare una correlazione a run time per capire cosa sta accadendo.


Occorre poter avere le mani sul dispositivo per catturare le firme di corrente prodotte quando il dispositivo è sotto attacco, è basato sull'idea che non sia invasiva, è stato possibile rompere AES in pochi minuti.

Ci sono vari tipi di analisi, vengono create delle tracce di assorbimento e ne servono molte per condurre un'analisi di successo.

esempio:

smart card, hanno 8 fili e per metterci le mani sopra c'è qualcosa di fisico che nel momento in cui tento di aprirlo, uno shield distrugge il chip, qui si può tentare di fare delle analisi di assorbimento di potenza.

Il setup tipico:



un inverter assorbe corrente quando il valore cambia, se A rimane 0 o 1 non ci sono assorbimenti di potenza, altrimenti sì.

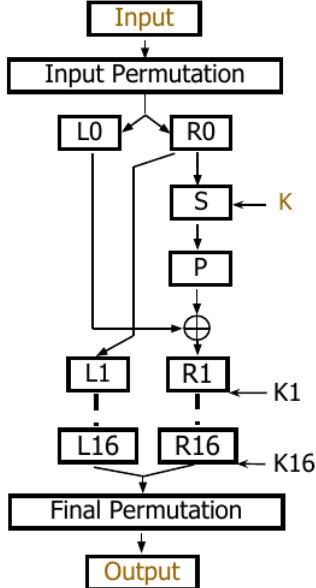
Correliamo l'assorbimento di potenza a quello di corrente, ad esempio collegiamo ad una resistenza, correliamo le uscite di un oscilloscopio alla caduta di potenziale alla cifratura di un plaintext, creiamo un numero elevato di tracce.

L'analisi più classica è la SPA (1996): basato su power analysis, cerchiamo di capire le operazioni che stanno avvenendo sul dispositivo.

Il vantaggio è che bastano poche tracce per capire il funzionamento, utile se non ho accesso al dispositivo, è inoltre correlabile ad un timing side channel attack, possiamo vedere cosa sta facendo il processore sotto attacco: vedendo le tracce possiamo capire se il dispositivo stava crittografando con

chiavi che hanno 0 o 1, possiamo anche applicare degli attacchi basati su ML, classificando i segreti che vengono trattati.

esempio:



smart card DES, è un product cipher che ha sia permutazioni che sostituzioni, ad ogni round (che sono 16), c'è una round key generata dalla segreta, si arriva da un blocco di 64 bit di plaintext ad uno di 64 bit di ciphertext, ci sono delle emissioni EM quando vengono compiuti i round: con le tracce, facendo lo zoom, riusciamo a capire le potenziali emissioni EM che possiamo correlare alla funzionalità di ciò che è stato fatto dal round del DES.

Può tornare utile perché possiamo, sapendo quali operazioni vengono fatte, se ci sono casi di operazioni condizionali in base al valore della chiave, possiamo sapere se c'è stato uno 0 o un 1, vediamo un pattern algoritmico di un if invece di un then, se queste hanno due manifestazioni di potenza diverse lo vediamo.

Anche se ci sono moltiplicazioni si possono vedere, perché hanno complessità che dipendono dal peso di Hamming, ovvero dal numero di 1 che vengono moltiplicati, quindi l'assorbimento può dipendere dal numero di 1 delle chiavi segrete.

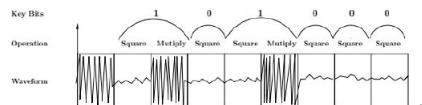
In più, egli RSA dove ci sono le esponenziazioni, c' è un algoritmo di tipo square and multiply: l'operazione di square è diversa dalla multiply per ragioni di velocità, qui di nuovo non pensiamo alla possibilità di side channel, qui:

```

exp1 (M, e, N)
{
    R = M
    for (i = n-2 down to 0)
    {
        R = R2 mod N
        if (ith bit of e is a 1)
            R = R · M mod N
    }
    return R
}
  
```

ci sono if sui bit del segreto, in base al valore facciamo o solo square oppure sq + mult., con un algoritmo naive le tempistiche ed i pattern di assorbimento sono differenti in base al fatto che l'esponente

abbia uno 0 o un 1, quindi il pattern è fatto in modo seguente:



vedo gli 0 e gli 1 della chiave → RSA rotta.

È un attacco anche di tipo timing + delay, correlo a cosa vedo dall'esterno in base a quanto tempo ci mette a fare le operazioni, quindi posso fare delle assunzioni sul peso di Hamming della chiave (quanti 1 ci sono).

Differential power analysis


È il più classico caso di side channel attack, si ottiene con un elevato numero di tracce. Si crea un modello del device fisico dove abbiamo i dati e la chiave e tiriamo fuori da questi un ipotetico modello della power absorption.

Man mano correliamo i dati osservati fino ad avere delle correlazioni forti che ci permettono di trovare i valori della parola in plaintext (e della chiave) perché la correlazione è forte.

Electromagnetic Power Analysis

Possiamo poi avere la EM power analysis: l'attacco è passivo, si mette una spia collegata ad un oscilloscopio, se c'è una caduta EM sulla spira, ci sono cambiamenti di dati nei transistor, anche qui si posson fare analisi simple o differential, qui cerchiamo di osservare quali sono le correnti circolate nel dispositivo.

Qui le tracce sono diverse dal caso della power:



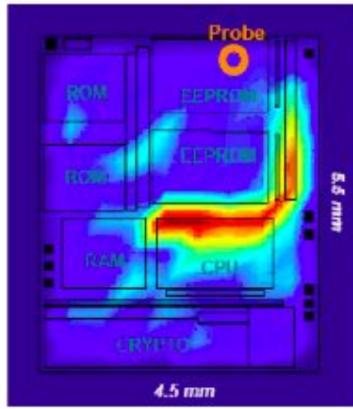
nel caso power le tracce sono smussate, meno rumoroso perché si eliminano le frequenze elevate dai condensatori, le emissioni EM sono invece più rumorose e più acute quindi occorre fare post processing del segnale.

Ad esempio, possiamo avere un processore usato per la crittografia:

con l'EM analysis possiamo vedere dove c'è stata attività durante la crittografia, la densità spettrale permette di correlare le attività funzionali e quindi anche di capire dove sono i bit dei segreti e quindi più informazioni = più facilità nel rompere l'algoritmo.

La potenza da una sola traccia su tutto il chip, posso solo osservare la potenza assorbita, mentre vedendo le probe nei diversi punti nel chip abbiamo una traccia per ognuno dei componenti hardware e possiamo capire quindi se:

- stiamo facendo fetch del dato



- stiamo facendo processamento del dato

Quindi il vantaggio dell'EMA è che le informazioni locali sono più correlate ai dati, bypassando i condensatori che altrimenti fanno smoothing dell'assorbimento di potenza.

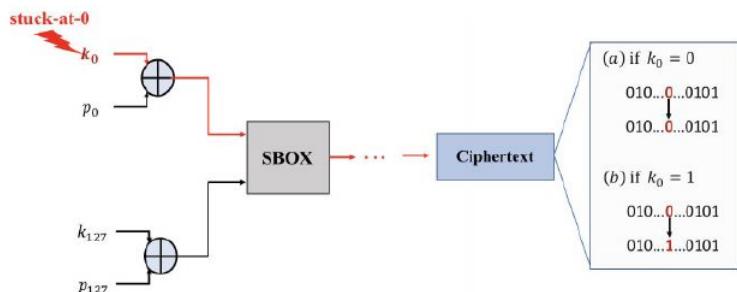
Sperimentalmente sono più complesse, lo scan su tutto il chip può essere tedioso e ci sono molte più problematiche da gestire.

Fault injection attacks

Il side channel è attivo: inietto un guasto, ad esempio glitchando il clock o l'alimentazione, cambio un bit e quindi l'effetto ad esempio sulle istruzioni è che ne venga eseguita un'altra che può causare dei side effect, quindi sono approcci algoritmici.

Facendo questo in massa, è possibile trovare delle correlazioni con la chiave.

esempio:



glitchiamo la chiave in modo che sia fatta da soli zeri, quindi ne vediamo l'effetto in quanto il ciphertext creato è diverso e ci permette di identificare poi il vero valore di k: correliamo alla stessa cifratura della parola che si ottiene senza fare glitching, già trovare un sotto insieme della chiave riduciamo esponenzialmente il numero di ricerche esaustive.

Le tecniche possono essere:

- di tipo voltage, buono in quanto non invasivo. Ci sono dei voltage smoother che riducono l'effetto, ma toccando il voltage si cambia il comportamento
- clock pin, si fa una piccola variazione del clock nel suo andamento oscillatorio, correlando questo effetto con quello "pulito", dopo tante simulazioni possiamo tirare fuori l'effetto sul dato misurato e quindi una rivelazione del dato segreto
- disturbi EM

- laser, possiamo andare in maniera molto puntuale a flippare dei bit in una locazione del chip. Il problema è che occorre togliere l'incapsulamento del chip, altrimenti il laser non può passare. Siccome il laser è puntuale, si possono flipare zone del chip dove possiamo immaginare che ci siano parole della crittografia o parti della chiave segreta. L'approccio è però molto invasivo.

Attacchi timing

Sfruttano vulnerabilità dell'hardware che potrebbero essere osservati da remoto.

Se ci collegiamo ad un dispositivo, mediante analisi accurata del timing, riusciamo a derivare i cicli che ci ha messo un processore per fare delle operazioni, posso inferire la chiave.

È un approccio come la SPA, dove assorbo la potenza e vedo dove sono gli 1, anche qui vedo almeno quanti 1 ci sono e lo faccio da remoto: sempre con l'approccio naive, possiamo avere questa misurazione.

Sfrutto un ottimizzazione a mio vantaggio, ce ne sono altre quando ci sono delle ottimizzazioni del microprocessore: ricorda OOO, caching, speculative execution, possiamo usarle per inferire il segreto. Nelle micro-architetture, tipicamente c'è un processore in-order, senza OOO, senza branch prediction: se c'è un errore la pipe è squashata, se serve prendere dati dalla memoria si va in stall.

Per avere ottimizzazione:

- branch prediction
- OOO
- pipelining

quando le cose vanno male, si flusha la pipeline e vengono rese non valide le operazioni fatte prima. Il problema è che le operazioni di flush lasciano un'impronta nel dispositivo. Abbiamo quindi transient execution attack, con due grandi esempi:

- spectre: lettura arbitraria di locazioni di memoria
- meltdown permette di leggere tutta la memoria di un sistema

dovute all'esecuzione speculativa, della presenza della pipeline e l'OOO.

Dipende dall'implementazione dei manufacturer, come funziona:

- preparazione della micro-architettura
- parte l'esecuzione di trigger
- c'è un'esecuzione transiente che porta ad eseguire istruzioni illegali, che porta quindi allo squash della pipeline
- la CPU fa il retirement dell'istruzione
- si può ricostruire l'informazione

Esiste ad esempio il caso del flush + reload: l'attacco è combinato, c'è qualcuno che osserva gli effetti fatti dall'altra fase. Qui:

- invalido tutta la cache di primo livello
- un dato richiesto va fetchato quindi dalla memoria centrale
- osservo un tempo elevato di accesso ai dati, perché il fetch richiede un accesso in memoria

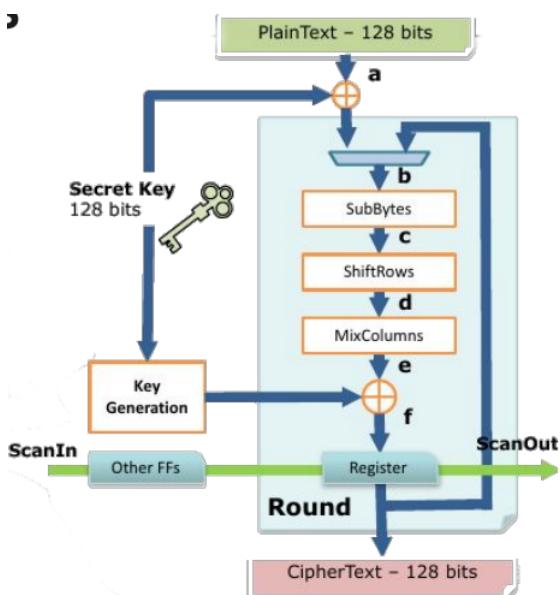
- ricarico e vedo tutti tempi lunghi. Ma se nel frattempo l'attaccante, per via di una operazione OOO o speculativa ha fetchato uno dei dati che sta in un indirizzo che ho invalidato e questo è correlabile con un segreto. Quindi al reload, per accedere all'indirizzo dove so che c'è il segreto, ci metterò di meno ad accedervi e saprò che è lì il segreto.

È l'indirizzo correlato al segreto

Sono tutti attacco micro-architetturali, ciò che ne viene fuori è che quando si progetta un dispositivo per le performance, non sempre questo è ottimizzato per la security: occorre pensare se le performance vadano a tradire la sicurezza, analogo allo square + multiply dove per ottimizzare non si fa multiply quando c'è 1 all'esponente.

Attacchi basati sul test

Potendo vedere il contenuto dei flip flop del dispositivo, potrei anche vedere il contenuto di registri intermedi che contengono parti della chiave AES, blocco quindi l'esecuzione intermedia e cerco di recuperare la chiave:




Una delle contromisure è la defuse, ovvero si spacca l'hardware usato, tanto lo vederemo meglio quando parliamo delle contromisure(??).

Capitolo 16

Blocco 4 - Contromisure

16.1 Introduzione

Le contromisure sono le tecniche ad oggi usate per o mitigare o evitare i problemi di trust o vulnerabilità. Parzialmente le tecniche fanno leva su quelle per garantire affidabilità e reliability del sistema. Possiamo vedere un riassunto delle problematiche ma anche delle soluzioni:



possiamo avere mischiate le problematiche di trust e vulnerability, anche se il prof preferisce separarle.

Di nuovo, siamo focalizzati su trojan horses e physical attacks, in campo più ampio si parla anche di

- IP piracy
- reverse engineering
- tampering
- ...

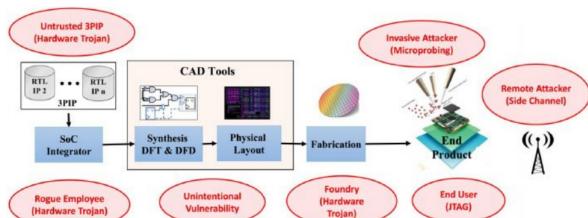
ci sono problematiche sia di fiducia che di sicurezza, che possiamo inquadrare in un generico trust. Quando si tratta di attacchi, vogliamo proteggere informazioni di sicurezza nel dispositivo:

- on-device key: la chiave privata di un algoritmo di cifratura.
Tipicamente salvate sul chip nella forma di memoria non volatile, se sono scoperte, il requisito di confidenzialità salta
- firmware del costruttore: istruzioni di basso livello e firmware proprietario.
Sono valori di IP del costruttore originale
- on-device protected data, oggetto di attacchi dove sia l'attore fa leva con trojan hardware sia con attacchi puramente hardware.

- configurazione del device, che contiene i dati di configurazione e determina quali risorse e servizi sono disponibili per un particolare utente.
Un attaccante potrebbe manomettere questi asset per ottenere accesso non autorizzato alle risorse
- bit di entropia: se rendo predicibile il TRNG, quindi cosa genera la chiave crittografia, ho sconfitto la crittografia.

Il confine quando si tratta gli assetta attaccati, fra trust e vulnerability, è molto più labile, ovviamente l'attaccante potrebbe anche voler causare DoS.

L'ambito è sempre di un attore malevolo che vuole causare un danno di qualunque tipo, quindi riasumendo i possibili attacchi:



possiamo anche parlare di j-tag: sta su tutti i chip, usata da chi programma hardware (FPGA) per fare debugging, ad esempio accedere al processore, si può fare step-by-step execution tramite questa porta.

Nasce come protocollo di test di produzione, che può essere soggetto ad attacchi.

16.2 Contromisure contro i trust issues

16.2.1 IP trust

Il primo problema può essere di IP trust, dovrei verificare un IP e come faccio a farlo?

Possiamo avere IP di diverso livello in base a quanto le possiamo manipolare, ma alla fine ne facciamo uso senza conoscerne il contenuto a fondo, sono protette da copyright.

Non abbiamo quindi un golden model (perché altrimenti sarebbe open), potrei usare le specifiche come golden che però magari non mi permettono di conoscerne il funzionamento al 100%.

Per capire se l'IP si comporta come dovrebbe, esistono diversi livelli di astrazione dove poter agire: nella fase di pre-sintesi, l'IP soft è solo codice HDL, dopo la sintesi il codice verrà tradotto in una netlist a livello di gate.

La verifica formale e la coverage analysis sono usate per assicurarsi che la netslist sia fidata.

Possiamo quindi distinguere diversi tipi di controlli:

- formal verification: possiamo fare tracing e verifica come nel software testing.
È un modo che può coprire delle problematiche che sono state introdotte a livello di specifica o a livello di progettazione.
Vengono quindi fatte:
 - property checking: ogni requisito è definito come un asserzione nei testbench ed è controllato
 - equivalent checking: controllo fra RTL (codice come il C), la netlist ed il GDSII file;
 - model checking: il sistema è descritto in codice C o HDL, viene fatto un insieme di proprietà e si verifica che l'implementazione verifichi il modello formale;

;

- coverage analysis: verifica che nel codice ci siano diversi livelli di coverage, che vengono verificati con un profiler usando dei benchmark significativi per vedere se il codice viene utilizzato.
es: una macchina a stati nascosta che si attivano tramite una molto rara combinazione di ingressi, mediante code coverage potrei trovare del codice che non viene mai eseguito.
Se un'asserzione fallisce, può esserci un problema di IP trust.
Altra cosa è il coverage, se non viene attivata una parte di codice, ci può essere del codice nascosto proprio perché l'attivazione dei trojan è pensata per essere rara.
Possono esserci diverse metriche di coverage:

- code coverage:
 - * line coverage
 - * statement coverage
 - * FSM coverage
 - * toggle coverage
- functional coverage, dove verifichiamo le asserzioni

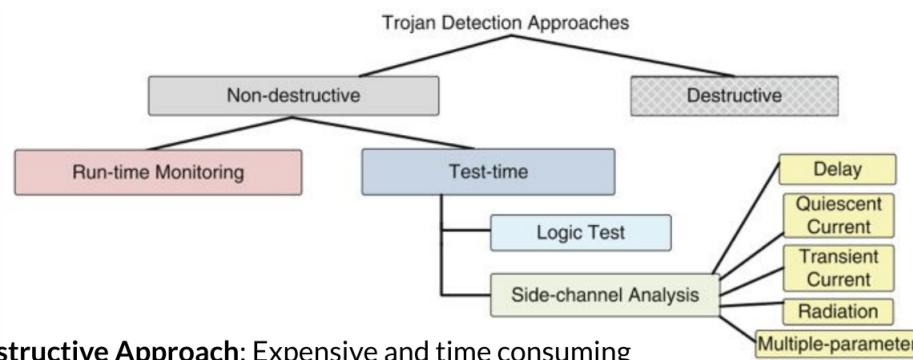
16.2.2 IC (System) trust

Provengono da tecniche per verificare il silicio.

Il problema qui è che l'avversario (payload etc..) potrebbe essere messo a posta per non venire scoperto.

Dopo la sintesi, il prodotto deve comportarsi da specifica, qui il problema è che i trojan sono piccoli e difficili da trovare, quindi gli approcci del test in production funzionano poco, non sono efficaci perché nel test di produzione ci focalizziamo sui difetti di produzione che sono predibili ma non su qualcosa aggiunto maliziosamente.

Abbiamo la tassonomia per la rilevazione dei trojan:



si può fare sia in maniera distruttiva che non distruttiva.

Nel secondo approccio, una volta avuto il chip (siamo a livello IC, è stato già prodotto), possiamo:

- mettere approcci di run time monitor: abbiamo messo delle ridondanze nel chip per verificare se run time qualcosa va storto.

I difetti malevoli che si attivano come time bomb le stanno perché ho queste ridondanze che cercano errori random ma anche maliziosi. Può verificare sia problematiche di trust che anche di affidabilità

- a livello di test, il famoso test di produzione. Si può fare sia logic test o un test che usa i side channel, che sono usati per verificare se ci sono delle emissioni, assorbimenti di potenza, corrente quiescente o transitoria che possono rivelare la presenza di trojan.

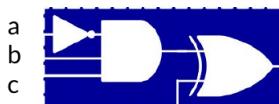
L'approccio distruttivo serve per verificare se un lotto è affetto da trojan, quindi lo distruggiamo: questo vuol dire dis-encapsularlo e fare una specie di affettatura di layer di metalizzazione, con agenti chimici o meccanici.

Facciamo delle "foto" con cad di ogni livello prima di rimuoverlo, guardando le caratteristiche fisiche del dispositivo capiamo cosa fa e quindi se ci sono dei trojan. È costoso e potenzialmente non risolutivo dovuti ad errori che possono esserci nel processo, inoltre a meno di capire al volo se un transistor doveva esserci o meno, occorre capire se il layout corrisponde con quello reale: io ho fatto il pape-out (il golden) mandato in foundry, dove è stato modificato maliziosamente, quindi se non ho il golden non posso verificarlo.

16.2.3 Approccio del logic test

Mutua le tecniche di test che vengono fatte in produzione. Devo generare dei vettori di test che triggerino il trojan e poi osservare il comportamento del payload.

Ad esempio:



Example: Find vector to activate Trojan Trigger Condition
(a=0, b=1, c=1)

il pro è che se riusciamo ad avere dei vettori funzionali e strutturali buoni usiamo tecniche note per trovare i trojan, in maniera rapida.

Se però i test sono fatti "alla cieca", il tasso di successo è basso, poiché esiste tutta una letteratura che riduce il numero di vettori necessari per trovare i problemi e comunque occorre fare del lavoro aggiuntivo per ridurne ancora il numero e serve la conoscenza del layout.

Senza sapere il layout occorre anche fare delle assunzioni, quindi ho diversi contro: (slides)

- la difficoltà nel eccitare od osservare nodi a bassa controllabilità o bassa osservabilità
- i trojan sono fatti per essere attivati in condizioni rare
- il test che si basa sulla ricerca delle attivazioni nelle net, non può ad esempio trovare trojan che vengono attivati dall'esterno ad esempio con emissioni EM dall'esterno, o anche trojan che non cambiano le funzionalità ma emettono EM verso l'esterno per info leaking

Ad esempio, per test funzionali su un adder (per trojan funzionali), dovremmo passare un numero di input elevato che quindi potrebbero richiedere centinaia di anni:

se ad esempio consideriamo un adder con 64 input occorrerebbe effettuare la combinazione di 2^{65} input, quindi conti non fattibili.

Invece di usare approcci funzionali, si possono applicare approcci strutturali, quindi invece di far fare al dispositivo quello che dovrebbe fare, lo scompongono e lo osservano: è l'approccio tipico del test di produzione, si perde la funzionalità ma ho maggiore controllo ed osservabilità.

Nel test strutturale si usa comunque un approccio deterministico, so dove sono i guasti sulla net,

ma per i trojan non è detto che io sappia dove siano, quindi posso usare approcci statistici come MERO: prendo la netlist, l'approccio cerca di vedere quali sono gli eventi rari (es: 1/4 per lo 0 sulla porta OR), cerchiamo quindi di trovare vettori che stimolino gli eventi rari N volte. Assumiamo che i trojan siano stati messi proprio per essere attivati da eventi rari, i test vector stimolano proprio gli eventi rari nella speranza di trovare i trojan.

L'articolo di MERO dimostra che la coverage in termini di trojan migliora, ma chiaramente anche la test length aumenta perché faccio toggling degli eventi rari molte più volte.

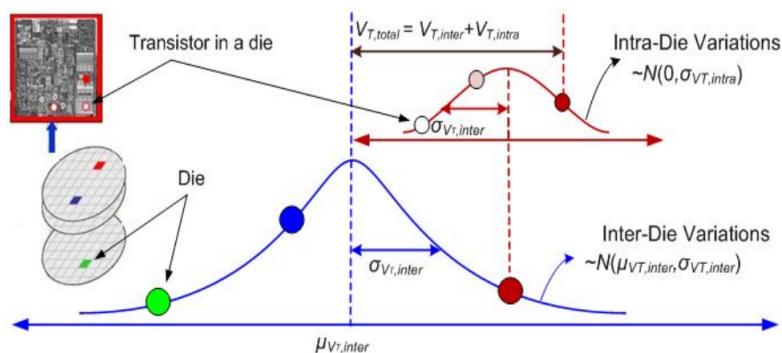
16.2.4 Analisi side channel - potenza assorbita

Usiamo l'approccio speculare di quello malevolo: qui l'assorbimento di potenza è un indicatore dell'eventuale presenza di qualcosa di malevolo nel dispositivo stesso.

Facciamo attivare (almeno parzialmente) il trojan, che creerà dei picchi di assorbimento di potenza (genera toggle di transitor) che si manifestano come outlayer nell'assorbimento medio del dispositivo. Occorre conoscere il circuito originale, la netlist originale, altrimenti non posso sapere qual è un outlayer: avendola, posso confrontare l'assorbimento di potenza che registro con quello originale.

Questi test sono anche usati in test di produzione ad esempio per vedere se ci sono dei transitor sempre accesi, quindi sono usati anche per cercare dispositivi guasti in produzione.

Il problema dell'approccio è che quando si fa la produzione del dispositivo elettronico, nei wafer etc.. c'è la così detta process variation: qualcosa che dice che non tutti i transistor sono nati uguali



questo porta a delle dimensioni di tutti i parametri che fanno sì che tutti i dispositivi non siano identici bensì distribuiti come una Gaussianas, c'è variazione fra i diversi die ma anche nello stesso die.

Questo vuol dire che ci sono molte problematiche nella capacità di poter rivelare la presenza effettiva del trojan.

I segnali di tipo side channel usati sono:

- IDDQ
- IDDT, gli switch extra consumano più potenza dinamica
- path delay, vedere i ritardi in una rete combinatoria per cercare delle porte logiche aggiuntive che introducono ritardi
- emissioni EM aggiuntive

Pro: è efficace per trovare trojan che non causano malfunzionamenti nel circuito, qui ad esempio con emissioni EM vediamo i trojan, non abbiamo il problema che avevamo nei test strutturali (ad esempio il MOLE fa un casino ma non cambia le funzionalità e quindi col test non si trovava).

Contro: la process variation rende complesso trovare i trojan, occorre togliere molto rumore. Inoltre occorre sempre avere i golden chip su cui parametrarsi. I metodi di sensitività prevedono che:

- più il trojan piccolo, più la sensitività si abbassa
- più la taglia del circuito aumenta e più si abbassa la sensitività

in generale, segue la regola:

$$Sensitivity = \frac{I_{tampered} - I_{original}}{I_{original}} \cdot 100\% \quad (16.1)$$

Riassumendo, pro e contro degli approcci di logic testing e side channel analysis:

	Logic testing	side-channel analysis
Pros	robusto al rumore nel processo	efficace con trojan grandi
	efficace per trojan molto piccoli	facile generale test vector efficaci
Cons	difficile generare vettori di test	vulnerabile al rumore nel processo
	i trojan grandi sono difficili da scoprire	i trojan piccoli sono difficili da scoprire


Corrente assorbita

Un altro modo per mitigare il rumore è usare più parametri, come la frequenza massima e la corrente assorbita durante la transizione.

Questo permette di togliere di mezzo la variazione: correlando i due parametri, siccome questa dipende dalla variazione, se il dispositivo è tamper (modificato) riusciamo meglio a rivelare la presenza di trojan, i due variano insieme e quindi il rapporto dovrebbe essere costante mentre se c'è un effetto di trojan, magari a parità di corrente riduce la frequenza massima.

esempio: ipotizziamo un trojan in un benchmark s, inserito in una zona specifica del dispositivo.

Vediamo la distribuzione dell'alimentazione modellata come una rete RC:



l'effetto del trojan può causare un assorbimento di corrente maggiore ad esempio nel PP4, mentre magari nel PP1 essendoci più carichi capacitivi c'è un minore assorbimento.

C'è quindi un aspetto di località dei trojan: nella rete di distribuzione della potenza, possiamo vedere in uno specifico pad che l'assorbimento di potenza è effettivamente più alto che nel resto del

dispositivo, quindi **sempre sapendo che ho il golden**, possiamo caratterizzare un assorbimento anomalo.

Qui il trojan è stato messo in un buco libero (??).

Integrazione della corrente

Un altro metodo prevede l'integrazione della corrente: integrando la corrente durante il funzionamento del golden e del tamper, dovrei vedere una differenza importante. Il trojan causerà un assorbimento maggiore della carica nel tempo

$$Q_{trojan-free}(t) = \int I_{trojan-free}(t)dt \quad (16.2)$$

ed anche

$$Q_{trojan-inserted}(t) = \int I_{trojan-inserted}(t)dt = \int (I_{trojan-free}(t) + I_{trojan}(t))dt \quad (16.3)$$


Il metodo è però poco localizzabile rispetto a prima.

La power analysis ha comunque dei problemi:

- come trovare dei vettori che stimolino i trojan
- come ridurre il rumore
- località dello switching (che può essere rilevata con tecniche viste sopra)
- random pattern: applichiamo un certo numero di vettori senza osservare i bit sul layout
- problemi legati al rumore nella misura
- calibrazione per via delle variazioni di processo

Delay analysis


Un altro modo per fare l'analisi dei side channel è con l'analisi dei ritardi:



abbiamo una rete combinatoria con il trojan che aumenta il carico capacitivo sui nodi, aumentando quindi i ritardi di propagazione, la costante RC è più alta e quindi la frequenza del dispositivo è più bassa.

Possiamo usare delle tecniche per rivelare la presenza di ritardi anomali, sempre sapendo il funzionamento ideale:

tecniche usate per fare DVFS: nei sistemi embedded c'è un controllore che si occupa di ridurre la potenza assorbita, avendo una batteria è inutile mandare il clock al massimo o tenere le tensioni alti. Guardo gli stati di potenza (i pstate, ovvero i power state che sono fondamentali in dispositivi IoT): dal più basso dove è quasi idle, al più alto (maggiore è lo stato maggiori le prestazioni e l'assorbimento di potenza).



Sono tutte tecniche per la riduzione di potenza assorbita. Usano spesso un doppio flop:

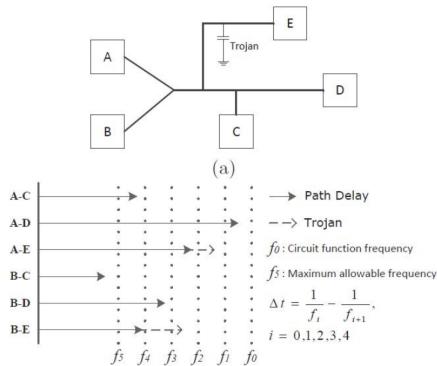
se il ritardo è elevato perché il circuito combinatorio è lento, la transizione che doveva arrivare al flop non ce la fa prima che quello shadow parallelo campioni.

Un flop è attivato col fronte d'onda che sale, l'altro con quello che scende, quindi se c'è differenza fra i due flop la frequenza (lo XOR alla fine compara i due bit e flagga se diversi) è troppo bassa e va alzata.

Se quindi c'è un trojan, a parità di tensione e frequenze di funzionamento, vedo dei fail sulla rete combinatoria, sfruttando una tecnica di ridondanza dell'affidabilità.

Clock sweeping

Altro è la clock sweeping technique: devo confrontare sempre col golden, se vedo dei ritardi anomali, provando tutti i percorsi possibili, riesco facilmente a dire, in base a quale percorso ha il problema, su quale net si trova il trojan:



Problematiche: rispetto alla power analysis non serve attivare il trojan, si vedono i ritardi. I test sono anche usati in produzione, quindi li posso riusare. Il problema è nella variazione di processo, temperatura e tensione che ovviamente introducono rumore.

16.3 Desing per trust dell'hardware

Oltre agli approcci di prima, possiamo cercare di rendere più difficile a 3° di introdurre dei side channel.

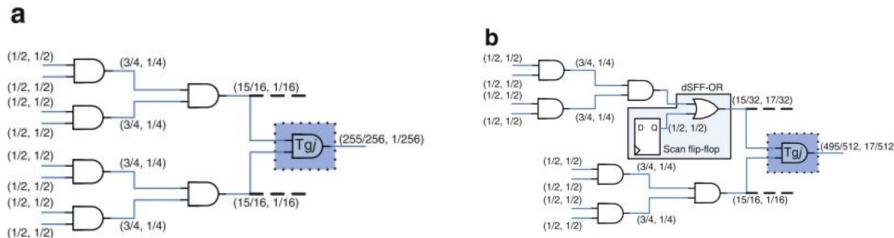
Come progettiamo per evitare la presenza dei trojan, o comunque ostacolarne l'inserimento:

- tecniche che migliorano la rilevazione dei trojan stessi. Faccio progettazione che li rende più rilevabili

- tecniche per prevenire l'inserimento del trojan, con una specie di offuscamento del progetto

Per migliorare la detection, possono rimuovere gli eventi rari: i trojan sono messi lì in modo da essere attivati da eventi rari della netlist.

Rimuovendo questi eventi, potrei rendere l'inserimento del trojan più difficile e la rilevazione più semplice. Per fare ciò: ipotizziamo di avere questa netlist:



il trojan sfrutta degli eventi molto rari, l'attivazione è $\frac{1}{256}$, per renderlo meno raro aumento l'osservabilità mettendo un flop di scan, che viene attivato solo durante il test, il flop è normalmente 0 ma mettendo 1 durante lo scan la probabilità dell'1 aumenta (immagine a dx), quindi posso migliorare la controllabilità e quindi ridurre la probabilità di eventi rari.

Questo aiuta sia quando vogliamo vedere la funzionalità del trojan, ma anche per vedere l'assorbimento di potenza (se ci sono pattern anomali) o di delay.

Possiamo quindi:

- aumentare l'attivazione completa
- generare delle attività di switching
- attivare più percorsi per migliorare la coverage

Possiamo avere tecniche di run time monitoring, a livello di progettazione si modifica la presenza di modifiche maliziose del dispositivo, così che se ci sono dei trojan su FPGA o un trojan su hard IP SoC si possono detectare.

Usano tecniche già note per la fault tolerance, ovvero aggiungere dei checker che monitorino il chip, ci sono varie tecniche già usate per avionica, etc... e si possono usare per determinare che l'evento random che causa il problema sia stato inserito in maniera malevola.

16.3.1 Design obfuscation

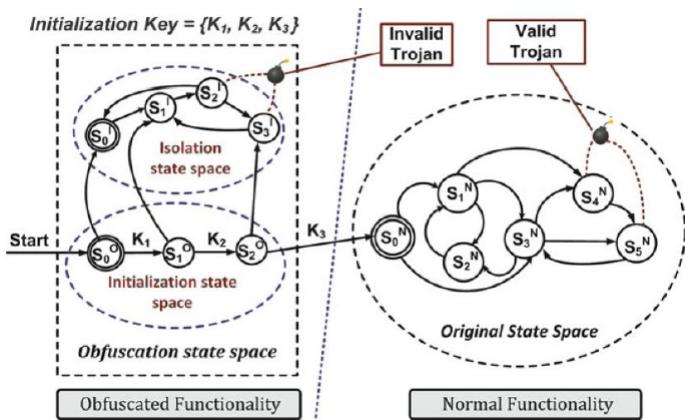
Rendiamo più complesso ad un attaccante di inserire un trojan, come si offusca il progetto: ipotizziamo di avere questa macchina a stati:

aggiungiamo delle transizioni che non servono a nulla, ma confondono l'eventuale attaccante, questo fa sì che l'attaccante magari inserisca il trojan in una transizione fra stati che non avverrà mai.

Magari il problema del trojan viene creato su una transizione fra due stati che funzionalmente non verrebbero mai usati. Il problema è che si aggiunge ridondanza, inoltre il trojan dovrà essere inserito negli stati inutili, comunque l'idea è rendere più complesso capire la struttura per l'attaccante.

Tipicamente in un circuito avanzano degli spazi inutilizzati dove si possono mettere dei checker, ha impatto basso da un punto di vista di layout.

Alcuni svantaggi:



- deve dirci bene che l'attaccante sbagli, essendo un approccio random avremo una certa probabilità di successo;
- introduco ridondanza, quindi più ritardi, più area necessaria ...

16.4 Contromisure per le problematiche di side channel

Qui l'obiettivo è rendere più complesso un attacco di tipo side channel:

- tecniche di hiding: riduco il rapporto segnale/rumore, aggiungendo ad esempio segnali di rumore mediante un TRNG, che faccia sì che non è semplice riconoscere il segnale utile.
È costoso, potrei quindi fare delle modifiche funzionali del dispositivo
 - usare i bit anche nel valore negato, così che tutte le transizioni siano sempre binarie e non si capisca quale valore c'è dentro perché ci sono sempre transizioni.
 - usare logica sincrona
 - low power design per ridurre le emissioni
 - shileding: la metallizzazione impedisce le emissioni EM
- mascheramento, possiamo ad esempio cambiare gli algoritmi per rendere le cose uniformi (come lo square + mult)
- partizionare il progetto, per rendere difficile all'attaccante capire in quali zone c'è il ct e in quale il pt
- tecniche di physical security ed anti-tamper, ad esempio facendo sì che il decapsulamento distrugga il chip

ha comunque tutto un costo.

Contromisure contro la DPA:

- contromisure applicative, che rendono la randomizzazione del messaggio impossibile:
 - fissare alcuni byte del messaggio
 - vincolare i byte variabili
- scorrelare le curve di potenza dai dati:
 - in hardware: scrubble di corrente, mediante rumore aggiunto

- in software: con data whitening

- desync delle N tracce: se l'approccio è tale per cui in una certa fase, ad esempio, si decifra una parola, l'attaccante deve avere tante tracce per poterle correlare.

Se rendiamo ogni taccia diverse dalle altre perché introduco dei delay random, la correlazione delle tracce con il modello è più complesso perché andrebbe anche modellato l'effetto della contromisura.


È molto usato, rendo random il clock e vado contro gli attacchi che usino tante tracce, saranno più complessi

- delay random nel software
- ordini random nel software
- stati di wait nell'hardware, stalli aggiunti dalla CPU
- clock hardware instabili internamente, con shift di fase

rendono difficile a chi sta osservando il comportamento della macchina a stati di capire cosa sta accadendo.

DPA è potente ma ci sono diversi algoritmi che mitigano gli attacchi.

Ad esempio:



quando si de-sincronizza, la tracce assomigliano sempre di più a rumore.

Attacchi EM: come negli approcci DPA o SPA, ridurre le emissioni radiative o cancellarle

- software che cambiano come sono implementate le crypto routine

- in hardware:

- confinare la radiazione con un layer metallico (tipo gabbia di Faraday)
- creo onde EM che si cancellano
- ridurre la radiazione
- cancellazione della radiazione

Contromisure per le micro-architetture: qui l'attacco non deve poter sfruttare i timing o dell'algoritmo elaborato sul processore:

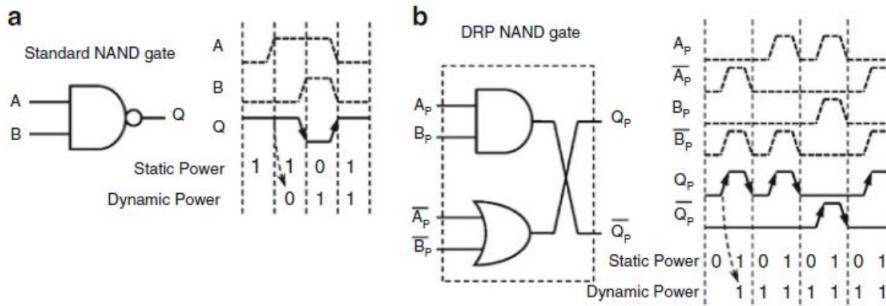
- cambiare il programma, così da evitare dei leak

- usare diverse micro-architetture che non creino il side channel

esempio: usare la Dual Rail Precharge:

qui assorbo potenza sempre, che è molto svantaggioso per sistemi embedded ad esempio, quindi potrei penalizzare un utilizzo ad esempio per dispositivi IoT.

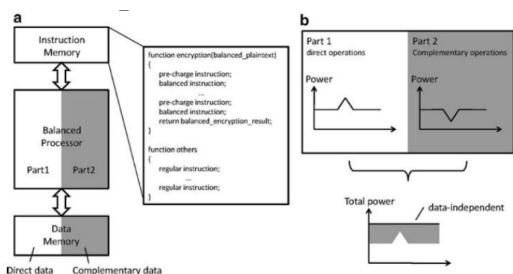
Il vantaggio è che avendo sempre l'opposto del segnale, se uno dei due flippa posso sempre verificare l'XOR che deve essere pari ad 1, se non lo è scopro che c'è un problema (è ridondanza spaziale).



avere delle transizioni che non abbiano dei picchi così definiti (NAND di sinistra), mentre con A, B ed in negati possono avere sempre una transizione o per uno o per l'altro, così da vedere sempre una potenza assorbita dinamica ed avere una dissipazione data-independent.

Lo svantaggio è comunque di dover avere due porte e dover propagare due segnali, ma avere un segnale che è sempre il negato dell'altro può dare benefici di dependability.

A livello di processore:



ho un doppio di tutto, solo la instruction memory è unica, se osservo le emissioni, la potenza totale che sarà la somma è costante.

Implica una modifica architettura del processore ed ha impatto sulle performance.

Un approccio che mitighi gli attacchi timing, ovvero le vulnerabilità micro-architetturali che monitorano i ritardi di esecuzione:

- modificare l'architettura, per evitare di mischiare lo spazio utente da quello kernel, con delle performance penalty;
- aggiungere un checker online per analizzare e trovare attività malevole: gli attacchi micro-architetturali sono spesso basati sull'esecuzione ripetitiva di una serie di operazioni che lasciano una firma. Possiamo fare un profiling del codice run time, per poter flaggare e passare ad un exception handler;

per evitare ad esempio un attacco sulla cache possiamo invalidare in maniera più o meno specifica la cache L1, ma poi avrò un miss e sarà come non usare la cache.

Open ISA sono l'equivalente delle open OS, da un punto di vista del mantenimento del codice è più facile.

Contromisure per fault injection: aggiungendo errori (cosa si fa nella FIA), posso avere più informazioni sull'algoritmo crittografico che sto cercando di rompere.

Attacchi side channel invasivi, in cui glitchiamo power, clock, laser che flippano etc... occorre usare:

- tecniche che rilevino la presenza dei guasti
- detection di fault injection
- detection per fault effect (error)

Si potrebbe far sì che sia difficile la predizione del timing: nel FIA dobbiamo inserire i trojan in un punto specifico dell'algoritmo di cifratura, così da sapere che l'effetto causerà delle conseguenze osservabili.

Per renderlo difficile:

- si crea una maggiore incertezza sul timing dell'esecuzione, aggiungendo jitter nel clock
- dummy instruction
- operazioni randomizzate

così che se si pensa che c'è il ciclo che fa la 4° iterazione di AES, questa è fatta sempre in tempi diversi.

Altro modo è fare delle metalizzazioni che impediscono il passaggio del laser.

O anche tecniche che:

- rilevino il problema:
 - fotocellule che rilevino attacchi
 - sensori bulk
 - rilevatori di glitch

ci possono essere falsi positivi.

Oppure si usano tecniche di ridondanza, di spazio tempo e informazione:

- fare due volte la stessa operazione e confrontare il risultato
- fare l'operazione ad anche la sua inversa e verificare
- aggiungere codici a correzione di errori
- gli stessi metodi per trovare errori nel software causati da sorgenti di rumore casuale

Infine, tecniche per mitigare la vulnerabilità al test: il test è fatto apposta per osservare e controllare, ma se posso farlo ho sconfitto tutto ciò che è sicurezza, quindi si possono tagliare i ponti oppure cifrare le scan chain.

Un'altra cosa che può essere spazio di attacco è che i dispositivi sotto test lascino aperti ponti da osservare nella vita utile. Dopo il test le scan chain vengono staccate così da impedire l'accesso fisico, a questo punto il debug e test successivi non sono più fattibili.

Possiamo anche far sì che il dispositivo non sia più accessibile da fuori, un tend attuale è il built

in self test, ovvero il dispositivo si testa da solo. È già fatto nelle memorie, ma il test logico di un circuito combinatorio sequenziale ancora non lo è ma permetterebbe di non avere accesso da fuori, però può fare problemi nella coverage.

Ultima contromisura: invece di tagliare le scan chain o usare il self test, si fa un accesso al dispositivo che sia cifrato: la chiave del dispositivo è nota solo a chi fa il test, il contenuto dello scan chain prima di essere mandato sul dispositivo è cifrato così che un attaccante che non conosce la chiave non possa attaccare.

È simile a cosa viene fatto per i bitstream crittografati delle FPGA.

Capitolo 17

Blocco 5 - Hardware Security Primitives

17.1 Randomness in hardware

Fin ora abbiamo visto tutto ciò che si fa sfruttando tecniche di affidabilità o di qualità. Esistono dei moduli ad hoc a supporto dell'autenticazione o della crittografia. Sono:

- PUF
- TRGN

Usano la randomicità dell'hardware, il "seed" è un fenomeno fisico impredicibile. Questi blocchi sfruttando le sorgenti di randomicità del dispositivo, nel processo ci sono delle randomicità aggiunte che non sono volute, per cui gli hw designer cercando di eliminarle prendendosi del margine ampio.

Queste invece la sfruttano a loro vantaggio, le randomicità possono essere:

- in fabbricazione, quindi usiamo quella per identificarlo con una "impronta digitale" che sarà sempre la stessa per tutta la vita utile. Sfrutta la process variaibility per i PUF
- a run time sfruttiamo diversi eventi che causano generazione randomica di eventi che possiamo usare come seed per le chiavi crittografiche

17.2 PUF

Usato tipicamente per l'autenticazione dei dispositivi integrati, esistono:

- strong PUF: dopo che il dispositivo viene prodotto, lo caratterizzo. Mandando dei segnali, memorizzo le risposte a queste random challenge. Ora, mando il dispositivo nel mondo e per verificare che sia lui uso una challenge / response pair che dovrebbe non essere replicabile perché non dipende dal layout del dispositivo: anche facendo revering del dispositivo non riesco a ricostruire quelle coppie di C/R.

Sono necessarie in quanto le chiavi segrete e gli ID dei circuiti spesso sono salvati in memorie non volatili e queste possono essere attaccate e le chiavi clonate.

La "spia" ha con se la chiave, mentre non dovrebbe essere così, l'approccio delle smart card non è fattibile, si possono approcciare con interfacce "non tradizionali"; come faccio a non memorizzare la chiave nel dispositivo, così che chi fa RE troverà solo un circuito: ci sono varie maniere di fare i PUF

17.2.1 Silicon PUF

Sfruttano delle variazioni fisiche che esistono nei circuiti integrati moderni.

Le piccole diversità vengono sfruttate per questi fini, la variazione come detto avviene sia nello stesso wafer che fra i diversi wafer.

Ognuno ha la sua variabilità e può essere ovunque, viene tenuta in considerazione quando si fa la progettazione, vengono chiamate **corners**, ovvero tutte le possibili transizioni fra due end di un circuito in modo che si prenda in considerazione che i transistori in media non sono tutti uguali, alcuni sono più veloci altri meno.

In realtà sono disposti più o meno su una Gaussiana:

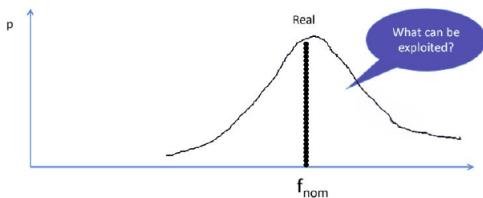


Figura 17.1:

nel circuito ci può essere variazione nella dimensione del condensatore etc... che fa variare la τ e quindi invece di una δ (Dirac) abbiamo una Gaussiana.

È solo uno dei casi di uso, ovvero la frequenza degli oscillatori.

Nel PUF devo prima caratterizzare il sistema fisico, per poi tirare fuori i response bits e posso generare diversi segreti in base alle challenge che mando.

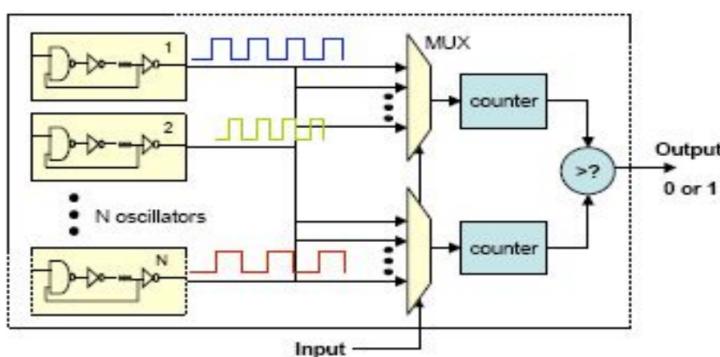
Ci sono diversi vantaggi:

- la chiave non è salvata
- posso generare diverse master keys

Ci sono vari approcci per costruirli relativi a dei fenomeni che sono facili da misurare

17.2.2 Ring oscillator PUF

Ci sono N oscillatori che hanno frequenze che dipendono dai transistori che li compongono:

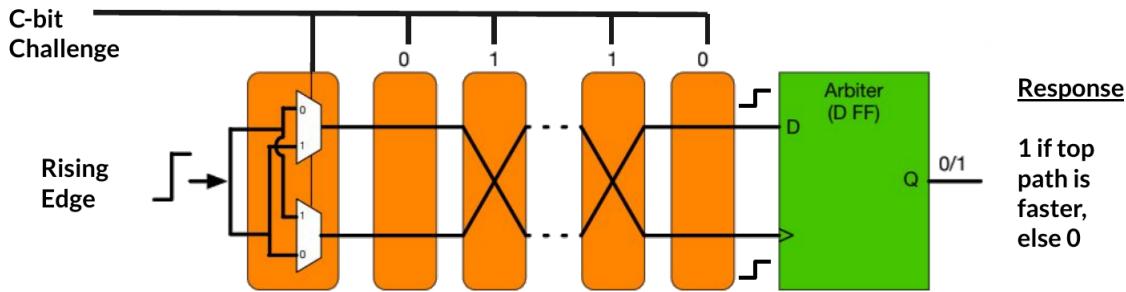


per tirare fuori l'informazione ed abbiamo dei contatori (la cui velocità è random), la response è se i contatori sono andati più veloci o più lenti fra loro mentre la challenge è la scelta degli oscillatori (fatta mediante multiplexer).

Per avere un output M-bit devo fare un confronto in parallelo di più paia di oscillatori.

17.2.3 Arbiter PUF

Mentre prima la variazione era basata sulla frequenza di oscillazione, qui:



- faccio partire la trasmissione di un segnale all'ingresso di una sequenza di multiplexer
- ogni stato ha due multiplexer in cui entra un segnale, possiamo invertire i segnali in base agli ingressi del multiplexer: se il select (sceglie quale input del multiplexer inviare in uscita) è 0, si prende un ingresso, altrimenti l'altro;

quindi se c'è un bit uguale ad 1 si inverte il percorso, altrimenti va diretto.

C'è una concatenazione di porte logiche, l'obiettivo è che questa è una transizione, alla fine i segnali vanno a finire come ingressi di un flop:

- l'ingresso D è quello che campiona
- l'ingresso CK è quello che fa campionare

se il clock arriva dopo la transizione del D campiona 1, altrimenti 0.


Siccome i segnali attraversano il circuito in un certo modo, arriva al flop sfasati e quindi verrà campionato o 0 o 1.

Da un punto di vista logico i due segnali dovrebbero essere concorrenti, ma in realtà i segnali dipendono dalla variabilità e dai bit di challenge (che determinano la selezione del mux), l'arbitro FF alla fine decide quale dei due segnali è il più veloce.

I ritardi dei percorsi sono dovuti alle variazioni di processo di produzione

17.2.4 SRAM PUF

Basato sul tipo di SRAM: le SRAM sono fatte così:



ci sono due inverter dove l'uscita di uno si chiude sull'ingresso dell'altro (e vice versa) è un multivibratore bi stabile, ovvero un dispositivo stabile che sta o su 01 o su 10 perché le uscite non fanno altro che confermare il valore.

È usata per i registri e per le cache di livello 1 perché sono veloci, ci sono anche altri due transistors per accedere alle informazioni (sono messi in array).

Quando accendiamo un dispositivo, lo stato degli inverter dipende dalla variazione del processo produttivo: non c'è una legge che ci dice uno stato di convergenza, lo stato iniziale è indeterminato, dipenderà da molte cose e quindi vendendo l'accensione c'è una capacità di tirare su o giù il segnale in base alla variazione di processo produttivo.

Quindi lo stato di ON della ROM all'accensione ha sempre la stessa configurazione di bit a 0 ed a 1.

17.2.5 Definizioni dei PUF

Dobbiamo avere il challenge response pair, possiamo separare i PUF in

- strong PUF, un dispositivo può generare un numero di CRP maggiore di 2^{80}
- weak PUF

Lo strong PUF può essere tipicamente un arbiter PUF, mentre il weak può essere SRAM PUF, su una memoria da 16 Mbit possiamo avere al più 2^{24} risposte, la challenge può essere l'indirizzo del bit e la response il contenuto.

Le caratteristiche richieste per il PUF:

- non predicibile, non dovrei poter conoscere i CRP sapendone alcuni
- non clonabile
- uniformi, il numero di 1 e 0 creati dai CRP dovrebbe essere simile, altrimenti potrei azzardare delle risposte
- ripetibile nel tempo, non dovrebbero esserci effetti di rumore o invecchiamento che cambino l'effetto della CRP

È vero fino ad un certo punto, perché c'è un problema di affidabilità del PUF: non è solo la process variation, ma anche

- invecchiamento
- rumore termico, ambientale etc...

quindi è difficile limitare questi effetti, i metodi prevedono aggiungere ad esempio dei codici a correzione di errore.

Ci sono attacchi ai PUF basati su ML che riescono anche efficacemente a predire le CRP mancanti basandosi sull'osservazione di un certo numero di CRP.

C'è una predicitività non evidente, dovuta a fenomeni fisici che sottostanno alla apparente randomicità che si possono predire.

Esistono maniere per mescolare le cose, ma è un problema sulla non predicitività della risposta soprattutto se provo a ripetere le risposte di qualcuno

17.2.6 Applicazioni

I weak PUF servono piuttosto ad:

- identificare un dispositivo
- generare una chiave
- SRAM based o ring oscillator

se il numero di CRP è limitato, ci possono essere approcci che banalmente testano tutte le possibili challenge, i ML approach usano una predicitività che non può essere solo brute force.

Gli strong PUF invece tipicamente sono usati per fare autenticazione, tipicamente sono arbiter PUF.

Il problema maggiore del PUF è se l'ID generato con la SRAM cambi nel tempo per via di invecchiamento etc... quindi si usano dei dati aggiuntivi a supporto, ovvero tecniche di correzione di errori (ridondanza di informazione).

Si cerca di correggere eventuali errori del PUF dovuti all'invecchiamento, in modo che durante la vita utile del dispositivo si manda la challenge, se anche le risposte sono diverse vanno corretti con gli $(n-k)$ bit memorizzati, che da soli on dicono nulla sui k bit della risposta.

Gli strong PUF invece possono essere usati per autenticazione, in quanto dopo la produzione viene fatto C/R col dispositivo, memorizzo le risposte in un DB sicuro ed inaccessibile.

Per autenticarlo mando la challenge e mi faccio mandare la risposta per autenticarlo, avendo a disposizione CRP a iosa, anche se alcune non corrispondono per i problemi detti prima possiamo usare gli altri.

17.3 TRNG

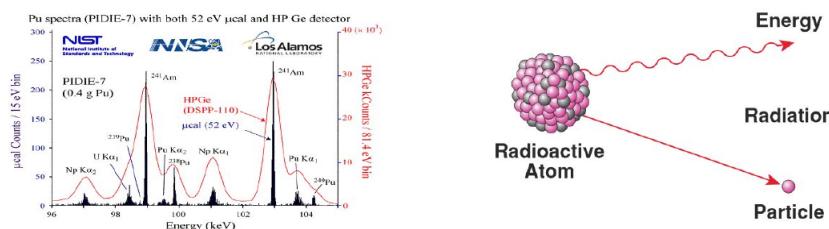
I numeri random vengono usati per differenti applicazioni:

- encryption / decryption keys
- challenges
- slides

Un generatore di numeri random reale genera una serie di bit che hanno diverse proprietà:

- statisticamente indipendenti
- identicamente distribuiti
- non predicibile

questo genera un entropia positiva, dobbiamo usare fenomeni fisici che creino dati ad alta entropia. Le sorgenti sono tipicamente fisiche, dove la randomicità è legata al fenomeno che non può essere rigenerato algoritmicamente:



Se vogliamo sfruttare i fenomeni:

- scegliamo la sorgente di entropia, che può essere differente ma fisica e non predicibile
- dobbiamo fare harvesting della sorgente, tradurre in qualcosa che riusciamo a leggere e che non disturbi il processo fisico e raccolga più entropia possibile

- fare post processing se ci sono delle imperfezioni nell'entropia

Le richieste sono che:

- la progettazione dovrebbe essere digitale
- la raccolta sia semplice
- la non predicitività non deve essere legata alla complessità dell'harvesting ma alla randomicità del processo
- non avere circuiti di correzione
- compatti
- design semplice per un'analisi rigorosa

L'harvesting deve essere qualcosa che digitalizzi, poi possiamo eventualmente normalizzare la distribuzione di 0 ed 1.


Alcuni TRNG possono essere biased ed inoltre la sorgente di entropia può deteriorarsi nel tempo. Alcune funzioni di PP sono XOR, block cipher etc... ma riducono l'assorbimento

17.3.1 Esempio: jitter del clock

Il clock non passa da 0 ad 1 secco, c'è un andamento di salita perché sono legati a carica / scarica di condensatore.

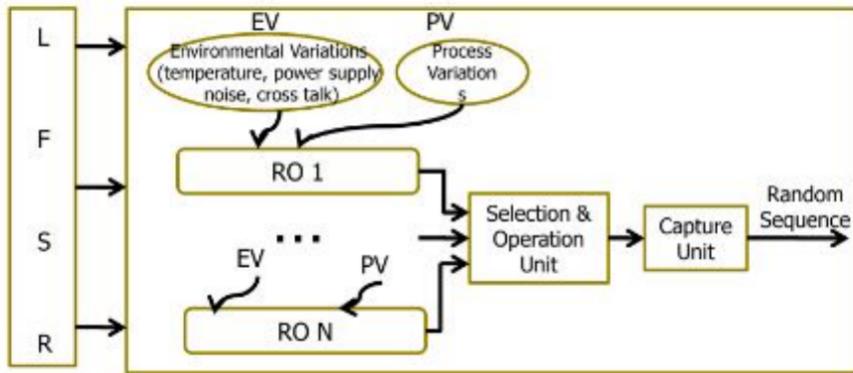
Inoltre, ipotizziamo anche che i clock siano tutti uguali, ma i fronti di salita quando avvengono non sono sempre esatti, il jitter è proprio la distribuzione del fronte di salita intorno ad una media che dipende da vari fattori:

- rumore del semi conduttore
- cross-talk
- variazioni nel power supply
- interazione con CEM esterni




c'è quindi un'incertezza dovuta al jitter sul tempo di salita del clock.

Posso usarli come LSFR che creano dei pattern random nel ring oscillator, campiono i segnali che hanno una fase variabile e catturo questa variabilità:



- il ring oscillator può essere process variation e variazione ambientale, o jitter random nella fase
- selection & operation unit: la fase random o il ring oscillator può essere tradotto in valori digitali da questa unità, come uno XOR
- capture unit: fa sì che i valori digitali siano campionati con la frequenza del numero true random

Quindi poi otteniamo questo:



abbiamo una sequenza truly random e non predicibile.

17.4 Riassunto finale

Applicazione primitiva	variazione di processo	temperatura	rumore del supplemento di potenza	invecchiamento	Wear-
design di logica/memoria	malissimo	male	male	male	male
PUF	buono	male	male	male	male
TRNG	buono	male	buono	male	male


qualcosa di deterministicamente funzionante da tempo 0 a fine vita ci sono tutta una serie di variazioni negative.

Il PUF sfrutta SOLO la process variation, tutte le altre fanno sì che esso cambi la risposta e quindi non sia più reliable.

Il TRNG ha più "sweet spots", la temperatura può causare perdita di randomicità, così come aging e wear-out perché danno un bias nella risposta.

Nuovamente, riassumendo:

- nella progettazione logica vogliamo sempre gli stessi output nel tempo
- nel PUF vogliamo uscite diverse per ogni PUF ma sempre identica per lo stesso
- nel TRNG uscite diverse e sempre diverse over time



**"I'm applying for the Information Security position.
Here is a copy of my resumé, encoded, encrypted and shredded."**

Parte III

Parte Localization

Capitolo 18

Generalità e concetti iniziali

18.1 Introduzione

Possiamo dividere i sistemi che usano segnali in 3 grossi gruppi:

- fotel: trasmettono il più alto numero di informazioni per unità di tempo
- sorveglianza e monitoraggio: trasmettono segnali per far sì che questo capiti o legga informazioni presenti sul territorio, come immagini ad alta risoluzione del terreno anche in condizioni di scarsa visibilità, sfruttando il fatto che diversi materiali e forme riflettono il segnale in modo diverso.
Progettando bene l'onda EM e conoscendo bene il segnale si possono costruire anche immagini ad alta risoluzione, ma anche costruire immagini "fittizie", come quella del traffico aereo.
- sistemi di posizionamento: usano trasmissione dei segnali radio per fare posizionamento e navigazione, ovvero per far sì che un oggetto mobile possa calcolare la sua posizione in base ad un sistema di riferimento

tutti condividono lo spettro EM, non solo esistono enti che standardizzano la condivisione della risorsa per non avere interferenza, ma lo spettro è così pieno di segnali che possono interferire fra di loro.

L'obiettivo è occuparsi di sicurezza per quanto riguarda la gestione dei segnali in questi ambiti applicativi, in particolare per la navigazione e la sorveglianza prettamente fatta tramite radar.

La sicurezza è differente in questo ambito, quando parliamo di apparati di sorveglianza o di navigazione, le problematiche di sicurezza provengono storicamente da questioni legate ad aspetti militari. Qui, gli aspetti sono legati all'uso di questi sistemi nell'ambiente militare, ciò che noi vederemo è:

- capire la differenza fra sorveglianza e navigazione
- introduzione sui sistemi di navigazione satellitare
- funzionamento dei radar
- metodi comuni di disturbo e di protezione:
 - normalmente un sistema di navigazione o sorveglianza è disturbato con un jammer, ovvero trasmettendo un segnale ad alta potenza nelle stesse bande di funzionamento del sistema attaccato.
Tipicamente il segnale è senza senso e copre il segnale di interesse così che il ricevitore non riceva il segnale corretto.

- un altro esempio è lo spoofing, ovvero anzi che trasmettere un segnale senza senso nella banda dell'oggetto, se ne trasmette uno simile a quello che il sistema si aspetta. Così, il ricevitore si confonde, può non capire di essere sotto attacco e fornire informazioni errate, si può ad esempio far credere ad un radar che è presente un oggetto in una posizione dove non è, si può anche muovere un oggetto in un'altra posizione, come nella navigazione satellitare.
- Questi attacchi sono molto diffusi e facili da realizzare, sono fatti a vari livelli (es: recentemente andava di moda Pokèmon Go, per farsi trovare in posti diversi del mondo, manomettendo il cellulare a livello di SO)
- falsi messaggi
- eavesdropping, leggere informazioni dell'utente che possono essere sensibili

tante telecomunicazioni per il traffico aereo viaggiano in chiaro, usando la banda L quindi con ricevitori economici si può sapere dove si trovano i voli, che potrebbe essere una vulnerabilità (è eavesdropping)

- attacchi chaff e ARM, abbastanza banali nel funzionamento
- possibili contromisure agli attacchi

18.1.1 Esempi storici di guerra elettronica

La guerra elettronica ed in generale la disinformazione si fa in molti modi, fra cui ad esempio da un punto di vista EM: creare delle false informazioni da un punto di vista degli apparati utilizzati per far credere al nemico qualcosa di falso.

Esempio: ammasso di truppe al confine per fare esercitazioni per mostrare la "forza".

Altri esempi classici: 1° guerra del golfo, Saddam aveva cosparso l'Iraq con falsi carri armati di cartone, i carri armati avevano anche una resistenza che li teneva riscaldati e produceva delle emissioni EM nel campo degli infrarossi per far credere a chi captava che i carri fossero davvero accesi.

Tecnica inventata dai tedeschi nella WWII, usata per poter navigare fino a Londra con gli aerei e bombardare anche in casi di scarsa visibilità: misero un'antenna molto direttiva a Stolleberg che trasmetteva un fascio molto stretto in modo che chi andasse "dritto" lungo il fascio era sicuro di andare nella giusta rotta.

Per trovare il punto dove sganciare la bomba, misero un altro fascio in Francia, i due fasci si incrociavano su Londra, sentendo entrambi i segnali si capiva che si era arrivati sulla città per bombardare. L'esistenza dei segnali era sconosciuta ai nemici, quello che veniva dalla Francia proveniva da un'antenna sostitutiva di "Radio Parigi", che cambiava da omni-direzionale a fortemente direttiva verso Londra, così che gli inglesi sentissero un segnale normale, mentre 1h prima circa veniva cambiato, era un segnale molto forte verso Londra.

Finita perché un radiomotore inglese ha correlato il fatto che radio Parigi venisse ricevuta molto bene da 1h prima del bombardamento, quindi vennero distrutte le antenne.

Altro classico esempio: (copia immagine)

royal air force (aeronautica inglese) aveva a disposizione fra gli aerei uno con il timone di coda fissato in modo che fossero come due code.


A bordo degli aerei c'erano solo radio, misero le antenne per la radio voce su entrambe le code per massimizzare il segnale ricevuto, sempre i tedeschi scoprirono questa cosa e misero sul muso dei propri aerei una ricevente per i segnali trasmessi dagli inglesi.

Se vengono trasmessi due segnali da due punti, li ricevo con interferenza costruttiva se sono al centro, mentre distruttiva se mi sposto e quindi posso capire se sono perfettamente allineato all'aereo.

Arrivato alla posizione di interferenza costruttiva per procedere e trovare gli aerei della marina.

18.1.2 Terminologia

Prima ancora di introdurre i sistemi radar e di navigazione, cerchiamo di capire come è concepito un sistema per la guerra elettronica:



ammesso di avere un sistema di qualunque tipo, abbiamo bisogno se ipotizziamo che questo sia sotto attacco, di 3 grosse funzioni:

- ESM: misure elettroniche di supporto.

Fondamentale, devo sapere come funziona ed avere informazioni rispetto all'apparato che voglio attaccare e vale per tutti gli aspetti di sicurezza.

Nel mondo EM, l'equivalente della conoscenza del nemico è fatta con una serie di attività che servono per acquisire la conoscenza dell'apparato da disturbare.

Nella navigazione satellitare, ad esempio per la navigazione ad uso civile è tutto noto, lo standard dice come sono fatti i segnali da disturbare.

Non vale però per i segnali ad uso militare, quindi per trovarli si fanno ulteriori attività, questo è a maggior ragione valido per tutti quei sistemi derivati dai radar, perché questi non seguono standard particolari ma dipendono da chi li ha prodotti e tipicamente chi li produce viene da una formazione militare quindi fa di tutto per nascondere come sono fatte, ad esempio, le forme d'onda militare.

Si cerca di prendere informazioni in tutti i modi, fra cui ad esempio studiare direttamente i segnali mediante ricevitori ed analizzare i segnali che gli apparati che vogliamo disturbare trasmettono, così da creare una grossa **library** che contiene informazioni sugli apparti.

- ECM: noti i punti deboli degli apparati, passo all'interferenza col funzionamento dell'apparato. Nasce come tecnica di guerra, è un modo spesso intelligente per risparmiare sulle vite umane in guerra.

Possono essere:

- attive: trasmettono segnali, come nel jamming
- passive


- ECCM: parliamo di attacco vs difesa, quindi la controparte svilupperà delle contro-contromisure, cercando di proteggersi o di disturbare a propria volta il disturbatore.

Esempio classico: costruisco un jammer per interferire con le bande del GPS, CCM quando debo trasmettere qualcosa di importante cambio la banda di trasmissione, cambia funzionamento.

Il processo diventa un loop: il radar che si accorge che è sotto attacco cambia frequenza, quindi anche il jammer cambia frequenza e così via.

Altra divisione:

- SIGINT (signal intelligence): cerca di capire come sono fatti i segnali



- communication intelligence
- elint, tutti gli altri

- ESM, sorvegliano di continuo l'apparato per decidere qual è il miglior momento per attaccare, per poi passare alla contromisura e quindi c'è poi la CCM

La differenza grande a questo livello è fra sistemi di contrasto:

- on board, sono a bordo con chi sta compiendo il disturbo
- off board, come ad esempio: dall'aereo sotto attacco (da un sistema che lancia missili a guida) ci si rende conto di essere sotto attacco, un contrasto è lanciare una specie di missile che produce molto calore, spesso molto visibili ai radar così che se il missile cerca il calore o ha un sistema che cerca forti emissioni EM sarà attirato dai **flares**

18.1.3 Concetti fondamentali

Quando parliamo di necessità di attaccare un sistema di navigazione o di sorveglianza occorre introdurre dei concetti base:

- library, ovvero la capacità di collezionare ed avere a disposizione una serie di informazioni che ci dicono come è fatto il sistema da attaccare.

Possono arrivare ad un livello di dettaglio elevato, si ottengono osservando le emissioni e si può arrivare a risalire ad una impronta digitale del radar: quanto è lungo l'impulso, il guadagno d'antenna, etc... si può arrivare ad identificare marca + modello.

Si può andare anche oltre, perché comunque ogni radar nel processo produttivo poi sarà diverso, quindi spingendo ai massimi livelli la ricerca, possiamo capire le imperfezioni di ciascun radar, un apparato avrà sicuramente delle deviazioni tramite cui possiamo risalire mediante i segnali e possiamo riconoscere l'oggetto e sapere ad esempio da quanto sta lavorando, quindi saprò che magari è vicino alla rottura.

Oppure posso scoprire che l'apparato è stato spostato. es: nel traffico aereo civile si usano dei trasponder che trasmettono la posizione, ognuno ha un indirizzo univoco quindi qualcuno in passato ha contato le ore di volo degli aerei. È stata modificata la normativa in modo che per gli aerei militari venga fatto cambiare il codice

- probabilità di intercetto: quanto è facile vedere il segnale del nemico? Se non possiamo vederlo non saremo mai in grado di disturbarlo, quindi avere dei segnali a bassa probabilità di intercetto vuol dire essere più sicuri, quasi tutti i sistemi che si vogliono proteggere si fa in modo che abbiano una bassa probabilità di intercetto. es: potenza del segnale al di sotto della potenza del rumore, così che un ricevitore veda solo rumore, per poterlo vedere dovrei applicare un processamento particolare (devo sapere come ricevere il segnale).

Le tecniche per avere una bassa probabilità di intercetto sono varie:

- si può lavorare nel tempo, trasmettendo solo per lo stretto indispensabile

- si trasmette con alta direttività, solo in certe direzioni specifiche (minor spazio possibile)
- allargare in maniera spropositata la banda
- trasmettere con la più bassa potenza possibile

così anche un segnale che non è così basso in rapporto segnale/rumore è difficile da intercettare: comunico in tempi molto corti con un'antenna molto direttiva, così che chi vuole ascoltare deve mettersi nel mezzo e stare sempre ad ascoltare il target, quindi il costo è più elevato

Quindi, anche solo concentrandosi su sistemi di sorveglianza e navigazione dobbiamo fare una serie di attività:

1. acquisire informazioni: possiamo farlo in modo diverso, a noi interessa in questo caso avere a disposizione ricevitori che analizzando i segnali e permettono di creare una library.

Con la library possiamo costruire le contromisure

2. trovare una vulnerabilità e disturbare: tipicamente la cosa che si fa è cercare di negare il servizio (come il DoS di informatica), ma non sempre è il più semplice, perché si capisce che si è sotto attacco e si passa al contro-attacco.

Quindi spesso è meglio degradare il servizio o far finta che il servizio sembra funzionare ugualmente.

L'effort è più costoso rispetto a quello richiesto, ad esempio, per un classico attacco informatico perché ad esempio le informazioni qui sono segrete mentre nel caso degli ultimi tipicamente sono inferite da documentazione etc...

Aggiungono ai sistemi radar una certa complessità, in quanto si fa attività di misura anche durante l'attacco in quanto questi sistemi cambiano di continuo per cercare di adattarsi alle possibili contromisure messe in piedi dal "nemico".

Durante l'operazione di attacco si cicla fra:

- ESM sorveglianza: mi accorgo che c'è un apparato di cui è possibile violare il funzionamento
- ECM contrasto: cerco di impedire il funzionamento dell'apparato
- ECCM reazione al contrasto: l'apparato cerca di difendersi

si torna all'ESM, dove dopo esserci accorti dei cambiamenti si ri-pianifica l'attacco e si riparte.

Gli attacchi sono più customizzati e cercano di rimanere vivi in quanto ad esempio, nella guerra elettronica, si vuole disturbare un radar per entrare nel territorio nemico con un caccia, quindi si vuole che i radar non funzionino per tutto il tempo in cui si entra nel territorio nemico.

Ho studiato tutto prima ("tempo di pace") e dopo aver iniziato la sorveglianza ed aver visto qual è la frequenza operativa, si parte col contrasto.

Il radar si accorge di essere sotto attacco e magari cambia frequenza operativa quindi serve nuovamente avere sorveglianza per cambiare modo di attacco in base al modo operativo che cambia.

18.2 Navigazione e sorveglianza

Vediamo sistemi di navigazione satellitare.

La navigazione è un processo autonomo che permette di raggiungere una certa posizione a partire da un punto predefinito che è l'origine.

Quindi è l'oggetto a guida autonoma che decide come muoversi, prevedono due fasi:

- positioning (localizzazione): capire la posizione dove si trova

- guida: sapendo dove mi trovo, devo sapere che strada prendere

passiamo quindi alla **radio determinazione**: trovare la posizione di un oggetto sfruttando le onde radio.

Di fatto, vorremmo sfruttare qualche tipo di onda radio per trovare la posizione di un oggetto, la radio determinazione può essere:

- attiva: è il mobile che compie l'operazione di determinare la propria posizione, è la **radio navigazione**. Da all'utente finale uno strumento che permette di calcolare la propria posizione
- passiva: radio localizzazione, il mobile è soggetto passivo.
Qui si usa il termine target, è in un punto e si vuole conoscere il punto dove si trova il target e chi vuole conoscerlo non è il mobile ma qualcun altro

È la grande differenza fra navigazione e sorveglianza:

- un apparato che monitora il traffico aereo fa sorveglianza, ovvero radio localizzazione
- un radar montato a bordo di un aereo che punta a terra e sa misurare la velocità di movimento dell'aereo è usato per navigazione. È l'aereo stesso che vuole sapere dove si trova

stesso strumento, due approcci diversi. Il dualismo fa capire che le tecniche saranno le stesse e quindi anche i modi di disturbo o di attacco.

Capiamo come sfruttare le onde radio per fare localizzazione, quindi trovare la posizione di qualcosa: ci sono dei principi fondamentali:

- misura di angoli
- misura di distanze
- misura di velocità

possiamo poi impostare un sistema di equazioni per trovare la posizione, vedremo solo i primi due tipi ed anche se generali le declineremo con misure fatte attraverso le onde radio.

esempio (no onde radio): un appassionato di trekking nei monti, con bussola e mappa.


individuo ad esempio una cima di un monte, riconoscerlo sulla mappa, identifico l'angolo risetto al nord ed identifico una retta che passa per la montagna, misuro la stessa cosa per la torre, interseco le rette e so dove sono.

Stesso esempio, senza bussola, ma ho un **TELEMETRO LASER**: identifico di nuovo due oggetti sulla mappa e misuro la distanza: identifico una circonferenza con centro l'oggetto e raggio la distanza, lo faccio con un altro ma le due circonferenze si identificano in due punti ma si dovrebbe risolvere. Le tecniche di posizionamento sono abbastanza banali, sempre risolvere un sistema di equazione che rappresentano le figure geometriche, la difficoltà sta nel misurare le distanze: devo saper trovare l'angolo di arrivo di un segnale EM.

18.2.1 Metodo di localizzazione

Tecnica che sfrutta l'angolo di arrivo. Ammettiamo di essere un oggetto in una certa posizione (x_N, y_N) e fissiamo un sistema di coordinate:

possiamo localizzare dei punti di riferimento, che nei sistemi di radio localizzazione vengono definiti radio-aiuti.



Non conosco la mia posizione (x_N, y_N) ma conosco (x_1, y_1) e so misurare, ad esempio, l'angolo rispetto all'asse x θ , posso quindi scrivere l'equazione della prima retta:


$$y_1 - y_N = \operatorname{tg}(\theta)(x_1 - x_N) \quad (18.1)$$

Nella prima, la tg è la mia misura, so misurare l'angolo, conosco (x_1, y_1) ma ho due incognite, quindi mi trovo un altro radio aiuto e faccio l'altra misura e metto a sistema:

$$\begin{cases} y_1 - y_N = \operatorname{tg}(\theta)(x_1 - x_N) \\ y_2 - y_N = \operatorname{tg}(\lambda)(x_2 - x_N) \end{cases} \quad (18.2)$$

È un sistema lineare in (x_N, y_N) e possiamo trovare la posizione.

Altro caso



misuriamo una distanza, sempre identificando il radio-aiuto e sappiamo fare la misura di distanza, quindi identifichiamo una circonferenza (1), poi col secondo radio-aiuto otteniamo il sistema:

$$\begin{cases} (x_1 - x_N)^2 + (y_1 - y_N)^2 = \rho_1^2 \\ (x_2 - x_N)^2 + (y_2 - y_N)^2 = \rho_2^2 \end{cases} \quad (18.3)$$


È un sistema quadratico quindi otteniamo due soluzioni, quindi c'è un problema di ambiguità e dobbiamo trovare un modo per eliminarla.

Cosa banale: abbiamo una conoscenza approssimativa della posizione che basta per scegliere qual è il punto corretto da scegliere.

Potremmo poi combinare le cose:

tecnica di localizzazione mista dove avviene sia una misura di distanza che di angoli, qui basta un solo radio aiuto, perché le equazioni rappresentano due misure indipendenti e quindi basta una sola equazione.

Non cambia nulla da un punto di vista matematico quanti radio-aiuti abbiamo, ma dal punto di vista



reale cambia perché avere un sistema misto permette di mettere a terra meno radio-aiuti e quindi meno sistemi di riferimento, ma aumenta la complessità dell'oggetto che deve fare le misure, perché sono due diverse.

Geometricamente il sistema è banale, basta avere due equazioni (o 3) in due incognite (o 3) ma viene declinato in sistemi di navigazione del mondo reale molto disparati che risolvono problemi diversi fra loro.

Il radar usa una tecnica come questa, riesce a misurare la distanza di un oggetto e l'angolo sotto cui lo vede.

18.2.2 Tecniche di radio localizzazione

Sappiamo trovare la posizione di un oggetto, dobbiamo capire come fare le misure di distanza ed angolo per sfruttare le EM.

Varie configurazioni tecniche, parliamo per lo più di navigazione si prevede l'uso dei radio aiuti che mandano segnali all'utente:

- trasmissione broadcast: il radio aiuto trasmette un segnale verso chiunque lo voglia ricevere, è un segnale che non cambia mai e non è tagliato per uno specifico utente.

Il mobile riceve il segnale e non trasmette nulla rispetto al radio aiuto, è infatti una tecnica passiva. Attraverso la ricezione del segnale, il mobile riesce a misurare l'angolo di arrivo del segnale ricevuto o la distanza del radio aiuto.

Esempio: il radio aiuto manda con un antenna omni-direzionale un segnale, a bordo del mobile c'è un'antenna con capacità direttiva che permette di orientare il fascio, il segnale viene ricevuto solo quando è puntata verso il radio aiuto, altrimenti il guadagno è bassissimo.

Oppure con tecniche interferometriche, dove se il segnale arriva da due punti tangenti è equifase, altrimenti ottengo che la somma passa da costruttiva a distruttiva in base all'angolo di arrivo (???, onde radio si spostano con fasi diverse, in base a quanto si spazia si ha un angolo diverso, pensare ad interferometro).

Ancora, si può misurare un tempo di arrivo: viene trasmesso un segnale la cui trama è nota nel tempo, quindi quando la ritrovo so che è passato un certo tempo, ad esempio si può pensare alla trama di un impulso, se sa l'istante di trasmissione si può misurare la distanza.

Questa tecnica permette di fare sia misure di angolo che di distanza ed è una delle più usate

- tecniche attive con cooperazione: qui, la comunicazione è bidirezionale.

Esiste un processo di richiesta/risposta: sia il radio aiuto che il mobile hanno a bordo un rice-trasmettitore, è una delle tecniche più usate per misurare le distanze in quanto è semplice.

Ad esempio: il mobile interroga il radio aiuto e questo risponde, quindi semplicemente misurando il tempo che intercorre si conosce la distanza del radio aiuto a due vie (si divide per 2), normalmente si conta anche il tempo che ci mette il radio aiuto a rispondere. Esiste DME, sistema per la navigazione aerea che funziona così

- attive o unmanned: di fatto il radio aiuto non trasmette nulla, potrebbe anche non esistere. Tutto l'apparato di localizzazione è a bordo ed autosufficiente, ad esempio un radar altimetro che dice la quota ed un radar che per effetto doppler misura la velocità, integrando nel tempo si ottiene la posizione e sapendo la posizione iniziale si sa dove ci si trova.

Passiva vs attiva con cooperazione

V1) la tecnica passiva dovrebbe far pensare alla radio o alla tv: il trasmettitore non si preoccupa dell'utente e quindi il primo grosso vantaggio è che il sistema funziona a prescindere dal numero di utenti nei paraggi del trasmettitore.

Intrinsecamente non c'è un limite massimo di utenti, avere un numero di utente massimo è un limite

V2) un sistema passivo prevede nell'utente solo la presenza del ricevitore, di solito è il trasmettitore che costa su un dispositivo, per consumi e costi fisici.

S1) la tecnica attiva è più semplice da utilizzare ed implementare, ad esempio nel caso del GPS. Usandole però occorre ricordarsi che il radio-aiuto non sarà in grado di rispondere a tutti gli utenti che fanno richiesta, all' $n+1$ sarà impegnato con gli altri e non potrà rispondere. Come ciò che avviene con la telefonia mobile: se telefono, trovo occupato perché la comunicazione è bidirezionale (se c'è una chiamata in corso).

Esistono tanti tipi diversi di sistemi di navigazione: tabella tanti metodi di navigazione diversa ma che sfruttano sempre le stesse cose:

- NDB primi metodi di radio aiuto, funzionano come i fari per la navigazione marittima. Trasmettono un sistema unidirezionale, a bordo dell'aereo ci sono due antenne formate da due loop che misurano l'angolo di arrivo del segnale trasmesso dal radio faro, con due di questi si trovano latitudine e longitudine.
- l'evoluzione sono i VOR, altro sistema che misura l'angolo
- LORAN C, OMEGA: sistemi a copertura globale che sfruttano misure di distanza dai radio aiuti (sono passivi)
- sistemi per l'aereo: viene definita una retta rispetto alla pista che ha una certa inclinazione (prolungamento della pista) e l'aereo la segue in modo che l'angolo di inclinazione e l'azimuth siano tali che sta sempre sulla retta, altrimenti corregge sopra/sotto, destra/sinistra; può atterrare anche senza visibilità.

ci focalizzeremo su tecniche di navigazione satellitare, tutti basati sulla misura di n distanze da satelliti, il sistema di riferimento è l'intersezione di 3 sfere di raggio la misura effettuata e centrate sul satellite.

Capitolo 19


Navigazione satellitare

19.1 Come funziona la navigazione satellitare

Tutti si basano sulla tecnica "rho-rho-rho" dove i radio aiuti sono posizionati su satelliti, la tecnica di misura è passiva e la misura fatta è di distanza attraverso il tempo di volo del segnale (time of arrival del segnale).

Il principio è ""banale"":

- si mettono in orbita dei satelliti, in modo da massimizzare prestazioni e copertura ...
- l'utente ha sempre a disposizione delle informazioni trasmesse dai satelliti stessi, ad esempio un modo per calcolare la posizione del satellite in ogni momento
- ogni satellite trasmette il suo identificativo
- il ricevitore riceverà segnali da diversi satelliti, calcola il tempo di arrivo del segnale (TOA), nel segnale stesso c'è scritto anche l'istante temporale di trasmissione, quindi: $(TOA - TOT) * c$ è la distanza del satellite. La posizione è scritta nel segnale del satellite e si può impostare l'equazione della sfera



Le informazioni trasportate conterranno:

- posizione
- identificativo
- TOT (Time Of Transmission), ovvero a che istante temporale è iniziata la trasmissione

- l'utente inizia a decodificare il segnale e ricava x_s, y_s e z_s che sono scritte lì
- trova anche TOT
- la cosa in più che fa il ricevitore è misurare il TOA

ora si scrive l'equazione della circonferenza: x_r, y_r, z_r sono incognite, ma so che

$$\begin{cases} (x_r - x_s)^2 + (y_r - y_s)^2 + (z_r - z_s)^2 = d \\ d = c \cdot (\text{TOA} - \text{TOT}) \end{cases}$$

abbiamo l'equazione di una sfera, 3 incognite.

Aggiungiamo altri due satelliti e così 3 equazioni in 3 incognite

tutta la complessità sta nel far sì che l'errore sia nell'ordine del metro, ovvero nel fare le misure correttamente: la misura è rumorosa, con molto rumore perché occorre attraversare molte "peripezie" (**C'È ER MARACANÀ**).

I satelliti di cui abbiamo bisogno devono però essere almeno 4 nei sistemi moderni di navigazione satellitare: in quanto abbiamo appena detto è stato semplificato il fatto che, basandosi su misure di tempo, ipotizziamo che siamo "bravi" a fare misure di tempo e quindi che il sistema di riferimento temporale sia noto ovvero che sia tutto sincrono nel sistema.

Abbiamo due tempi nell'equazione:

- TOA lo misura l'utente
- TOT è misurato dal satellite

se i due orologi non sono sincroni, la misura non è più di distanza perché l'errore incorporato è abbastanza grosso.

La sincronizzazione non sarà mai perfetta, quindi si deve ammettere un certo grado di mancanza di sincronizzazione, ma qui l'errore deve essere il più piccolo possibile, perché la c moltiplica tutto ed anche un ms di errore (10^{-3} nel tempo) diviene un 10^5 in distanza e qui c'è il problema che tutti i satelliti devono essere fra loro sincronizzati e non è facile.

Tutti i sistemi di navigazione satellitare fanno due ipotesi:

I1 i satelliti sono tutti sincronizzati fra loro, si mette a bordo dei satelliti dei clock atomici molto stabili ed anche avere qualcuno da terra che monitora i clock dei satelliti e corregge eventuali mancate sincronizzazione.

Così possiamo dire che tutti i satelliti condividono la stessa sincronizzazione

- ora agli utenti: sincronizzare con qualcosa di centralizzato non è bene, quindi si risolve dicendo senza chiedere che il ricevitore sia sincronizzato, ovvero accettiamo che ci sia un δ_t di errore nella misura dei tempi.

Questo δ_t può essere quanto si vuole, è un'altra incognita del sistema di equazione

ho di nuovo il problema iniziale, ma ora faccio risolvere al sistema di equazioni anche il problema della sincronizzazione.

Abbiamo quindi: $c \cdot (\text{TOA} - \text{TOT} + \Delta t)$, quindi il $t_{toavero} = \text{TOA} + \Delta t$, quindi l'errore è il Δt nella misura che l'utente fa e occorre tenerne conto.


Ora abbiamo 1 equazione in 4 incognite, **IL BARBATRUCCO** è che se faccio l'equazione per un altro satellite avrà le stesse incognite: (copia e metti le i ai pedici del satellite, così come anche al TOA), il Δt è sempre lo stesso.

Quindi, accettiamo che il sistema sia più complesso dal punto di vista di chi fornisce il servizio, perché servono più satelliti ma non devo mantenere sincronizzati i ricevitori e questo permette anche

di sincronizzare al tempo universale di sistema tutti i ricevitori.

Implicitamente abbiamo anche una tecnica di sincronizzazione globale, così da trovare sia la mia posizione in qualunque punto del globo ma anche di capire di quanto va male il mio orologio rispetto a quello del tempo.

In realtà, tutta la prima parte della formula è una distanza geometrica, nel caso dei sistemi di navigazione satellitare l'utente misura una pseudo-distanza: è la distanza $+ c +$ l'errore dell'orologio ed è chiamato **pseudo-range**:



$$r = c(T_u - T_s) = c\Delta t$$

$$\rho = r + ct_u$$

$$\rho - ct_u = \|\mathbf{s} - \mathbf{u}\|$$

$$\rho_i = \|\mathbf{s}_i - \mathbf{u}\| + ct_u \quad \text{con } i = 1, 2, 3, 4$$

La distanza fra il punto u ed il punto s è di fatto legata al tempo di volo del segnale, il ricevitore non è sincrono col clock di sistema e quindi ne va tenuto conto, quindi maneggiamo la pseudo-distanza ρ . (eq sotto è la stessa ma scritta in forma normale).

Ne consegue che per fare localizzazione servono almeno 4 satelliti, la realizzazione matematica non corrisponde però ad una realizzazione semplice nella realtà: anche sapendo fare le misure, ci sarà rumore nella misura ed avrà $\rho_i - \epsilon$.

Nei sistemi satellitari la ϵ è data da molti fattori, che si cerca di minimizzare:

- il segnale deve arrivare all'utente, attraversa ionosfera a troposfera che inficiano sulla velocità di propagazione del segnale.
Dipende dalle condizioni meteorologiche o dalle condizioni di ionizzazione che sono random (modellabili magari con v.a)
- segnale ricevuto magari in un edificio, altro errore
- non avere la posizione del satellite in modo accurato introduce un errore di misura
- clock del satellite, ha sempre un piccolo errore

c'è una quantità di errori enorme, complessi da maneggiare ma oltre agli errori dovuti al normale funzionamento del sistema, le prestazioni possono essere degradate anche da altre cose ovvero legate a questioni di sicurezza:

- interferenza sul canale:
 - intenzionale: jamming, qualcuno trasmette potenza EM sul canale di comunicazione. Può andare dal DoS completo, non vedo i segnali che arrivano dal satellite perché troppo sotto a quella del satellite, oppure degrado performance
 - non intenzionale
- spoofing: invio di messaggi simili a quello che arriva dai satelliti ma con codificate delle informazioni errate.
Questo comporta un errore sulla posizione finale, se ben fatto si può creare una costellazione virtuale nella posizione dove c'è il ricevitore sotto attacco in modo da farlo andare dove si vuole. I segnali sono noti, quindi chiunque può sapere cosa scriverci per sostituirlo

Per proteggersi si può usare tipicamente la crittografia.

Due tecniche introdotte per degradare intenzionalmente le prestazioni del servizio:

- selective availability: in tempo normale, il sistema fornisce il servizio a tutti ma ad esempio il GPS nasce come sistema ad arma.

Quindi si usa un disturbo legato al GPS che gli utenti legati al dipartimento della difesa americano sanno rimuovere, quindi hanno migliori prestazioni, mentre chi non sa come rimuovere ha un degrado delle performance

- anti-spoofing: cambio delle caratteristiche del segnale per evitare che vi sia disturbo con lo spoofing.

Uso un segnale nuovo, con caratteristiche che nessuno conosce (come se usassi la crittografia) quindi nessuno può attaccare.

Classica tecnica militare: in tempo di pace il servizio è noto a tutti, ma se entro in zona di guerra in tempo di guerra applico la tecnica, quindi il dispositivo non è disturbabile.

Di solito il segnale normalmente non viene trasmesso, ha una probabilità di intercetto molto bassa perché è usato solo nei periodi in cui serve che il sistema sia disponibile solo a poche persone specifiche ed autorizzate


terreno nascosto: non è una buona idea, prima o poi il nemico scoprirebbe almeno una parte dei codici, quindi tutti i sistemi hanno due parti, una nota al pubblico ed una no.

Quindi, il sistema di navigazione ha necessità di 4 satelliti da cui ricevere i segnali che portino le informazioni viste sopra.

Lette queste e misurate il tempo di arrivo del segnale è possibile impostare il sistema, partendo da un guess iniziale, per trovare la posizione utente. (N.B: la posizione iniziale inficia poco il processo)

19.1.1 Misurazione del tempo di arrivo

Come viene misurato il tempo di arrivo, è qui che si annidano le debolezze.



il satellite trasmette verso terra continuamente, oltre alle informazioni dette prima, un **codice pseudo-randomico**, una sequenza di 0,1 che sembrano casuali e questo è trasmesso continuamente verso terra, ha una certa lunghezza e non porta nessun tipo di informazione ed è completamente noto sia al satellite che all'utente.

Può essere replicato, come fa il satellite, nel ricevitore dell'utente e quindi avranno entrambe una sequenza di 01 sincronizzate fra di loro (ammettiamo che sia così).


Il satellite trasmette questa sequenza verso terra, il ricevitore la vedrà ed avrà nel suo interno due sequenze identiche, di cui una l'ha generata lui, l'unica differenza è che quella ricevuta dal satellite ha subito un ritardo di propagazione necessario per raggiungere l'utente (d/c), lo sfasamento dipende

proprio da quanto tempo ha volato il segnale.

Quindi, la misura del tempo di arrivo funziona così:

- il ricevitore comincia a ritardare la sua copia del codice finché le due copie non sono perfettamente sovrapposte
- quando lo saranno, misura il tempo

Prendo un segnale, ne ho due copie identiche e comincio a traslarne uno e cerco il punto in cui i due segnali sono perfettamente sovrapposti, per capire di quanto devo traslare posso moltiplicarli fra loro e quando saranno perfettamente sovrapposti ci saranno solo 1, quindi l'integrale sarà molto grande. Faccio la **correlazione** del segnale che genero a terra con quello che genero io, ma in questo caso è importante l'approccio perché posso misurare il tempo di arrivo del segnale, andando a vedere dove è il picco della cross-correlazione tra il segnale replicato dal ricevitore e quello ricevuto dal satellite. Ricevitore avrà: $r(t)$ ed $s(t)$ e farà $\int_{-\infty}^{\infty} r(\tau)s(t - \tau)d\tau$ e sappiamo che è massima quando i segnali sono sovrapposti, ci sono una 30ina di **codici gold** nel GPS e li associo al satellite:



I segnali si portano quindi dentro dei codici pseudo random che con la correlazione col ricevitore permettono di calcolare il tempo.

19.2 GPS

Nel caso del GPS, ogni satellite trasmette segnali su due bande L diverse (slides):

- L_1 : fa broadcast a 1575.42 MHz (10.23 · 154).
Trasmette il codice C/A (modulato a 1.023 MHz) e P (a 10.23 MHz)
- L_2 solo il codice P a 10.23 MHz

sono due codici pseudo-random associati al satellite, con caratteristiche diverse:


- il codice C/A ha larghezza di banda di 1 MHz, associato ad un utente standard.
Non è molto lungo, si può "trovare" con un attacco bruteforce ed è quindi il motivo per cui non viene nascosto.

- il codice P di 10.23 MHz, è un codice di precisione che danno prestazioni maggiori (banda più larga) e sono presenti su due frequenze.


Nel caso del GPS possono essere cambiati dal Dipartimento della Difesa Americano per divenire Y e non essere noti a tutti se non al Dipartimento stesso.

Il codice P è molto lungo (circa 30 settimane), si tronca ad una settimana e si ripete: ha throughput di 10 MBit/sec con una lunghezza di 1 settimana, quindi fare bruteforcing non è pensabile.

Il clock del satellite può essere riassunto come segue



Questi sono invece gli spettri dei segnali trasmessi:



sono segnali a banda larga perché trasportano poche informazioni ma hanno una banda abbastanza elevata e questo è importante perché di fatto usando delle bande così elevate, a parità di potenza trasmessa per arrivare a terra, i segnali arrivano a terra con una potenza molto bassa e quindi non sono intercettabili in condizioni normali.

Per potervi risalire, occorre correlare il segnale che ri riceve con quello generato a terra, è il **desplifting??**: la potenza del segnale ricevuto cresce molto, si stringe la banda, quindi possiamo decodificarlo e leggerlo.


Il trasmettitore di bordo del satellite inserisce nel segnale da trasmettere un segnale pseudo random che allarghi la banda (modulazione a spettro espanso), fa sì che il segnale abbia una bassa probabilità di intercetto e non disturbi gli altri.

Nel ricevitore si va l'inverso, tutta la potenza del segnale è concentrata su una banda stretta per decodificare, quindi se non si conosce il codice non si può ricevere il segnale mail codice poi di fatto è a disposizione di chiunque.

È utile anche per proteggere il sistema da disturbi intenzionali a banda stretta.

Un ricevitore per navigazione satellitare è tipicamente fatto così:

- si arriva fino alla banda base
- si fanno una serie di processamenti




- si risolve il sistema di equazioni


Il sistema non è un semplice ricevitore:

- deve fare code acquisition, ovvero cercare di capire se c'è un satellite nei paraggi, deve acquisire almeno 4 segnali diversi
- siccome i satelliti si muovono cambia la frequenza su cui arriva il segnale e deve trovarla
- si deve agganciare al segnale per fare misure precise

solo dopo può fare tutti i calcoli, dentro al ricevitore ci sono quindi algoritmi diversi ad esempio:



nella parte a sinistra c'è proprio la correlazione e poi si comincia a cercare il picco: (frequenza doppler, ritardo)



trovo il satellite ed acquisisco il segnale.

Si passa poi al tracking del segnale per far sì che si rimanga sempre agganciati al picco per stimare il tempo di arrivo (si muove sull'asse delle x).

Tutti i sistemi di navigazione satellitare sono fatti così, hanno le caratteristiche simili a quanto abbiamo detto.

Capitolo 20

Sistemi radar

20.1 Funzionamento

RADAR sta per Radio Detection and Ranging, sfrutta le onde radio per capire se c'è qualche cosa e per fare posizionamento, in realtà i radar riescono a localizzare in due direzioni (anche in azimuth). Il segnale viene riflesso dall'oggetto, chiamato target, viene ricevuto dal ricevitore del radar ed il tempo che intercorre fra la trasmissione ed il ritorno da la distanza del bersaglio (per radar bistatico)

$$\Delta t = \frac{R_1 + R_2}{c} \quad (20.1)$$

o nel radar monostatico

$$\Delta t = \frac{2R}{c} \quad (20.2)$$

Esistono radar per fare diverse cose:

- sorveglianza, per avere immagini ad esempio del traffico aereo oppure radar per la sorveglianza di basi militari
- radar di inseguimento, che nascono per fare misure molto precise su un solo oggetto. esempio: radar di tiro, viene identificato un oggetto come minaccioso ed il radar di inseguimento punta sull'oggetto e ne fa una misura precisa e l'informazione serve per abbattere l'oggetto.
- radar ad altissima risoluzione da piattaforme aeree (es droni, satelliti spia), sfruttano delle tecniche che permettono di avere delle risoluzioni ottime anche con piccole antenne, lavorano con qualsiasi condizione del meteo
- radar altimetri, servono solo per misurare la quota dell'aereo
- radar meteorologici
- radar automotive

Sono sistemi che possono essere molto complessi, spaziano per forma, costo etc...

Radar diversi usano anche diverse frequenze che sono anche state standardizzate, "conoscere il tuo nemico" non è così semplice: l'apparato che si vuole disturbare può essere ovunque nelle frequenze (300 MHz - 300 GHz) ed avere la possibilità di collezionare informazioni in questo spettro così ampio è complicato.


A meno che non si usino apparati specifici in banda larghissima in tempo di pace, così che in tempo di guerra si riesce ad individuare con buona sicurezza in che banda sarà l'apparato nemico.

20.1.1 Misure del radar

Il segnale trasmesso è quasi sempre un impulso, che raggiunge il bersaglio e riceve l'eco dell'impulso, quando vedo l'eco posso dire che il bersaglio è presente.

Il tempo è facilmente misurabile, possiamo poi anche ricavare la distanza invertendo la formula.

Ci aspettiamo quindi questo:



se riceviamo l'eco il bersaglio è presente. Normalmente:


- la grandezza dell'impulso è τ
- la grandezza è il ...

metto una soglia, se la supero ho trovato il bersaglio, posso anche misurare la distanza.

Nello stesso dispositivo persistono elettroniche che lavorano con segnali a diversa potenza

Si misura anche almeno un angolo:

- azimuth sul piano orizzontale
- elevazione sul piano verticale






possiamo avere anche radar che misurano tutti e 3.

Per misurare gli angoli, si sfruttano antenne multi direttive: monto antenne con lobi molto stretti, per cui posso ipotizzare che se ricevo un eco l'ho ricevuto dalla posizione di puntamento dell'antenna.

il fascio dell'antenna, nel principale c'è un alto guadagno e ricevendo con un antenna del genere possiamo supporre (molto facilmente) che si riceva la risposta dalla posizione di puntamento.

Sapendo in che direzione sto trasmettendo, misuro l'angolo del bersaglio e poi muovo l'antenna.

I tipi di antenna per applicazioni radar sono sempre a fascio stretto, normalmente:



- la pencil beam ha un angolo stretto in direzione e stretto in azimuth.
Risolve bene tutti e due gli angoli
- stretta in azimuth, larga in altezza??

Per fare la **misura radiale** si può sfruttare l'effetto doppler.

Il radar trasmette un impulso su una portante, possiamo scrivere: (copia), dove f_0 indica la frequenza della portante (è una sinusoide).

Il target da un segnale di eco del tutto analogo a quello trasmesso, sarà attenuato (fattore $k < 1$) e sarà ritardato di $2R(t)/c$.

Ci aspettiamo quindi lo stesso segnale in ricezione ritardato ed attenuato, se il bersaglio si muove la distanza R dipende dal tempo t :

la fase del segnale ricevuto è (copia) e dipende da $R(t)$

-sappiamo anche che la frequenza è la derivata della fase: (copiaa), ma la derivata nel tempo di R è la velocità radiale dell'oggetto.

Quindi, fissando tutto, possiamo dire che (copia slides), quindi il segnale viene ricevuto sulla frequenza $f_0 + f_D$ ed un radar che sa misurare f_D sa anche misurare la velocità radiale.

ATTENZIONE: non è la velocità del dispositivo, ma è quella radiale quindi con cui mi allontano / avvicino dal radar!! (copia immagine), se si muove in modo ortogonale è come se fosse fermo.

Tutte le prestazioni ottenibili dipendono da diversi fattori.

Nel radar inoltre persistono diverse dimensioni temporali: (copia slides)

il radar trasmette un impulso, la cui durata dipende da determinate caratteristiche, può però trasmettere n impulsi su ogni oggetto e per poter riametterli sullo stesso oggetto serve aspettare che il radar faccia tutto il giro (radar di sorveglianza).

(immagine)

Quindi riusciamo ad avere la capacità di trovare un oggetto senza che questo collabori, deve solo avere la capacità di retro-diffondere onde EM ed in natura nessun oggetto non lo fa. L'informazione di interesse al radar la aggiunge l'oggetto: la forma d'onda è pienamente nota, la presenza dell'oggetto aggiunge l'informazione, nella navigazione e localizzazione per sorveglianza non c'è trasferimento di informazione, ma lo fa la presenza del target nell'ambiente e questo ha implicazioni nel tipo di attacco.

20.1.2 Capacità di rilevazione - RCS

Nel mondo reale l'oggetto produce eco ma non tutti danno luogo a detection del radar perché possono essere poco potenti e nascondersi sotto al rumore termico del ricevitore, quindi c'è un limite di sensibilità tipica dei sistemi elettronici.

La portata, ovvero la massima distanza alla quale possiamo vedere l'oggetto ha un limite legato alla sensitività, inoltre dipende anche dalle capacità dell'oggetto stesso ovvero quanto retrodiffonde:

- oggetto metallico, retrodiffonde molto
- altri oggetti assorbono, quindi coefficiente di retrodiffusione è più basso

dipende anche dalla forma, dall'assetto etc...

Tutte queste proprietà si riassumono nella **radar cross-action** del bersaglio, un parametro che identifica la capacità del bersaglio di retrodiffondere la potenza EM che lo colpisce.

Ha la misura di un'area (m^2), quindi qualitativamente è relativa alla grandezza dell'oggetto ma nella realtà non è strettamente legata solo alle dimensioni fisiche dell'oggetto.

Maggiore questo valore e maggiore sarà la capacità (quindi la distanza) con cui il radar identifica l'oggetto.

Per il principio di funzionamento del radar, c'è una retrodiffusione, quindi l'onda EM si deve propagare per 2 volte la distanza r , si può dimostrare che la potenza ricevuta è proporzionale ad r^{-4} .

È importante perché fa capire che per vedere oggetti lontani occorre trasmettere potenze elevate perché l'oggetto ritrasmetterà con una potenza più bassa ed inoltre è legata alla RCS.

Uno dei possibili modi per mettere in crisi un radar è ridurre la RCS: se riesco a costruire gli oggetti in modo che nella direzione del radar trasmettono una potenza bassissima, ho costruito degli oggetti praticamente invisibili al radar, è il principio di funzionamento della tecnologia stealth.

esempio:

se ho una sfera retrodiffondo in più direzioni, se ho un "piano infinito", si retrodiffonde gran parte della potenza incidente con un angolo di 90° rispetto alla normale.

Se quindi la superficie è infinita e messa storta, si retrodiffonde lontano dal radar, in realtà non è infinita quindi c'è poco eco verso il radar.

Possiamo pensare ad un oggetto complesso come una serie di "faccette" scatteratrici che diffondono con una certa potenza.

Quindi nel radar trasmetto un certo segnale, vedo quello di ritorno e misuro una certa soglia della potenza e se la supera vuol dire che l'oggetto è presente e quindi calcolo l'angolo, per poter superare la soglia

- o sono vicino
- oppure devo avere un RCS grande

se costruisco bersagli in modo che tutte le onde incidenti sono riflesse in altre direzioni ma mai in quella di arrivo allora sono invisibili al radar.

altro esempio: una superficie piana è ben visibile, ma se anche il radar si sposta di poco tutta la potenza EM è diffusa in un'altra direzione.

Ammettiamo quindi di avere due piani metallici a 90° la radar cross action è estremamente elevata, sono dei **corner reflector**, quindi se ci sono superfici normali alla direzione del radar è elevato ma anche in caso di superfici fra loro ortogonali.

Spesso usati per aumentare la RCS degli oggetti per aumentarne la rilevabilità.

20.2 Tecnologia stealth

Non si vuole essere visti, quindi occorre evitare il più possibile di avere superfici metalliche normali alla direzione di incidenza dell'onda EM e superfici ortogonali fra loro.

C'è comunque potenza EM retrodiffusa ed è il punto critico di questa tecnologia, perché l'energia incidente da qualche parte deve andare, non può assorbirla tutta.

Si cerca quindi di minimizzarla in direzione del radar, andando nelle altre direzioni e funziona finché l'antenna del radar in tx è la stessa in rx, ma se le due antenne vengono disaccoppiate non è più invisibile.

Deve essere invisibile a tutto non solo al radar:

- colore per volo notturno
- emissioni termiche ridotte al massimo
- dentro c'è un pilota, che ha bisogno di vetro per vedere.

Ma il vetro lascia passare potenza EM, quindi anche quello va coperto da un sottile film metallico

quindi l'oggetto in se non è banale da realizzare e costa soldi veri.

Quantifichiamo "l'invisibilità":

(copia immagine)

un target normale come una nave è nell'ordine dei 10000 dBm^2 , l'uomo è nella frazione dei pochi dBm^2 per poi scendere agli insetti.

Il JSF, ovvero l'ultima tecnologia da un punto di vista del fighter sta alla RCS visto frontalmente di un insetto, il bombardiere B2 ancora più in basso.

Non sono totalmente invisibili al radar, ma trasmettendo a più potenza si ha un grande numero di falsi allarmi dovuti alla presenza di uccelli, insetti etc...

esempio: fighter moderno e dove lavorare per rendere l'oggetto invisibile (immagini??)

si tende a:

- ridurre le taniche di cherosene
- si evitano i corner reflector
- si lavora sulle cavità
- etc...

Questa è la prima capacità di fare contromisura rispetto al sistema radar: funziona ricevendo l'eco, quindi se riesco a minimizzare l'eco ho abbassato la probabilità di intercetto.

Capitolo 21

Tecniche di disturbo e difesa

21.1 Electronic Warfare

Abbiamo visto 2 grandi sistemi:

1. radar, in cui un oggetto cerca di fare sorveglianza e capire la presenza e la posizione di un oggetto.

Il segnale qui è:

- tipicamente impulsivo
- segnale non noto
- frequenze disparate
- a banda abbastanza stretta
- informazione calcolata mediante il tempo di volo e dipende dalle proprietà del target (RCS)

2. sistemi di navigazione, l'approccio più classico è il GPS dove ci sono n satelliti in orbita ed un ricevitore a terra, tutti i satelliti trasmettono un segnale ed il ricevitore calcola la propria posizione.

Qui i segnali sono:

- continui nel tempo
- noti a tutti
- a banda larga
- trasmettono informazioni sul tempo di trasmissione e sulla posizione del satellite.

Con queste, l'utente calcola la sua posizione

Ora dobbiamo trovare un modo per non fare funzionare i sistemi, è il mondo dell'Electronic Warfare:

- nel caso dei radar è molto sviluppato quello che è chiamato SIGNIT, ELINT o ESM, ovvero prevede tutta una attività per capire come è fatto il radar perché questo non è uno standard. C'è poi tutta la parte di ECM;
- nella navigazione satellitare la prima parte è ridotta all'osso perché i segnali sono noti, quindi è molto sviluppata la ECM

Dovendo lavorare con la navigazione satellitare, non possiamo entrare nel device utente, quindi sfruttiamo ciò che succede prima di entrare nell'antenna utente, quindi fare in modo che non vi arrivi il segnale dal satellite.

È molto efficace perché il segnale che arriva è a potenza molto bassa, abbiamo:

- jamming, l'attaccante comincia a trasmettere verso la vittima fino a non far più ricevere segnali dai satelliti, DoS (**SMARMELLI IL SEGNALE CIT***)
- spoofing, ovvero trasmettere segnali analoghi a quelli dei satelliti.
Se ben fatto l'utente non se ne rende conto, a differenza magari del jamming, quindi il ricevitore continua a fornire la posizione all'utente che è errata e può essere tanto errata quanto è bravo chi fa spoofing nel mimare la costellazione di satelliti

Ci sono poi altre questioni che sono ad esempio manomissioni di hardware e software.

Sui radar ci sono varie possibilità di contromisure elettroniche, ma anche qui si lavora sul fatto che l'informazione per il radar è aggiunta dal target, quindi possiamo:

- far sparire l'aereo lavorando sull'RCS (stealth)
- inganni, cioè mettere finti target da qualche parte per ingannare il radar
- nascondere il target, ad esempio dietro una cortina di echi radar che riempie il visore del radar di questi echi e rende impossibile capire dove si trova il target, è il chaff
- jamming, l'eco che torna dall'aereo è nascosto da segnali trasmessi appositamente.
Questa si declina quasi a tendere fino allo spoofing, anche se non si chiama così nel radar

Riprendiamo lo schema generale: (copia immagine) Le misure di SIGINT ed ELINT va fatta sia in tempo reale che in tempo differito perché il nemico può cambiare segnale operativo durante l'attacco (magari sono applicate in maniera differente).

21.2 Contromisure nei radar

21.2.1 ARM

È una tipica contromisura radar, ha costo basso: è un "missilotto" che al posto della punta ha un antenna che se fatto bene è adattata al segnale radar usato dal nemico.

Il sistema funziona sganciando il "missilotto" che con l'antenna capta il segnale radar e cerca il massimo di potenza ricevuta dal radar, quindi si autoguida verso la direzione da dove arriva la potenza EM e cade dritto sul radar, è economico e fa bene il suo lavoro.

Esistono contro-contromisure in cui il radar ha diverse antenne per far sì che il missile cominci a puntare le antenne a stecche e poi perda il controllo per non andare su nessuna.

21.2.2 Attività ESM

L'approccio classico prevede di vedere il sistema costituito da: (copia immagine)
questa catena dice chi abbiamo di fronte, quindi come è fatto il segnale che stiamo ricevendo, es: un aereo in missione accende il ricevitore ESM che dopo il processamento dice quale radar c'è.

Si attiva quindi un'altra catena di ricezione, in quel momento adattato a quel particolare radar (copia altra immagine)

c'è quindi il technique generator che comincia a trasmettere il disturbo con dei segnali adattati, il ricevitore ECM può non essere necessario ma aiuta.

È un oggetto non banale perché riceve e trasmettere contemporaneamente sulle stesse frequenze, quindi si usano tipicamente tecniche per evitare che ciò che venga trasmesso rientri nel ricevitore: si comincia a disturbare, si ci ferma e ri riascolta per vedere ad esempio se il radar ha cambiato la

forma d'onda di disturbo per adattarsi e ricominciare a disturbare.

Nel ricevitore ESM, come si fa a capire con chi si ha a che fare: dobbiamo avere la capacità di ricevere qualsiasi tipo di segnale radar.

Un radar moderno ha tutta una serie di processamenti nel segnale trasmesso che non lo rendono più il classico impulso e non lo rendono facile da ricevere se non con un filtro, quindi bisogna rinunciare a qualche cosa.

Gli apparati sono dotati di strumenti che misurano solo l'ampiezza del segnale ricevuto, così da poter fare delle misure come la direzione da dove arriva, il tempo etc... ma non è ancora banale perché comunque non sappiamo la frequenza su cui lavora il radar (almeno inizialmente), quindi sono chiamati ricevitori a banda larga (panoramici).

Quindi da una parte sono "banali": (metti immagine sopra)

oggetti così hanno bande passanti strette, quindi non si possono ricevere bande dai 100 Mhz ai 100 Ghz, occorre selezionare una banda e questo abbassa la probabilità di intercetto perché ogni volta si sceglie una banda e si riceve su quella: (immagine)

dovendo capire dove trasmette un radar non posso sapere subito che sta a 10GHz, posso cercare di provare a ricevere sulle diverse bande e devo farlo di continuo perché di oggetti che emettono potenza EM ce ne sono molti, quindi devo ciclicamente scansionare tutte le possibili frequenze, quindi la probabilità di intercettare si abbassa perché magari il radar quando entro nella frequenza giusta sta trasmettendo altrove o magari perché cambia frequenza.

Quindi lo schema è questo (immagine sotto)

il ricevitore ha diversi svantaggi ma rispetto al radar ha il vantaggio di ricevere segnali per propagazione diretta, quindi con una potenza che va con r^{-2} , quindi la capacità è maggiore del radar (r^{-4}). L'ESM confronta con la sua library per capire il tipo di radar con cui ha a che fare, riempito in tempo di pace.

Esistono tecniche per evitare la bassa probabilità di intercetto, che sono i ricevitori folding che ripiegano tutte le bande osservate contemporaneamente in una.

Ci sono poi casi di ESM con più antenne in più direzioni dove si compara l'ampiezza del segnale delle diverse antenne per trovare gli angoli (immagine):

ogni canale di ricezione misura l'impulso, si mettono insieme per misurare da dove arrivano e per poi matchare l'informazione nella library e capire quali radar ci sono.

Il radar tipicamente trasmette qualcosa come: 0 - pezzo di sinusode (la portante) - 0 ... il ricevitore ad inviluppo vede un segnale molto simile a quello in banda base del radar.

Misura quindi l'impulso, da dove arriva, quanto è potente ... estrae delle feature dell'impulso, poi ne riceverà un altro e farà la stessa estrazione per poi vedere le distanze intra-impulso e con tutte queste misure capirà che c'è un radar con la PRT data (distanza fra gli impulsi) e grandezza dell'impulso τ nota quindi confronta nella library e trova il radar.

Inoltre se misuro l'ampiezza degli impulsi troverò che dove l'ampiezza è molto alta l'antenna punta su di me mentre quando è piccola sono sul lobo laterale, quindi sto campionando di fatto il diagramma di radiazione dell'antenna e quindi riesco a capire che antenna il radar sta usando.

La cosa è periodica, prima o poi l'antenna ripungerà su di me quindi conosco anche la velocità con cui gira l'antenna, posso anche conoscere il fascio di antenna quindi acquisisco tante informazioni che restringono l'insieme dove fare matching.

Posso anche vedere che l'impulso non è proprio netto, ma ci sia un certo massimo dovuto a come realmente è fatta l'antenna quindi posso fare un fingerprinting ancora più sicuro perché non posso avere due radar che hanno le stesse tolleranze nella generazione delle forme d'onda.

Se ci sono tanti radar il segnale diviene pieno di impulsi quindi il processo diviene complesso, ma è importante capire il principio: anche se il ricevitore è di scarse qualità e riceve solo l'inviluppo del segnale riesco comunque ad ottenere molte informazioni.

21.2.3 Attività ECM

L'obiettivo è disturbare l'apparato radar del nemico, dove nemico ha accezione generica e può anche essere un sistema civile.

Per attivare una contromisura elettronica, ci sono 3 possibili modalità di intervento:

- SSJ, Self Screaming Jammer: l'oggetto che entra nella copertura radar si auto-protegge, ha lui stesso gli apparati per disturbare il radar
- EJ due aerei, uno protegge dagli apparati elettronici
- SOJ, Stand Of Jammer, un sistema molto più lontano dalla minaccia ha come unico compito disturbare il radar

I primi due casi sono molto simili, il caso 1 è buono perché più ci si avvicina al radar e più il disturbo è efficace.

Svantaggio è che l'aereo si deve portare dietro tutto l'apparato di difesa elettronica, la classica configurazione fatta da aerei caccia si leva spazio a qualcosa altro come un sistema ad arma per difendersi.

Occorre trovare il giusto compromesso, quindi la EJ dove un aereo protegge se stesso e l'altro e quindi porta solo lui i sistemi di difesa elettronica.

C'è ancora il vantaggio della vicinanza, ma stiamo mandando due aerei in condizioni operative in ambiente pericoloso, inoltre i due sono costretti a viaggiare in formazione perché altrimenti quello senza apparato è completamente visibile.

Ultima soluzione, disturbo continuo da lontano: vantaggio è che l'aereo di disturbo è grande, non si avvicina mai ma lo svantaggio è che chi deve entrare nella zona di copertura radar verrà prima o poi scoperto

La 1 sarebbe la configurazione che più mi protegge (più mi avvicino più aumenta la potenza del jamming) ma poi rimane poco spazio per armi di tipo convenzionale.

La 2 sembra la più usata, ma se poi vengono scoperti i due caccia devono attuare misure di fuga, ma quello senza ECM rimane indifeso.

21.2.4 Tecniche passive

Misura di guerra elettronica banalissima, con costo praticamente nullo e molto efficace.

Non è altro che il lancio da parte dell'oggetto che si vuole difendere dal radar una nuvola di piccoli oggetti metallici, che cadono per caduta libera, hanno dimensioni diverse e vengono viste dal radar come una grossa nuvola metallica che "nasconde" l'oggetto vero al radar.

Il radar è "accecato" dalle riflessioni della nube e nel frattempo il target può scappare, c'è però un grosso svantaggio dovuto al fatto che è un'arma tenuta come ultima spiaggia: se si attiva, il nemico vede sicuramente il target, quindi normalmente si lancia il chaff quando si è sicuri di essere visti o che sia stato lanciato un missile.

Tecnica stealth, divenire "invisibili" al radar, ci sono vari limiti riguardo cose difficili da nascondere sull'aereo (vedi sopra).

I radar moderni sono talmente tanto sensibili che magari non vedono l'aereo ma i gas combusti dall'aereo e quindi vedono questa turbolenza e non l'aereo, le tecniche funzionano bene con radar a frequenze X.

21.2.5 Tecniche attive - Jammer

La tecnica attiva più famosa è il jammer: si costruisce un apparato che trasmette più potenza possibile sulla banda dell'oggetto che si vuole disturbare.

Si può fare su qualunque apparato di comunicazione, costano anche pochi dollari infatti chi in passato aveva assicurazione basata su GPS si auto-disturbava per non far sapere dove andava.

Se so quindi su quale banda sta lavorando il radar lo inibisco con questo segnale a potenza molto alta che nega la potenza di ritorno degli echi, ad esempio nel caso 1 di prima il radar riceve la mia trasmissione con r^{-2} mentre l'eco con r^{-4} quindi anche non trasmettendo a potenza elevatissima riesco a sovrastare l'eco.

Per sapere su che frequenza trasmette i radar occorre avere un ESM, mentre per la navigazione satellitare li sappiamo già.

Solitamente il radar lavora su una certa frequenza, ma normalmente questa cambia nel tempo proprio per non essere visto, quindi in generale non posso mai sapere con estrema accuratezza che frequenza sta usando l'oggetto.

Conosco quindi il range di frequenza, quindi per avere una altissima probabilità di intercetto dobbiamo disturbare tutto l'intervallo di frequenze dove lavora il radar, ma ho energia limitata.

Posso ad esempio trasmettere un segnale a banda larga e disturbare tutta la frequenza del radar, oppure concentrare l'energia che ho a disposizione su una banda più stretta così che il disturbo abbia una potenza maggiore mal col rischio che non disturbo la frequenza corretta. (copia immagine) instantaneamente la banda usata è molto stretta (grigio), se riesco a disturbare solo dove necessario farò molto più danno al radar.

Abbiamo quindi **barrage noise** vs **spot noise**

Ma non so dove sta lavorando il radar, allora faccio muovere lo spot noise avanti ed indietro sulla banda grande: nel caso del barrage noise disturbo sempre ma a potenza più bassa, mentre nello spot noise disturbo forte ma solo quando è perfettamente sovrapposto alla frequenza che il radar sta usando.

Il metodo migliore dipende sempre da chi sto disturbando, la fa da padrone la library o anche come è fatto l'apparato di disturbo che magari non può generare bande troppo larghe e mi costringe quindi ad usare stop noise.

(copia immagine)

il radar vedrà sempre disturbo, anche su i lobi laterali, quindi lo schermo radar vedrà sempre l'oggetto tranne in punti dove ci sono i nulli dei lobi, si oscura tutto il visore radar.

Stesso vale nel barrage noise, ma con intensità minore, mentre con lo stop noise conta la sincronizzazione col radar: manda impulso - riceve eco ma durante questo processo riceverà anche il segnale di disturbo quando la spot noise è perfettamente sovrapposta al segnale di riferimento.

Ogni tanto verrà vista una potenza molto elevata, quindi cominceranno ad apparire sul visore del radar una serie di bersagli finti, sono delle forme a spirale che ruotano su se stesse quindi il radar non è più in grado di funzionare e c'è un DoS.

Il radar ha un guadagno di antenna molto elevato nel main beam, quindi qui il jammer è ricevuto a potenze molto elevate, altrimenti di meno quindi: (immagine del grafico) quando il l'antenna punta sul jammer c'è molto più disturbo, la riduzione della portata radar può essere anche al 10% (da 100 km ne vedo 10).

(altra figura importante)

ammettendo di avere un radar che trasmette con potenza di picco anche elevata, l'eco del bersaglio va con r^{-4} con cui decade la potenza.

La potenza del jammer ricevuta dal radar va con r^{-2} , non sarà grande come quella ricevuta dal radar (parte più bassa), ma allontanandosi dal radar esisterà un punto per cui per ogni distanza la potenza ricevuta dal jammer sarà $>$ di quella ricevuta dall'eco.

Quindi portandosi dietro un jammer ci sarà protezione dal radar fino a quel punto, è la **distanza di mascheramento**.

Chi attacca deve avere cognizione di quanto è il punto di smascheramento, perché avvicinandosi di

più si viene visti, non si può andare oltre e si gioca tutto: conoscendolo (es 30 km), occorre armarsi per avere capacità maggiori in distanza del punto di smascheramento.

Di contro il radar cercherà di alzarlo così da vedere prima l'oggetto.

Jammer in navigazione satellitare

Abbiamo i satelliti in orbita ed il ricevitore a terra, che è cosa vogliamo disturbare.

I satelliti trasmettono al ricevitore a terra con una potenza bassissima, trasportano un codice PRNG ovvero una portante più un codice di 01 che modula la portante in fase dove il codice di 01 è pienamente noto al ricevitore, usato per fare la misura del tempo di arrivo e decodificare il segnale.

È modulazione a spettro espanso: moltiplico il segnale per il codice PRGN ed allargo la banda del segnale trasmesso (passo da Dirac a "semicerchio", area dentro è la stessa), viene fatto per evitare di interferire con altri segnali.

Nel ricevitore si fa il desplitting, correlazione tra il segnale ricevuto ed il codice, restringo la banda del segnale ricevuto e riportarlo in banda stretta per vederlo sopra il rumore termico. (copia disegno, r rumore (applico splitting??)), quindi lo spettro del segnale ricevuto è nascosto.

Nel ricevitore faccio la correlazione fra il segnale ed una sua replica che ridiviene a spettro stretto, permette anche di avere bassa probabilità di intercetto perché non si può fare desplitting se non si conosce il PRNG con cui fare correlazione.

Quindi il segnale nella navigazione satellitare è:

- a banda larga
- spettro espanso
- LPDI
- TOA

i primi due punti dipendono da che codici PRNG si usano (nel P si allunga la banda su 20 MHz quindi si è ancora più nascosti).

Vediamo l'effetto del jammer: ammettiamo di sapere che il sistema lavora sulla L1, costruiamo un jammer con: oscillatore sulla frequenza L1, un amplificatore ed un antenna, la potenza entra nel ricevitore e nasconde la potenza mandata dal satellite.

Se il jammer è vicino la potenza mandata dentro nega il servizio, ma anche se non si è vicini il rapporto segnale/rumore sarà abbassato ma nel processo di splitting/desplitting: entra nel ricevitore il segnale di disturbo nel ricevitore, se lo moltiplico per un codice PRNG e questo era a banda stretta, diventa a banda larga perché è come fare splitting.

Ci da protezione rispetto al disturbo: arriva un segnale molto potente che è il jammer ed un segnale a banda larga: abbiamo che il satellite dopo il desplitting diventa stretto.

Il rapporto segnale/jammer cambia e prima del processo magari vince il segnale del jammer e magari dopo vince il segnale del satellite, tutto dipende dalla banda del codice pesudo-random: più è larga e più siamo robusti al rumore.

Costo importante: per trasmettere pochi bit uso una banda molto larga, si decide di sprecare la risorsa per divenire robusti rispetto alle interferenze.

Quindi per disturbare il GPS occorre trasmettere segnali a banda larga altrimenti non sono visti come disturbo, un jammer per GPS deve necessariamente trasmettere segnali a banda larga che comporta un aumento del costo dell'apparato, sia nella produzione ma anche dal punto di vista dell'utilizzo: stiamo spalmando la potenza da trasmettere su banda larga quindi i rapporti cambiano, un oscillatore di 10W messi su una banda più larga mi fa essere meno efficace.

I sistemi di navigazione satellitare si proteggono dal jamming con segnali a spettro espanso e banda più larga possibile, mentre i segnali civili sono tipicamente a banda più stretta e sono facilmente disturbabili.

I sistemi sono intrinsecamente sicuri perché la prima fase è il desplitting ma sul disturbo spalma su banda più larga e cambia i rapporti di potenza in gioco.